

Inférence causale

Introduction : Corrélation et causalité : ce que la régression ne dit pas

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Inférence causale

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Un paradoxe de Simpson sur une aide aux entreprises

Une agence de développement économique subventionne certaines entreprises. Un an après, on observe le taux de survie des entreprises :

	Subventionnées	Non subventionnées
Petites entreprises	$280/800 = 35 \%$	$50/200 = 25 \%$
Grandes entreprises	$170/200 = 85 \%$	$600/800 = 75 \%$

- (a) Calculer le taux de survie global des entreprises subventionnées et celui des entreprises non subventionnées (1 000 dans chaque groupe).
- (b) Calculer l'écart global entre les deux groupes. La subvention semble-t-elle aider ou nuire, au vu de ce seul chiffre ?
- (c) Calculer l'écart entre subventionnées et non subventionnées au sein de chacune des deux strates (petites, grandes). Ce résultat est-il cohérent avec la conclusion de la question (b) ?

Exercice 2 — Multiplier les observations ne corrige rien

On reprend les données de l'exercice 1, mais multipliées par 50 (chaque effectif et chaque nombre de survies sont multipliés par 50, de sorte que chaque groupe compte désormais 50 000 entreprises).

- (a) Calculer les nouveaux effectifs totaux et les nouveaux taux de survie globaux, pour les entreprises subventionnées et non subventionnées.
- (b) Comparer ces taux à ceux obtenus à l'exercice 1(a). Qu'observez-vous ?
- (c) En quoi ce résultat illustre-t-il concrètement l'affirmation de l'introduction selon laquelle « le problème n'est pas statistique, il est d'identification » ?

Exercice 3 — Une stratification qui ne renverse pas le signe

Une campagne publicitaire est menée dans certains magasins. On observe le taux de ventes en hausse :

	Avec campagne	Sans campagne
Petits magasins	$300/600 = 50 \%$	$160/400 = 40 \%$
Grands magasins	$320/400 = 80 \%$	$390/600 = 65 \%$

- (a) Calculer le taux global de ventes en hausse pour les magasins avec et sans campagne (1 000 magasins dans chaque groupe).
- (b) Calculer l'écart global, puis l'écart au sein de chacune des deux strates.
- (c) Contrairement à l'exercice 1, le signe de l'écart global change-t-il par rapport aux écarts par strate ? Que reste-t-il vrai malgré tout : l'écart global est-il simplement la moyenne des deux écarts par strate, ou dépend-il aussi de la composition des groupes ?

2 Applications en sciences économiques

Exercice 4 — Le salaire minimum et l'emploi des jeunes, par région

Une hausse du salaire minimum est appliquée dans certaines régions. On observe ensuite le taux d'emploi des jeunes :

	Hausse appliquée	Pas de hausse
Régions urbaines	$315/700 = 45 \%$	$105/300 = 35 \%$
Régions rurales	$225/300 = 75 \%$	$455/700 = 65 \%$

- Calculer le taux d'emploi global des jeunes dans les régions ayant appliqué la hausse et dans celles qui ne l'ont pas appliquée.
- Calculer l'écart global, puis l'écart au sein de chacune des deux strates.
- Un débat public utilise le seul chiffre global pour conclure que la hausse du salaire minimum réduit l'emploi des jeunes. Que répondriez-vous, muni des chiffres par région ? La composition régionale (quelles régions ont appliqué la hausse) joue-t-elle un rôle dans le résultat global ?

Exercice 5 — Un crédit d'impôt recherche qui semble sans effet

Un crédit d'impôt recherche est accordé à certaines entreprises. On observe ensuite si elles ont augmenté leur investissement en R&D :

	Avec crédit	Sans crédit
Jeunes entreprises	$100/250 = 40 \%$	$225/750 = 30 \%$
Entreprises matures	$150/750 = 20 \%$	$25/250 = 10 \%$

- Calculer le taux global d'augmentation de l'investissement pour les entreprises avec et sans crédit d'impôt.
- Calculer l'écart global, puis l'écart au sein de chacune des deux strates.
- Le résultat global suggère qu'il « n'y a aucun effet » du crédit d'impôt. Est-ce cohérent avec ce qui se passe dans chacune des deux strates ? Un décideur qui s'appuierait uniquement sur le chiffre global commettrait-il une erreur, et de quelle nature ?


1 Exercices du chapitre

Correction — Exercice 1

(a) Subventionnées : $280 + 170 = 450$ survies sur $800 + 200 = 1\,000$, soit **45 %**. Non subventionnées : $50 + 600 = 650$ survies sur $200 + 800 = 1\,000$, soit **65 %**.

(b) Écart global = $45\% - 65\% = -20$ points. Au vu de ce seul chiffre, la subvention semble **nuire** nettement à la survie des entreprises.

(c) Petites entreprises : $35\% - 25\% = +10$ points. Grandes entreprises : $85\% - 75\% = +10$ points. Ce résultat n'est **pas** cohérent, en apparence, avec la question (b) : dans chaque strate, la subvention **aide** de 10 points, alors que le chiffre global affiche -20 points. C'est exactement le paradoxe de Simpson : les entreprises subventionnées sont majoritairement des petites entreprises (au taux de survie structurellement plus bas), tandis que les non subventionnées sont majoritairement de grandes entreprises – la composition des groupes, non l'effet de la subvention, domine le chiffre global.




Correction — Exercice 2

(a) Subventionnées : 50 000 entreprises, $450 \times 50 = 22\,500$ survies, taux = $22\,500/50\,000 = 45\%$. Non subventionnées : 50 000 entreprises, $650 \times 50 = 32\,500$ survies, taux = $32\,500/50\,000 = 65\%$.

(b) Les taux sont **rigoureusement identiques** à ceux de l'exercice 1 (a) : 45 % et 65 %, malgré un effectif 50 fois plus grand.

(c) Multiplier les effectifs par 50 ne change **rien** au biais de composition : la même proportion de petites et grandes entreprises est présente dans chaque groupe, subventionné ou non, quel que soit le facteur d'échelle. Un échantillon plus grand donnerait une estimation plus **précise** de ce chiffre de -20 points (un intervalle de confiance plus étroit), mais ce chiffre resterait tout aussi **trompeur** sur l'effet réel de la subvention. C'est exactement l'affirmation de l'introduction : le problème est d'identification, pas de taille d'échantillon.




Correction — Exercice 3

(a) Avec campagne : $300 + 320 = 620$ sur $600 + 400 = 1\,000$, soit **62 %**. Sans campagne : $160 + 390 = 550$ sur $400 + 600 = 1\,000$, soit **55 %**.

(b) Écart global = $62\% - 55\% = +7$ points. Petits magasins : $50\% - 40\% = +10$ points. Grands magasins : $80\% - 65\% = +15$ points.

(c) Non, le signe **ne change pas** ici : la campagne aide dans les deux strates **et** globalement – aucun renversement de type Simpson. Ce qui reste vrai, en revanche, c'est que l'écart global (+7 points) n'est **ni** la moyenne simple des deux écarts par strate ($(10+15)/2 = 12,5$), **ni** égal à l'un ou l'autre : il dépend de la **composition** des groupes (ici, les petits magasins, à effet plus faible, sont surreprésentés parmi les magasins avec campagne, ce qui tire l'écart global vers le bas). La composition influence toujours le chiffre agrégé, qu'il y ait renversement de signe ou seulement une différence de magnitude.




2 Applications en sciences économiques

Correction — Exercice 4

(a) Hausse appliquée : $315 + 225 = 540$ sur $700 + 300 = 1\,000$, soit **54 %**. Pas de hausse : $105 + 455 = 560$ sur $300 + 700 = 1\,000$, soit **56 %**.

(b) Écart global = $54\% - 56\% = -2$ points. Régions urbaines : $45\% - 35\% = +10$ points. Régions rurales : $75\% - 65\% = +10$ points.

(c) Le débat public se trompe en s'appuyant sur le seul chiffre global : dans **chaque** région, la hausse du salaire minimum est associée à un taux d'emploi des jeunes **plus élevé** de 10 points, pas plus bas. Le petit écart global négatif (-2 points) provient de la composition : les régions urbaines, où la hausse a été surtout appliquée, ont un taux d'emploi structurellement plus bas que les régions rurales, où la hausse a été moins appliquée. Oui, la composition régionale joue un rôle déterminant : elle suffit à elle seule à retourner le signe d'un effet par ailleurs uniformément positif. (Il faut aussi noter, comme le rappelle l'introduction, que cette comparaison brute reste une association et non une preuve de causalité : les régions qui ont choisi d'appliquer la hausse peuvent différer d'autres façons non observées.)



Correction — Exercice 5

(a) Avec crédit : $100 + 150 = 250$ sur $250 + 750 = 1\,000$, soit **25 %**. Sans crédit : $225 + 25 = 250$ sur $750 + 250 = 1\,000$, soit **25 %**.

(b) Écart global = $25\% - 25\% = 0$ point. Jeunes entreprises : $40\% - 30\% = +10$ points. Entreprises

matures : $20\% - 10\% = +10$ points.

(c) Non, ce n'est **pas** cohérent avec ce qui se passe dans chacune des deux strates : le crédit d'impôt augmente l'investissement en R&D de 10 points chez les jeunes entreprises **et** chez les entreprises matures, un effet parfaitement uniforme – et pourtant le chiffre global affiche un écart **exactement nul**, masquant totalement cet effet réel. Un décideur qui s'appuierait uniquement sur le chiffre global commettrait une erreur d'**identification** particulièrement grave : il conclurait à l'absence totale d'effet, et pourrait recommander l'abandon d'une politique qui, en réalité, fonctionne de façon homogène dans toutes les catégories d'entreprises. C'est le cas le plus extrême du paradoxe de Simpson : non pas un renversement de signe, mais une annulation complète et trompeuse de l'effet apparent.

