

Chapitre 9

Le double machine learning

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale


1 Exercices du chapitre

Correction — Exercice 1

- (a) $\hat{g}(X=0) = (10+15+17)/3 = 14$. $\hat{m}(X=0) = (0+1+1)/3 \approx 0,667$. $\hat{g}(X=1) = (20+22+28)/3 \approx 23,333$. $\hat{m}(X=1) = (0+0+1)/3 \approx 0,333$.
- (b) $X=0 : \tilde{T} = (-0,667; 0,333; 0,333)$, $\tilde{Y} = (-4; 1; 3)$. $X=1 : \tilde{T} = (-0,333; -0,333; 0,667)$, $\tilde{Y} = (-3,333; -1,333; 4,667)$.
- (c) $\sum \tilde{T}_i \tilde{Y}_i \approx 8,667$, $\sum \tilde{T}_i^2 \approx 1,333$, donc $\hat{\tau} \approx 8,667/1,333 = 6,5$. Cette construction (résidualiser Y et T par rapport à X , puis régresser les résidus l'un sur l'autre) est exactement le théorème de **Frisch-Waugh**, ici appliqué avec des moyennes de groupe en guise de fonctions de nuisance.

Correction — Exercice 2

- (a) Bloc A : $\hat{g}(X=0)=12$, $\hat{m}(X=0)=0,5$; $\hat{g}(X=1)=22$, $\hat{m}(X=1)=0,5$. Bloc B : $\hat{g}(X=0)=17$, $\hat{m}(X=0)=1,0$; $\hat{g}(X=1)=28$, $\hat{m}(X=1)=0,5$.
- (b) Résidus du bloc A (avec les moyennes du bloc B) : $(\tilde{Y}, \tilde{T}) = (-7, -1, 0), (-3, 0), (-8, -0,5), (-4, 0,5)$. Résidus du bloc B (avec les moyennes du bloc A) : $(4, 0,5), (6, 0,5), (4, -0,5), (8, 0,5)$.
- (c) $\sum \tilde{T}_i \tilde{Y}_i = 16$, $\sum \tilde{T}_i^2 = 2,5$, donc $\hat{\tau} = 16/2,5 = 6,4$. Il aurait été incorrect d'utiliser les moyennes du bloc A pour calculer les résidus du bloc A lui-même : les fonctions de nuisance auraient alors été estimées et appliquées sur les **mêmes** observations, ce qui expose l'estimateur au sur-ajustement – une méthode flexible capterait une part du bruit propre à ces observations, biaisant les résidus et donc $\hat{\tau}$.



Correction — Exercice 3

- (a) **Résolu** : c'est exactement le problème de dimension pour lequel le double machine learning est conçu – estimer g et m sans imposer une forme paramétrique arbitraire à un grand nombre de covariables.
- (b) **Hors de portée** : un confondant non observé (la motivation) n'est traité par aucune sophistication de l'estimation. La méthode gère la dimension de X , pas son exhaustivité; c'est un problème d'**identification**, que le graphe causal du chapitre 2 doit d'abord résoudre.
- (c) **Résolu** : c'est précisément le résultat théorique central du chapitre – l'orthogonalisation et le fractionnement croisé permettent d'obtenir un estimateur convergent, asymptotiquement normal, avec des écarts-types valides, malgré des nuisances estimées par des méthodes non paramétriques comme les forêts aléatoires.
- (d) **Hors de portée, mais pour une autre raison** : ce chercheur n'applique pas correctement la méthode. Sans fractionnement croisé, l'estimation des nuisances et le calcul des résidus se font sur le même échantillon, ce qui réintroduit le biais de sur-ajustement que le double machine learning est censé éliminer. Ce n'est pas un problème d'identification, mais une erreur d'implémentation.

2 Exercices cumulatifs (chapitre 9, chapitre 4, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\hat{g}(\text{petite}) = (800 \times 0,35 + 200 \times 0,25)/1\,000 = (280 + 50)/1\,000 = 0,33$. $\hat{g}(\text{grande}) = (200 \times 0,85 + 800 \times 0,75)/1\,000 = (170 + 600)/1\,000 = 0,77$.

(b) Cellule (petite, $T=1$) : $\tilde{T} = 1 - 0,8 = 0,2$, $\tilde{Y} = 0,35 - 0,33 = 0,02$. Cellule (petite, $T=0$) : $\tilde{T} = 0 - 0,8 = -0,8$, $\tilde{Y} = 0,25 - 0,33 = -0,08$. Cellule (grande, $T=1$) : $\tilde{T} = 1 - 0,2 = 0,8$, $\tilde{Y} = 0,85 - 0,77 = 0,08$. Cellule (grande, $T=0$) : $\tilde{T} = 0 - 0,2 = -0,2$, $\tilde{Y} = 0,75 - 0,77 = -0,02$. Numérateur pondéré = $800(0,2)(0,02) + 200(-0,8)(-0,08) + 200(0,8)(0,08) + 800(-0,2)(-0,02) = 3,2 + 12,8 + 12,8 + 3,2 = 32$. Dénominateur pondéré = $800(0,2)^2 + 200(0,8)^2 + 200(0,8)^2 + 800(0,2)^2 = 32 + 128 + 128 + 32 = 320$. $\hat{\tau} = 32/320 = 0,10 = 10$ points.

(c) Oui, ce résultat est **identique** à toutes les estimations précédentes du cours (10, 10, 12, 11, 10, 10). Avec seulement deux catégories pour X , orthogonaliser par moyennes de groupe **revient exactement** à stratifier (chapitre 1) et à pondérer par l'inverse de la probabilité (chapitre 4) : la « fonction de nuisance flexible » $\hat{g}(X)$ n'est ici rien d'autre qu'une moyenne conditionnelle par strate, et le double machine learning n'apporte donc **aucune valeur ajoutée** dans ce cas simple – il ne fait que retrouver, sous une forme plus générale, ce que les méthodes plus simples calculaient déjà directement.

(d) Non : le double machine learning suppose toujours l'**indépendance conditionnelle** sachant X . Si la qualité du management, non observée, confond à la fois la subvention et la survie, ni la stratification du chapitre 1 ni le double machine learning ne peuvent corriger ce biais : les deux méthodes gèrent la façon dont on exploite les variables **observées**, pas l'absence de variables **non observées**. Une procédure d'estimation plus sophistiquée appliquée à des contrôles insuffisants reste une estimation biaisée, simplement mieux habillée.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\hat{g}(\text{agro}) = (100+112+118)/3 = 110$. $\hat{m}(\text{agro}) = (0+1+1)/3 \approx 0,667$. $\hat{g}(\text{textile}) = (80+84+95)/3 \approx 86,333$. $\hat{m}(\text{textile}) = (0+0+1)/3 \approx 0,333$.

(b) $\sum \tilde{T}_i \tilde{Y}_i \approx 18,667$, $\sum \tilde{T}_i^2 \approx 1,333$, donc $\hat{\tau} \approx 18,667/1,333 = 14$.

(c) Parce que le secteur (X) est associé à la fois à la probabilité de certification et au niveau de prix (l'agroalimentaire affiche des prix plus élevés que le textile, indépendamment de la certification) : une comparaison brute entre certifiées et non certifiées, sans tenir compte du secteur, mélangerait l'effet de la certification avec cette différence structurelle entre secteurs – exactement le biais de confusion étudié depuis le chapitre 1.

Correction — Exercice 6

(a) Avec 200 covariables, le nombre d'interactions possibles explose, et rien ne garantit que la relation entre ces variables et la volatilité (ou la probabilité de couverture) soit linéaire. Imposer une forme linéaire à g et m dans un espace de si grande dimension expose à une erreur de spécification quasi certaine, qui contaminerait l'estimation de l'effet de la couverture.

(b) Le double machine learning est adapté ici car il permet d'estimer g et m par des méthodes flexibles (forêts aléatoires, boosting, etc.) sans imposer de forme fonctionnelle, tout en conservant, grâce à l'orthogonalisation et au fractionnement croisé, un estimateur convergent avec une inférence valide – exactement ce que les méthodes des chapitres 1 et 4, conçues pour un petit nombre de profils discrets, ne pourraient pas offrir face à 200 variables continues et corrélées.

(c) Non, le double machine learning ne peut **pas**, à lui seul, résoudre ce problème : une information privée non enregistrée dans les 200 variables est un confondant **non observé**, exactement le type de menace que la méthode ne traite pas. Il faudrait, en plus, soit mesurer cette information (l'ajouter aux contrôles), soit recourir à une autre stratégie d'identification exploitant une source de variation exogène (un instrument, une discontinuité, une double différence), comme le rappelle le chapitre : le

double machine learning prend en charge l'estimation, jamais l'identification.