

Inférence causale

Chapitre 9 : Le double machine learning

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Inférence causale

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Orthogonaliser à la main

Six entreprises sont réparties selon leur secteur (X , deux catégories), avec leur statut de traitement T et leur résultat Y :

Secteur	T	Y
$X=0$	0, 1, 1	10, 15, 17
$X=1$	0, 0, 1	20, 22, 28

On estime les fonctions de nuisance par simples moyennes de groupe : $\hat{g}(X) = \bar{Y}_X$, $\hat{m}(X) = \bar{T}_X$.

- (a) Calculer $\hat{g}(X)$ et $\hat{m}(X)$ pour chaque secteur.
- (b) Calculer les résidus $\tilde{Y}_i = Y_i - \hat{g}(X_i)$ et $\tilde{T}_i = T_i - \hat{m}(X_i)$ pour les six entreprises.
- (c) Calculer $\hat{\tau} = \frac{\sum_i \tilde{T}_i \tilde{Y}_i}{\sum_i \tilde{T}_i^2}$. À quel théorème économétrique classique cette construction correspond-elle?

Exercice 2 — Le fractionnement croisé en pratique

Huit entreprises sont réparties en deux blocs, chacun servant tour à tour à estimer les nuisances pour l'autre :

Bloc A ($X=0$)	$T = 0, 1$	$Y = 10, 14$
Bloc A ($X=1$)	$T = 0, 1$	$Y = 20, 24$
Bloc B ($X=0$)	$T = 1, 1$	$Y = 16, 18$
Bloc B ($X=1$)	$T = 0, 1$	$Y = 26, 30$

- (a) Calculer $\hat{g}(X)$ et $\hat{m}(X)$ séparément dans le bloc A et dans le bloc B.
- (b) Calculer les résidus des entreprises du bloc A en utilisant les moyennes estimées sur le bloc B, et les résidus des entreprises du bloc B en utilisant les moyennes estimées sur le bloc A.
- (c) Calculer $\hat{\tau}$ sur l'ensemble des huit résidus croisés. Pourquoi aurait-il été incorrect d'utiliser les moyennes du bloc A pour calculer les résidus du bloc A lui-même?

Exercice 3 — Nuisance ou identification ?

Pour chacune des situations suivantes, indiquer si le double machine learning peut raisonnablement **résoudre** le problème décrit, ou si le problème reste **hors de portée** de la méthode.

- (a) Un chercheur dispose de 60 covariables aux interactions inconnues, et craint qu'une régression linéaire de Y sur X soit mal spécifiée.
- (b) Un chercheur soupçonne que la « motivation » des individus, non mesurée dans les données, détermine à la fois leur participation au programme et le résultat étudié.
- (c) Un chercheur souhaite des écarts-types valides pour $\hat{\tau}$, après avoir estimé les fonctions de nuisance par des forêts aléatoires.
- (d) Un chercheur estime $\hat{g}$ et $\hat{m}$ sur l'échantillon complet, puis régresse les résidus sur ce **même** échantillon, sans aucun fractionnement.

2 Exercices cumulatifs (chapitre 9, chapitre 4, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Le double machine learning appliqué à la subvention

On reprend l'exemple filé : X = taille (petite/grande), T = subvention, Y = survie, avec les mêmes effectifs et taux de survie que dans les chapitres précédents (800 petites subventionnées à 35 %, 200 petites non subventionnées à 25 %, 200 grandes subventionnées à 85 %, 800 grandes non subventionnées à 75 %). Le score de propension du chapitre 4 donne $\hat{m}(\text{petite}) = 0,8$ et $\hat{m}(\text{grande}) = 0,2$.

- Calculer $\hat{g}(X) = E[Y \mid X]$ pour chaque taille, en regroupant subventionnées et non subventionnées (sans distinguer T).
- Calculer les résidus $\tilde{T}$ et $\tilde{Y}$ pour chacune des quatre cellules (taille $\times$ statut de subvention), puis calculer $\hat{\tau} = \frac{\sum n_{\text{cellule}} \tilde{T} \tilde{Y}}{\sum n_{\text{cellule}} \tilde{T}^2}$.
- Ce résultat est-il identique à l'ATT du chapitre 1, à l'ATE par IPW du chapitre 4, et aux autres estimations du cours ? Pourquoi ce cas particulier (deux catégories seulement pour X) fait-il que l'orthogonalisation « retombe » exactement sur les méthodes déjà vues ?
- Ce calcul suppose toujours que la taille est le **seul** confondant pertinent. Si la qualité du management (non observée) affectait aussi à la fois la subvention et la survie, le double machine learning résoudrait-il ce problème mieux que la stratification du chapitre 1 ? Justifier.

3 Applications en sciences économiques

Exercice 5 — Certification qualité et prix de vente

Six entreprises, réparties entre deux secteurs, ont ou non obtenu une certification qualité (T), avec les prix de vente suivants (Y , en indice) :

Secteur	T	Y
Agroalimentaire	0, 1, 1	100, 112, 118
Textile	0, 0, 1	80, 84, 95

- Calculer $\hat{g}(X)$ et $\hat{m}(X)$ pour chaque secteur, par simples moyennes de groupe.
- Calculer $\hat{\tau}$ par régression des résidus.
- Pourquoi ne peut-on pas comparer directement la moyenne des Y chez les certifiées à celle chez les non certifiées, sans tenir compte du secteur ?

Exercice 6 — Une étude de gestion des risques avec de nombreux contrôles

Une équipe de gestion des risques souhaite estimer l'effet d'une stratégie de couverture (T) sur la volatilité d'un portefeuille (Y), en contrôlant pour 200 variables décrivant chaque actif (secteur, taille, notation, liquidité, corrélations historiques, etc.).

- En quoi le nombre élevé de covariables rend-il une régression linéaire classique risquée pour estimer les fonctions de nuisance g et m ?
- Pourquoi le double machine learning est-il particulièrement adapté à cette situation, comparé aux méthodes des chapitres 1 et 4, qui supposaient un nombre restreint de profils ?
- L'équipe soupçonne que certains gérants choisissent leur stratégie de couverture en fonction d'informations privées sur les marchés, non enregistrées dans les 200 variables. Le double machine learning peut-il, à lui seul, résoudre ce problème ? Que faudrait-il en plus, selon le chapitre ?


1 Exercices du chapitre

Correction — Exercice 1

- (a) $\hat{g}(X=0) = (10+15+17)/3 = 14$. $\hat{m}(X=0) = (0+1+1)/3 \approx 0,667$. $\hat{g}(X=1) = (20+22+28)/3 \approx 23,333$. $\hat{m}(X=1) = (0+0+1)/3 \approx 0,333$.
- (b) $X=0 : \tilde{T} = (-0,667; 0,333; 0,333)$, $\tilde{Y} = (-4; 1; 3)$. $X=1 : \tilde{T} = (-0,333; -0,333; 0,667)$, $\tilde{Y} = (-3,333; -1,333; 4,667)$.
- (c) $\sum \tilde{T}_i \tilde{Y}_i \approx 8,667$, $\sum \tilde{T}_i^2 \approx 1,333$, donc $\hat{\tau} \approx 8,667/1,333 = 6,5$. Cette construction (résidualiser Y et T par rapport à X , puis régresser les résidus l'un sur l'autre) est exactement le théorème de **Frisch-Waugh**, ici appliqué avec des moyennes de groupe en guise de fonctions de nuisance.

Correction — Exercice 2

- (a) Bloc A : $\hat{g}(X=0)=12$, $\hat{m}(X=0)=0,5$; $\hat{g}(X=1)=22$, $\hat{m}(X=1)=0,5$. Bloc B : $\hat{g}(X=0)=17$, $\hat{m}(X=0)=1,0$; $\hat{g}(X=1)=28$, $\hat{m}(X=1)=0,5$.
- (b) Résidus du bloc A (avec les moyennes du bloc B) : $(\tilde{Y}, \tilde{T}) = (-7, -1, 0), (-3, 0), (-8, -0,5), (-4, 0,5)$. Résidus du bloc B (avec les moyennes du bloc A) : $(4, 0,5), (6, 0,5), (4, -0,5), (8, 0,5)$.
- (c) $\sum \tilde{T}_i \tilde{Y}_i = 16$, $\sum \tilde{T}_i^2 = 2,5$, donc $\hat{\tau} = 16/2,5 = 6,4$. Il aurait été incorrect d'utiliser les moyennes du bloc A pour calculer les résidus du bloc A lui-même : les fonctions de nuisance auraient alors été estimées et appliquées sur les **mêmes** observations, ce qui expose l'estimateur au sur-ajustement – une méthode flexible capterait une part du bruit propre à ces observations, biaisant les résidus et donc $\hat{\tau}$.



Correction — Exercice 3

- (a) **Résolu** : c'est exactement le problème de dimension pour lequel le double machine learning est conçu – estimer g et m sans imposer une forme paramétrique arbitraire à un grand nombre de covariables.
- (b) **Hors de portée** : un confondant non observé (la motivation) n'est traité par aucune sophistication de l'estimation. La méthode gère la dimension de X , pas son exhaustivité; c'est un problème d'**identification**, que le graphe causal du chapitre 2 doit d'abord résoudre.
- (c) **Résolu** : c'est précisément le résultat théorique central du chapitre – l'orthogonalisation et le fractionnement croisé permettent d'obtenir un estimateur convergent, asymptotiquement normal, avec des écarts-types valides, malgré des nuisances estimées par des méthodes non paramétriques comme les forêts aléatoires.
- (d) **Hors de portée, mais pour une autre raison** : ce chercheur n'applique pas correctement la méthode. Sans fractionnement croisé, l'estimation des nuisances et le calcul des résidus se font sur le même échantillon, ce qui réintroduit le biais de sur-ajustement que le double machine learning est censé éliminer. Ce n'est pas un problème d'identification, mais une erreur d'implémentation.

2 Exercices cumulatifs (chapitre 9, chapitre 4, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\hat{g}(\text{petite}) = (800 \times 0,35 + 200 \times 0,25)/1\,000 = (280 + 50)/1\,000 = 0,33$. $\hat{g}(\text{grande}) = (200 \times 0,85 + 800 \times 0,75)/1\,000 = (170 + 600)/1\,000 = 0,77$.

(b) Cellule (petite, $T=1$) : $\tilde{T} = 1 - 0,8 = 0,2$, $\tilde{Y} = 0,35 - 0,33 = 0,02$. Cellule (petite, $T=0$) : $\tilde{T} = 0 - 0,8 = -0,8$, $\tilde{Y} = 0,25 - 0,33 = -0,08$. Cellule (grande, $T=1$) : $\tilde{T} = 1 - 0,2 = 0,8$, $\tilde{Y} = 0,85 - 0,77 = 0,08$. Cellule (grande, $T=0$) : $\tilde{T} = 0 - 0,2 = -0,2$, $\tilde{Y} = 0,75 - 0,77 = -0,02$. Numérateur pondéré = $800(0,2)(0,02) + 200(-0,8)(-0,08) + 200(0,8)(0,08) + 800(-0,2)(-0,02) = 3,2 + 12,8 + 12,8 + 3,2 = 32$. Dénominateur pondéré = $800(0,2)^2 + 200(0,8)^2 + 200(0,8)^2 + 800(0,2)^2 = 32 + 128 + 128 + 32 = 320$. $\hat{\tau} = 32/320 = 0,10 = 10$ points.

(c) Oui, ce résultat est **identique** à toutes les estimations précédentes du cours (10, 10, 12, 11, 10, 10). Avec seulement deux catégories pour X , orthogonaliser par moyennes de groupe **revient exactement** à stratifier (chapitre 1) et à pondérer par l'inverse de la probabilité (chapitre 4) : la « fonction de nuisance flexible » $\hat{g}(X)$ n'est ici rien d'autre qu'une moyenne conditionnelle par strate, et le double machine learning n'apporte donc **aucune valeur ajoutée** dans ce cas simple – il ne fait que retrouver, sous une forme plus générale, ce que les méthodes plus simples calculaient déjà directement.

(d) Non : le double machine learning suppose toujours l'**indépendance conditionnelle** sachant X . Si la qualité du management, non observée, confond à la fois la subvention et la survie, ni la stratification du chapitre 1 ni le double machine learning ne peuvent corriger ce biais : les deux méthodes gèrent la façon dont on exploite les variables **observées**, pas l'absence de variables **non observées**. Une procédure d'estimation plus sophistiquée appliquée à des contrôles insuffisants reste une estimation biaisée, simplement mieux habillée.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\hat{g}(\text{agro}) = (100+112+118)/3 = 110$. $\hat{m}(\text{agro}) = (0+1+1)/3 \approx 0,667$. $\hat{g}(\text{textile}) = (80+84+95)/3 \approx 86,333$. $\hat{m}(\text{textile}) = (0+0+1)/3 \approx 0,333$.

(b) $\sum \tilde{T}_i \tilde{Y}_i \approx 18,667$, $\sum \tilde{T}_i^2 \approx 1,333$, donc $\hat{\tau} \approx 18,667/1,333 = 14$.

(c) Parce que le secteur (X) est associé à la fois à la probabilité de certification et au niveau de prix (l'agroalimentaire affiche des prix plus élevés que le textile, indépendamment de la certification) : une comparaison brute entre certifiées et non certifiées, sans tenir compte du secteur, mélangerait l'effet de la certification avec cette différence structurelle entre secteurs – exactement le biais de confusion étudié depuis le chapitre 1.

Correction — Exercice 6

(a) Avec 200 covariables, le nombre d'interactions possibles explose, et rien ne garantit que la relation entre ces variables et la volatilité (ou la probabilité de couverture) soit linéaire. Imposer une forme linéaire à g et m dans un espace de si grande dimension expose à une erreur de spécification quasi certaine, qui contaminerait l'estimation de l'effet de la couverture.

(b) Le double machine learning est adapté ici car il permet d'estimer g et m par des méthodes flexibles (forêts aléatoires, boosting, etc.) sans imposer de forme fonctionnelle, tout en conservant, grâce à l'orthogonalisation et au fractionnement croisé, un estimateur convergent avec une inférence valide – exactement ce que les méthodes des chapitres 1 et 4, conçues pour un petit nombre de profils discrets, ne pourraient pas offrir face à 200 variables continues et corrélées.

(c) Non, le double machine learning ne peut **pas**, à lui seul, résoudre ce problème : une information privée non enregistrée dans les 200 variables est un confondant **non observé**, exactement le type de menace que la méthode ne traite pas. Il faudrait, en plus, soit mesurer cette information (l'ajouter aux contrôles), soit recourir à une autre stratégie d'identification exploitant une source de variation exogène (un instrument, une discontinuité, une double différence), comme le rappelle le chapitre : le

double machine learning prend en charge l'estimation, jamais l'identification.