

Chapitre 9

Le double machine learning

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale

1 Exercices du chapitre

Exercice 1 — Orthogonaliser à la main

Six entreprises sont réparties selon leur secteur (X , deux catégories), avec leur statut de traitement T et leur résultat Y :

Secteur	T	Y
$X=0$	0, 1, 1	10, 15, 17
$X=1$	0, 0, 1	20, 22, 28

On estime les fonctions de nuisance par simples moyennes de groupe : $\hat{g}(X) = \bar{Y}_X$, $\hat{m}(X) = \bar{T}_X$.

- (a) Calculer $\hat{g}(X)$ et $\hat{m}(X)$ pour chaque secteur.
- (b) Calculer les résidus $\tilde{Y}_i = Y_i - \hat{g}(X_i)$ et $\tilde{T}_i = T_i - \hat{m}(X_i)$ pour les six entreprises.
- (c) Calculer $\hat{\tau} = \frac{\sum_i \tilde{T}_i \tilde{Y}_i}{\sum_i \tilde{T}_i^2}$. À quel théorème économétrique classique cette construction correspond-elle?

Exercice 2 — Le fractionnement croisé en pratique

Huit entreprises sont réparties en deux blocs, chacun servant tour à tour à estimer les nuisances pour l'autre :

Bloc A ($X=0$)	$T = 0, 1$	$Y = 10, 14$
Bloc A ($X=1$)	$T = 0, 1$	$Y = 20, 24$
Bloc B ($X=0$)	$T = 1, 1$	$Y = 16, 18$
Bloc B ($X=1$)	$T = 0, 1$	$Y = 26, 30$

- (a) Calculer $\hat{g}(X)$ et $\hat{m}(X)$ séparément dans le bloc A et dans le bloc B.
- (b) Calculer les résidus des entreprises du bloc A en utilisant les moyennes estimées sur le bloc B, et les résidus des entreprises du bloc B en utilisant les moyennes estimées sur le bloc A.
- (c) Calculer $\hat{\tau}$ sur l'ensemble des huit résidus croisés. Pourquoi aurait-il été incorrect d'utiliser les moyennes du bloc A pour calculer les résidus du bloc A lui-même?

Exercice 3 — Nuisance ou identification ?

Pour chacune des situations suivantes, indiquer si le double machine learning peut raisonnablement **résoudre** le problème décrit, ou si le problème reste **hors de portée** de la méthode.

- (a) Un chercheur dispose de 60 covariables aux interactions inconnues, et craint qu'une régression linéaire de Y sur X soit mal spécifiée.
- (b) Un chercheur soupçonne que la « motivation » des individus, non mesurée dans les données, détermine à la fois leur participation au programme et le résultat étudié.
- (c) Un chercheur souhaite des écarts-types valides pour $\hat{\tau}$, après avoir estimé les fonctions de nuisance par des forêts aléatoires.
- (d) Un chercheur estime $\hat{g}$ et $\hat{m}$ sur l'échantillon complet, puis régresse les résidus sur ce **même** échantillon, sans aucun fractionnement.

2 Exercices cumulatifs (chapitre 9, chapitre 4, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Le double machine learning appliqué à la subvention

On reprend l'exemple filé : X = taille (petite/grande), T = subvention, Y = survie, avec les mêmes effectifs et taux de survie que dans les chapitres précédents (800 petites subventionnées à 35 %, 200 petites non subventionnées à 25 %, 200 grandes subventionnées à 85 %, 800 grandes non subventionnées à 75 %). Le score de propension du chapitre 4 donne $\hat{m}(\text{petite}) = 0,8$ et $\hat{m}(\text{grande}) = 0,2$.

- (a) Calculer $\hat{g}(X) = E[Y \mid X]$ pour chaque taille, en regroupant subventionnées et non subventionnées (sans distinguer T).
- (b) Calculer les résidus $\tilde{T}$ et $\tilde{Y}$ pour chacune des quatre cellules (taille $\times$ statut de subvention), puis calculer $\hat{\tau} = \frac{\sum n_{\text{cellule}} \tilde{T} \tilde{Y}}{\sum n_{\text{cellule}} \tilde{T}^2}$.
- (c) Ce résultat est-il identique à l'ATT du chapitre 1, à l'ATE par IPW du chapitre 4, et aux autres estimations du cours ? Pourquoi ce cas particulier (deux catégories seulement pour X) fait-il que l'orthogonalisation « retombe » exactement sur les méthodes déjà vues ?
- (d) Ce calcul suppose toujours que la taille est le **seul** confondant pertinent. Si la qualité du management (non observée) affectait aussi à la fois la subvention et la survie, le double machine learning résoudrait-il ce problème mieux que la stratification du chapitre 1 ? Justifier.

3 Applications en sciences économiques

Exercice 5 — Certification qualité et prix de vente

Six entreprises, réparties entre deux secteurs, ont ou non obtenu une certification qualité (T), avec les prix de vente suivants (Y , en indice) :

Secteur	T	Y
Agroalimentaire	0, 1, 1	100, 112, 118
Textile	0, 0, 1	80, 84, 95

- (a) Calculer $\hat{g}(X)$ et $\hat{m}(X)$ pour chaque secteur, par simples moyennes de groupe.
- (b) Calculer $\hat{\tau}$ par régression des résidus.
- (c) Pourquoi ne peut-on pas comparer directement la moyenne des Y chez les certifiées à celle chez les non certifiées, sans tenir compte du secteur ?

Exercice 6 — Une étude de gestion des risques avec de nombreux contrôles

Une équipe de gestion des risques souhaite estimer l'effet d'une stratégie de couverture (T) sur la volatilité d'un portefeuille (Y), en contrôlant pour 200 variables décrivant chaque actif (secteur, taille, notation, liquidité, corrélations historiques, etc.).

- (a) En quoi le nombre élevé de covariables rend-il une régression linéaire classique risquée pour estimer les fonctions de nuisance g et m ?
- (b) Pourquoi le double machine learning est-il particulièrement adapté à cette situation, comparé aux méthodes des chapitres 1 et 4, qui supposaient un nombre restreint de profils ?
- (c) L'équipe soupçonne que certains gérants choisissent leur stratégie de couverture en fonction d'informations privées sur les marchés, non enregistrées dans les 200 variables. Le double machine learning peut-il, à lui seul, résoudre ce problème ? Que faudrait-il en plus, selon le chapitre ?