

Chapitre 2

Graphes causaux et variables à ne pas contrôler

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale

1 Exercices du chapitre

Correction — Exercice 1


(a) $T \rightarrow M \rightarrow Y$: c'est une **chaîne**. M (brevets déposés) est un **médiateur** : la R&D agit sur la croissance à travers les brevets. Il ne faut **pas** le contrôler, sous peine de retirer une partie de l'effet que l'on cherche à mesurer.

(b) $T \leftarrow X \rightarrow Y$: c'est une **fourche**. La qualité du management (X) est un **confondant** : elle cause à la fois l'adoption de l'ERP et la productivité. Il **faut** le contrôler.

(c) $T \rightarrow C \leftarrow Y$: c'est un **collisionneur**. La certification (C) est causée par les deux. Il ne faut **pas** le contrôler : cela créerait une association artificielle entre l'ERP et la productivité là où, structurellement, aucun chemin causal direct ne les relie via C .

$$T \longrightarrow M \longrightarrow Y$$

chaîne : médiateur, ne pas contrôler




fourche : confondant, contrôler

Correction — Exercice 2

(a) $P(N=1 \mid R=1) = 100/200 = 0,5$. $P(N=1 \mid R=0) = 100/200 = 0,5$. Les deux probabilités sont **identiques** : R et N sont bien indépendants dans la population complète.

(b) $\text{Admis} = 100(RN) + 100(R\bar{N}) + 100(\bar{R}N) = 300$ candidats (les 100 candidats $\bar{R}\bar{N}$ sont exclus). $P(N=1 \mid R=1, \text{admis}) = 100/200 = 0,5$. $P(N=1 \mid R=0, \text{admis}) = 100/100 = 1,0$.

(c) Oui : parmi les admis, $R = 0$ implique désormais **systématiquement** $N = 1$, alors que R et N étaient indépendants dans la population. Le motif en cause est le **collisionneur** : « admis » (A) est causé à la fois par R et par N ($R \rightarrow A \leftarrow N$). En restreignant l'analyse aux seuls admis, on **conditionne implicitement sur** A , ce qui ouvre le chemin $R \rightarrow A \leftarrow N$ et crée une association artificielle (ici, une dépendance parfaite) entre R et N .



Correction — Exercice 3

(a) Un seul chemin de porte arrière : $T \leftarrow X_1 \rightarrow Y$. Les chemins $T \rightarrow M \rightarrow Y$ et $T \rightarrow C \leftarrow Y$ ne sont **pas** des chemins de porte arrière, car ils ne commencent pas par une flèche entrant dans T .

(b) Oui : $\{X_1\}$ **bloque** l'unique chemin de porte arrière (en conditionnant sur la fourche X_1), et X_1 n'est **pas** un descendant de T . Les deux conditions du critère sont satisfaites.

(c) Non : C est un **descendant** de T (via $T \rightarrow C$), ce qui viole d'emblée la seconde condition du critère. Plus grave encore, C est un **collisionneur** sur le chemin $T \rightarrow C \leftarrow Y$: le conditionner **ouvre** ce chemin, qui était fermé par défaut, et introduit une association artificielle supplémentaire entre T et Y .

(d) Non : M est également un **descendant** de T (chemin $T \rightarrow M$), ce qui viole la seconde condition. De plus, contrôler M **bloque une partie de l'effet causal** de T sur Y (celui qui transite par M), ce qui biaiserait l'estimation même si l'unique chemin de porte arrière restait, par ailleurs, non bloqué.

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)


Correction — Exercice 4

(a) $X \rightarrow T$ (la taille influence la probabilité de subvention) et $X \rightarrow Y$ (la taille influence la survie) : c'est une **fourche**, $T \leftarrow X \rightarrow Y$. La taille est bien un **confondant**.

(b) Oui : $\{X\}$ bloque l'unique chemin de porte arrière $T \leftarrow X \rightarrow Y$, et X (la taille) n'est pas un descendant de T (la subvention ne change pas la taille déjà observée à la décision). Le critère est satisfait.

(c) La différence observée (−20 points) compare les groupes subventionné/non subventionné **sans conditionner sur X** : le chemin de porte arrière $T \leftarrow X \rightarrow Y$ reste **ouvert**, et une partie de l'écart de −20 points ne reflète que la composition différente en taille des deux groupes (le biais de −30 points identifié au chapitre 1). L'ATT (10 points), lui, est obtenu en **stratifiant sur la taille** – c'est-à-dire en conditionnant sur X – ce qui **ferme** ce chemin de porte arrière et isole l'effet propre de la subvention.

(d) Non : M (l'accès au crédit) est un **médiateur** sur le chemin $T \rightarrow M \rightarrow Y$, donc un **descendant** de T . Contrôler $\{X, M\}$ viole la seconde condition du critère de la porte arrière : cela fermerait non seulement le chemin de confusion via X (ce qui est souhaité), mais **aussi** une partie du chemin causal $T \rightarrow M \rightarrow Y$ par lequel la subvention agit réellement sur la survie. L'estimation obtenue **sous-estimerait** l'ATT total (elle ne capterait que l'effet de T sur Y qui ne passe pas par M), exactement le **biais du médiateur** défini dans ce chapitre.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $P(Y=1 | T=1) = 250/500 = 0,5$. $P(Y=1 | T=0) = 250/500 = 0,5$. Les deux sont identiques : T et Y sont bien indépendants dans la population complète (aucun effet causal du levier sur le rendement).

(b) Survivants = $250(T=1, Y=1) + 0(T=1, Y=0) + 250(T=0, Y=1) + 250(T=0, Y=0) = 750$. $P(Y=1 | T=1, \text{survit}) = 250/250 = 1,0$. $P(Y=1 | T=0, \text{survit}) = 250/500 = 0,5$.

(c) Oui : l'analyste observe un écart de $100\% - 50\% = 50$ points entre fonds à fort levier et fonds à faible levier, parmi les survivants – alors que l'effet réel est **nul**. Ce lien est purement artificiel car la survie (S) est un **collisionneur** sur le chemin $T \rightarrow S \leftarrow Y$: rester coté dépend à la fois du levier (indirectement, via la règle de fermeture) et du rendement. En restreignant l'échantillon aux fonds encore cotés, on conditionne sur S , ce qui ouvre ce chemin et fabrique une association entre levier et rendement qui n'existe nulle part dans la population complète – une illustration chiffrée exacte du biais du survivant évoqué dans le chapitre.



Correction — Exercice 6

(a) $E[Y | T=0] = 0,30 \times 9\,000 + 0,70 \times 6\,000 = 2\,700 + 4\,200 = \mathbf{6\,900}$ DH. $E[Y | T=1] = 0,70 \times 9\,000 + 0,30 \times 6\,000 = 6\,300 + 1\,800 = \mathbf{8\,100}$ DH. Effet total = $8\,100 - 6\,900 = \mathbf{1\,200}$ DH.

(b) Parmi les emplois qualifiés : $9\,000 - 9\,000 = \mathbf{0}$ DH. Parmi les emplois non qualifiés : $6\,000 - 6\,000 = \mathbf{0}$ DH. Dans les deux strates, la différence est **nulle**.

(c) Non, il conclut à **tort** à l'absence d'effet de la formation sur le salaire : en contrôlant le type d'emploi, il obtient un écart nul dans chaque strate, alors que l'effet total réel est de 1 200 DH. L'erreur commise est le **biais du médiateur** : le type d'emploi (M) n'est **pas** un facteur de confusion à retirer, c'est la **variable par laquelle la formation agit** ($T \rightarrow M \rightarrow Y$). La contrôler bloque exactement le canal par lequel l'effet transite. L'exemple est particulièrement trompeur car le biais est ici **total** : la totalité de l'effet (1 200 DH) disparaît, ce qui pourrait conduire à recommander l'abandon d'un programme pourtant pleinement efficace.

