

Inférence causale

Chapitre 2 : Graphes causaux et variables à ne pas contrôler

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Inférence causale

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Classer trois motifs

Une entreprise étudie trois relations, chacune impliquant trois variables.

- (a) Investissement en R&D (T) $\rightarrow$ Brevets déposés (M) $\rightarrow$ Croissance du chiffre d'affaires (Y).
- (b) Qualité du management (X) $\rightarrow$ Adoption d'un ERP (T); Qualité du management (X) $\rightarrow$ Productivité (Y).
- (c) Adoption d'un ERP (T) $\rightarrow$ Obtention d'une certification qualité (C) $\leftarrow$ Productivité (Y).

Pour chacune des trois situations : dessiner le graphe, nommer le motif (chaîne, fourche ou collisionneur), et indiquer si la troisième variable (M , X ou C) doit être contrôlée pour estimer l'effet de T sur Y .

Exercice 2 — Un biais de collisionneur chiffré

Un fonds d'investissement recrute des gérants selon deux critères indépendants dans la population des candidats : un rendement passé élevé (R) et un réseau professionnel de qualité (N). Sur 400 candidats :


	$N = 1$ (réseau de qualité)	$N = 0$
$R = 1$ (rendement élevé)	100	100
$R = 0$	100	100

Un candidat est **admis** si $R = 1$ **ou** $N = 1$ (au moins l'un des deux critères suffit).

- (a) Vérifier que R et N sont indépendants dans la population complète, en comparant $P(N=1 | R=1)$ et $P(N=1 | R=0)$.
- (b) Combien de candidats sont admis ? Calculer $P(N=1 | R=1, \text{admis})$ et $P(N=1 | R=0, \text{admis})$.
- (c) Le fait de restreindre l'analyse aux seuls candidats admis crée-t-il une association entre R et N ? Quel motif de graphe (chaîne, fourche, collisionneur) explique ce phénomène, et quelle variable a-t-on implicitement conditionnée en n'observant que les admis ?

Exercice 3 — Le critère de la porte arrière

On considère le graphe causal suivant, où l'on cherche l'effet de T sur Y :



- (a) Lister tous les chemins de porte arrière entre T et Y (les chemins qui commencent par une flèche **entrant** dans T).
- (b) L'ensemble $\{X_1\}$ satisfait-il le critère de la porte arrière pour identifier l'effet de T sur Y ? Justifier.
- (c) L'ensemble $\{X_1, C\}$ satisfait-il ce critère ? Justifier en discutant à la fois du rôle de C dans le graphe et de sa position par rapport à T .
- (d) L'ensemble $\{M\}$, utilisé seul, satisfait-il ce critère ? Justifier.

Exercice 4 — Relire la subvention aux entreprises avec le graphe causal

L'introduction et le chapitre 1 ont étudié la subvention aux entreprises : taille (petite/grande) comme variable qui distingue les taux de survie non subventionnés (25 % vs 75 %) et la composition des entreprises subventionnées (80 % petites, 20 % grandes). Le chapitre 1 (exercice 4) a calculé, en stratifiant sur la taille : ATT = 10 points, biais de sélection = -30 points, et différence observée = -20 points (retrouvée dès l'introduction).

- Représenter le graphe causal reliant la taille de l'entreprise (X), la subvention (T) et la survie (Y). Quel est le motif? La taille est-elle un confondant?
- L'ensemble $\{X\}$ (la taille) satisfait-il le critère de la porte arrière pour identifier l'effet de la subvention sur la survie?
- En vous appuyant sur les valeurs rappelées ci-dessus, expliquer en langage du graphe pourquoi la différence observée (-20 points, qui ne conditionne sur rien) diffère de l'ATT (10 points, qui conditionne sur la taille) : quel chemin reste ouvert dans un cas, fermé dans l'autre?
- Supposons qu'une variable supplémentaire M , « accès au crédit bancaire », se situe sur le chemin $T \rightarrow M \rightarrow Y$ (la subvention facilite l'accès au crédit, qui favorise à son tour la survie), sans qu'il existe de flèche directe $X \rightarrow M$. Si l'analyste contrôle $\{X, M\}$ plutôt que $\{X\}$ seul, obtient-il toujours une estimation de l'ATT total de la subvention sur la survie? Justifier à l'aide du critère de la porte arrière.

3 Applications en sciences économiques

Exercice 5 — Le biais du survivant comme collisionneur

On étudie l'effet de l'effet de levier (T : fonds à fort levier ou non, sur 1 000 fonds au départ) sur l'obtention d'un rendement élevé (Y), sachant que T et Y sont en réalité **indépendants** dans la population complète :

	$Y = 1$ (rendement élevé)	$Y = 0$
$T = 1$ (fort levier)	250	250
$T = 0$ (levier faible)	250	250

Un fonds **reste coté** (survit, $S=1$) si $Y = 1$ **ou** si $T = 0$: un fonds à fort levier ne survit que s'il a obtenu un rendement élevé, tandis qu'un fonds à faible levier survit dans tous les cas.

- Vérifier que $P(Y=1 | T=1) = P(Y=1 | T=0)$ dans la population complète.
- Combien de fonds survivent? Calculer $P(Y=1 | T=1, \text{survit})$ et $P(Y=1 | T=0, \text{survit})$.
- Un analyste qui n'étudie que les fonds encore cotés aujourd'hui observe-t-il un lien entre levier et rendement? De quelle ampleur? Pourquoi ce lien est-il purement artificiel, et quelle variable joue ici le rôle du collisionneur?

Exercice 6 — Le biais du médiateur sur un programme de formation

Un programme de formation professionnelle (T) augmente la probabilité d'obtenir un emploi **qualifié** (M) : 30 % des personnes non formées obtiennent un emploi qualifié, contre 70 % des personnes formées. Le salaire moyen est de 9 000 DH pour un emploi qualifié et de 6 000 DH pour un emploi non qualifié, **quel que soit** le statut de formation – la formation n'agit sur le salaire **que** via le type d'emploi obtenu.

- Calculer $E[Y | T=0]$ et $E[Y | T=1]$, puis l'effet total de la formation sur le salaire.
- Calculer la différence de salaire entre formés et non formés **à l'intérieur** de chaque catégorie d'emploi (parmi les qualifiés, puis parmi les non qualifiés).

- (c) Un chercheur qui contrôle le type d'emploi obtenu pour « purger » l'effet de facteurs de confusion conclut-il correctement à l'existence d'un effet de la formation sur le salaire ? Quel est le nom de l'erreur commise, et pourquoi est-elle particulièrement trompeuse dans cet exemple ?

1 Exercices du chapitre

Correction — Exercice 1


(a) $T \rightarrow M \rightarrow Y$: c'est une **chaîne**. M (brevets déposés) est un **médiateur** : la R&D agit sur la croissance à travers les brevets. Il ne faut **pas** le contrôler, sous peine de retirer une partie de l'effet que l'on cherche à mesurer.

(b) $T \leftarrow X \rightarrow Y$: c'est une **fourche**. La qualité du management (X) est un **confondant** : elle cause à la fois l'adoption de l'ERP et la productivité. Il **faut** le contrôler.

(c) $T \rightarrow C \leftarrow Y$: c'est un **collisionneur**. La certification (C) est causée par les deux. Il ne faut **pas** le contrôler : cela créerait une association artificielle entre l'ERP et la productivité là où, structurellement, aucun chemin causal direct ne les relie via C .

$$T \longrightarrow M \longrightarrow Y$$

chaîne : médiateur, ne pas contrôler




fourche : confondant, contrôler

Correction — Exercice 2

(a) $P(N=1 \mid R=1) = 100/200 = 0,5$. $P(N=1 \mid R=0) = 100/200 = 0,5$. Les deux probabilités sont **identiques** : R et N sont bien indépendants dans la population complète.

(b) $\text{Admis} = 100(RN) + 100(R\bar{N}) + 100(\bar{R}N) = 300$ candidats (les 100 candidats $\bar{R}\bar{N}$ sont exclus). $P(N=1 \mid R=1, \text{admis}) = 100/200 = 0,5$. $P(N=1 \mid R=0, \text{admis}) = 100/100 = 1,0$.

(c) Oui : parmi les admis, $R = 0$ implique désormais **systématiquement** $N = 1$, alors que R et N étaient indépendants dans la population. Le motif en cause est le **collisionneur** : « admis » (A) est causé à la fois par R et par N ($R \rightarrow A \leftarrow N$). En restreignant l'analyse aux seuls admis, on **conditionne implicitement sur** A , ce qui ouvre le chemin $R \rightarrow A \leftarrow N$ et crée une association artificielle (ici, une dépendance parfaite) entre R et N .



Correction — Exercice 3

(a) Un seul chemin de porte arrière : $T \leftarrow X_1 \rightarrow Y$. Les chemins $T \rightarrow M \rightarrow Y$ et $T \rightarrow C \leftarrow Y$ ne sont **pas** des chemins de porte arrière, car ils ne commencent pas par une flèche entrant dans T .

(b) Oui : $\{X_1\}$ **bloque** l'unique chemin de porte arrière (en conditionnant sur la fourche X_1), et X_1 n'est **pas** un descendant de T . Les deux conditions du critère sont satisfaites.

(c) Non : C est un **descendant** de T (via $T \rightarrow C$), ce qui viole d'emblée la seconde condition du critère. Plus grave encore, C est un **collisionneur** sur le chemin $T \rightarrow C \leftarrow Y$: le conditionner **ouvre** ce chemin, qui était fermé par défaut, et introduit une association artificielle supplémentaire entre T et Y .

(d) Non : M est également un **descendant** de T (chemin $T \rightarrow M$), ce qui viole la seconde condition. De plus, contrôler M **bloque une partie de l'effet causal** de T sur Y (celui qui transite par M), ce qui biaiserait l'estimation même si l'unique chemin de porte arrière restait, par ailleurs, non bloqué.

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)


Correction — Exercice 4

(a) $X \rightarrow T$ (la taille influence la probabilité de subvention) et $X \rightarrow Y$ (la taille influence la survie) : c'est une **fourche**, $T \leftarrow X \rightarrow Y$. La taille est bien un **confondant**.

(b) Oui : $\{X\}$ bloque l'unique chemin de porte arrière $T \leftarrow X \rightarrow Y$, et X (la taille) n'est pas un descendant de T (la subvention ne change pas la taille déjà observée à la décision). Le critère est satisfait.

(c) La différence observée (-20 points) compare les groupes subventionné/non subventionné **sans conditionner sur X** : le chemin de porte arrière $T \leftarrow X \rightarrow Y$ reste **ouvert**, et une partie de l'écart de -20 points ne reflète que la composition différente en taille des deux groupes (le biais de -30 points identifié au chapitre 1). L'ATT (10 points), lui, est obtenu en **stratifiant sur la taille** – c'est-à-dire en conditionnant sur X – ce qui **ferme** ce chemin de porte arrière et isole l'effet propre de la subvention.

(d) Non : M (l'accès au crédit) est un **médiateur** sur le chemin $T \rightarrow M \rightarrow Y$, donc un **descendant** de T . Contrôler $\{X, M\}$ viole la seconde condition du critère de la porte arrière : cela fermerait non seulement le chemin de confusion via X (ce qui est souhaité), mais **aussi** une partie du chemin causal $T \rightarrow M \rightarrow Y$ par lequel la subvention agit réellement sur la survie. L'estimation obtenue **sous-estimerait** l'ATT total (elle ne capterait que l'effet de T sur Y qui ne passe pas par M), exactement le **biais du médiateur** défini dans ce chapitre.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $P(Y=1 | T=1) = 250/500 = 0,5$. $P(Y=1 | T=0) = 250/500 = 0,5$. Les deux sont identiques : T et Y sont bien indépendants dans la population complète (aucun effet causal du levier sur le rendement).

(b) Survivants = $250(T=1, Y=1) + 0(T=1, Y=0) + 250(T=0, Y=1) + 250(T=0, Y=0) = 750$. $P(Y=1 | T=1, \text{survit}) = 250/250 = 1,0$. $P(Y=1 | T=0, \text{survit}) = 250/500 = 0,5$.

(c) Oui : l'analyste observe un écart de $100\% - 50\% = 50$ points entre fonds à fort levier et fonds à faible levier, parmi les survivants – alors que l'effet réel est **nul**. Ce lien est purement artificiel car la survie (S) est un **collisionneur** sur le chemin $T \rightarrow S \leftarrow Y$: rester coté dépend à la fois du levier (indirectement, via la règle de fermeture) et du rendement. En restreignant l'échantillon aux fonds encore cotés, on conditionne sur S , ce qui ouvre ce chemin et fabrique une association entre levier et rendement qui n'existe nulle part dans la population complète – une illustration chiffrée exacte du biais du survivant évoqué dans le chapitre.



Correction — Exercice 6

(a) $E[Y | T=0] = 0,30 \times 9\,000 + 0,70 \times 6\,000 = 2\,700 + 4\,200 = \mathbf{6\,900}$ DH. $E[Y | T=1] = 0,70 \times 9\,000 + 0,30 \times 6\,000 = 6\,300 + 1\,800 = \mathbf{8\,100}$ DH. Effet total = $8\,100 - 6\,900 = \mathbf{1\,200}$ DH.

(b) Parmi les emplois qualifiés : $9\,000 - 9\,000 = \mathbf{0}$ DH. Parmi les emplois non qualifiés : $6\,000 - 6\,000 = \mathbf{0}$ DH. Dans les deux strates, la différence est **nulle**.

(c) Non, il conclut à **tort** à l'absence d'effet de la formation sur le salaire : en contrôlant le type d'emploi, il obtient un écart nul dans chaque strate, alors que l'effet total réel est de 1 200 DH. L'erreur commise est le **biais du médiateur** : le type d'emploi (M) n'est **pas** un facteur de confusion à retirer, c'est la **variable par laquelle la formation agit** ($T \rightarrow M \rightarrow Y$). La contrôler bloque exactement le canal par lequel l'effet transite. L'exemple est particulièrement trompeur car le biais est ici **total** : la totalité de l'effet (1 200 DH) disparaît, ce qui pourrait conduire à recommander l'abandon d'un programme pourtant pleinement efficace.

