

Chapitre 2

Graphes causaux et variables à ne pas contrôler

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale

1 Exercices du chapitre

Exercice 1 — Classer trois motifs

Une entreprise étudie trois relations, chacune impliquant trois variables.

- (a) Investissement en R&D (T) $\rightarrow$ Brevets déposés (M) $\rightarrow$ Croissance du chiffre d'affaires (Y).
- (b) Qualité du management (X) $\rightarrow$ Adoption d'un ERP (T); Qualité du management (X) $\rightarrow$ Productivité (Y).
- (c) Adoption d'un ERP (T) $\rightarrow$ Obtention d'une certification qualité (C) $\leftarrow$ Productivité (Y).

Pour chacune des trois situations : dessiner le graphe, nommer le motif (chaîne, fourche ou collisionneur), et indiquer si la troisième variable (M , X ou C) doit être contrôlée pour estimer l'effet de T sur Y .

Exercice 2 — Un biais de collisionneur chiffré

Un fonds d'investissement recrute des gérants selon deux critères indépendants dans la population des candidats : un rendement passé élevé (R) et un réseau professionnel de qualité (N). Sur 400 candidats :


	$N = 1$ (réseau de qualité)	$N = 0$
$R = 1$ (rendement élevé)	100	100
$R = 0$	100	100

Un candidat est **admis** si $R = 1$ **ou** $N = 1$ (au moins l'un des deux critères suffit).

- (a) Vérifier que R et N sont indépendants dans la population complète, en comparant $P(N=1 | R=1)$ et $P(N=1 | R=0)$.
- (b) Combien de candidats sont admis ? Calculer $P(N=1 | R=1, \text{admis})$ et $P(N=1 | R=0, \text{admis})$.
- (c) Le fait de restreindre l'analyse aux seuls candidats admis crée-t-il une association entre R et N ? Quel motif de graphe (chaîne, fourche, collisionneur) explique ce phénomène, et quelle variable a-t-on implicitement conditionnée en n'observant que les admis ?

Exercice 3 — Le critère de la porte arrière

On considère le graphe causal suivant, où l'on cherche l'effet de T sur Y :



- (a) Lister tous les chemins de porte arrière entre T et Y (les chemins qui commencent par une flèche entrant dans T).
- (b) L'ensemble $\{X_1\}$ satisfait-il le critère de la porte arrière pour identifier l'effet de T sur Y ? Justifier.
- (c) L'ensemble $\{X_1, C\}$ satisfait-il ce critère ? Justifier en discutant à la fois du rôle de C dans le graphe et de sa position par rapport à T .
- (d) L'ensemble $\{M\}$, utilisé seul, satisfait-il ce critère ? Justifier.

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Relire la subvention aux entreprises avec le graphe causal

L'introduction et le chapitre 1 ont étudié la subvention aux entreprises : taille (petite/grande) comme variable qui distingue les taux de survie non subventionnés (25 % vs 75 %) et la composition des entreprises subventionnées (80 % petites, 20 % grandes). Le chapitre 1 (exercice 4) a calculé, en stratifiant sur la taille : $ATT = 10$ points, biais de sélection = -30 points, et différence observée = -20 points (retrouvée dès l'introduction).

- Représenter le graphe causal reliant la taille de l'entreprise (X), la subvention (T) et la survie (Y). Quel est le motif ? La taille est-elle un confondant ?
- L'ensemble $\{X\}$ (la taille) satisfait-il le critère de la porte arrière pour identifier l'effet de la subvention sur la survie ?
- En vous appuyant sur les valeurs rappelées ci-dessus, expliquer en langage du graphe pourquoi la différence observée (-20 points, qui ne conditionne sur rien) diffère de l'ATT (10 points, qui conditionne sur la taille) : quel chemin reste ouvert dans un cas, fermé dans l'autre ?
- Supposons qu'une variable supplémentaire M , « accès au crédit bancaire », se situe sur le chemin $T \rightarrow M \rightarrow Y$ (la subvention facilite l'accès au crédit, qui favorise à son tour la survie), sans qu'il existe de flèche directe $X \rightarrow M$. Si l'analyste contrôle $\{X, M\}$ plutôt que $\{X\}$ seul, obtient-il toujours une estimation de l'ATT total de la subvention sur la survie ? Justifier à l'aide du critère de la porte arrière.

3 Applications en sciences économiques

Exercice 5 — Le biais du survivant comme collisionneur

On étudie l'effet de l'effet de levier (T : fonds à fort levier ou non, sur 1 000 fonds au départ) sur l'obtention d'un rendement élevé (Y), sachant que T et Y sont en réalité **indépendants** dans la population complète :

	$Y = 1$ (rendement élevé)	$Y = 0$
$T = 1$ (fort levier)	250	250
$T = 0$ (levier faible)	250	250

Un fonds **reste coté** (survit, $S=1$) si $Y = 1$ **ou** si $T = 0$: un fonds à fort levier ne survit que s'il a obtenu un rendement élevé, tandis qu'un fonds à faible levier survit dans tous les cas.

- Vérifier que $P(Y=1 | T=1) = P(Y=1 | T=0)$ dans la population complète.
- Combien de fonds survivent ? Calculer $P(Y=1 | T=1, \text{survit})$ et $P(Y=1 | T=0, \text{survit})$.
- Un analyste qui n'étudie que les fonds encore cotés aujourd'hui observe-t-il un lien entre levier et rendement ? De quelle ampleur ? Pourquoi ce lien est-il purement artificiel, et quelle variable joue ici le rôle du collisionneur ?

Exercice 6 — Le biais du médiateur sur un programme de formation

Un programme de formation professionnelle (T) augmente la probabilité d'obtenir un emploi **qualifié** (M) : 30 % des personnes non formées obtiennent un emploi qualifié, contre 70 % des personnes formées. Le salaire moyen est de 9 000 DH pour un emploi qualifié et de 6 000 DH pour un emploi non qualifié, **quel que soit** le statut de formation – la formation n'agit sur le salaire **que** via le type d'emploi obtenu.

- Calculer $E[Y | T=0]$ et $E[Y | T=1]$, puis l'effet total de la formation sur le salaire.
- Calculer la différence de salaire entre formés et non formés **à l'intérieur** de chaque catégorie d'emploi (parmi les qualifiés, puis parmi les non qualifiés).

- (c) Un chercheur qui contrôle le type d'emploi obtenu pour « purger » l'effet de facteurs de confusion conclut-il correctement à l'existence d'un effet de la formation sur le salaire ? Quel est le nom de l'erreur commise, et pourquoi est-elle particulièrement trompeuse dans cet exemple ?