

Chapitre 4

Appariement et pondération par le score de propension

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale

1 Exercices du chapitre

Exercice 1 — Score de propension et poids extrêmes

Un programme d'aide à l'export est proposé à des PME. Sur trois profils de taille :

Profil	Effectif total	Dont bénéficiaires du programme
Petite entreprise	500	450
Moyenne entreprise	500	250
Grande entreprise	500	25

- Calculer le score de propension $e(X) = P(T=1 | X)$ pour chacun des trois profils.
- Calculer le poids de pondération par l'inverse de la probabilité ($1/e(X)$ si traité, $1/(1 - e(X))$ sinon) pour : une petite entreprise **non** bénéficiaire, et une grande entreprise **bénéficiaire**.
- Ces deux poids vous semblent-ils raisonnables ? Quels sont les deux remèdes usuels face à des poids extrêmes ?

Exercice 2 — Calculer un estimateur IPW

Six individus ont été observés, avec leur statut de traitement T , leur score de propension $e(X)$ et leur résultat Y :

Individu	T	$e(X)$	Y
1	1	0,6	80
2	1	0,6	90
3	1	0,3	60
4	0	0,6	70
5	0	0,3	50
6	0	0,3	40

- Calculer la différence de moyennes brute entre traités et témoins (sans pondération).
- Calculer l'estimateur IPW : $\frac{1}{n} \sum_i \left[\frac{T_i Y_i}{e(X_i)} - \frac{(1 - T_i) Y_i}{1 - e(X_i)} \right]$.
- Les deux estimations diffèrent-elles ? Pourquoi la pondération peut-elle changer le résultat même si aucune observation n'est ajoutée ni retirée ?

Exercice 3 — Vérifier l'équilibre par la différence standardisée

Pour une covariable (l'expérience professionnelle, en années), on observe :

	Avant pondération		Après pondération	
	Traités	Témoins	Traités	Témoins
Moyenne	12,5	9,0	10,2	9,8
Écart-type	4,0	3,5	4,2	4,0

La différence standardisée se calcule $d = \frac{\bar{X}_T - \bar{X}_C}{\sqrt{(s_T^2 + s_C^2)/2}}$, et on la souhaite inférieure à 0,1 en valeur absolue.

- Calculer d avant pondération. L'équilibre est-il satisfaisant ?
- Calculer d après pondération. La pondération a-t-elle résolu le problème ?
- Pourquoi vérifie-t-on la différence standardisée plutôt que la capacité du score de propension à **prédire** le traitement (son AUC) ?

2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Repondérer la subvention aux entreprises

Rappel : sur les 2 000 entreprises de l'exemple filé (introduction, chapitres 1 à 3), les petites entreprises comptent 1 000 au total, dont 800 subventionnées ; les grandes entreprises comptent 1 000 au total, dont 200 subventionnées. Les taux de survie sont : petites subventionnées 35 %, petites non subventionnées 25 %, grandes subventionnées 85 %, grandes non subventionnées 75 %.

- Calculer le score de propension $e(X) = P(T=1 | X)$ pour les petites entreprises, puis pour les grandes.
- Calculer l'estimateur IPW de l'ATE, en utilisant la version agrégée par strate :
$$\frac{1}{N} \left[\sum_{\text{strate}} n_{\text{strate},1} \frac{\bar{Y}_{\text{strate},1}}{e_{\text{strate}}} - n_{\text{strate},0} \frac{\bar{Y}_{\text{strate},0}}{1 - e_{\text{strate}}} \right]$$
, avec $N = 2\,000$.
- Ce résultat est-il cohérent avec l'ATE de 10 points établi au chapitre 3 sous l'hypothèse d'un tirage au sort ? Expliquer pourquoi la pondération IPW, appliquée à des données **observationnelles**, peut reproduire ce que la randomisation aurait donné directement.
- Le chapitre 2 exigeait de contrôler la taille car elle est un confondant (une fourche). En quoi la pondération par $e(X)$ réalise-t-elle, sous une autre forme, exactement ce que demandait le critère de la porte arrière ?

3 Applications en sciences économiques

Exercice 5 — Poids extrêmes dans une étude de certification agricole

Une étude évalue l'effet d'une certification biologique sur le prix de vente d'exploitations agricoles, selon la région :

Région	Effectif total	Dont certifiées bio
Nord	400	380
Sud	400	40

- Calculer $e(X)$ pour chaque région.
- Calculer le poids IPW d'une exploitation **non certifiée** dans le Nord, et celui d'une exploitation **certifiée** dans le Sud.
- Ces deux poids extrêmes signalent-ils le même problème sous-jacent ? Quelle décision méthodologique (parmi les deux remèdes usuels) semble la plus adaptée si l'on veut conserver toutes les régions dans l'analyse ?

Exercice 6 — Un programme de numérisation des PME, avant et après pondération

Un programme de numérisation est évalué sur les heures de formation numérique suivies par les employés (une covariable, non le résultat étudié) :

	Avant pondération		Après pondération	
	Traités	Témoins	Traités	Témoins
Moyenne (heures)	15,0	8,0	11,5	11,0
Écart-type	5,0	4,5	5,2	5,0

- Calculer la différence standardisée avant pondération. Que révèle-t-elle sur la comparabilité initiale des deux groupes ?
- Calculer la différence standardisée après pondération.

- (c) Si cette covariable (heures de formation numérique déjà suivies) est fortement liée à la probabilité de participer au programme **et** à la productivité future, pourquoi son déséquilibre initial menaçait-il la validité de l'étude, et pourquoi une bonne pondération le résout-elle?