


Inférence causale et machine learning

Chapitre 2 : Le cadre des résultats potentiels



La notation

La décomposition du biais

Les hypothèses

Ce qu'il faut retenir

La notation

Deux mondes pour chaque individu

Résultats potentiels

Pour chaque individu i :

- $Y_i(1)$ — ce qu'il obtiendrait **s'il était traité**;
- $Y_i(0)$ — ce qu'il obtiendrait **s'il ne l'était pas**.

L'effet causal individuel est

$$\tau_i = Y_i(1) - Y_i(0)$$

Le problème fondamental

On n'observe **jamais** les deux. Si $T_i = 1$, on voit $Y_i(1)$; sinon, $Y_i(0)$.

$$Y_i = T_i Y_i(1) + (1 - T_i) Y_i(0)$$

L'effet individuel n'est jamais observable. C'est un problème de données manquantes, et il est irréparable au niveau individuel.

Ce que cette notation apporte immédiatement

Les effets moyens

Paramètre	Définition	Population
ATE	$E[Y(1) - Y(0)]$	tout le monde
ATT	$E[Y(1) - Y(0) \mid T = 1]$	les traités
ATU	$E[Y(1) - Y(0) \mid T = 0]$	les non traités

Lequel intéresse le décideur

L'ATT répond à : le programme a-t-il servi à ceux qui l'ont suivi ?

L'ATE répond à : faudrait-il l'étendre à tous ?

Ce sont deux questions distinctes, et les deux réponses diffèrent dès que l'effet varie d'un individu à l'autre. **Annoncer un chiffre sans préciser lequel des trois est incomplet.**

La décomposition du biais

Ce que la comparaison naïve mesure vraiment

La décomposition

$$\underbrace{E[Y \mid T=1] - E[Y \mid T=0]}_{\text{différence observée}} = \underbrace{\text{ATT}}_{\text{ce qu'on cherche}} + \underbrace{E[Y(0) \mid T=1] - E[Y(0) \mid T=0]}_{\text{biais de sélection}}$$

Le biais de sélection

C'est l'écart entre traités et non traités **en l'absence de traitement**.

Il vaut zéro si les deux groupes sont comparables au départ. Sinon, la différence observée mélange l'effet et l'écart préexistant.

Quatre individus, entièrement chiffrés

Individu	$Y(0)$	$Y(1)$	Effet
1	10	14	+4
2	20	22	+2
3	30	36	+6
4	40	44	+4

Les hypothèses

Ce qu'il faut pour identifier

Indépendance conditionnelle

$$(Y(0), Y(1)) \perp T \mid X$$

À caractéristiques X égales, l'affectation au traitement est indépendante des résultats potentiels.

On l'appelle aussi *ignorabilité*, ou hypothèse d'absence de confondant non observé.

Support commun

$$0 < P(T = 1 \mid X) < 1$$

Pour chaque profil X , il doit exister des traités **et** des non traités. Sans cela, aucune comparaison n'est possible pour ce profil.

SUTVA

Deux exigences souvent oubliées :

1. **Pas d'interférence** — le traitement d'un individu n'affecte pas le résultat d'un autre.
2. **Un seul traitement** — la version reçue est la même pour tous.

Ce qu'il faut retenir

Cinq points

1. $Y_i(1)$ et $Y_i(0)$ définissent l'effet; on n'en observe **jamais** qu'un.
2. **ATE**, **ATT**, **ATU** diffèrent dès que l'effet est hétérogène.
3. Différence observée = **ATT** + **biais de sélection** — ici $25 = 5 + 20$.
4. Identifier exige **indépendance conditionnelle**, **support commun** et **SUTVA**.
5. Ces hypothèses ne se **testent pas** : elles se défendent.

La suite

L'indépendance conditionnelle exige de savoir **quelles** variables conditionner. Le chapitre 3 donne l'outil qui répond — et montre que certains contrôles sont nuisibles.