

Introduction à l'analyse des données

Chapitre 8 : Axes, valeurs propres et inertie expliquée

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Valeurs propres de deux variables corrélées

Deux variables réduites ont pour matrice des corrélations $R = \begin{pmatrix} 1 & 0,6 \\ 0,6 & 1 \end{pmatrix}$.

- (a) Calculer les deux valeurs propres λ_1 et λ_2 à l'aide de la formule du cours.
- (b) Vérifier que $\lambda_1 + \lambda_2 = p$.
- (c) Rappeler, sans les recalculer, les deux directions propres associées à ces valeurs propres pour une matrice de cette forme. Que représente chacune d'elles ?

Exercice 2 — Lire un spectre de valeurs propres

Une ACP sur $p = 5$ variables réduites donne le spectre de valeurs propres suivant : $\lambda_1 = 3,5$, $\lambda_2 = 0,9$, $\lambda_3 = 0,4$, $\lambda_4 = 0,15$, $\lambda_5 = 0,05$.

- (a) Vérifier que la somme des cinq valeurs propres vaut bien $p = 5$.
- (b) Calculer le pourcentage d'inertie porté par chaque axe.
- (c) À quelle des trois configurations décrites dans le cours (« dimension dominante », « valeurs décroissant régulièrement », « toutes proches de 1 ») ce spectre correspond-il ? Combien de variables « indépendantes utiles » ce tableau contient-il, intuitivement ?

Exercice 3 — Reconnaître le cas où l'ACP ne sert à rien

On calcule les valeurs propres de la matrice des corrélations de $p = 4$ variables réduites, et l'on trouve : $\lambda_1 = 1,08$, $\lambda_2 = 1,02$, $\lambda_3 = 0,96$, $\lambda_4 = 0,94$.

- (a) Vérifier que la somme vaut $p = 4$.
- (b) Que peut-on en déduire sur la matrice des corrélations R elle-même, sans même la regarder directement ?
- (c) Le cours affirme que « constater qu'il n'y a rien à résumer est un résultat, pas un échec ». En une phrase, expliquer ce que cela signifie concrètement pour un analyste qui aurait espéré réduire ce tableau à deux ou trois axes.

2 Exercices cumulatifs (introduction au chapitre 8)

Exercice 4 — Vérifier les valeurs propres du fil rouge par le calcul direct

On reprend le fil rouge, avec les coordonnées centrées réduites $z_x = (-1,414; -0,707; 0; 0,707; 1,414)$ et $z_y = (-1,414; 0; -0,707; 0,707; 1,414)$ (chapitre 2), et les deux directions propres $(1; 1)/\sqrt{2}$ et $(1; -1)/\sqrt{2}$ (chapitre 8, cours).

- (a) Pour chacun des cinq clients, calculer sa coordonnée sur le premier axe, $c_{1,i} = \frac{z_{x,i} + z_{y,i}}{\sqrt{2}}$, puis la variance de cette nouvelle variable C_1 sur les cinq clients.
- (b) Faire de même pour le second axe, $c_{2,i} = \frac{z_{x,i} - z_{y,i}}{\sqrt{2}}$, et calculer $V(C_2)$.
- (c) Comparer $V(C_1)$ et $V(C_2)$ aux valeurs propres $\lambda_1 = 1,9$ et $\lambda_2 = 0,1$ annoncées par le cours. Qu'est-ce que ce calcul direct vient de vérifier, très concrètement, sur la définition même de « l'inertie portée par un axe » ?

3 Applications en sciences économiques

Exercice 5 — Décider combien d'axes retenir (indicateurs boursiers)

Une société de gestion calcule les valeurs propres de la matrice des corrélations de $p = 5$ indicateurs boursiers réduits (rendement, volatilité, volume, spread, momentum) : $\lambda_1 = 3,5$, $\lambda_2 = 0,9$, $\lambda_3 = 0,4$, $\lambda_4 = 0,15$, $\lambda_5 = 0,05$.

- (a) Calculer le pourcentage d'inertie porté par le premier axe seul.
- (b) En appliquant le critère annoncé par le cours (« une valeur propre supérieure à 1 porte plus d'inertie qu'une variable seule »), combien d'axes la société devrait-elle retenir ?
- (c) Sachant que les cinq indicateurs mesurent des aspects très différents du marché (rendement, risque, liquidité, coût de transaction, tendance), qu'est-ce qu'une inertie aussi concentrée sur un seul axe ($\lambda_1 = 3,5$) suggère sur la façon dont ces cinq indicateurs se comportent réellement, en période normale de marché ?

Exercice 6 — Un spectre presque plat : le piège d'un critère mécanique


Un questionnaire de satisfaction comporte $p = 4$ items réduits, jugés a priori indépendants les uns des autres par les concepteurs de l'enquête. Le calcul donne : $\lambda_1 = 1,15$, $\lambda_2 = 1,05$, $\lambda_3 = 0,95$, $\lambda_4 = 0,85$.

- (a) Vérifier que la somme des valeurs propres vaut bien $p = 4$, puis calculer le pourcentage d'inertie cumulé porté par les deux premiers axes.
- (b) En appliquant mécaniquement le critère « $\lambda_k > 1$ » du cours, combien d'axes seraient retenus ?
- (c) Ce spectre, presque plat, correspond-il à la configuration « toutes proches de 1 » décrite dans le cours ? Expliquer pourquoi retenir « deux axes » au sens strict du critère ne constitue, dans ce cas précis, presque *aucune* réduction utile de l'information – et pourquoi ce résultat était en réalité prévisible dès la conception du questionnaire (items jugés indépendants).

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\lambda_1 = 1 + 0,6 = 1,6$, $\lambda_2 = 1 - 0,6 = 0,4$.
(b) $\lambda_1 + \lambda_2 = 1,6 + 0,4 = 2,0 = p$.
(c) Les deux directions propres sont, comme pour toute matrice 2×2 de cette forme (diagonale = 1, hors-diagonale = r), les deux bissectrices $(1; 1)/\sqrt{2}$ et $(1; -1)/\sqrt{2}$. La première combine les deux variables **dans le même sens** (les deux critères « ensemble »); la seconde les oppose (les deux critères « en écart l'un de l'autre »).



Correction — Exercice 2

- (a) $3,5 + 0,9 + 0,4 + 0,15 + 0,05 = 5,0 = p$.
(b) $\frac{3,5}{5} = 70\%$, $\frac{0,9}{5} = 18\%$, $\frac{0,4}{5} = 8\%$, $\frac{0,15}{5} = 3\%$, $\frac{0,05}{5} = 1\%$.
(c) C'est la configuration « λ_1 très grande, les autres faibles » : une **dimension dominante**. Intuitivement, ce tableau ne contient qu'une seule variable réellement « indépendante et utile » – les cinq variables de départ redisent, pour l'essentiel (70 %, et 88 % avec le second axe), la même information.

Correction — Exercice 3

- (a) $1,08 + 1,02 + 0,96 + 0,94 = 4,0 = p$.
(b) Une matrice des corrélations dont **toutes** les valeurs propres sont proches de 1 est nécessairement, elle-même, proche de la matrice **identité** – ce qui signifie que les corrélations entre les quatre variables sont, elles aussi, toutes proches de 1 : c'est la troisième configuration du cours, « variables non corrélées ».
(c) Cela signifie que le tableau ne contient tout simplement **pas** de structure commune à résumer : les quatre variables mesurent des choses réellement distinctes. L'analyste ne doit pas y voir un échec de la méthode ni chercher à « forcer » une réduction à deux ou trois axes – le résultat honnête est de conserver les quatre variables telles quelles, ce constat étant lui-même une information utile sur la structure du phénomène étudié.

2 Exercices cumulatifs (introduction au chapitre 8)

Correction — Exercice 4


- (a) $c_{1,i} = \frac{z_{x,i} + z_{y,i}}{\sqrt{2}}$: client 1 : $\frac{-1,414 - 1,414}{1,41421} = -2,000$; client 2 : $\frac{-0,707 + 0}{1,41421} = -0,500$; client 3 : $\frac{0 - 0,707}{1,41421} = -0,500$; client 4 : $\frac{0,707 + 0,707}{1,41421} = 1,000$; client 5 : $\frac{1,414 + 1,414}{1,41421} = 2,000$. Moyenne = $\frac{-2,000 - 0,500 - 0,500 + 1,000 + 2,000}{5} = 0$.

$$\frac{-2 - 0,5 - 0,5 + 1 + 2}{5} = 0. \quad V(C_1) = \frac{4 + 0,25 + 0,25 + 1 + 4}{5} = \frac{9,5}{5} = 1,9.$$

(b) $c_{2,i} = \frac{z_{x,i} - z_{y,i}}{\sqrt{2}}$: client 1 : 0 ; client 2 : -0,500 ; client 3 : 0,500 ; client 4 : 0 ; client 5 : 0. Moyenne = 0.

$$V(C_2) = \frac{0 + 0,25 + 0,25 + 0 + 0}{5} = 0,1.$$

(c) $V(C_1) = 1,9 = \lambda_1$ et $V(C_2) = 0,1 = \lambda_2$: les deux calculs coïncident **exactement** avec les valeurs propres annoncées par le cours. Ce calcul direct vient de vérifier, très concrètement, que « l'inertie portée par un axe » n'est rien d'autre que la **variance** des coordonnées des individus une fois projetés sur cet axe – la valeur propre n'est donc pas un objet mathématique abstrait, mais un nombre calculable directement, comme n'importe quelle variance du chapitre 2, une fois qu'on a projeté chaque individu sur la bonne direction.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\frac{3,5}{5} = 70\%$.

(b) Seul $\lambda_1 = 3,5$ dépasse 1 ; $\lambda_2 = 0,9$, $\lambda_3 = 0,4$, $\lambda_4 = 0,15$ et $\lambda_5 = 0,05$ sont tous inférieurs à 1. La société devrait donc retenir **un seul** axe.

(c) Une inertie aussi concentrée sur un seul axe suggère qu'en période normale, ces cinq dimensions du marché (rendement, risque, liquidité, coût de transaction, tendance) **bougent largement ensemble** – un marché qui devient plus volatil tend, dans ce jeu de données, à voir simultanément son volume, son spread et son momentum évoluer dans une direction cohérente. Statistiquement, un seul « facteur de marché » explique donc l'essentiel des mouvements conjoints de ces cinq indicateurs, même s'ils paraissent conceptuellement indépendants.

Correction — Exercice 6

(a) $1,15 + 1,05 + 0,95 + 0,85 = 4,0 = p$. Pourcentage cumulé des deux premiers axes : $\frac{1,15 + 1,05}{4} = \frac{2,2}{4} = 55\%$.

(b) Deux valeurs propres dépassent 1 ($\lambda_1 = 1,15$ et $\lambda_2 = 1,05$) : le critère retiendrait donc mécaniquement **deux** axes.

(c) Oui : les quatre valeurs propres (1,15 ; 1,05 ; 0,95 ; 0,85) sont toutes très proches de 1, ce qui correspond exactement à la troisième configuration du cours – des variables quasiment non corrélées. Retenir « deux axes » au sens strict du critère ne réduit ici presque rien : ces deux axes portent seulement 55 % de l'inertie totale (loin des 90 % ou plus visés d'ordinaire), et passer de 4 variables à 2 composantes fait perdre près de la moitié de l'information sans vraiment simplifier la lecture – puisqu'aucune des quatre variables de départ ne redisait ce qu'une autre disait déjà. Ce résultat était prévisible dès la conception du questionnaire : des items pensés comme indépendants par construction ne peuvent, par définition, produire un spectre de valeurs propres inégal.