Introduction à l'analyse des données

Chapitre 8 : Axes, valeurs propres et inertie expliquée

Jaouad Madkour

31 octobre 2026

Plan du chapitre

La solution du problème **2**
- Le résultat . . . 2
- Vecteur propre et valeur propre, rappelés . . . 2
- Ce que fait la matrice, en image . . . 3
- Pourquoi cela tombe juste . . . 3

Le calcul sur le fil rouge **4**
- L'équation caractéristique . . . 4
- Les vecteurs propres . . . 5
- La lecture, immédiate . . . 5
- Deux contrôles systématiques . . . 5
- Pourquoi réduire d'abord : l'ACP non normée . . . 6

Ce qui rend tout lisible **7**
- La somme des valeurs propres . . . 7
- Sur le fil rouge . . . 7

Le fichier réel **8**
- Les huit valeurs propres . . . 8
- Ce que disent ces huit nombres . . . 8
- Les deux premiers vecteurs propres . . . 8

Ce que valent les valeurs **9**
- Trois configurations . . . 9
- Une propriété qui sera utile au chapitre 9 . . . 9

Sur machine **10**
- Avec R : la fonction PCA de FactoMineR . . . 10
- Avec R : les vecteurs propres . . . 10
- Le signe d'un axe est arbitraire . . . 10
- Avec Python : numpy . . . 11
- Avec Python : scikit-learn . . . 11

S'entraîner **11**

Exercice 1 : une corrélation de 0,6 11
Exercice 1 : solution 12
Exercice 2 : trois variables 12
Exercice 2 : solution 12
Exercice 3 : lire une sortie de logiciel 12
Exercice 3 : solution 13

Ce qu'il faut retenir **13**
Le résumé du chapitre 13
La suite 13

La solution du problème

Le résultat

Le théorème central de l'ACP

Les **axes principaux** sont les **vecteurs propres** de la matrice des corrélations R.
L'**inertie portée** par chaque axe est la **valeur propre** associée.

Un résultat du cours d'Algèbre linéaire

C'est le chapitre « Diagonalisation des matrices carrées » du cours d'*Algèbre linéaire*. L'ACP n'est donc pas une méthode statistique nouvelle : **c'est une diagonalisation**. Le problème d'optimisation du chapitre 7 se ramène exactement à ce calcul.

Vecteur propre et valeur propre, rappelés

La définition

Un vecteur u non nul est **vecteur propre** de la matrice R, de **valeur propre** λ, si

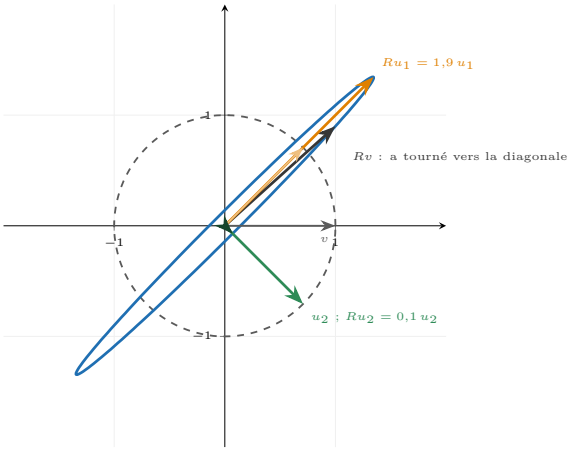
$$R\,u = \lambda\,u$$

La matrice ne fait pas **tourner** u : elle se contente de l'étirer (ou de le contracter) d'un facteur λ.

Sur la matrice du fil rouge

$$\begin{pmatrix} 1 & 0{,}9 \\ 0{,}9 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1{,}9 \\ 1{,}9 \end{pmatrix} = 1{,}9 \begin{pmatrix} 1 \\ 1 \end{pmatrix} \qquad \begin{pmatrix} 1 & 0{,}9 \\ 0{,}9 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = 0{,}1 \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Ce que fait la matrice, en image



Le cercle devient une ellipse

R transforme le cercle unité en une **ellipse** dont les axes sont les deux bissectrices, de demi-longueurs 1,9 et 0,1. Un vecteur quelconque, comme $v = (1\,;\,0)$, est **tourné** vers la diagonale ; les deux vecteurs propres, eux, gardent leur direction.

Pourquoi cela tombe juste

La forme du nuage est dans R

La matrice des corrélations décrit la forme du nuage. Ses directions propres sont celles selon lesquelles il s'étire, et les valeurs propres mesurent de combien.
Chercher la direction d'allongement maximal, c'est donc chercher le vecteur propre de plus grande valeur propre. **Le problème du photographe a une solution exacte, et elle se calcule.**

Le lien avec le chapitre 7

L'inertie projetée sur une direction u de longueur 1 s'écrit $I(u) = u'Ru$ — c'est la formule $a^2+b^2+2ab\,r$ du chapitre 7, écrite avec la matrice. Si u est vecteur propre, $u'Ru = \lambda\,u'u = \lambda$: **l'inertie portée par l'axe est sa valeur propre**.

Démonstration : Le meilleur axe est le vecteur propre de plus grande valeur propre

La matrice R est symétrique : d'après le cours d'algèbre linéaire, elle possède une base **orthonormée** de vecteurs propres $e_1, \dots, e_p$, de valeurs propres $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p$. Un vecteur u de longueur 1 s'écrit $u = \sum_k c_k\,e_k$, avec $\sum_k c_k^2 = 1$ (les e_k sont orthonormés). Alors $Ru = \sum_k c_k\,\lambda_k\,e_k$ et

$$I(u) = u'\,R\,u = \sum_{k=1}^{p} \lambda_k\,c_k^2.$$

C'est une **moyenne des valeurs propres**, pondérée par les nombres positifs c_k^2 dont la

somme vaut 1 : elle ne peut pas dépasser la plus grande,

$$I(u) = \sum_k \lambda_k\, c_k^2 \;\le\; \lambda_1 \sum_k c_k^2 = \lambda_1,$$

avec égalité si et seulement si $c_k = 0$ dès que $\lambda_k < \lambda_1$, c'est-à-dire si u est vecteur propre de λ_1 (e_1, au signe près). **Le meilleur axe est e_1, et il conserve λ_1.**

Les axes suivants. Si u est orthogonal à e_1, alors $c_1 = 0$ et $I(u) = \sum_{k\ge 2} \lambda_k\, c_k^2 \le \lambda_2$, atteint en e_2 ; et ainsi de suite : l'orthogonalité imposée au chapitre 7 donne exactement les vecteurs propres suivants.

Sur les cinq clients, $e_1 = (1\,;\,1)/\sqrt{2}$ et $e_2 = (1\,;\,-1)/\sqrt{2}$. Pour $u = (0{,}6\,;\,0{,}8)$: $c_1 = 1{,}4/\sqrt{2}$ et $c_2 = -0{,}2/\sqrt{2}$, donc $c_1^2 = 0{,}98$ et $c_2^2 = 0{,}02$ (leur somme est bien 1), et $I(u) = 1{,}9 \times 0{,}98 + 0{,}1 \times 0{,}02 = 1{,}864$, la valeur du chapitre 7. *Sur les huit notes,* aucune des 2 000 directions tirées au hasard ne dépasse $\lambda_1 = 4{,}535$; la meilleure en conserve 4,34.

■

Le calcul sur le fil rouge

L'équation caractéristique

Trouver les valeurs propres

$Ru = \lambda u$ avec $u \neq 0$ exige que $R - \lambda I$ ne soit pas inversible :

$$\det(R - \lambda I) = 0$$

Sur la matrice du fil rouge

$$\det \begin{pmatrix} 1-\lambda & 0{,}9 \\ 0{,}9 & 1-\lambda \end{pmatrix} = (1-\lambda)^2 - 0{,}81 = 0 \iff 1 - \lambda = \pm 0{,}9$$

$$\lambda_1 = 1 + 0{,}9 = \mathbf{1{,}9} \qquad \lambda_2 = 1 - 0{,}9 = \mathbf{0{,}1}$$

Démonstration : Les valeurs propres d'une matrice symétrique deux sur deux

Soit $M = \begin{pmatrix} a & b \\ b & d \end{pmatrix}$. L'équation caractéristique est $(a-\lambda)(d-\lambda) - b^2 = 0$, soit

$$\lambda^2 - (a+d)\,\lambda + (ad - b^2) = 0, \qquad \Delta = (a+d)^2 - 4(ad-b^2) = (a-d)^2 + 4b^2 \;\ge\; 0.$$

Le discriminant n'est jamais négatif : les deux valeurs propres sont **toujours réelles**, et valent

$$\lambda = \frac{a+d}{2} \pm \sqrt{\Big(\frac{a-d}{2}\Big)^2 + b^2}.$$

Si $b \neq 0$, la première ligne de $Mu = \lambda u$ s'écrit $(a-\lambda)\,u_1 + b\,u_2 = 0$: le vecteur $u = (b\,;\,\lambda - a)$ convient.

Matrice de corrélations. Avec $a = d = 1$ et $b = r$, on obtient $\lambda = 1 \pm |r|$; les vecteurs propres sont $(r\,;\,\pm r)$, c'est-à-dire les directions $(1\,;\,1)$ et $(1\,;\,-1)$, **quelle que soit** r : les axes sont toujours les bissectrices, seules les valeurs propres changent.

Matrice des covariances des cinq clients (sans réduction), $a = 8$, $d = 32$, $b = 14{,}4$:

$$\lambda = 20 \pm \sqrt{12^2 + 14{,}4^2} = 20 \pm \sqrt{351{,}36} = 20 \pm 18{,}745, \qquad \lambda_1 = 38{,}745, \quad \lambda_2 = 1{,}255.$$

Le premier axe est dirigé par $(b\,;\,\lambda_1 - a) = (14{,}4\,;\,30{,}745)$, soit, une fois ramené à la longueur 1, $(0{,}42\,;\,0{,}91)$. Les parts sont $38{,}745/40 = 96{,}9\,\%$ et $3{,}1\,\%$.

■

Les vecteurs propres

Résoudre $Ru = \lambda u$

Pour $\lambda_1 = 1{,}9$: $u_1 + 0{,}9\,u_2 = 1{,}9\,u_1$ donne $u_2 = u_1$. Normé à 1 : $u_1 = (1\,;\,1)/\sqrt{2}$.
Pour $\lambda_2 = 0{,}1$: $u_1 + 0{,}9\,u_2 = 0{,}1\,u_1$ donne $u_2 = -u_1$. Normé : $u_2 = (1\,;\,-1)/\sqrt{2}$.

Axe	Valeur propre	Direction	Sens
1	1,9	$(1\,;\,1)/\sqrt{2}$	les deux critères **ensemble**
2	0,1	$(1\,;\,-1)/\sqrt{2}$	les deux critères **en opposition**

La lecture, immédiate

Deux axes, deux sens

Le **premier axe** porte les deux variables dans le même sens : c'est la **satisfaction globale**. Un client qui monte sur cet axe juge bien l'accueil *et* se montre fidèle.
Le **deuxième** les oppose : il distingue les clients dont les deux notes s'écartent l'une de l'autre. Comme il ne porte que 0,1 d'inertie, ces cas sont rares — ce que le $r = 0{,}9$ laissait prévoir.

Ce sont les axes trouvés en faisant tourner

La diagonale du chapitre 7, qui conservait 1,9, et l'anti-diagonale, qui conservait 0,1. **Le calcul algébrique retrouve, sans essayer aucun angle, ce que l'expérience avait trouvé à tâtons.**

Deux contrôles systématiques

Trace et déterminant

$$\lambda_1 + \lambda_2 + \cdots + \lambda_p = \operatorname{trace}(R) = p \qquad \lambda_1 \times \lambda_2 \times \cdots \times \lambda_p = \det(R)$$

Sur le fil rouge

$\lambda_1 + \lambda_2 = 1{,}9 + 0{,}1 = 2 = p$ ✓ $\qquad$ $\lambda_1 \lambda_2 = 1{,}9 \times 0{,}1 = 0{,}19 = 1 - 0{,}81 = \det R$ ✓

Si la somme ne tombe pas sur p, le calcul est faux.

Démonstration : La somme des valeurs propres est la trace, leur produit le déterminant

Rangeons les vecteurs propres orthonormés dans les colonnes d'une matrice U (donc $U'U = I$) et les valeurs propres dans une matrice diagonale Λ : $RU = U\Lambda$, soit $R = U\Lambda U'$.

La trace. La trace d'un produit ne dépend pas de l'ordre des facteurs, $\text{trace}(AB) = \sum_{i,j} A_{ij}B_{ji} = \text{trace}(BA)$. Donc

$$\text{trace}(R) = \text{trace}(U\Lambda U') = \text{trace}(\Lambda U'U) = \text{trace}(\Lambda) = \lambda_1 + \cdots + \lambda_p.$$

Les p cases diagonales d'une matrice de corrélations valent 1 : la trace vaut p.

Le déterminant. $\det(R) = \det(U)\det(\Lambda)\det(U')$, et $\det(U)\det(U') = \det(U'U) = \det(I) = 1$: il reste $\det(R) = \lambda_1\lambda_2\cdots\lambda_p$.

Sur nos données. Fil rouge : $1{,}9 + 0{,}1 = 2$ et $1{,}9 \times 0{,}1 = 0{,}19 = 1 - 0{,}9^2$. Huit notes : la somme des huit valeurs propres est 8,000, et leur produit, 0,0053, est le déterminant de la matrice des corrélations.

■

Pourquoi réduire d'abord : l'ACP non normée

Les cinq clients sans réduction

On diagonalise la matrice des **covariances** du chapitre 3 :

$$\Sigma = \begin{pmatrix} 8 & 14{,}4 \\ 14{,}4 & 32 \end{pmatrix} \qquad \lambda_1 = 38{,}75, \quad \lambda_2 = 1{,}26 \qquad (96{,}9\,\% \text{ et } 3{,}1\,\%)$$

Le premier axe a pour direction $(0{,}42\,;\,0{,}91)$: il suit **presque uniquement la fidélité**.

Un résultat trompeur

96,9 % semble mieux que 95 %. C'est une illusion : l'axe colle à la fidélité parce qu'elle a la plus grande variance, non parce qu'il résume mieux les deux critères. Avec un panier en dirhams, il collerait au panier. **L'ACP normée, sur R, est la règle** dès que les unités ou les dispersions diffèrent.

Démonstration : Sans réduction, la plus grande variance l'emporte

Sans réduction, on diagonalise la matrice Σ des covariances : l'inertie projetée sur u est $u'\Sigma u$ (même démonstration que pour R), et le premier axe la maximise. Prenons pour u l'axe de la

variable j seule, $u = (0, \dots, 1, \dots, 0)$: $u'\Sigma\, u = V(x_j)$. Le maximum est au moins aussi grand :

$$\lambda_1 \;\geq\; V(x_j) \quad \text{pour chaque } j, \qquad \text{donc} \qquad \lambda_1 \geq V_{\max}.$$

Et comme $\sum_k \lambda_k \;=\; \text{trace}(\Sigma) \;=\; \sum_j V(x_j)$, la part du premier axe vaut **au moins** $V_{\max} \big/ \sum_j V(x_j)$: une variable dont la variance écrase les autres commande le premier axe, quelle que soit la structure du tableau.

Sur les cinq clients, $\lambda_1 \;\geq\; V(\text{fidélité}) \;=\; 32$ et la part est au moins $32/40 \;=\; 80\,\%$ (elle vaut 96,9 %). *Sur le fichier réel,* avec le panier (en dirhams), l'âge, l'ancienneté et l'accueil, la variance du panier représente 99,4 % de la variance totale : le premier axe en conserve au moins autant, et il est presque confondu avec l'axe du panier (coefficient 0,9998 sur le panier). Ce pourcentage mesure l'unité du panier, non une information sur les clients.

■

Ce qui rend tout lisible

La somme des valeurs propres

Le résultat

$$\sum_{k=1}^{p} \lambda_k = I = p$$

La somme des valeurs propres est l'inertie totale, donc le nombre de variables. C'est le contrôle de la trace, et c'est le chapitre 6 : chaque variable réduite apporte une unité d'inertie.

L'inertie expliquée

$$\text{part de l'axe } k = \frac{\lambda_k}{p}$$

Sur le fil rouge

Deux axes

Axe	Valeur propre	Part	Cumul
1	1,9	**95** %	95 %
2	0,1	5 %	100 %

Un seul axe conserve 95 % **de l'information du tableau.** Représenter les cinq clients sur cette unique droite ne perd que 5 % — et fait passer de deux dimensions à une.

Le chameau, résolu

C'est la réponse chiffrée à l'introduction. Le « bon angle » existe, il se calcule, et l'on sait **exactement** ce qu'il conserve.

Le photographe n'avait que son œil. L'analyse des données a un nombre.

Le fichier réel

Les huit valeurs propres

L'ACP normée des huit notes des 300 clients

Axe	λ_k	Part	Cumul
1	4,535	56,69 %	56,69 %
2	1,645	20,57 %	77,26 %
3	0,382	4,77 %	82,03 %
4	0,349	4,37 %	86,40 %
5	0,327	4,09 %	90,49 %
6	0,283	3,54 %	94,02 %
7	0,249	3,11 %	97,14 %
8	0,229	2,86 %	100 %

Ce que disent ces huit nombres

Les contrôles

$4{,}535 + 1{,}645 + 0{,}382 + 0{,}349 + 0{,}327 + 0{,}283 + 0{,}249 + 0{,}229 = 8{,}000$: la somme vaut bien p. Et chaque part est $\lambda_k/8$: $4{,}535/8 = 56{,}69\,\%$.

Deux dimensions, puis du bruit

Le premier axe porte à lui seul plus de la moitié de l'information : c'est le **niveau général** de satisfaction du chapitre 7. Le deuxième en ajoute un cinquième : l'**offre contre le service**. Les six suivants se partagent les 23 % restants presque également, **sans structure** : c'est la signature du bruit, que le chapitre 9 apprendra à reconnaître.

Les deux premiers vecteurs propres

Les coefficients : longueur 1, axes orthogonaux

Note	u_1	u_2
prix	0,295	0,486
choix	0,362	0,342
qualité	0,377	0,296
agencement	0,389	0,189
propreté	0,389	−0,099
rapidité	0,349	−0,371
conseil	0,334	−0,414
accueil	0,323	−0,453

Démonstration : Deux axes de valeurs propres différentes sont orthogonaux

Soient e_1 et e_2 deux vecteurs propres de la matrice symétrique R, de valeurs propres $\lambda_1 \neq \lambda_2$. Calculons de deux façons le nombre $e_2' \, R \, e_1$:

$$e_2' \, (R \, e_1) = \lambda_1 \, e_2' e_1 \qquad \text{et} \qquad (R \, e_2)' \, e_1 = \lambda_2 \, e_2' e_1 .$$

Comme R est symétrique, $e_2' \, R \, e_1 = (R \, e_2)' \, e_1$: les deux écritures sont égales, d'où $(\lambda_1 - \lambda_2) \; e_2' e_1 = 0$. Les valeurs propres étant différentes, **le produit scalaire $e_1' e_2$ est nul** : les axes sont perpendiculaires.

Sur le tableau ci-dessus, $u_1 \cdot u_2 = 0{,}295 \times 0{,}486 + 0{,}362 \times 0{,}342 + \cdots + 0{,}323 \times (-0{,}453) = -0{,}0003$, nul aux arrondis près (les coefficients sont arrondis à trois décimales, ce qui explique aussi $\|u_1\|^2 = 1{,}0005$ et non exactement 1).

■

Ce que valent les valeurs

Trois configurations

Lire le spectre des valeurs propres

Configuration	Ce qu'elle signifie
λ_1 très grande, les autres faibles	une **dimension dominante**
décroissance régulière	plusieurs dimensions utiles
toutes proches de 1	variables **non corrélées** : rien à résumer

Le dernier cas mérite d'être reconnu tout de suite

Si toutes les valeurs propres avoisinent 1, la matrice des corrélations est proche de l'identité : chaque variable porte une information propre. Il n'y a alors **rien à résumer** — et le constater est un résultat, pas un échec. Sur les huit variables simulées du chapitre 7, elles allaient de 0,81 à 1,26.

Une propriété qui sera utile au chapitre 9

Le seuil de 1

Sur données réduites, une valeur propre supérieure à 1 signifie que l'axe porte **plus d'inertie qu'une variable seule**.
Un axe sous ce seuil résume donc moins bien qu'une variable isolée : c'est le fondement du critère de Kaiser.

Sur nos deux tableaux

Cinq clients : $\lambda_1 = 1{,}9 > 1$, $\lambda_2 = 0{,}1 < 1$ — un axe. Trois cents clients : 4,535 et 1,645 dépassent 1, la troisième (0,382) en est loin — deux axes.

Sur machine

Avec R : la fonction PCA de FactoMineR

Le code et sa sortie

```
library(FactoMineR)
# clients et notes : lus et définis comme au chapitre 6
acp <- PCA(clients[, notes], graph = FALSE)   # normée par défaut
e <- acp$eig
colnames(e) <- c("valeur", "pct", "cumul")
round(e, 2)
#        valeur   pct  cumul
# comp 1   4.54 56.69  56.69
# comp 2   1.65 20.57  77.26
# comp 3   0.38  4.77  82.03
#   ...    (cinq lignes de plus, jusqu'à 100.00)
sum(e[, "valeur"])                            # [1] 8
```

Avec R : les vecteurs propres

Les deux premiers axes

```
round(acp$svd$V[, 1:2], 3)
#       [,1]   [,2]
# [1,] 0.295 -0.486
# [2,] 0.362 -0.342
# [3,] 0.377 -0.296
# [4,] 0.389 -0.189
# [5,] 0.389  0.099
# [6,] 0.349  0.371
# [7,] 0.334  0.414
# [8,] 0.323  0.453
```

Le signe d'un axe est arbitraire

FactoMineR retourne le second axe

`FactoMineR` donne le second axe avec le **signe opposé** au nôtre : le prix à $-0{,}486$, l'accueil à $+0{,}453$. Si u est vecteur propre, $-u$ l'est aussi, avec la même valeur propre : **les deux réponses sont justes**.

Ce que cela change, et ce que cela ne change pas

	Ce cours	FactoMineR
coefficient du prix sur l'axe 2	0,486	−0,486
client 36 sur l'axe 2	−2,15	2,15
inertie de l'axe 2	1,645	1,645

Retourner un axe échange seulement le haut et le bas de la figure. On garde ici la convention des figures du cours : **l'offre en haut**.

Avec Python : numpy

eigh diagonalise une matrice symétrique, par ordre croissant

```
import numpy as np
import pandas as pd
clients = pd.read_csv("clients.csv")
notes = ["prix", "choix", "qualite", "agencement",
         "proprete", "rapidite", "conseil", "accueil"]
R = clients[notes].corr().to_numpy()
lam, U = np.linalg.eigh(R)            # ordre croissant
lam = lam[::-1]
print(lam.round(3), lam.sum().round(3))
# [4.535 1.645 0.382 0.349 0.327 0.283 0.249 0.229] 8.0
print((100 * lam / 8).round(2))
# [56.69 20.57  4.77  4.37  4.09  3.54  3.11  2.86]
```

Avec Python : scikit-learn

La classe PCA

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
Z = StandardScaler().fit_transform(clients[notes])
acp = PCA().fit(Z)
print(acp.explained_variance_[:2].round(3))          # [4.55  1.651]
print((100 * acp.explained_variance_ratio_[:2]).round(2))
# [56.69 20.57]
```

Le diviseur, une dernière fois

`scikit-learn` réduit en n, mais calcule la variance des composantes en n — $1 : 4{,}535 \times 300/299 = 4{,}550$. Les **pourcentages**, eux, sont identiques. C'est la raison de lire une ACP en parts d'inertie plutôt qu'en valeurs brutes.

S'entraîner

Exercice 1 : une corrélation de 0,6

Diagonaliser à la main

$$R = \begin{pmatrix} 1 & 0{,}6 \\ 0{,}6 & 1 \end{pmatrix}$$

1. Écrire et résoudre l'équation caractéristique.
2. Donner les vecteurs propres normés.

3. Vérifier la somme et le produit des valeurs propres ; donner la part de chaque axe.

Exercice 1 : solution

1,6 et 0,4

1. $(1-\lambda)^2 - 0{,}36 = 0$, donc $1-\lambda = \pm 0{,}6$: $\lambda_1 = 1{,}6$ et $\lambda_2 = 0{,}4$.
2. Les mêmes bissectrices : $(1\,;\,1)/\sqrt{2}$ et $(1\,;\,-1)/\sqrt{2}$. Pour **toute** matrice 2×2 de corrélation, les axes sont les bissectrices ; seules les valeurs propres changent.
3. Somme $2 = p$; produit $0{,}64 = 1 - 0{,}36 = \det R$. Parts : 80 % et 20 % — ce que l'exercice 1 du chapitre 7 avait trouvé en maximisant.

Exercice 2 : trois variables

Un bloc et une variable isolée

Trois notes ont pour matrice des corrélations

$$R = \begin{pmatrix} 1 & 0{,}8 & 0 \\ 0{,}8 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

1. Vérifier que $(1;1;0)$, $(0;0;1)$ et $(1;-1;0)$ sont vecteurs propres, et donner leurs valeurs propres.
2. Donner la part de chaque axe. Combien d'axes dépassent 1 ?
3. Interpréter.

Exercice 2 : solution

1,8 ; 1 ; 0,2

1. $R(1;1;0) = (1{,}8;1{,}8;0) : \lambda = 1{,}8$. $R(0;0;1) = (0;0;1) : \lambda = 1$. $R(1;-1;0) = (0{,}2;-0{,}2;0) : \lambda = 0{,}2$. Somme $3 = p$.
2. 60 %, 33,3 %, 6,7 %. Un seul axe **dépasse** 1 ; le deuxième est exactement à 1.
3. Le premier axe résume le **bloc** des deux notes liées ; le deuxième est la troisième note **seule**, qui n'est liée à rien et ne peut être résumée par personne.

Exercice 3 : lire une sortie de logiciel

Une ligne a été effacée

Une ACP normée sur cinq variables affiche les valeurs propres 2,60 ; 1,20 ; ? ; 0,30 ; 0,15.

1. Retrouver la valeur manquante.
2. Calculer les parts et les parts cumulées.
3. Le logiciel affiche une première valeur propre de 2,613 au lieu de 2,60 et a été lancé sur 200 individus. Que s'est-il passé ?

Exercice 3 : solution

La somme vaut p

1. La somme vaut $p = 5 : 5 - (2{,}60 + 1{,}20 + 0{,}30 + 0{,}15) = 0{,}75$.
2. Parts : 52 ; 24 ; 15 ; 6 ; 3 %. Cumul : 52 ; 76 ; 91 ; 97 ; 100 %.
3. Le logiciel divise par $n - 1$: $2{,}60 \times 200/199 = 2{,}613$. Les parts ne changent pas.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Les axes principaux sont les **vecteurs propres** de R ; l'inertie portée par un axe est sa **valeur propre** ($u'Ru = \lambda$).
2. Sur le fil rouge : $\det(R - \lambda I) = (1 - \lambda)^2 - 0{,}81 = 0$, d'où $\lambda_1 = 1{,}9$ et $\lambda_2 = 0{,}1$, de directions $(1\,;\,1)$ et $(1\,;\,-1)$.
3. **Somme des valeurs propres** $= p$, produit $= \det R$: deux contrôles systématiques.
4. Le premier axe conserve $1{,}9/2 = \mathbf{95}\,\%$; sans réduction, l'axe suivrait la fidélité seule.
5. Sur les 300 clients : 4,535 et 1,645, soit 56,7 % et 20,6 % — 77,3 % sur deux axes.
6. Le signe d'un axe est arbitraire ; R et `scikit-learn` peuvent différer en signe ou en diviseur, jamais en parts.

La suite

Combien d'axes garder

Avec deux variables, le choix était simple. Avec huit, il faut décider **combien d'axes retenir** — et c'est le chapitre 9.

Ce qu'on y fera

On appliquera trois critères aux huit valeurs propres du fichier réel — Kaiser, le coude, le pourcentage cumulé — et l'on verra s'ils s'accordent sur deux axes.