Introduction à l'analyse des données

Chapitre 10 : Le cercle des corrélations

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Représenter les variables **2**
- Le principe . . . 2
- Le cercle des huit notes . . . 2
- Pourquoi un cercle, et pourquoi il est utile . . . 3

Les coordonnées, d'où elles viennent **3**
- Corrélation d'une variable avec un axe . . . 3
- Sur le fil rouge . . . 4
- Le cercle des cinq clients . . . 4
- Sur le fichier réel . . . 5

Les trois lectures **5**
- La longueur : la qualité de représentation . . . 5
- Qualités et contributions des huit notes . . . 6
- Ce que ce tableau dit . . . 6
- La contribution : qui a construit l'axe . . . 6
- L'angle : la corrélation entre variables . . . 7
- L'angle sur le plan, et l'angle vrai . . . 7
- La position : le sens des axes . . . 8
- Taille et forme . . . 8

Le fil rouge **9**
- Deux variables, un cercle minuscule . . . 9

Sur machine **9**
- Avec R : les coordonnées des variables . . . 9
- Avec R : le cercle . . . 10
- Avec Python : les corrélations . . . 10
- Avec Python : le cercle . . . 11

S'entraîner **11**
- Exercice 1 : du vecteur propre au cercle . . . 11
- Exercice 1 : solution . . . 11
- Exercice 2 : lire le cercle réel . . . 12

Exercice 2 : solution 12
Exercice 3 : une variable près du centre 12
Exercice 3 : solution 12

Ce qu'il faut retenir **13**
Le résumé du chapitre 13
La suite 13

Représenter les variables

Le principe

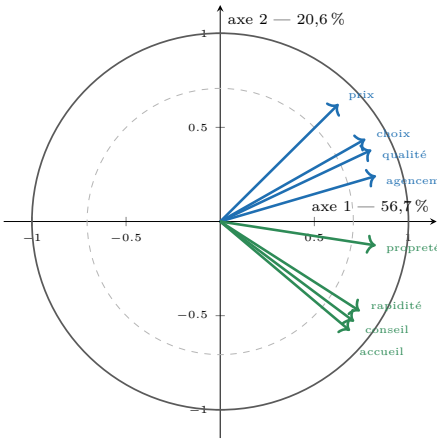
Le cercle des corrélations

Chaque **variable** est représentée par un point dont les coordonnées sont ses **corrélations avec les deux axes** retenus.
Ces coordonnées étant des corrélations, elles sont comprises entre -1 et $+1$: tous les points tombent à l'intérieur d'un **cercle de rayon** 1.

Le nuage des variables, enfin dessiné

Au chapitre 5, les variables étaient des flèches de longueur 1 dans un espace à n dimensions, impossible à dessiner. Le cercle en est la **projection** sur le plan des deux axes : chaque flèche y garde sa direction, et raccourcit d'autant plus qu'elle sort du plan.

Le cercle des huit notes



Trois règles de lecture, et elles ne se discutent pas.

1. La longueur mesure la qualité de représentation. Toutes les flèches approchent le cercle : les huit notes sont bien restituées par le plan.

2. L'angle mesure la corrélation. *Prix* et *accueil* forment un angle proche de 90° : ces deux jugements sont indépendants.

3. Le côté donne le sens. Toutes les flèches pointent à droite : **l'axe 1 est la satisfaction d'ensemble**. L'axe 2 sépare l'offredu service.

Une flèche courte ne s'interprète pas : elle est ailleurs.

Pourquoi un cercle, et pourquoi il est utile

Une borne, qui donne une échelle

Le cercle n'est pas un ornement : c'est une **borne**, qui donne à la figure une échelle absolue. Une variable proche du bord est bien représentée, une variable proche du centre ne l'est pas. Sans cette borne, on interpréterait des positions qui ne veulent rien dire.

Pourquoi la borne est exacte

Les corrélations d'une variable avec **tous** les axes vérifient $\sum_k r^2(x_j, C_k) = 1$. Sur deux axes seulement, la somme est donc au plus 1 : la flèche reste dans le cercle, et elle n'atteint le bord que si la variable est **entièrement** dans le plan.

Démonstration : La borne du cercle est exacte

Écrivons la matrice des corrélations avec ses valeurs et vecteurs propres : $R = \sum_k \lambda_k \, e_k e_k'$, c'est-à-dire, case par case, $r_{jl} = \sum_k \lambda_k \, u_{jk} \, u_{lk}$. Sur la diagonale ($l = j$), $r_{jj} = 1$ (une variable est parfaitement corrélée à elle-même) :

$$1 = \sum_{k=1}^{p} \lambda_k \, u_{jk}^2 = \sum_{k=1}^{p} \left(\sqrt{\lambda_k} \, u_{jk} \right)^2 = \sum_{k=1}^{p} r^2(x_j, C_k).$$

La somme des carrés des corrélations d'une variable avec **tous** les axes vaut exactement 1. Garder seulement les deux premiers termes donne un nombre $q_j = r^2(x_j, C_1) + r^2(x_j, C_2) \leq 1$: la flèche est dans le cercle. Elle touche le bord ($q_j = 1$) si et seulement si tous les autres carrés sont nuls, c'est-à-dire si la variable est une combinaison des deux premières composantes seulement ; et $1 - q_j$ est exactement la part de la variable qui s'exprime hors du plan.

Sur les huit notes, les qualités q_j vont de 0,701 (propreté) à 0,811 (accueil), toutes inférieures à 1 ; il reste, pour l'accueil, $1 - 0{,}811 = 0{,}189$ sur les six autres axes.

■

Les coordonnées, d'où elles viennent

Corrélation d'une variable avec un axe

La formule

$$r(x_j, C_k) = \sqrt{\lambda_k} \, u_{jk}$$

La corrélation de la variable j avec l'axe k est son **coefficient** dans le vecteur propre, multiplié par la **racine de la valeur propre**.

La démonstration, en deux lignes

$C_k = \sum_l u_{lk} \, z_l$, donc $\operatorname{cov}(z_j, C_k) = \sum_l u_{lk} \, r_{jl} = (R \, u_k)_j = \lambda_k \, u_{jk}$.
Comme $V(z_j) = 1$ et $V(C_k) = \lambda_k$: $r(x_j, C_k) = \lambda_k \, u_{jk} / \sqrt{\lambda_k} = \sqrt{\lambda_k} \, u_{jk}$.

Sur le fil rouge

Les quatre corrélations

Variable	u_1	r avec l'axe 1	u_2	r avec l'axe 2
accueil	0,707	0,975	0,707	0,224
fidélité	0,707	0,975	−0,707	−0,224

$$\sqrt{1{,}9} \times 0{,}707 = 1{,}378 \times 0{,}707 = 0{,}975 \qquad \sqrt{0{,}1} \times 0{,}707 = 0{,}316 \times 0{,}707 = 0{,}224$$

Deux contrôles

Par variable : $0{,}975^2 + 0{,}224^2 = 1$ — tout est dans le plan. Par axe : $0{,}975^2 + 0{,}975^2 = 1{,}9 = \lambda_1$ — **la somme des carrés des corrélations avec un axe est sa valeur propre**.

Démonstration : Les carrés des corrélations avec un axe somment à la valeur propre

Pour un axe k, la corrélation de la variable j est $r(x_j, C_k) = \sqrt{\lambda_k}\, u_{jk}$. En sommant les carrés sur les p variables,

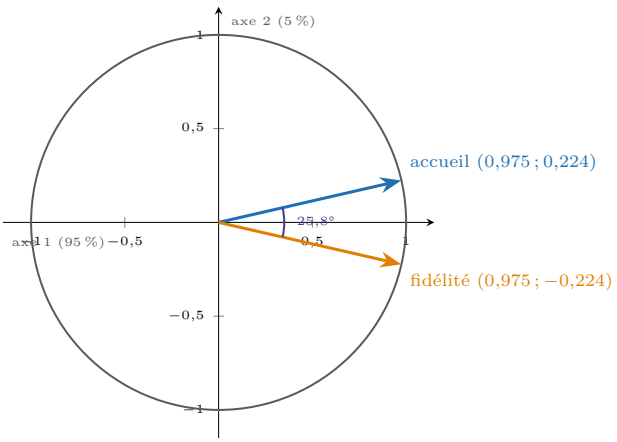
$$\sum_{j=1}^{p} r^2(x_j, C_k) = \lambda_k \sum_{j=1}^{p} u_{jk}^2 = \lambda_k,$$

car le vecteur propre u_k est de longueur 1 (c'est ainsi qu'on le choisit). La contribution $\mathrm{ctr}_{jk} = r^2(x_j, C_k)/\lambda_k = u_{jk}^2$ est donc la part de λ_k apportée par la variable j, et les contributions à un axe somment à 100 % ; leur moyenne est $1/p$.

Sur les huit notes, la somme des huit carrés vaut 4,535 pour l'axe 1 et 1,645 pour l'axe 2. Pour l'axe 1, les contributions vont de 8,7 % (prix) à 15,1 % (agencement, propreté), autour de la moyenne $100/8 = 12{,}5$ % ; pour l'axe 2, elles vont de 1,0 % (propreté) à 23,6 % (prix).

■

Le cercle des cinq clients



Deux flèches sur le bord

Les deux flèches touchent le cercle : elles sont **parfaitement** représentées. L'angle qui les sépare vaut 25,8°, et $\cos 25{,}8° = 0{,}9$: c'est leur corrélation.

Sur le fichier réel

Prix et accueil

$$r(\text{prix}, C_1) = \sqrt{4{,}535} \times 0{,}295 = 2{,}130 \times 0{,}295 = 0{,}629$$

$$r(\text{prix}, C_2) = \sqrt{1{,}645} \times 0{,}486 = 1{,}283 \times 0{,}486 = 0{,}624$$

$$r(\text{accueil}, C_1) = 2{,}130 \times 0{,}323 = 0{,}689 \qquad r(\text{accueil}, C_2) = 1{,}283 \times (-0{,}453) = -0{,}580$$

Le contrôle de la valeur propre

La somme des carrés des huit corrélations avec l'axe 1 vaut $0{,}629^2 + 0{,}771^2 + \cdots + 0{,}689^2 = 4{,}535 = \lambda_1$. C'est le moyen le plus simple de vérifier une sortie de logiciel.

Les trois lectures

La longueur : la qualité de représentation

Le cosinus carré

La **qualité de représentation** d'une variable sur le plan est le carré de la longueur de sa flèche :

$$\cos^2 = r^2(x_j, C_1) + r^2(x_j, C_2)$$

La règle de prudence

Une variable **proche du cercle** est bien représentée dans le plan : sa position est fiable.
Une variable **proche du centre** est mal représentée : elle s'exprime sur des axes non retenus.

Qualités et contributions des huit notes

note	r axe 1	r axe 2	$\cos^2$ plan	ctr 1	ctr 2
prix	0,629	0,624	0,784	8,7 %	23,6 %
choix	0,771	0,438	0,787	13,1 %	11,7 %
qualité	0,803	0,380	0,789	14,2 %	8,8 %
agencement	0,828	0,242	0,744	15,1 %	3,6 %
propreté	0,827	−0,127	0,701	15,1 %	1,0 %
rapidité	0,742	−0,476	0,778	12,2 %	13,8 %
conseil	0,711	−0,531	0,787	11,1 %	17,1 %
accueil	0,689	−0,580	0,811	10,5 %	20,5 %
		total		100 %	100 %

Deux colonnes, deux questions différentes — et on les confond sans cesse.
Le $\cos^2$ répond à : *cette variable est-elle bien représentée sur le plan ?* Il se lit par ligne, et vaut au plus 1.
La **contribution** répond à : *cette variable a-t-elle fabriqué cet axe ?* Elle se lit par colonne, et les colonnes somment à 100 %.
Une variable peut être très bien représentée sans avoir construit l'axe — et une contribution moyenne vaut ici 100/8 = 12,5 % : au-delà, la variable compte.

Ce que ce tableau dit

Huit variables bien représentées

Les huit qualités vont de 0,70 (propreté) à 0,81 (accueil) : **toutes** les notes sont représentées aux trois quarts au moins. On peut commenter chacune d'elles.

La faute la plus courante

Interpréter la direction d'une variable située près du centre. Sa position y est instable et essentiellement arbitraire — le plan ne capte presque rien de cette variable. Il faut soit l'ignorer, soit examiner un autre plan factoriel où elle sortira.
On ne commente que les variables proches du bord. C'est la première discipline à acquérir.

La contribution : qui a construit l'axe

Une autre question

La **contribution** d'une variable à l'axe k est la part de la valeur propre qu'elle apporte :

$$\mathrm{ctr}_{jk} = \frac{r^2(x_j, C_k)}{\lambda_k} = u_{jk}^2$$

Les contributions à un axe somment à 100 % ; leur moyenne est $100/p$ %, soit 12,5 % pour huit notes.

Les deux axes des huit notes

Axe 1 : des contributions entre 8,7 % (prix) et 15,1 % (agencement, propreté) — **toutes** les notes le construisent.
Axe 2 : le prix (23,6 %), l'accueil (20,5 %) et le conseil (17,1 %) le font ; la propreté n'y ap-

porte que 1 %.

L'angle : la corrélation entre variables

La lecture des angles

Pour deux variables **bien représentées** :

Angle entre les deux flèches	Corrélation
Proche de 0°	fortement **positive**
Proche de 90°	**nulle**
Proche de 180°	fortement **négative**

Pourquoi l'angle dit la corrélation

Le cosinus de l'angle entre deux flèches de longueur 1 **est** leur coefficient de corrélation — c'est la lecture géométrique du chapitre 5. Le cercle est une lecture visuelle de la matrice des corrélations, plus rapide qu'un parcours de ses cases.

L'angle sur le plan, et l'angle vrai

Trois paires de notes

Paire	r	angle vrai	angle sur le plan
prix et accueil	0,09	84,9°	84,9°
prix et qualité	0,67	48,3°	19,5°
conseil et accueil	0,73	43,0°	3,4°

Le plan rapproche les variables

Les flèches ne sont représentées qu'aux trois quarts : leurs parts **hors du plan** sont différentes, et la projection les écrase. Le conseil et l'accueil semblent confondus, alors que $r = 0{,}73$. **Le cercle montre les familles de variables ; la matrice donne les valeurs.**

Démonstration : Ce que l'angle sur le plan dit de la corrélation

Reprenons $r_{jl} = \sum_k \lambda_k \, u_{jk} \, u_{lk}$ et partageons la somme en deux : les deux axes du plan, puis les autres. Comme $\lambda_k \, u_{jk} \, u_{lk} = r(x_j, C_k) \, r(x_l, C_k)$,

$$r_{jl} = \underbrace{r(x_j, C_1) \, r(x_l, C_1) + r(x_j, C_2) \, r(x_l, C_2)}_{\text{produit scalaire des deux flèches du plan}} + \underbrace{\sum_{k \geq 3} r(x_j, C_k) \, r(x_l, C_k)}_{\text{reste, hors du plan}} .$$

Le reste est le produit scalaire de deux vecteurs de longueurs au carré $1 - q_j$ et $1 - q_l$ (démonstration précédente) ; d'après l'inégalité de Cauchy-Schwarz, il est borné par $\pm\sqrt{(1-q_j)(1-q_l)}$. **Quand les deux flèches touchent le bord**, $q_j = q_l = 1$: le reste est nul et r_{jl} est le produit scalaire de deux vecteurs de longueur 1, soit $\cos(\alpha - \beta) =$

$\cos\alpha\cos\beta \;+\; \sin\alpha\sin\beta$ pour les angles α et β des flèches : l'angle **est** la corrélation. Sinon, l'erreur possible est de l'ordre de $\sqrt{(1-q_j)(1-q_l)}$, et elle n'est négligeable que pour des variables proches du bord.

Sur les huit notes. Conseil et accueil : produit scalaire sur le plan 0,797, reste −0,066 (borne ±0,201), d'où $r = 0{,}797 - 0{,}066 = 0{,}731$; l'angle sur le plan est 3,4° alors que l'angle vrai, $\arccos 0{,}731$, est 43,0°. Prix et accueil : $0{,}071 + 0{,}017 = 0{,}088$; le reste est faible, et les deux angles coïncident (84,9°).

■

La position : le sens des axes

Nommer un axe

Un axe se nomme en regardant **quelles variables** lui sont fortement corrélées, positivement et négativement.

Les deux axes des huit notes

Axe	Côté positif	Côté négatif	Nom
1	les huit notes (0,63 à 0,83)	—	**niveau général**
2	prix, choix, qualité	accueil, conseil, rapidité	**offre contre service**

Taille et forme

Deux configurations à reconnaître

Un premier axe où toutes les variables sont du même signe est un **effet de taille** : les individus se distinguent surtout par un niveau global.
Un axe qui oppose deux groupes de variables est un **effet de forme** : il distingue des profils, à niveau égal.

Sur nos données

L'axe 1 est un effet de taille : il range les clients du plus sévère au plus satisfait. L'axe 2 est un effet de forme : à satisfaction égale, il sépare ceux qui viennent pour les **produits** de ceux qui viennent pour les **personnes**. C'est lui qui distinguait les clients 36 et 246.

Le fil rouge

Deux variables, un cercle minuscule

Sur nos cinq clients

Avec deux variables corrélées à 0,9, le cercle est simple :

- **accueil** et **fidélité** sont toutes deux corrélées à 0,975 au premier axe, du même côté — l'angle entre elles est de 25,8°, cohérent avec $r = 0{,}9$;
- le second axe, qui ne porte que 5 % d'inertie, les sépare à peine ($\pm 0{,}224$).

Le premier axe se nomme donc sans difficulté : **satisfaction globale**.

La limite du fil rouge, assumée

Avec deux variables, le cercle n'apprend rien qu'on ne sache déjà : il n'y a qu'une corrélation à lire. Son intérêt apparaît à partir de six ou huit variables, quand la matrice des corrélations devient illisible et que la figure, elle, reste lisible.

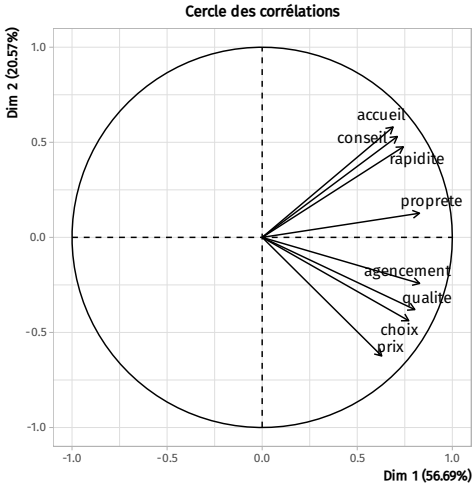
Sur machine

Avec R : les coordonnées des variables

Coordonnées et qualités des variables

```
# acp : comme au chapitre 8
v <- cbind(acp$var$coord[, 1:2],
           cos2 = rowSums(acp$var$cos2[, 1:2]))
round(v, 3)
#            Dim.1  Dim.2  cos2
# prix       0.629 -0.624 0.784
# choix      0.771 -0.438 0.787
# qualite    0.803 -0.380 0.789
# agencement 0.828 -0.242 0.744
# proprete   0.827  0.127 0.701
# rapidite   0.742  0.476 0.778
# conseil    0.711  0.531 0.787
# accueil    0.689  0.580 0.811
```

Avec R : le cercle



Une seule instruction

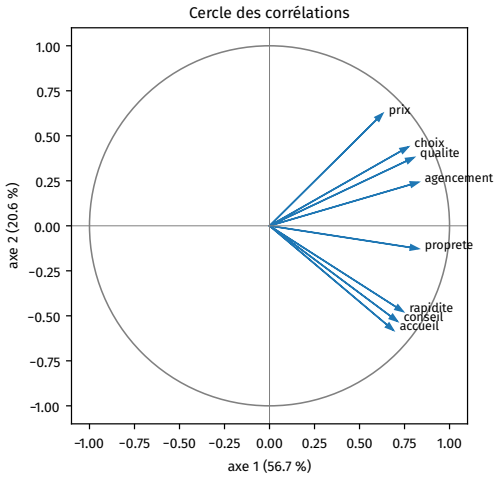
`plot(acp, choix = "var")` trace le cercle. Le second axe y est **retourné** par rapport aux figures du cours : l'offre est en bas, le service en haut. La lecture est la même.

Avec Python : les corrélations

numpy et pandas, avec la convention du cours

```
lam, U = np.linalg.eigh(clients[notes].corr())
lam, U = lam[::-1], U[:, ::-1]
U = U * np.sign(U[0])                    # prix positif sur chaque axe
cor = np.sqrt(lam) * U                   # corrélations variables-axes
tab = pd.DataFrame(cor[:, :2], index=notes, columns=["axe1", "axe2"])
tab["cos2"] = tab.axe1 ** 2 + tab.axe2 ** 2
print(tab.round(3))
#              axe1   axe2   cos2
# prix        0.629  0.624  0.784
# choix       0.771  0.438  0.787
#   ...       (cinq lignes)
# accueil     0.689 -0.580  0.811
print((cor[:, 0] ** 2).sum().round(3))           # 4.535
```

Avec Python : le cercle



Tracé avec matplotlib

Un cercle (`plt.Circle`), une flèche par note (`ax.arrow`) et son nom (`ax.annotate`) : une quinzaine de lignes, dans le fichier `figsrc/gen/fig_py.py` du cours.

S'entraîner

Exercice 1 : du vecteur propre au cercle

Une corrélation de 0,6

Deux notes réduites ont $r = 0{,}6$: $\lambda_1 = 1{,}6$, $\lambda_2 = 0{,}4$, et les vecteurs propres sont les bissectrices (chapitre 8).

1. Calculer les corrélations des deux notes avec les deux axes.
2. Vérifier que chaque flèche touche le cercle.
3. Retrouver λ_1 à partir des corrélations.

Exercice 1 : solution

0,894 et 0,447

1. Axe 1 : $\sqrt{1{,}6} \times 0{,}707 = 0{,}894$ pour les deux. Axe 2 : $\sqrt{0{,}4} \times 0{,}707 = 0{,}447$ pour l'une, $-0{,}447$ pour l'autre.
2. $0{,}894^2 + 0{,}447^2 = 0{,}8 + 0{,}2 = 1$: les deux flèches sont sur le bord.
3. $0{,}894^2 + 0{,}894^2 = 1{,}6 = \lambda_1$. L'angle entre les flèches vaut $2 \times 26{,}6° = 53{,}1°$, et $\cos 53{,}1° = 0{,}6$.

Exercice 2 : lire le cercle réel

Les huit notes

À partir du tableau des corrélations avec les axes :

1. Quelle note est la mieux représentée sur le plan ? la moins bien ?
2. Quelles notes contribuent le plus à l'axe 2 ?
3. Un étudiant écrit : « le conseil et l'accueil sont presque parfaitement corrélés, puisque leurs flèches se superposent. » Corriger.

Exercice 2 : solution

Accueil, propreté, et un angle trompeur

1. La mieux représentée : l'accueil (0,811). La moins bien : la propreté (0,701) — encore aux sept dixièmes.
2. Le prix (23,6 %), l'accueil (20,5 %), le conseil (17,1 %) : les deux extrémités de l'opposition offre-service.
3. Les flèches font 3,4° sur le plan, mais la vraie corrélation vaut 0,73 (angle de 43°). Le plan ne représente chacune qu'à 80 % environ et **rapproche** les flèches. On dit : « ils appartiennent à la même famille de critères ».

Exercice 3 : une variable près du centre

On ajoute une variable

On ajoute au fichier une neuvième variable, l'âge, et l'on refait l'ACP. Ses corrélations avec les deux premiers axes valent 0,05 et −0,12.

1. Calculer sa qualité de représentation sur le plan.
2. Peut-on dire que l'âge est lié à l'offre plutôt qu'au service ?
3. Que faire pour savoir où l'âge s'exprime ?

Exercice 3 : solution

Ne pas commenter

1. $0{,}05^2 + 0{,}12^2 = 0{,}0025 + 0{,}0144 = 0{,}017$: moins de 2 %.
2. **Non** : la flèche est collée au centre, sa direction n'a aucun sens. L'âge n'est presque pas lié aux deux dimensions de la satisfaction.
3. Regarder ses corrélations avec les axes suivants, ou — mieux — l'utiliser comme variable **illustrative** (chapitre 11) : elle n'aurait pas dû participer au calcul d'axes qui décrivent la satisfaction.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Les coordonnées d'une variable sont ses **corrélations avec les axes** : $r(x_j, C_k) = \sqrt{\lambda_k}\, u_{jk}$ — d'où un cercle de rayon 1.
2. La somme des carrés des corrélations avec un axe est sa **valeur propre** (4,535 pour l'axe 1).
3. **Longueur** : la qualité de représentation ($\cos^2$) ; on ne commente **que** les variables proches du bord.
4. **Contribution** : u_{jk}^2, la part de la variable dans la construction de l'axe ; moyenne $1/p$.
5. **Angle** : son cosinus est la corrélation pour des flèches sur le bord ; sur le plan, il rapproche les variables imparfaitement représentées.
6. Un axe où toutes les variables sont du même côté est un **effet de taille** (axe 1) ; un axe qui les oppose, un **effet de forme** (axe 2, offre contre service).

La suite

De l'autre côté du tableau

Les variables sont interprétées. Le chapitre 11 passe de l'autre côté du tableau et place les **individus** sur le même plan.

Ce qu'on y fera

On placera les trois cents clients, on vérifiera qui est bien représenté et qui a construit les axes, et l'on projettera la fréquence de visite pour voir de quel côté se placent les clients hebdomadaires.