

Introduction à l'analyse des données

Chapitre 9 : Combien d'axes retenir

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Faire dialoguer les trois critères

Une ACP sur $p = 6$ variables réduites donne le spectre suivant : $\lambda_1 = 2,8$, $\lambda_2 = 1,3$, $\lambda_3 = 0,9$, $\lambda_4 = 0,6$, $\lambda_5 = 0,3$, $\lambda_6 = 0,1$.

- (a) Vérifier que la somme vaut $p = 6$. Combien d'axes le critère de Kaiser retient-il ?
- (b) Calculer, pour chaque paire d'axes consécutifs, la chute de valeur propre ($\lambda_k - \lambda_{k+1}$). Où se situe le « coude » le plus net – après quel axe ?
- (c) Le critère du coude et le critère de Kaiser donnent-ils le même nombre d'axes ici ? Si non, quel critère supplémentaire, non numérique, permettrait de trancher ?

Exercice 2 — Un pourcentage ne se lit jamais dans l'absolu

Deux études indépendantes atteignent chacune 80 % d'inertie cumulée avec leurs deux premiers axes : l'étude A portait sur $p = 3$ variables, l'étude B sur $p = 25$ variables.

- (a) Pour l'étude A, combien de variables restent « hors » des deux axes retenus ? Même question pour l'étude B.
- (b) Laquelle des deux réductions ($3 \rightarrow 2$ ou $25 \rightarrow 2$) est la plus « remarquable » au sens du cours ? Justifier.
- (c) Un collègue affirme : « 80 %, c'est 80 %, peu importe le nombre de variables de départ ». Expliquer en une phrase pourquoi cette affirmation est trompeuse.

Exercice 3 — Lire un plan factoriel avec prudence

Un premier plan factoriel (axes 1 et 2) porte 55 % de l'inertie totale d'un nuage à $p = 8$ variables.

- (a) Quelle proportion de l'inertie totale n'est *pas* représentée sur ce plan ?
- (b) Deux individus apparaissent très proches sur ce plan. D'après la règle de lecture du cours, peut-on conclure avec certitude qu'ils se ressemblent globalement, sur les $p = 8$ variables ? Justifier.
- (c) Formuler, en une phrase, la précaution que tout commentaire de ce plan devrait systématiquement rappeler.

2 Exercices cumulatifs (introduction au chapitre 9)

Exercice 4 — Le fil rouge : une question presque sans objet

On reprend le fil rouge : $p = 2$ variables réduites, $\lambda_1 = 1,9$ et $\lambda_2 = 0,1$ (chapitre 8).

- (a) Combien d'axes le critère de Kaiser retient-il ici ?
- (b) Calculer le pourcentage d'inertie cumulée obtenu avec un seul axe. Ce pourcentage dépasse-t-il les seuils habituels (70 ou 80 %) mentionnés dans le cours ?
- (c) Le cours affirme que « le problème de représentation » (chapitre 1) ne commence vraiment qu'à partir de $p = 3$ variables. En quoi la question « combien d'axes retenir », posée sur le fil rouge à $p = 2$ variables, est-elle différente de la même question posée sur un tableau à $p = 12$ variables – que gagnerait-on réellement, ici, à retenir un seul axe plutôt que les deux ?

3 Applications en sciences économiques

Exercice 5 — Réduire dix indicateurs macroéconomiques

Un institut de conjoncture réalise une ACP sur $p = 10$ indicateurs macroéconomiques réduits (croissance, inflation, chômage, taux d'intérêt, etc.) et obtient le spectre : $\lambda_1 = 4,5$, $\lambda_2 = 2,1$, $\lambda_3 = 1,2$, $\lambda_4 = 0,8$, $\lambda_5 = 0,5$, $\lambda_6 = 0,3$, $\lambda_7 = 0,2$, $\lambda_8 = 0,15$, $\lambda_9 = 0,15$, $\lambda_{10} = 0,1$.

- (a) Combien d'axes le critère de Kaiser retient-il ?
- (b) Calculer le pourcentage d'inertie cumulée obtenu avec ces axes.
- (c) Ce résultat ($p = 10$ réduit à 3 axes, 78 % d'inertie conservée) constitue-t-il, au sens du cours, une réduction « remarquable » ou « triviale » ? Justifier en la comparant aux deux cas extrêmes évoqués dans l'exercice 2.

Exercice 6 — Prudence dans la lecture d'une carte perceptuelle

Un cabinet marketing réalise une ACP sur $p = 6$ critères de perception de marque et obtient : $\lambda_1 = 2,0$, $\lambda_2 = 1,3$, $\lambda_3 = 0,9$, $\lambda_4 = 0,7$, $\lambda_5 = 0,6$, $\lambda_6 = 0,5$. Le rapport présenté au client ne montre que le premier plan factoriel (axes 1 et 2), sur lequel deux marques concurrentes apparaissent très proches l'une de l'autre.


- (a) Combien d'axes le critère de Kaiser retient-il, et quel pourcentage d'inertie porte le premier plan (axes 1 et 2) ?
- (b) Le client conclut, à la vue du graphique, que les deux marques sont « perçues de façon quasiment identique par les consommateurs ». Cette conclusion est-elle justifiée par le seul plan présenté ? Pourquoi ?
- (c) Reformuler la conclusion du client de façon plus rigoureuse, en tenant compte du pourcentage d'inertie réellement représenté sur ce plan.

1 Exercices du chapitre

Correction — Exercice 1

(a) $2,8 + 1,3 + 0,9 + 0,6 + 0,3 + 0,1 = 6,0 = p$. Kaiser retient les axes tels que $\lambda_k > 1$: seuls $\lambda_1 = 2,8$ et $\lambda_2 = 1,3$ dépassent ce seuil – Kaiser retient donc **deux** axes.

(b) Chutes : $\lambda_1 - \lambda_2 = 1,5$; $\lambda_2 - \lambda_3 = 0,4$; $\lambda_3 - \lambda_4 = 0,3$; $\lambda_4 - \lambda_5 = 0,3$; $\lambda_5 - \lambda_6 = 0,2$. La chute la plus nette (1,5) se situe juste après l'axe 1 ; les chutes suivantes sont nettement plus régulières et modérées (0,2 à 0,4). Le coude se situe donc après le premier axe.



(c) Non : Kaiser retient **deux** axes, le coude n'en suggère qu'**un** seul. Ils divergent. Le critère supplémentaire, non numérique, est celui de l'**interprétabilité** de l'axe : si le second axe ($\lambda_2 = 1,3$) oppose clairement des groupes de variables identifiables, on peut le conserver malgré le coude ; s'il ne se laisse pas interpréter, on suit plutôt l'indication du coude et on n'en retient qu'un.

Correction — Exercice 2

(a) Étude A ($p = 3$) : $3 - 2 = 1$ variable reste hors des deux axes retenus. Étude B ($p = 25$) : $25 - 2 = 23$ variables restent hors des deux axes retenus.

(b) La réduction de l'étude B ($25 \rightarrow 2$) est la plus remarquable : atteindre 80 % d'inertie en ne retenant que 2 axes sur 25 variables de départ signale une structure de corrélation très forte entre les variables. Pour l'étude A, avec seulement 3 variables de départ, atteindre 80 % avec 2 axes sur 3 est presque automatique et ne prouve pas grand-chose.

(c) Un même pourcentage de 80 % ne représente pas la même performance de résumé selon le nombre de variables initial : passer de 3 à 2 (une réduction d'une seule dimension) n'a pas la même portée que passer de 25 à 2 (une réduction de 23 dimensions) – le pourcentage doit toujours être rapporté au p de départ pour être interprété correctement.

Correction — Exercice 3

(a) $100\% - 55\% = 45\%$ de l'inertie totale n'est pas représentée sur ce plan.

(b) Non : la règle de lecture du cours précise que « deux individus qui y paraissent proches peuvent être éloignés dans les dimensions non représentées ». Avec 45 % de l'inertie absente du plan, une proximité apparente ne garantit en rien une ressemblance globale sur les $p = 8$ variables.

(c) Tout commentaire de ce plan devrait rappeler son pourcentage d'inertie (55 % ici), afin que le lecteur sache d'emblée qu'une part substantielle (45 %) de l'information du tableau n'y figure pas.

2 Exercices cumulatifs (introduction au chapitre 9)

Correction — Exercice 4

- (a) Seul $\lambda_1 = 1,9$ dépasse 1 ($\lambda_2 = 0,1 < 1$) : Kaiser retient **un seul** axe.
- (b) $\frac{1,9}{2} = 95\%$. Ce pourcentage dépasse largement les seuils habituels de 70 ou 80 %.
- (c) Sur un tableau à $p = 12$ variables, retenir un seul axe résoudrait un véritable problème pratique : on passerait d'un espace à 12 dimensions, impossible à représenter directement, à une seule droite lisible sur une feuille. Ici, avec $p = 2$, le nuage tenait *déjà* tout entier sur un plan à deux dimensions – le « problème de représentation » évoqué depuis le chapitre 1 ne se posait pas. Retenir un seul axe sur le fil rouge ne fait donc gagner **aucune** lisibilité supplémentaire par rapport au plan de départ : cela ne fait que remplacer un graphique en deux dimensions, déjà parfaitement visible, par une droite – un exercice utile pour vérifier les formules, mais sans l'enjeu pratique qu'il aurait sur un tableau à $p \geq 3$ variables.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $\lambda_1 = 4,5$, $\lambda_2 = 2,1$ et $\lambda_3 = 1,2$ dépassent 1 ; les sept valeurs suivantes (0,8 à 0,1) sont toutes inférieures à 1. Kaiser retient donc **trois** axes.
- (b) $\frac{4,5 + 2,1 + 1,2}{10} = \frac{7,8}{10} = 78\%$.
- (c) C'est une réduction **remarquable** : passer de 10 variables macroéconomiques à 3 axes tout en conservant 78 % de l'inertie – proche des 80 % atteints par l'étude B de l'exercice 2 sur 25 variables, mais ici avec seulement 10 variables de départ, ce qui reste une réduction bien plus significative que celle de l'étude A à $p = 3$ (où 80 % avec 2 axes sur 3 ne prouvait presque rien).

Correction — Exercice 6

- (a) Seul $\lambda_1 = 2,0$ dépasse 1 ($\lambda_2 = 1,3$ également, puisque $1,3 > 1$) – Kaiser retient donc **deux** axes. Le premier plan porte $\frac{2,0 + 1,3}{6} = \frac{3,3}{6} = 55\%$ de l'inertie totale.
- (b) Non, cette conclusion n'est pas justifiée : avec seulement 55 % de l'inertie représentée sur ce plan, 45 % de l'information – portée par les quatre axes non représentés – reste invisible. Deux marques proches sur ce plan peuvent très bien se distinguer nettement sur ces dimensions non affichées.
- (c) Une reformulation plus rigoureuse serait : « sur les deux dimensions qui résument 55 % de la variabilité des perceptions de marque, ces deux marques apparaissent proches ; cette proximité ne permet cependant pas d'exclure des différences significatives sur les 45 % d'inertie restants, portés par des axes non représentés ici. »