Introduction à l'analyse des données

Chapitre 9 : Combien d'axes retenir

Jaouad Madkour

22 octobre 2026

Plan du chapitre

La question **2**
Un arbitrage, non un calcul . . . 2
Ce qu'on va trancher sur nos données . . . 2

Les trois critères **2**
Le critère de Kaiser . . . 2
Kaiser, sur nos deux tableaux . . . 3
Le critère du coude . . . 3
L'éboulis des huit notes . . . 4
Lire le coude, chiffres en main . . . 4
Le critère du pourcentage cumulé . . . 4
Le cumul, sur nos huit notes . . . 5

Faire converger les critères **5**
Les trois critères, sur le fichier réel . . . 5
Une contre-épreuve : comparer à du bruit . . . 5
Quand les critères divergent . . . 6

Le plan factoriel **6**
Deux axes, une feuille . . . 6
La règle de lecture la plus importante . . . 6
Ce que le chapitre 11 apportera . . . 7

Sur machine **7**
Avec R . . . 7
L'éboulis tracé par R . . . 8
Avec Python . . . 8
L'éboulis tracé par matplotlib . . . 9

S'entraîner **9**
Exercice 1 : six variables, des critères en désaccord . . . 9
Exercice 1 : solution . . . 9
Exercice 2 : un pourcentage à juger . . . 10
Exercice 2 : solution . . . 10

Exercice 3 : le plan ne dit pas tout 10
Exercice 3 : solution 10

Ce qu'il faut retenir **10**
Le résumé du chapitre 10
La suite 11

La question

Un arbitrage, non un calcul

Les deux extrêmes sont mauvais

Retenir **tous** les axes ne perd aucune information — et ne réduit rien. On revient au tableau de départ, avec son problème de dimension intact.
Retenir **un seul** axe donne la représentation la plus simple, au prix d'une perte qui peut être considérable.

La démarche

Il n'existe pas de réponse unique, et aucun critère ne tranche à lui seul. On en utilise donc trois, et l'on regarde s'ils concordent ; en cas de désaccord, un quatrième décide : l'axe est-il **interprétable** ?

Ce qu'on va trancher sur nos données

Les huit valeurs propres du chapitre 8

Axe	1	2	3	4	5	6	7	8
λ_k	4,535	1,645	0,382	0,349	0,327	0,283	0,249	0,229
cumul	56,7	77,3	82,0	86,4	90,5	94,0	97,1	100

La question, posée concrètement

Faut-il commenter un plan (deux axes), un seul axe, ou ajouter un troisième ? La réponse décide de **combien de figures** on montrera à la direction, et de ce qu'on aura le droit d'y lire.

Les trois critères

Le critère de Kaiser

La règle

Sur données réduites, retenir les axes dont la valeur propre dépasse 1 :

$$\lambda_k > 1$$

Sa justification

Chaque variable réduite porte exactement une unité d'inertie. Un axe qui en porte moins **résume moins bien qu'une variable seule** — il ne mérite donc pas d'être conservé.
Le seuil n'est pas arbitraire : il découle directement du fait que $I = p$, établi au chapitre 6.

Kaiser, sur nos deux tableaux

Cinq clients, trois cents clients

Tableau	Valeurs propres	Axes retenus
cinq clients	**1,9** ; 0,1	1
huit notes	**4,54** ; **1,65** ; 0,38 ; …	2

Ses limites

La règle est mécanique et souvent trop généreuse quand les variables sont nombreuses. Un axe à 1,02 et un axe à 0,98 ne diffèrent en rien de substantiel, et pourtant la règle les sépare. **C'est un point de départ, pas une décision.** Sur nos huit notes, elle ne pose aucun problème : la troisième valeur propre est très loin du seuil.

Le critère du coude

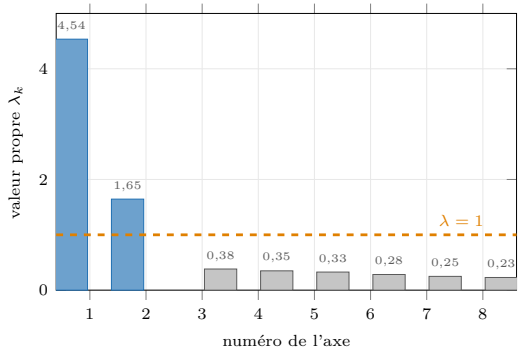
L'éboulis des valeurs propres

On trace les valeurs propres par ordre décroissant, et l'on cherche le **décrochement** — le point où la courbe cesse de chuter et s'aplatit.
On retient les axes situés **avant** ce coude.

Ce que le coude traduit

Avant le coude, chaque axe apporte nettement moins que le précédent : les dimensions sont hiérarchisées, structurées.
Après, les valeurs propres décroissent lentement et régulièrement — c'est la signature du **bruit**, qui se répartit à peu près également sur toutes les directions restantes. Le coude sépare donc ce qui est structure de ce qui ne l'est pas.

L'éboulis des huit notes



Les trois critères disent la même chose.

Le coude : la falaise entre l'axe 2 et l'axe 3 — de 1,65 à 0,38. On coupe au pied de la falaise.

Kaiser : garder les axes de valeur propre > 1, c'est-à-dire ceux qui résument mieux qu'une variable seule. Ici : deux.

Le cumul : $56{,}7 + 20{,}6 = 77{,}3\,\%$ de l'information conservée sur un simple plan.

Quand les trois concordent, la décision est facile. Quand ils divergent, c'est l'interprétabilité qui tranche.

Lire le coude, chiffres en main

Les chutes successives

Axes	$1 \to 2$	$2 \to 3$	$3 \to 4$	$4 \to 5$	$5 \to 6$	$6 \to 7$	$7 \to 8$
chute	2,890	1,263	0,033	0,022	0,044	0,034	0,020

La courbe tombe de 1,263 entre les axes 2 et 3, puis ne descend plus que de quelques centièmes. **Le coude est au troisième axe : on garde les deux premiers.**

Sa limite

Le coude est parfois net, souvent ambigu, et parfois absent. Deux lecteurs peuvent le placer différemment. C'est un critère **visuel**, à assumer comme tel — ici, il est d'une netteté rare.

Le critère du pourcentage cumulé

La règle

Retenir assez d'axes pour atteindre un seuil d'inertie cumulée — souvent 70 ou 80 %.

Le seuil dépend du nombre de variables

Avec **trois** variables, atteindre 80 % est facile et ne prouve rien.
Avec **trente**, y parvenir sur trois axes est une réduction remarquable — de trente dimensions à trois, en ne perdant qu'un cinquième.
Un pourcentage ne se juge donc jamais dans l'absolu, mais rapporté au p de départ.

Le cumul, sur nos huit notes

Deux axes suffisent pour 70 pour cent

Le premier axe seul porte 56,7 % ; les deux premiers **77,3** %. Le seuil de 70 % est franchi au deuxième axe. Celui de 80 % demanderait un troisième axe, qui n'ajouterait que 4,8 %.

Rapporté à p = 8

Si les huit notes étaient indépendantes, deux axes porteraient environ $2/8 = 25$ % de l'inertie. Ils en portent 77,3 %, **trois fois plus** : la réduction est forte.

Faire converger les critères

Les trois critères, sur le fichier réel

Un accord complet

Critère	Ce qu'il dit	Axes
Kaiser	$1{,}645 > 1 > 0{,}382$	2
Coude	chute brutale de 1,645 à 0,382	2
Cumul	77,3 % au deuxième axe	2

Et le quatrième critère

Les deux axes ont un **sens** : le niveau général de satisfaction, puis l'offre contre le service (chapitre 7). Le troisième, à 4,8 %, ne se distingue en rien des cinq suivants. **On retient deux axes, et l'on commente un plan.**

Une contre-épreuve : comparer à du bruit

L'idée

On simule un tableau de **même taille** — 300 lignes, 8 colonnes — fait de variables **indépendantes**, et l'on calcule ses valeurs propres. Un axe réel ne mérite d'être gardé que s'il fait **mieux que le hasard** au même rang.

Les huit notes contre huit variables simulées

Axe	1	2	3	4
huit notes	4,535	1,645	0,382	0,349
hasard	1,256	1,182	1,095	1,019

Les deux premiers axes font **bien mieux** que le hasard ; le troisième fait moins bien. **Deux axes**, encore.

Quand les critères divergent

Le cas fréquent

L'accord parfait de nos données est une chance. Le plus souvent, Kaiser propose trois axes, le coude deux, le cumul quatre.
Il faut alors ajouter un critère qui n'est pas numérique : **l'axe est-il interprétable ?** Un axe à 1,05 sur lequel aucune variable ne se distingue n'apporte rien. Un axe à 0,95 qui oppose clairement deux familles de critères mérite d'être gardé.

Un jugement, qui doit être motivé

C'est un jugement, et il doit être motivé — pas dissimulé derrière un seuil. Dans un rapport, on écrit les trois critères, leur verdict, et la raison du choix final.

Le plan factoriel

Deux axes, une feuille

Le plan principal

En pratique, on représente presque toujours le **plan** formé des deux premiers axes. Son inertie est $(\lambda_1 + \lambda_2)/p$.

Les plans possibles, sur nos huit notes

Plan	Inertie	Part
axes 1 et 2	$4{,}535 + 1{,}645 = 6{,}180$	**77,3 %**
axes 1 et 3	$4{,}535 + 0{,}382 = 4{,}917$	61,5 %
axes 2 et 3	$1{,}645 + 0{,}382 = 2{,}027$	25,3 %

Si un troisième axe était retenu, on tracerait un second plan — axes 1 et 3 — plutôt que d'imaginer une figure en trois dimensions.

La règle de lecture la plus importante

Toujours afficher le pourcentage

Toute lecture d'un plan factoriel doit être accompagnée de son pourcentage d'inertie.
Un plan à 77 % se commente avec confiance, mais près d'un quart de l'information n'y figure pas. Deux individus qui y paraissent proches peuvent être éloignés dans les dimensions non représentées.

Les clients 28 et 79

Sur le plan, ils sont à 0,24 l'un de l'autre — presque confondus. Dans l'espace des huit notes, ils sont à **4,00**, plus que la distance moyenne entre deux clients (3,76). Le client 28 note l'accueil 18,5 et la propreté 11,3, le client 79 l'inverse : 12,7 et 17,0. **Leur différence vit**

sur le troisième axe, que le plan ne montre pas.

Ce que le chapitre 11 apportera

Un outil pour chaque individu

Le pourcentage du plan est une moyenne : il dit combien de l'information **totale** est représentée, pas si **chaque** individu l'est bien.
Les clients 28 et 79 sont représentés à 8 % et 11 % seulement. Le chapitre 11 donnera cet outil — la **qualité de représentation** — et la règle qui va avec : ne jamais commenter un individu mal représenté.

Le chapitre 10, d'abord

Avant les individus, les variables : le chapitre 10 trace le plan des deux axes retenus **vu du côté des huit notes**.

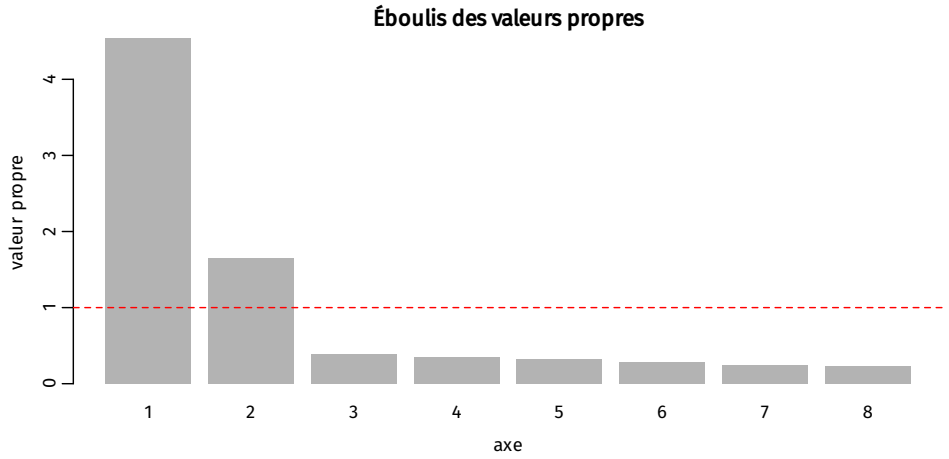
Sur machine

Avec R

Les trois critères, et l'éboulis

```
library(FactoMineR)
# clients et notes : comme au chapitre 6
acp <- PCA(clients[, notes], graph = FALSE)
lam <- acp$eig[, 1]
sum(lam > 1)                          # [1] 2        Kaiser
which(acp$eig[, 3] >= 70)[1]          # comp 2 : 2   cumul
round(-diff(lam), 3)                  # les chutes  : coude
# comp 2 comp 3 comp 4 comp 5 comp 6 comp 7 comp 8
#  2.890  1.263  0.033  0.022  0.044  0.034  0.020
barplot(lam, names.arg = 1:8, col = "grey70", border = NA,
        main = "Éboulis des valeurs propres",
        xlab = "axe", ylab = "valeur propre")
abline(h = 1, lty = 2, col = "red")
```

L'éboulis tracé par R



La même figure, sans mise en forme

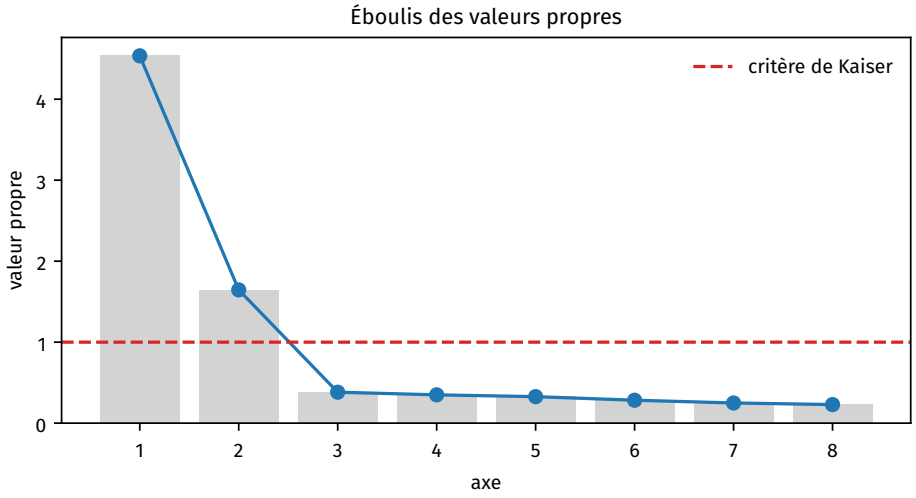
C'est la sortie brute de `barplot` : la ligne rouge est le seuil de Kaiser. Le paquet `factoextra` en donne une version plus soignée avec `fviz_eig(acp)`.

Avec Python

Les critères, puis la figure avec matplotlib

```
import numpy as np
import matplotlib.pyplot as plt
# clients et notes : comme au chapitre 6
lam = np.linalg.eigvalsh(clients[notes].corr())[::-1]
print((lam > 1).sum())                          # 2
cumul = 100 * lam.cumsum() / len(lam)
print(cumul.round(1))
# [ 56.7  77.3  82.   86.4  90.5  94.   97.1 100. ]
print(np.argmax(cumul >= 70) + 1)               # 2
fig, ax = plt.subplots(figsize=(7, 3.2))
ax.bar(range(1, 9), lam, color="lightgrey")
ax.plot(range(1, 9), lam, "o-", color="C0")
ax.axhline(1, color="C3", ls="--", label="critère de Kaiser")
```

L'éboulis tracé par matplotlib



Le coude saute aux yeux

La courbe tombe de 1,65 à 0,38 entre les axes 2 et 3, puis devient presque plate. Les trois critères, calculés en trois lignes, disent tous **deux**.

S'entraîner

Exercice 1 : six variables, des critères en désaccord

Appliquer les trois critères

Une ACP normée sur six variables donne les valeurs propres 2,4 ; 1,3 ; 0,9 ; 0,6 ; 0,5 ; 0,3.

1. Vérifier la somme, puis calculer les parts et les parts cumulées.
2. Que disent Kaiser, le coude et le cumul à 70 % ?
3. Comment trancher ?

Exercice 1 : solution

Deux ou trois axes

1. Somme : $6 = p$. Parts : 40 ; 21,7 ; 15 ; 10 ; 8,3 ; 5 %. Cumul : 40 ; 61,7 ; 76,7 ; 86,7 ; 95 ; 100 %.
2. **Kaiser** : deux axes (2,4 et 1,3). **Coude** : les chutes valent 1,1 ; 0,4 ; 0,3 ; 0,1 ; 0,2 — pas de décrochement net après le deuxième axe. **Cumul** : il faut trois axes pour dépasser 70 %.
3. Par l'**interprétation** : si le troisième axe oppose clairement deux groupes de variables, on le garde (axe 0,9, plan 1-3 en complément) ; s'il ne dit rien de lisible, on s'en tient au plan 1-2 à 61,7 %, en le signalant.

Exercice 2 : un pourcentage à juger

Deux études, le même 70 pour cent

Deux études obtiennent 70 % d'inertie sur leurs deux premiers axes. La première porte sur $p = 3$ variables, la seconde sur $p = 25$.

1. Quelle part porteraient deux axes si les variables étaient indépendantes ?
2. Laquelle des deux études a obtenu la réduction la plus remarquable ?

Exercice 2 : solution

Rapporter le pourcentage à p

1. Chaque axe porterait environ $1/p$ de l'inertie : $2/3 = 66{,}7\,\%$ pour la première étude, $2/25 = 8\,\%$ pour la seconde.
2. **La seconde** : 70 % au lieu de 8 % attendus, près de neuf fois plus. Pour la première, 70 % au lieu de 66,7 % : presque rien de plus que le hasard. Le même pourcentage peut signaler une structure forte ou aucune structure.

Exercice 3 : le plan ne dit pas tout

Deux clients proches sur la figure

Sur le plan 1-2 des huit notes (77,3 %), deux clients sont presque superposés.

1. Peut-on affirmer qu'ils ont des notes semblables ?
2. Quelle information supplémentaire faudrait-il consulter ?
3. Les clients 28 et 79 ont des coordonnées $-1{,}84$ et 1,34 sur le troisième axe. Que conclure ?

Exercice 3 : solution

Proches en projection, loin en réalité

1. **Non** : la projection peut superposer deux points éloignés, comme deux étoiles alignées vues de la Terre.
2. Leur **qualité de représentation** sur le plan (chapitre 11) : si elle est faible, leur position ne veut rien dire.
3. Ils sont séparés de 3,2 unités sur l'axe 3 : leur différence (accueil contre propreté) vit **hors du plan**. Les représentations sur le plan, 8 % et 11 %, interdisaient de les commenter.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Le nombre d'axes est un **arbitrage** entre simplicité et fidélité.
2. **Kaiser** : garder les axes tels que $\lambda > 1$, puisque chaque variable pèse 1 — sur nos notes, deux axes.
3. Le **coude** de l'éboulis sépare la structure du bruit : chute de 1,26 entre les axes 2 et 3,

puis quelques centièmes.

4. Le **cumul** se juge relativement au nombre de variables : 77,3 % sur deux axes, pour 25 % attendus par hasard.
5. Un quatrième critère décide en cas de désaccord : **l'axe est-il interprétable ?**
6. Toute lecture d'un plan s'accompagne de son **pourcentage** — et deux points proches sur le plan peuvent être loin en réalité.

La suite

Interpréter les axes

Les axes sont choisis. Il faut maintenant les **interpréter** — et cela commence par le côté des variables, avec le cercle des corrélations.

Ce qu'on y fera

On placera les huit notes dans le plan des deux axes, d'après leurs corrélations avec chacun : 0,63 et 0,62 pour le prix, 0,69 et −0,58 pour l'accueil.