

Chapitre 4

La corrélation linéaire

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{10 + 15 + 12 + 18 + 20}{5} = 15$. $\bar{y} = \frac{65 + 72 + 68 + 80 + 85}{5} = 74$. Écarts $x_i - \bar{x}$: $-5, 0, -3, 3, 5$; écarts $y_i - \bar{y}$: $-9, -2, -6, 6, 11$. Produits : $45, 0, 18, 18, 55$. $\text{cov}(x, y) = \frac{45 + 0 + 18 + 18 + 55}{5} = \frac{136}{5} = 27,2$.

(b) $s_x = \sqrt{13,6} \approx 3,688$. $s_y = \sqrt{55,6} \approx 7,457$. $r_{xy} = \frac{27,2}{3,688 \times 7,457} \approx \frac{27,2}{27,50} \approx 0,989$.

(c) $r \approx 0,989$ est très proche de $+1$: une liaison linéaire **quasiment parfaite**. Phrase de gestion : « Sur cet échantillon, la performance des employés augmente de façon presque parfaitement linéaire avec le nombre d'heures de formation suivies. »



Correction — Exercice 2

(a) $\bar{p}_1 = \frac{8 + 12 + 9 + 15 + 14}{5} = 11,6$. $\bar{p}_2 = \frac{20 + 28 + 22 + 35 + 33}{5} = 27,6$. $\bar{p}_3 = \frac{45 + 38 + 50 + 25 + 30}{5} = 37,6$. $V(p_1) = 7,44$, $s_{p_1} \approx 2,728$. $V(p_2) = 34,64$, $s_{p_2} \approx 5,886$. $V(p_3) = 85,04$, $s_{p_3} \approx 9,222$.

(b) $\text{cov}(p_1, p_2) = 16,04$, donc $r_{p_1 p_2} = \frac{16,04}{2,728 \times 5,886} \approx 0,999$. $\text{cov}(p_1, p_3) = -23,96$, donc $r_{p_1 p_3} = \frac{-23,96}{2,728 \times 9,222} \approx -0,953$. $\text{cov}(p_2, p_3) = -51,96$, donc $r_{p_2 p_3} = \frac{-51,96}{5,886 \times 9,222} \approx -0,957$.

(c)

$$R \approx \begin{pmatrix} 1 & 0,999 & -0,953 \\ 0,999 & 1 & -0,957 \\ -0,953 & -0,957 & 1 \end{pmatrix}$$

La diagonale ne contient bien que des 1. Lecture économique : prix et marge sont **quasiment redondants** ($r \approx 0,999$, presque une seule information dédoublée); la part de marché, elle, varie en **sens opposé** du prix et de la marge ($r \approx -0,95$ dans les deux cas) – ce qui est cohérent avec l'idée qu'un produit plus cher et plus marginé perd, ici, en parts de marché.


Correction — Exercice 3

(a) $\bar{x} = 0$, $\bar{y} = \frac{4 + 1 + 0 + 1 + 4}{5} = 2$. Écarts $x_i - \bar{x}$: $-2, -1, 0, 1, 2$; écarts $y_i - \bar{y}$: $2, -1, -2, -1, 2$. Produits : $-4, 1, 0, -1, 4$. Somme = 0, donc $\text{cov}(x, y) = 0$ et $r_{xy} = 0$. **Non**, ce résultat ne signifie *pas* l'absence de liaison : x et y sont liées par une relation **parfaitement déterministe** ($y = x^2$), simplement **non linéaire**.

– exactement le premier piège du cours : $r = 0$ signifie « pas de liaison linéaire », jamais « pas de liaison » tout court.

(b) Cette phrase illustre le **troisième piège** (la causalité). Les deux autres explications, aussi valables a priori que « la publicité fait vendre », sont : (i) la causalité inverse – une entreprise qui vend déjà bien peut se permettre d’investir davantage en publicité (les ventes causeraient alors le budget publicitaire, et non l’inverse) ; (ii) une troisième variable – la conjoncture économique générale, ou la notoriété globale de l’entreprise, pourrait faire monter à la fois le budget publicitaire et les ventes sans lien de cause direct entre eux.

(c) Le premier piège montre qu’un r proche de 0 peut masquer une liaison non linéaire réelle et forte ; le deuxième montre qu’un r élevé (ou faible) peut être entièrement **produit** par un seul point aberrant, sans refléter la tendance générale du nuage. Dans les deux cas, le nombre r , à lui seul, peut donc **mentir** sur la nature véritable de la relation ; seul le nuage de points permet de voir directement la forme réelle de la liaison et de repérer les points qui pèsent anormalement sur le calcul.



2 Exercices cumulatifs (introduction au chapitre 4)

Correction — Exercice 4

(a) $s_x s_y = \sqrt{8} \times \sqrt{32} = \sqrt{256} = 16$. $r_{xy} = \frac{14,4}{16} = 0,9$, exactement.

(b) $\text{cov}(z_x, z_y) = \frac{1}{5} [(-1,414)(-1,414) + (-0,707)(0) + (0)(-0,707) + (0,707)(0,707) + (1,414)(1,414)] = \frac{1}{5} [2 + 0 + 0 + 0,5 + 2] = \frac{4,5}{5} = 0,9$. On retrouve bien la même valeur qu’en (a).

(c)

$$\Sigma = \begin{pmatrix} 8 & 14,4 \\ 14,4 & 32 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0,9 \\ 0,9 & 1 \end{pmatrix}$$

La diagonale de Σ contient les **variances brutes** $V(x) = 8$ et $V(y) = 32$, qui dépendent des unités d’origine de l’accueil et de la fidélité. La diagonale de R contient, elle, les variances des variables **centrées réduites**, $V(z_x) = V(z_y) = 1$ (chapitre 2) – ce qui n’est jamais qu’une réécriture de l’identité $\text{cov}(z, z) = V(z) = 1$ démontrée en (b) : la matrice R est simplement la matrice Σ calculée sur les variables réduites plutôt que sur les variables brutes.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\bar{x} = \frac{3 + 5 + 4 + 7 + 6 + 8}{6} = 5,5$. $\bar{y} = \frac{42 + 58 + 48 + 72 + 65 + 78}{6} \approx 60,5$. $\text{cov}(x, y) \approx 21,58$. $s_x \approx 1,708$, $s_y \approx 12,672$. $r_{xy} \approx \frac{21,58}{1,708 \times 12,672} \approx 0,997$.

(b) **Oui** : $r \approx 0,997$ est une corrélation extrêmement forte, très proche de +1.

(c) « Cette corrélation, aussi forte soit-elle, établit une **association** entre exposition publicitaire et notoriété, mais ne prouve pas à elle seule un lien de **causalité** : une troisième variable (par exemple, un budget marketing global plus large qui finance à la fois davantage d'expositions publicitaires et d'autres actions de communication) pourrait expliquer conjointement les deux évolutions. »

Correction — Exercice 6

(a) $\bar{x} = 5,5$, $\bar{y} = 19,7$. $\text{cov}(x, y) = -1$. $s_x = 1$, $s_y \approx 1,077$. $r_{xy} \approx \frac{-1}{1,077} \approx -0,928$. **Oui**, le signe négatif est cohérent avec l'idée d'une légère baisse de satisfaction avec l'ancienneté.

(b) Avec le sixième client (30, 50) : $\bar{x} \approx 9,58$, $\bar{y} = 24,75$, $\text{cov}(x, y) \approx 102,27$, $s_x \approx 9,176$, $s_y \approx 11,335$,
 $r_{xy} \approx \frac{102,27}{9,176 \times 11,335} \approx 0,983$.

(c) Le signe de la corrélation s'est **inversé** : de $-0,928$ (liaison négative forte) à $+0,983$ (liaison positive tout aussi forte), sous l'effet d'un **unique** point très éloigné du reste du nuage. C'est une illustration frappante du deuxième piège du cours : un seul point aberrant peut non seulement affaiblir ou renforcer une corrélation, mais littéralement en **inverser le signe**. Avant de publier un coefficient de corrélation, il faut donc systématiquement visualiser le nuage de points, identifier les points isolés du reste de la distribution, et vérifier – en recalculant r avec et sans ces points – si la conclusion tient encore une fois ces valeurs atypiques mises à l'écart (ou traitées séparément).

