

Introduction à l'analyse des données

Chapitre 4 : La corrélation linéaire

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une corrélation, du début à la fin

Un service formation mesure, pour 5 employés, le nombre d'heures de formation suivies (x) et un score de performance (y , sur 100) :

Employé	1	2	3	4	5
x (heures)	10	15	12	18	20
y (score)	65	72	68	80	85

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x) = 13,6$, $V(y) = 55,6$ (déjà donnés pour vous concentrer sur la suite), puis $\text{cov}(x, y)$.
- (b) Calculer s_x , s_y , puis $r_{xy} = \text{cov}(x, y) / (s_x s_y)$.
- (c) Situer cette valeur de r sur l'échelle de lecture du cours (-1 à $+1$), et conclure en une phrase de gestion.

Exercice 2 — La matrice des corrélations, à trois variables

Un fichier de 5 produits porte sur trois variables : p_1 (prix, en dh), p_2 (marge, en %) et p_3 (part de marché, en %).

Produit	1	2	3	4	5
p_1 (prix)	8	12	9	15	14
p_2 (marge)	20	28	22	35	33
p_3 (part de marché)	45	38	50	25	30

- (a) Calculer les moyennes, variances et écarts-types des trois variables.
- (b) Calculer les trois corrélations deux à deux : $r_{p_1 p_2}$, $r_{p_1 p_3}$, $r_{p_2 p_3}$.
- (c) Écrire la matrice des corrélations R (matrice 3×3), vérifier que sa diagonale ne contient que des 1, et proposer une lecture économique de ces trois corrélations (quelles paires de variables semblent redondantes, quelles paires varient en sens opposé).

Exercice 3 — Les trois pièges de la corrélation

- (a) On considère $x = -2, -1, 0, 1, 2$ et $y = x^2$ (donc $y = 4, 1, 0, 1, 4$). Calculer $\bar{x}$, $\bar{y}$, puis $\text{cov}(x, y)$ et r_{xy} , sans arrondir en cours de route. Ce résultat signifie-t-il qu'il n'existe *aucune* liaison entre x et y ? Commenter à la lumière du premier piège du cours.
- (b) Un directeur commercial affirme : « la corrélation entre nos dépenses publicitaires et nos ventes est de 0,85 sur les cinq dernières années ; nos publicités font donc vendre ». Quel piège du cours cette phrase illustre-t-elle, et quelles sont les deux autres explications possibles, aussi valables a priori, que celle retenue par le directeur ?
- (c) Pourquoi le cours recommande-t-il de « toujours regarder le nuage de points » plutôt que de se fier au seul coefficient r ? Reformuler cette recommandation en s'appuyant sur les deux premiers pièges (liaison non linéaire, points aberrants).

2 Exercices cumulatifs (introduction au chapitre 4)

Exercice 4 — Du tableau brut à la matrice des corrélations du fil rouge

On reprend le fil rouge : cinq clients, accueil x et fidélité y : $(8, 4)$, $(10, 12)$, $(12, 8)$, $(14, 16)$, $(16, 20)$. On rappelle (chapitres 2-3) $V(x) = 8$, $V(y) = 32$, $\text{cov}(x, y) = 14,4$.

- (a) Calculer $s_x s_y$ et r_{xy} , et vérifier qu'on retrouve exactement $r_{xy} = 0,9$.
- (b) En utilisant les valeurs centrées réduites $z_x = (-1,414, -0,707, 0, 0,707, 1,414)$ et $z_y = (-1,414, 0, -0,707, 0,707, 1,414)$ (chapitre 2), calculer $\text{cov}(z_x, z_y) = \frac{1}{5} \sum_i z_{x,i} z_{y,i}$, et vérifier qu'on retrouve la même valeur 0,9 que celle obtenue en (a).
- (c) Écrire, côte à côte, la matrice des variances-covariances Σ du fil rouge (chapitre 3) et sa matrice des corrélations R . Expliquer en une phrase pourquoi la diagonale de Σ contient $(8, 32)$ alors que celle de R contient $(1, 1)$, en reliant cette différence à l'identité $\text{cov}(z, z) = V(z) = 1$ démontrée en (b).

3 Applications en sciences économiques

Exercice 5 — Notoriété de marque et exposition publicitaire

Une agence mesure, pour 6 campagnes, le nombre d'expositions publicitaires par semaine (x , en millions) et un score de notoriété de marque (y , sur 100) :

Campagne	1	2	3	4	5	6
x (expositions)	3	5	4	7	6	8
y (notoriété)	42	58	48	72	65	78

- (a) Calculer $\bar{x}$, $\bar{y}$, $\text{cov}(x, y)$, puis r_{xy} .
- (b) Cette corrélation est-elle forte, au sens de l'échelle de lecture du cours ?
- (c) L'agence souhaite communiquer ce résultat à son client comme une preuve que « la publicité crée de la notoriété ». Rédiger, en une phrase, la mise en garde qu'un statisticien rigoureux devrait ajouter à cette communication.

Exercice 6 — Un client hors norme peut inverser une conclusion

Une entreprise étudie la relation entre l'ancienneté d'un contrat (x , en années) et un indice de satisfaction (y) sur 5 clients « ordinaires » : $(5, 20)$, $(6, 19)$, $(4, 21)$, $(7, 18)$, $(5, 5, 20, 5)$.

- (a) Calculer r_{xy} sur ces 5 clients. Le signe de cette corrélation est-il cohérent avec l'idée que la satisfaction diminuerait légèrement avec l'ancienneté (usure de la relation) ?
- (b) Un sixième client, très atypique (contrat très ancien de 30 ans, satisfaction exceptionnelle de 50), est ajouté à l'échantillon. Recalculer r_{xy} sur les 6 clients.
- (c) Que s'est-il passé entre les deux calculs ? Expliquer, en une phrase, pourquoi ce résultat illustre concrètement le deuxième piège du cours (« un seul point très éloigné peut créer une corrélation forte là où il n'y en a aucune, ou détruire une corrélation réelle »), et proposer une précaution à prendre avant de publier un coefficient de corrélation calculé sur un échantillon réel.


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{10 + 15 + 12 + 18 + 20}{5} = 15$. $\bar{y} = \frac{65 + 72 + 68 + 80 + 85}{5} = 74$. Écarts $x_i - \bar{x}$: $-5, 0, -3, 3, 5$; écarts $y_i - \bar{y}$: $-9, -2, -6, 6, 11$. Produits : $45, 0, 18, 18, 55$. $\text{cov}(x, y) = \frac{45 + 0 + 18 + 18 + 55}{5} = \frac{136}{5} = 27,2$.

(b) $s_x = \sqrt{13,6} \approx 3,688$. $s_y = \sqrt{55,6} \approx 7,457$. $r_{xy} = \frac{27,2}{3,688 \times 7,457} \approx \frac{27,2}{27,50} \approx 0,989$.

(c) $r \approx 0,989$ est très proche de $+1$: une liaison linéaire **quasiment parfaite**. Phrase de gestion : « Sur cet échantillon, la performance des employés augmente de façon presque parfaitement linéaire avec le nombre d'heures de formation suivies. »



Correction — Exercice 2

(a) $\bar{p}_1 = \frac{8 + 12 + 9 + 15 + 14}{5} = 11,6$. $\bar{p}_2 = \frac{20 + 28 + 22 + 35 + 33}{5} = 27,6$. $\bar{p}_3 = \frac{45 + 38 + 50 + 25 + 30}{5} = 37,6$. $V(p_1) = 7,44$, $s_{p_1} \approx 2,728$. $V(p_2) = 34,64$, $s_{p_2} \approx 5,886$. $V(p_3) = 85,04$, $s_{p_3} \approx 9,222$.

(b) $\text{cov}(p_1, p_2) = 16,04$, donc $r_{p_1 p_2} = \frac{16,04}{2,728 \times 5,886} \approx 0,999$. $\text{cov}(p_1, p_3) = -23,96$, donc $r_{p_1 p_3} = \frac{-23,96}{2,728 \times 9,222} \approx -0,953$. $\text{cov}(p_2, p_3) = -51,96$, donc $r_{p_2 p_3} = \frac{-51,96}{5,886 \times 9,222} \approx -0,957$.

(c)

$$R \approx \begin{pmatrix} 1 & 0,999 & -0,953 \\ 0,999 & 1 & -0,957 \\ -0,953 & -0,957 & 1 \end{pmatrix}$$

La diagonale ne contient bien que des 1. Lecture économique : prix et marge sont quasiment **redondants** ($r \approx 0,999$, presque une seule information dédoublée); la part de marché, elle, varie en **sens opposé** du prix et de la marge ($r \approx -0,95$ dans les deux cas) – ce qui est cohérent avec l'idée qu'un produit plus cher et plus marginé perd, ici, en parts de marché.


Correction — Exercice 3

(a) $\bar{x} = 0$, $\bar{y} = \frac{4 + 1 + 0 + 1 + 4}{5} = 2$. Écarts $x_i - \bar{x}$: $-2, -1, 0, 1, 2$; écarts $y_i - \bar{y}$: $2, -1, -2, -1, 2$. Produits : $-4, 1, 0, -1, 4$. Somme = 0, donc $\text{cov}(x, y) = 0$ et $r_{xy} = 0$. **Non**, ce résultat ne signifie pas l'absence de liaison : x et y sont liées par une relation **parfaitement déterministe** ($y = x^2$), simplement **non linéaire**.

– exactement le premier piège du cours : $r = 0$ signifie « pas de liaison linéaire », jamais « pas de liaison » tout court.

(b) Cette phrase illustre le **troisième piège** (la causalité). Les deux autres explications, aussi valables a priori que « la publicité fait vendre », sont : (i) la causalité inverse – une entreprise qui vend déjà bien peut se permettre d’investir davantage en publicité (les ventes causeraient alors le budget publicitaire, et non l’inverse) ; (ii) une troisième variable – la conjoncture économique générale, ou la notoriété globale de l’entreprise, pourrait faire monter à la fois le budget publicitaire et les ventes sans lien de cause direct entre eux.

(c) Le premier piège montre qu’un r proche de 0 peut masquer une liaison non linéaire réelle et forte ; le deuxième montre qu’un r élevé (ou faible) peut être entièrement **produit** par un seul point aberrant, sans refléter la tendance générale du nuage. Dans les deux cas, le nombre r , à lui seul, peut donc **mentir** sur la nature véritable de la relation ; seul le nuage de points permet de voir directement la forme réelle de la liaison et de repérer les points qui pèsent anormalement sur le calcul.



2 Exercices cumulatifs (introduction au chapitre 4)

Correction — Exercice 4

$$(a) s_x s_y = \sqrt{8} \times \sqrt{32} = \sqrt{256} = 16. r_{xy} = \frac{14,4}{16} = 0,9, \text{ exactement.}$$

$$(b) \text{cov}(z_x, z_y) = \frac{1}{5} [(-1,414)(-1,414) + (-0,707)(0) + (0)(-0,707) + (0,707)(0,707) + (1,414)(1,414)] = \frac{1}{5} [2 + 0 + 0 + 0,5 + 2] = \frac{4,5}{5} = 0,9. \text{ On retrouve bien la même valeur qu'en (a).}$$

(c)

$$\Sigma = \begin{pmatrix} 8 & 14,4 \\ 14,4 & 32 \end{pmatrix} \quad R = \begin{pmatrix} 1 & 0,9 \\ 0,9 & 1 \end{pmatrix}$$

La diagonale de Σ contient les **variances brutes** $V(x) = 8$ et $V(y) = 32$, qui dépendent des unités d’origine de l’accueil et de la fidélité. La diagonale de R contient, elle, les variances des variables **centrées réduites**, $V(z_x) = V(z_y) = 1$ (chapitre 2) – ce qui n’est jamais qu’une réécriture de l’identité $\text{cov}(z, z) = V(z) = 1$ démontrée en (b) : la matrice R est simplement la matrice Σ calculée sur les variables réduites plutôt que sur les variables brutes.

3 Applications en sciences économiques

Correction — Exercice 5

$$(a) \bar{x} = \frac{3 + 5 + 4 + 7 + 6 + 8}{6} = 5,5. \bar{y} = \frac{42 + 58 + 48 + 72 + 65 + 78}{6} \approx 60,5. \text{cov}(x, y) \approx 21,58. s_x \approx 1,708, s_y \approx 12,672. r_{xy} \approx \frac{21,58}{1,708 \times 12,672} \approx 0,997. \quad 4$$

(b) **Oui** : $r \approx 0,997$ est une corrélation extrêmement forte, très proche de +1.

(c) « Cette corrélation, aussi forte soit-elle, établit une **association** entre exposition publicitaire et notoriété, mais ne prouve pas à elle seule un lien de **causalité** : une troisième variable (par exemple, un budget marketing global plus large qui finance à la fois davantage d'expositions publicitaires et d'autres actions de communication) pourrait expliquer conjointement les deux évolutions. »

Correction — Exercice 6

(a) $\bar{x} = 5,5$, $\bar{y} = 19,7$. $\text{cov}(x, y) = -1$. $s_x = 1$, $s_y \approx 1,077$. $r_{xy} \approx \frac{-1}{1,077} \approx -0,928$. **Oui**, le signe négatif est cohérent avec l'idée d'une légère baisse de satisfaction avec l'ancienneté.

(b) Avec le sixième client (30, 50) : $\bar{x} \approx 9,58$, $\bar{y} = 24,75$, $\text{cov}(x, y) \approx 102,27$, $s_x \approx 9,176$, $s_y \approx 11,335$,
 $r_{xy} \approx \frac{102,27}{9,176 \times 11,335} \approx 0,983$.

(c) Le signe de la corrélation s'est **inversé** : de $-0,928$ (liaison négative forte) à $+0,983$ (liaison positive tout aussi forte), sous l'effet d'un **unique** point très éloigné du reste du nuage. C'est une illustration frappante du deuxième piège du cours : un seul point aberrant peut non seulement affaiblir ou renforcer une corrélation, mais littéralement en **inverser le signe**. Avant de publier un coefficient de corrélation, il faut donc systématiquement visualiser le nuage de points, identifier les points isolés du reste de la distribution, et vérifier – en recalculant r avec et sans ces points – si la conclusion tient encore une fois ces valeurs atypiques mises à l'écart (ou traitées séparément).

