

Chapitre 4

La corrélation linéaire

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Calculer une corrélation, du début à la fin

Un service formation mesure, pour 5 employés, le nombre d'heures de formation suivies (x) et un score de performance (y , sur 100) :

Employé	1	2	3	4	5
x (heures)	10	15	12	18	20
y (score)	65	72	68	80	85

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x) = 13,6$, $V(y) = 55,6$ (déjà donnés pour vous concentrer sur la suite), puis $\text{cov}(x, y)$.
- (b) Calculer s_x , s_y , puis $r_{xy} = \text{cov}(x, y) / (s_x s_y)$.
- (c) Situer cette valeur de r sur l'échelle de lecture du cours (-1 à $+1$), et conclure en une phrase de gestion.

Exercice 2 — La matrice des corrélations, à trois variables

Un fichier de 5 produits porte sur trois variables : p_1 (prix, en dh), p_2 (marge, en %) et p_3 (part de marché, en %).

Produit	1	2	3	4	5
p_1 (prix)	8	12	9	15	14
p_2 (marge)	20	28	22	35	33
p_3 (part de marché)	45	38	50	25	30

- (a) Calculer les moyennes, variances et écarts-types des trois variables.
- (b) Calculer les trois corrélations deux à deux : $r_{p_1 p_2}$, $r_{p_1 p_3}$, $r_{p_2 p_3}$.
- (c) Écrire la matrice des corrélations R (matrice 3×3), vérifier que sa diagonale ne contient que des 1, et proposer une lecture économique de ces trois corrélations (quelles paires de variables semblent redondantes, quelles paires varient en sens opposé).

Exercice 3 — Les trois pièges de la corrélation

- (a) On considère $x = -2, -1, 0, 1, 2$ et $y = x^2$ (donc $y = 4, 1, 0, 1, 4$). Calculer $\bar{x}$, $\bar{y}$, puis $\text{cov}(x, y)$ et r_{xy} , sans arrondir en cours de route. Ce résultat signifie-t-il qu'il n'existe *aucune* liaison entre x et y ? Commenter à la lumière du premier piège du cours.
- (b) Un directeur commercial affirme : « la corrélation entre nos dépenses publicitaires et nos ventes est de 0,85 sur les cinq dernières années ; nos publicités font donc vendre ». Quel piège du cours cette phrase illustre-t-elle, et quelles sont les deux autres explications possibles, aussi valables a priori, que celle retenue par le directeur ?
- (c) Pourquoi le cours recommande-t-il de « toujours regarder le nuage de points » plutôt que de se fier au seul coefficient r ? Reformuler cette recommandation en s'appuyant sur les deux premiers pièges (liaison non linéaire, points aberrants).

2 Exercices cumulatifs (introduction au chapitre 4)

Exercice 4 — Du tableau brut à la matrice des corrélations du fil rouge

On reprend le fil rouge : cinq clients, accueil x et fidélité y : $(8, 4)$, $(10, 12)$, $(12, 8)$, $(14, 16)$, $(16, 20)$. On rappelle (chapitres 2-3) $V(x) = 8$, $V(y) = 32$, $\text{cov}(x, y) = 14,4$.

- (a) Calculer $s_x s_y$ et r_{xy} , et vérifier qu'on retrouve exactement $r_{xy} = 0,9$.
- (b) En utilisant les valeurs centrées réduites $z_x = (-1,414, -0,707, 0, 0,707, 1,414)$ et $z_y = (-1,414, 0, -0,707, 0,707, 1,414)$ (chapitre 2), calculer $\text{cov}(z_x, z_y) = \frac{1}{5} \sum_i z_{x,i} z_{y,i}$, et vérifier qu'on retrouve la même valeur 0,9 que celle obtenue en (a).
- (c) Écrire, côte à côte, la matrice des variances-covariances Σ du fil rouge (chapitre 3) et sa matrice des corrélations R . Expliquer en une phrase pourquoi la diagonale de Σ contient $(8, 32)$ alors que celle de R contient $(1, 1)$, en reliant cette différence à l'identité $\text{cov}(z, z) = V(z) = 1$ démontrée en (b).

3 Applications en sciences économiques

Exercice 5 — Notoriété de marque et exposition publicitaire

Une agence mesure, pour 6 campagnes, le nombre d'expositions publicitaires par semaine (x , en millions) et un score de notoriété de marque (y , sur 100) :

Campagne	1	2	3	4	5	6
x (expositions)	3	5	4	7	6	8
y (notoriété)	42	58	48	72	65	78

- (a) Calculer $\bar{x}$, $\bar{y}$, $\text{cov}(x, y)$, puis r_{xy} .
- (b) Cette corrélation est-elle forte, au sens de l'échelle de lecture du cours ?
- (c) L'agence souhaite communiquer ce résultat à son client comme une preuve que « la publicité crée de la notoriété ». Rédiger, en une phrase, la mise en garde qu'un statisticien rigoureux devrait ajouter à cette communication.

Exercice 6 — Un client hors norme peut inverser une conclusion

Une entreprise étudie la relation entre l'ancienneté d'un contrat (x , en années) et un indice de satisfaction (y) sur 5 clients « ordinaires » : $(5, 20)$, $(6, 19)$, $(4, 21)$, $(7, 18)$, $(5, 5, 20, 5)$.

- (a) Calculer r_{xy} sur ces 5 clients. Le signe de cette corrélation est-il cohérent avec l'idée que la satisfaction diminuerait légèrement avec l'ancienneté (usure de la relation) ?
- (b) Un sixième client, très atypique (contrat très ancien de 30 ans, satisfaction exceptionnelle de 50), est ajouté à l'échantillon. Recalculer r_{xy} sur les 6 clients.
- (c) Que s'est-il passé entre les deux calculs ? Expliquer, en une phrase, pourquoi ce résultat illustre concrètement le deuxième piège du cours (« un seul point très éloigné peut créer une corrélation forte là où il n'y en a aucune, ou détruire une corrélation réelle »), et proposer une précaution à prendre avant de publier un coefficient de corrélation calculé sur un échantillon réel.