Introduction à l'analyse des données

Chapitre 4 : La corrélation linéaire

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Rendre la covariance lisible **2**
- La définition . . . 2
- Sur le fil rouge . . . 3
- Le paradoxe du chapitre 3, résolu . . . 3

Ce que r vaut, et ce qu'il dit **3**
- La borne . . . 3
- La démonstration, sur nos cinq clients . . . 4
- La lecture . . . 4
- Six nuages, six corrélations . . . 5
- Ce que la galerie enseigne . . . 5

La lecture géométrique **6**
- La corrélation est une covariance de variables réduites . . . 6
- Corréler, c'est réduire puis covarier . . . 6
- La matrice des corrélations . . . 7
- Les huit notes du fichier réel . . . 8
- Ce qu'on y lit avant tout calcul . . . 8

Les trois pièges **8**
- Premier piège : la liaison non linéaire . . . 8
- La règle qui en découle . . . 9
- Deuxième piège : les points aberrants . . . 9
- Pourquoi un seul point suffit . . . 9
- Troisième piège : la causalité . . . 10

Sur machine **10**
- Avec R . . . 10
- Avec Python . . . 10

S'entraîner **11**
- Exercice 1 : quatre magasins . . . 11
- Exercice 1 : solution . . . 11
- Exercice 2 : un client aberrant . . . 11

Exercice 2 : solution 12
Exercice 3 : lire la matrice réelle 12
Exercice 3 : solution 12

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 13

Rendre la covariance lisible

La définition

Le coefficient de corrélation linéaire

$$r_{xy} = \frac{\operatorname{cov}(x, y)}{s_x\, s_y}$$

On divise la covariance par le produit des deux écarts-types.

Pourquoi cette division précisément

La covariance s'exprime en « unité de x × unité de y », et le produit $s_x s_y$ **exactement dans la même unité**. Le quotient est donc **sans unité** — la condition pour comparer, établie au chapitre 2.
Changer d'unité multiplie la covariance par $a\,b$ et le produit des écarts-types par $a\,b$ aussi : **le quotient ne bouge pas**.

Démonstration : La corrélation ne dépend ni de l'unité ni de l'origine

Posons $x' = a\,x + c$ et $y' = b\,y + d$, avec $a, b \neq 0$. D'après le chapitre 3, $\operatorname{cov}(x', y') = a\,b\,\operatorname{cov}(x, y)$; d'après le chapitre 2, $s_{x'} = |a|\,s_x$ et $s_{y'} = |b|\,s_y$. Donc

$$r_{x'y'} = \frac{a\,b\,\operatorname{cov}(x, y)}{|a|\,|b|\,s_x\,s_y} = \frac{a\,b}{|a\,b|}\,r_{xy},$$

c'est-à-dire r_{xy} multiplié par le signe de ab. Si a et b sont positifs (changement d'unité ou d'origine), la corrélation est **exactement** la même. Si l'un des deux est négatif (on inverse le sens d'une échelle, par exemple « note » devient « 20 moins la note »), elle change de signe et garde sa valeur absolue.

Sur les cinq clients, l'accueil noté sur 100 ($a = 5$) a pour écart-type $\sqrt{200} = 14{,}14$; le produit des écarts-types vaut $14{,}14 \times 5{,}66 = 80$ et la covariance 72 : $r = 72/80 = 0{,}9$, comme avant. Sur le fichier réel, compter le panier en milliers de dirhams ne change pas sa corrélation avec l'accueil.

■

Sur le fil rouge

Un calcul qui tombe juste

$$s_x\, s_y = \sqrt{8} \times \sqrt{32} = \sqrt{8 \times 32} = \sqrt{256} = 16$$

$$r_{xy} = \frac{14{,}4}{16} = \mathbf{0{,}9}$$

Le produit des écarts-types tombe **exactement** sur 16, et la corrélation vaut **exactement** 0,9.

Le paradoxe du chapitre 3, résolu

Deux liaisons avec l'accueil

Paire	Covariance	Corrélation
panier et accueil	90,37	0,23
conseil et accueil	4,21	**0,73**

Une fois les unités retirées, l'ordre s'inverse : le conseil est **trois fois plus** lié à l'accueil que le panier.

Ce que la division a fait

$90{,}37/(166{,}3\times 2{,}40) = 0{,}23$ et $4{,}21/(2{,}40\times 2{,}40) = 0{,}73$. La grande covariance du panier venait **entièrement** de son écart-type en dirhams.

Ce que r vaut, et ce qu'il dit

La borne

Le résultat central

$$-1 \;\leq\; r_{xy} \;\leq\; +1$$

Cette borne ne dépend d'aucune hypothèse : elle est une propriété algébrique du quotient.

La démonstration, en une ligne

Avec les variables réduites z_x et z_y, la formule du chapitre 3 donne

$$V(z_x \pm z_y) = V(z_x) + V(z_y) \pm 2\,\mathrm{cov}(z_x, z_y) = 2 \pm 2\, r_{xy}$$

Une variance n'est jamais négative : $2 + 2r \geq 0$ et $2 - 2r \geq 0$, donc $-1 \leq r \leq 1$.

La démonstration, sur nos cinq clients

Les deux variances

$$V(z_x + z_y) = 2 + 2 \times 0{,}9 = 3{,}8 \qquad V(z_x - z_y) = 2 - 1{,}8 = 0{,}2$$

La somme des deux notes réduites est très dispersée ; leur différence l'est à peine.

Deux nombres à garder en mémoire

3,8 et 0,2, divisés par deux, donnent 1,9 et 0,1. Ce seront, au chapitre 8, les **deux valeurs propres** de l'ACP des cinq clients : la somme et la différence des notes réduites sont déjà, à un facteur près, ses deux axes.

La lecture

Ce que dit la valeur de r

Valeur de r	Situation
$+1$	les points sont **exactement alignés**, pente positive
proche de $+1$	liaison positive forte
0	**aucune liaison linéaire**
proche de -1	liaison négative forte
-1	alignement exact, pente négative

Les cas extrêmes

$r = \pm 1$ exactement si $V(z_x \mp z_y) = 0$, c'est-à-dire si $z_y = \pm z_x$ pour **tous** les individus : les points sont sur une droite.

Démonstration : La corrélation vaut plus ou moins un exactement quand les points sont alignés

Sens direct. Supposons $r_{xy} = 1$. Alors $V(z_x - z_y) = 2 - 2\,r_{xy} = 0$. Or une variance nulle exige que tous les écarts à la moyenne soient nuls (chapitre 2), et la moyenne de $z_x - z_y$ est 0 : on obtient $z_{y,i} = z_{x,i}$ pour **tout** individu i, soit

$$\frac{y_i - \bar{y}}{s_y} = \frac{x_i - \bar{x}}{s_x} \quad \Longleftrightarrow \quad y_i = \bar{y} + \frac{s_y}{s_x}\,(x_i - \bar{x}).$$

Tous les points sont sur une droite, de pente $s_y/s_x > 0$. De même, $r_{xy} = -1$ donne $V(z_x + z_y) = 0$, donc $z_{y,i} = -z_{x,i}$ et une droite de pente $-s_y/s_x$.

Sens réciproque. Si $y_i = a\,x_i + b$ avec $a \neq 0$, alors $\mathrm{cov}(x, y) = a\,V(x)$ et $s_y = |a|\,s_x$ (chapitres 2 et 3), donc

$$r_{xy} = \frac{a\,V(x)}{s_x \cdot |a|\,s_x} = \frac{a}{|a|} = \pm 1.$$

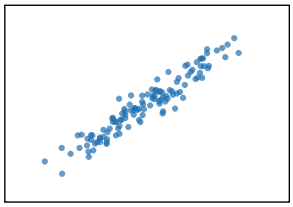
Sur les cinq clients, $V(z_x - z_y) = 0{,}2$ n'est pas nulle : les points ne sont pas alignés, bien que

$r = 0{,}9$ soit proche de 1. En revanche $y = 3x - 5$ donne $r = 1$ exactement.

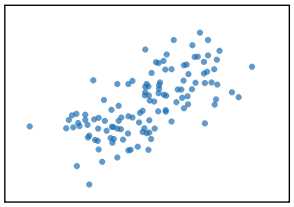
■

Six nuages, six corrélations

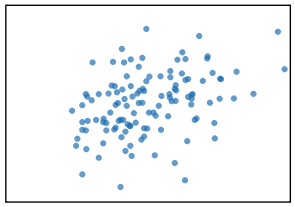
$r = 0{,}96$



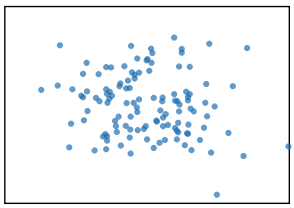
$r = 0{,}65$



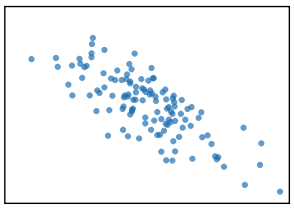
$r = 0{,}38$



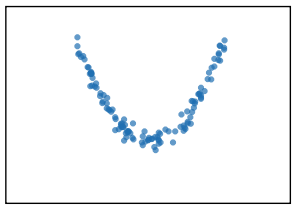
$r = -0{,}15$



$r = -0{,}76$



$r = 0{,}03$: une parabole



Ce que la galerie enseigne

Lire r sur un nuage

Plus le nuage est **étiré le long d'une droite**, plus $|r|$ est proche de 1. À 0,38, la liaison existe mais se voit à peine ; à $-0{,}15$, l'œil n'en voit aucune.
Le dernier nuage montre une liaison **parfaite**, en forme de parabole, et pourtant $r = 0{,}03$: nous y reviendrons avec les pièges.

Sur nos cinq clients

$r = 0{,}9$ est une liaison **très forte**. Accueil et fidélité vont ensemble de façon presque parfaitement linéaire.
Sur des données réelles, un tel r entre deux critères suggère que les deux questions **mesurent en partie la même chose**. L'analyse en composantes principales exploitera précisément ces redondances.

La lecture géométrique

La corrélation est une covariance de variables réduites

Une écriture équivalente

$$r_{xy} = \mathrm{cov}(z_x, z_y) = \frac{1}{n}\sum_{i=1}^{n} z_{x,i}\, z_{y,i}$$

Démonstration : La corrélation est la covariance des variables réduites

Les variables réduites $z_x = (x - \bar{x})/s_x$ et $z_y = (y - \bar{y})/s_y$ ont une moyenne nulle (chapitre 2). La covariance de deux variables de moyenne nulle est la simple moyenne de leurs produits :

$$\mathrm{cov}(z_x, z_y) = \frac{1}{n}\sum_i z_{x,i}\, z_{y,i} = \frac{1}{n}\sum_i \frac{x_i - \bar{x}}{s_x}\cdot\frac{y_i - \bar{y}}{s_y} = \frac{1}{s_x\, s_y}\cdot\frac{1}{n}\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \frac{\mathrm{cov}(x,y)}{s_x\, s_y} = r_{xy}.$$

Sur les cinq clients, les produits $z_x\, z_y$ valent 2 ; 0 ; 0 ; 0,5 ; 2, de somme 4,5 et de moyenne 0,9.

■

Sur nos cinq clients

Client	1	2	3	4	5	Somme
z_x	−1,414	−0,707	0	0,707	1,414	
z_y	−1,414	0	−0,707	0,707	1,414	
$z_x\, z_y$	2	0	0	0,5	2	4,5

$$r = 4{,}5/5 = 0{,}9$$

Corréler, c'est réduire puis covarier

Les trois rappels se referment ici

Centrer et réduire (chapitre 2), covarier (chapitre 3), et le quotient du chapitre 4 n'est que la combinaison des deux.
Une fois les variables réduites, covariance et corrélation sont le même nombre. C'est pourquoi l'analyse en composantes principales travaillera sur données réduites : elle n'aura plus à choisir entre les deux.

Un cosinus

La corrélation est le **cosinus de l'angle** entre les deux colonnes centrées, vues comme des vecteurs de $\mathbb{R}^n$. Sur nos cinq clients, $\cos\theta = 0{,}9$: les deux colonnes font un angle de 25,8°. Le chapitre 10 en fera une figure.

Démonstration : La corrélation est un cosinus

Rangeons les valeurs centrées de chaque variable dans un vecteur de $\mathbb{R}^n$: $\tilde{x} = (x_1 - \bar{x}, \dots, x_n - \bar{x})$ et $\tilde{y} = (y_1 - \bar{y}, \dots, y_n - \bar{y})$. Le produit scalaire et la longueur s'écrivent

$$\langle \tilde{x}, \tilde{y} \rangle = \sum_i (x_i - \bar{x})(y_i - \bar{y}) = n \operatorname{cov}(x, y), \qquad \|\tilde{x}\|^2 = \sum_i (x_i - \bar{x})^2 = n\, V(x),$$

donc $\|\tilde{x}\| = \sqrt{n}\, s_x$ et $\|\tilde{y}\| = \sqrt{n}\, s_y$. Le cosinus de l'angle θ entre deux vecteurs est leur produit scalaire divisé par le produit de leurs longueurs :

$$\cos\theta = \frac{\langle \tilde{x}, \tilde{y} \rangle}{\|\tilde{x}\|\, \|\tilde{y}\|} = \frac{n \operatorname{cov}(x, y)}{\sqrt{n}\, s_x \cdot \sqrt{n}\, s_y} = \frac{\operatorname{cov}(x, y)}{s_x\, s_y} = r_{xy}.$$

Un cosinus est compris entre -1 et 1 (inégalité de Cauchy-Schwarz) : on retrouve la borne de r. Et $r = \pm 1$ correspond à des vecteurs proportionnels ($\theta = 0$ ou $180°$), c'est-à-dire à des points alignés.

Sur les cinq clients, $\tilde{x} = (-4, -2, 0, 2, 4)$ et $\tilde{y} = (-8, 0, -4, 4, 8)$: $\langle \tilde{x}, \tilde{y} \rangle = 32 + 0 + 0 + 8 + 32 = 72$, $\|\tilde{x}\|^2 = 40$ et $\|\tilde{y}\|^2 = 160$, donc $\cos\theta = 72/\sqrt{40 \times 160} = 72/80 = 0{,}9$, soit $\theta = 25{,}8°$.

■

La matrice des corrélations

La matrice du fil rouge

$$R = \begin{pmatrix} 1 & 0{,}9 \\ 0{,}9 & 1 \end{pmatrix}$$

Sa diagonale ne contient que des 1 : $\operatorname{cov}(z, z) = V(z) = 1$. C'est la matrice des variances-covariances des **variables réduites**.

Le même objet que la matrice du chapitre 3

R se déduit de Σ en divisant chaque case par le produit des deux écarts-types : $14{,}4/(2{,}83 \times 5{,}66) = 0{,}9$, et $8/(2{,}83 \times 2{,}83) = 1$.

Les huit notes du fichier réel

	prix	choix	qual.	agen.	prop.	rapid.	cons.	accu.
prix	1	0,67	0,67	0,59	0,43	0,22	0,15	0,09
choix	0,67	1	0,73	0,69	0,56	0,32	0,34	0,31
qualité	0,67	0,73	1	0,71	0,56	0,41	0,36	0,35
agencement	0,59	0,69	0,71	1	0,59	0,50	0,44	0,41
propreté	0,43	0,56	0,56	0,59	1	0,64	0,59	0,58
rapidité	0,22	0,32	0,41	0,50	0,64	1	0,69	0,71
conseil	0,15	0,34	0,36	0,44	0,59	0,69	1	0,73
accueil	0,09	0,31	0,35	0,41	0,58	0,71	0,73	1

L'ACP est déjà là, dans ce tableau.

Deux blocs sombres se détachent : **prix, choix, qualité, agencement**d'un côté — ce que le magasin *propose* — et **propreté, rapidité, conseil, accueil**de l'autre — ce que le personnel *fait*. Entre les deux, les corrélations tombent à 0,09.

L'ACP ne fera que rendre visible cette structure — mais sur 30 variables, aucun œil ne l'aurait vue dans le tableau.

Ce qu'on y lit avant tout calcul

La matrice se regarde avant de lancer quoi que ce soit

- des blocs de variables fortement corrélées entre elles signalent des **groupes de critères redondants** ;
- une variable corrélée à aucune autre n'apportera rien aux premiers axes ;
- une corrélation proche de 1 entre deux variables indique qu'on en mesure une deux fois.

C'est déjà de l'analyse des données, faite à l'œil.

Sur nos huit notes

Toutes les corrélations sont **positives** : un client sévère sur un critère tend à l'être sur tous. Et deux blocs se détachent — prix, choix, qualité, agencement d'un côté ; rapidité, conseil, accueil de l'autre, la propreté entre les deux.

Les trois pièges

Premier piège : la liaison non linéaire

r ne voit que les droites

r ne mesure que la liaison **linéaire**. Deux variables liées par une relation en cloche ou en creux, parfaitement déterministe, peuvent avoir une corrélation **nulle**.

Cinq points sur une parabole

u	-2	-1	0	1	2
$v = u^2$	4	1	0	1	4

$\bar{u} = 0$, $\bar{v} = 2$. Produits des écarts : $(-2)(2)+(-1)(-1)+0+(1)(-1)+(2)(2) = -4+1-1+4 = 0$. **Donc** $r = 0$, alors que v est entièrement déterminé par u.

La règle qui en découle

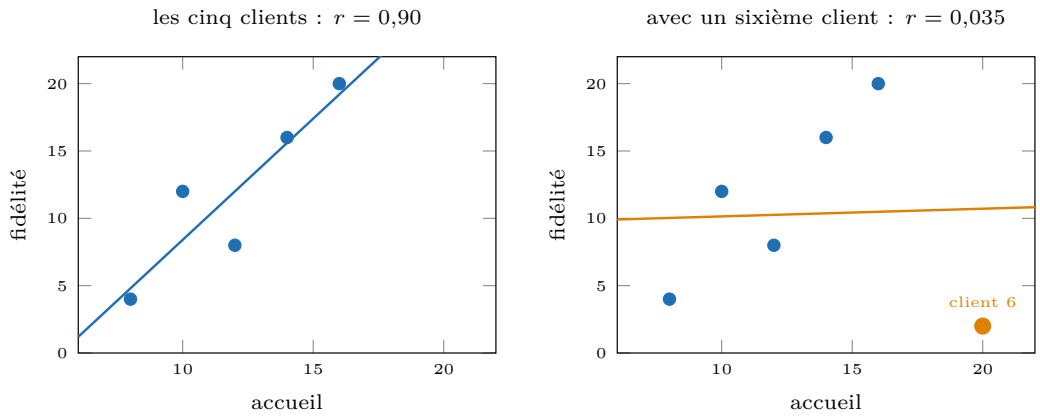
Toujours regarder le nuage

Un r de zéro signifie « pas de liaison **linéaire** », jamais « pas de liaison ».
Il faut donc **toujours regarder le nuage de points**, et ne jamais se contenter du coefficient.

En gestion

La satisfaction peut être maximale pour un prix **moyen** et plus faible aux deux extrêmes — trop cher, ou si bon marché qu'il inquiète. La corrélation entre prix et satisfaction serait alors proche de zéro, et masquerait une relation forte.

Deuxième piège : les points aberrants



Un seul client de plus

Ajoutons un sixième client, très accueilli (20) et pas du tout fidèle (2). La corrélation passe de 0,90 à **0,035** : **un point sur six a effacé la liaison**.

Pourquoi un seul point suffit

Une moyenne, sensible aux extrêmes

Le coefficient est une **moyenne de produits** $z_x\, z_y$. Un individu très éloigné du centre fournit un produit énorme, qui domine tous les autres.
Il peut ainsi **détruire** une corrélation réelle — comme ici — ou en **créer** une là où il n'y en a aucune.

Ce qu'il faut faire

Repérer les individus extrêmes **avant** de calculer, se demander s'il s'agit d'une erreur de saisie ou d'un cas réel, et calculer r avec et sans eux. Si les deux valeurs diffèrent beaucoup, aucune ne résume seule la liaison.

Troisième piège : la causalité

Corrélation n'est pas cause

Une corrélation forte n'établit **aucun** lien de cause à effet. Trois explications restent ouvertes :

1. x agit sur y ;
2. y agit sur x ;
3. une **troisième variable** agit sur les deux.

Le troisième cas est le plus fréquent : l'ancienneté du client, par exemple, pourrait produire à elle seule la corrélation entre accueil et fidélité.

Ce que ce cours s'interdit

Les distinguer est l'objet du cours d'**inférence causale**, au Master. Celui-ci décrit des associations, et s'y tient.

Sur machine

Avec R

Le code et sa sortie

```r
x <- c(8, 10, 12, 14, 16)
y <- c(4, 12, 8, 16, 20)
cor(x, y)                                    # [1] 0.9
clients <- read.csv("clients.csv")
round(cor(clients[, c("panier", "conseil", "accueil")]), 3)
#         panier conseil accueil
# panier   1.000   0.247   0.227
# conseil  0.247   1.000   0.731
# accueil  0.227   0.731   1.000
```

Plus de piège du diviseur

La corrélation est un **quotient** : le diviseur n ou n — 1 apparaît en haut et en bas, et s'élimine. R, `numpy` et `pandas` donnent exactement 0,9.

Avec Python

Le code et sa sortie

```
import numpy as np
import pandas as pd
x = np.array([8, 10, 12, 14, 16])
y = np.array([4, 12, 8, 16, 20])
print(round(np.corrcoef(x, y)[0, 1], 4))   # 0.9
clients = pd.read_csv("clients.csv")
cols = ["panier", "conseil", "accueil"]
print(clients[cols].corr().round(3))
#          panier  conseil  accueil
# panier    1.000    0.247    0.227
# conseil   0.247    1.000    0.731
# accueil   0.227    0.731    1.000
```

S'entraîner

Exercice 1 : quatre magasins

La corrélation de l'exercice du chapitre 3

Pour les quatre magasins du chapitre 3, on a trouvé $V(x) = 5$, $V(y) = 3{,}5$ et $\text{cov}(x, y) = 3{,}5$.

1. Calculer la corrélation entre surface et chiffre d'affaires.
2. Que devient-elle si la surface est mesurée en m² plutôt qu'en centaines de m² ?
3. Calculer $V(z_x + z_y)$ et $V(z_x - z_y)$.

Exercice 1 : solution

r = 0,837

1. $r = 3{,}5/\sqrt{5 \times 3{,}5} = 3{,}5/\sqrt{17{,}5} = 3{,}5/4{,}183 = 0{,}837$.
2. **Inchangée** : la covariance et l'écart-type de la surface sont tous deux multipliés par 100.
3. $V(z_x + z_y) = 2 + 2 \times 0{,}837 = 3{,}67$; $V(z_x - z_y) = 2 - 1{,}67 = 0{,}33$. Les deux sont positives, comme la démonstration l'exige.

Exercice 2 : un client aberrant

Avant et après

Cinq clients ont pour notes (accueil, fidélité) : $(10; 12)$, $(11; 10)$, $(12; 13)$, $(13; 11)$, $(14; 12)$. On ajoute un sixième client noté $(30; 30)$.

1. Sans calcul : la corrélation des cinq premiers est-elle forte ?
2. On trouve $r = 0{,}14$ sans le sixième, $r = 0{,}98$ avec. Expliquer.
3. Laquelle des deux valeurs décrit le mieux ces clients ?

Exercice 2 : solution

Un point fabrique la liaison

1. **Non** : les cinq fidélités $(12, 10, 13, 11, 12)$ montent et descendent sans suivre l'accueil.
2. Le sixième client est à près de 2 écarts-types de tous les autres sur **les deux** notes : son produit $z_x z_y$ est énorme et positif, et il domine la moyenne. **Il fabrique à lui seul** une corrélation de 0,98.
3. Aucune seule. Il faut décrire la situation : cinq clients sans liaison nette, et un client très différent — à vérifier (erreur de saisie ?) avant toute conclusion.

Exercice 3 : lire la matrice réelle

Trois questions sur la matrice des huit notes

Dans la matrice des corrélations des huit notes (diapositive « Les huit notes du fichier réel ») :

1. Quelle est la paire de notes la plus liée ? la moins liée ?
2. Le prix et l'accueil ont $r = 0{,}09$. Peut-on en conclure que le prix n'a aucun rapport avec l'accueil ?
3. Toutes les corrélations sont positives. Qu'est-ce que cela suggère sur les clients ?

Exercice 3 : solution

Deux blocs et un effet de niveau

1. Les plus liées : choix et qualité, conseil et accueil (0,73). La moins liée : prix et accueil (0,09).
2. **Non** : seulement qu'il n'y a pas de liaison **linéaire**. Il faut regarder le nuage — c'était le troisième des six nuages de l'introduction, et il ne montre rien de net.
3. Un client sévère tend à l'être **partout** : il existe un **niveau général** de satisfaction, qui sera le premier axe de l'ACP. Les deux blocs, eux, annoncent le second.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. $r_{xy} = \mathrm{cov}(x, y)/(s_x s_y)$: la covariance débarrassée de ses unités.
2. Sur le fil rouge : $s_x s_y = \sqrt{256} = 16$, donc $r = 14{,}4/16 = \mathbf{0{,}9}$ exactement.
3. $V(z_x \pm z_y) = 2 \pm 2r \geq 0$, d'où $-1 \leq r \leq +1$; sur nos clients, 3,8 et 0,2.
4. La corrélation est la **covariance des variables réduites**, et le cosinus d'un angle.
5. La matrice des huit notes montre déjà deux blocs : l'offre et le service.
6. Trois pièges : liaison **non linéaire**, points **aberrants** (0,9 $\rightarrow$ 0,035 avec un client de plus), et **causalité**.

La suite

Les rappels sont terminés

Le chapitre 5 change de regard : il cesse de voir un tableau de chiffres et se met à voir un **nuage de points** dans un espace à p dimensions.

Ce qu'on y calculera

Le centre de gravité des cinq clients, leurs distances deux à deux, brutes puis réduites — et l'on verra que la réduction change qui ressemble à qui.