

Chapitre 3

La covariance, généralisation de la variance

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{5 + 8 + 6 + 10 + 11}{5} = 8$, $\bar{y} = \frac{12 + 18 + 15 + 22 + 23}{5} = 18$.

(b) Écarts $x_i - \bar{x}$: -3, 0, -2, 2, 3. Écarts $y_i - \bar{y}$: -6, 0, -3, 4, 5. Produits : 18, 0, 6, 8, 15. Somme = 47.
 $\text{cov}(x, y) = \frac{47}{5} = 9,4$.

(c) **Oui** : le signe est positif, cohérent avec l'intuition que davantage de budget s'accompagne de davantage de visites. La campagne 1 contribue le plus (produit = 18) : elle s'écarte le plus fortement de la moyenne **dans le même sens** sur les deux variables (budget nettement inférieur *et* visites nettement inférieures à la moyenne).



Correction — Exercice 2

(a) $\text{cov}(x, y)$ serait multipliée par 100 : $\text{cov}(x, ay) = \frac{1}{n} \sum_i (x_i - \bar{x})(ay_i - a\bar{y}) = a \times \text{cov}(x, y)$, ici $a = 100$.

(b) Écarts de $y' = 5y$: -30, 0, -15, 20, 25 (soit 5× les écarts de y). $\text{cov}(x, y') = \frac{1}{5} [(-3)(-30) + 0 + (-2)(-15) + 2 \times 20 + 3 \times 25] = \frac{90 + 0 + 30 + 40 + 75}{5} = \frac{235}{5} = 47 = 5 \times 9,4$. Conforme à la prédiction.

(c) **Oui**, c'est cohérent : passer de notes sur 20 à des notes sur 100 revient à multiplier y (et x si les deux variables sont concernées) par 5 chacune, donc à multiplier leur produit par $5 \times 5 = 25$. Règle générale : si x est multipliée par a et y par b , alors $\text{cov}(ax, by) = ab \times \text{cov}(x, y)$.

Correction — Exercice 3

(a) $\bar{a} = \frac{3 + 5 + 4 + 7 + 6}{5} = 5$, $\bar{b} = \frac{10 + 14 + 11 + 18 + 17}{5} = 14$, $\bar{c} = \frac{50 + 42 + 55 + 30 + 38}{5} = 43$.

Écarts de a : -2, 0, -1, 2, 1, $V(a) = \frac{4 + 0 + 1 + 4 + 1}{5} = 2$. Écarts de b : -4, 0, -3, 4, 3, $V(b) = \frac{16 + 0 + 9 + 16 + 9}{5} = 10$. Écarts de c : 7, -1, 12, -13, -5, $V(c) = \frac{49 + 1 + 144 + 169 + 25}{5} = \frac{388}{5} = 77,6$.

(b) $\text{cov}(a, b) = \frac{(-2)(-4) + 0 + (-1)(-3) + 2 \times 4 + 1 \times 3}{5} = \frac{8 + 0 + 3 + 8 + 3}{5} = \frac{22}{5} = 4,4$. $\text{cov}(a, c) = \frac{(-2)(7) + 0 + (-1)(12) + 2(-13) + 1(-5)}{5} = \frac{-14 + 0 - 12 - 26 - 5}{5} = \frac{-57}{5} = -11,4$. $\text{cov}(b, c) = \frac{(-4)(7) + 0 + (-3)(12) + 4(-13) + 3(-5)}{5} = \frac{-28 + 0 - 36 - 52 - 15}{5} = \frac{-131}{5} = -26,2$.

(c)

$$\Sigma = \begin{pmatrix} 2 & 4,4 & -11,4 \\ 4,4 & 10 & -26,2 \\ -11,4 & -26,2 & 77,6 \end{pmatrix}$$

La matrice est bien symétrique par rapport à sa diagonale (par exemple, la case ligne 1/colonne 3 et la case ligne 3/colonne 1 valent toutes deux $-11,4$).

2 Exercices cumulatifs (introduction au chapitre 3)

Correction — Exercice 4

(a) Produits des écarts : $(-4)(-8) = 32$, $(-2)(0) = 0$, $(0)(-4) = 0$, $(2)(4) = 8$, $(4)(8) = 32$. Somme $= 72$. $\text{cov}(x, y) = \frac{72}{5} = 14,4$, conforme au cours.

(b)

$$\Sigma = \begin{pmatrix} 8 & 14,4 \\ 14,4 & 32 \end{pmatrix}$$

Symétrique : la case (1, 2) et la case (2, 1) valent toutes deux 14,4.

(c) La matrice Σ a une taille $p \times p$ qui ne dépend que du nombre de **variables**, jamais du nombre de **lignes** n du tableau initial : que le fichier compte 5 ou 500 000 clients, la matrice reste 2×2 pour deux variables. C'est une réduction **considérable** du volume d'information à manipuler (de $n \times p$ nombres à $p \times p$, et même $p(p+1)/2$ nombres distincts grâce à la symétrie). Mais ce n'est **pas encore** la réduction de dimension de l'introduction : celle-ci consiste à réduire le nombre de **variables** p elles-mêmes (en passant de p variables à 2 axes), alors que la matrice Σ conserve, elle, la totalité des p variables – elle ne fait que **résumer** les relations entre elles sous une forme compacte, qui servira justement de point de départ, au chapitre 8, pour calculer les axes qui, eux, réduiront véritablement le nombre de variables.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\bar{x} = \frac{45 + 62 + 38 + 71 + 55 + 48}{6} \approx 53,17$ k dh. $\bar{y} = \frac{320 + 410 + 290 + 480 + 375 + 340}{6} \approx 369,17$ k dh. $\text{cov}(x, y) \approx 683,47$.

(b) **Oui** : $\text{cov}(x, y) > 0$ confirme que les régions qui dépensent le plus en marketing sont aussi, dans cet échantillon, celles qui réalisent le plus de chiffre d'affaires.

(c) **Non** : le cours est explicite – une covariance positive est une **association**, jamais une **causalité**. Il est tout à fait possible que la relation soit inverse (les régions au CA déjà élevé reçoivent davantage de budget marketing, par choix stratégique de l'entreprise) ou qu'un troisième facteur (la taille du marché régional, par exemple) explique à la fois le budget alloué et le CA réalisé, sans lien de cause à effet direct entre les deux. Conclure « il suffit d'augmenter le budget pour augmenter le CA » à partir de la seule covariance est une généralisation abusive.

Correction — Exercice 6

(a) $\bar{A} \approx 1,233$, $\bar{B} = 1,050$, $\bar{C} \approx 0,367$.

$$\Sigma \approx \begin{pmatrix} 2,676 & 0,920 & -1,892 \\ 0,920 & 0,643 & -1,025 \\ -1,892 & -1,025 & 1,836 \end{pmatrix}$$

(b) $\text{cov}(A, B) \approx 0,92 > 0$: A et B évoluent plutôt dans le même sens. $\text{cov}(A, C) \approx -1,89 < 0$ et $\text{cov}(B, C) \approx -1,03 < 0$: C évolue, lui, plutôt en **sens contraire** de A et de B. Ces signes suggèrent que A et B forment un groupe d'actifs qui « montent et descendent ensemble », tandis que C tend à faire le mouvement inverse.

(c) D'après cette matrice, combiner C avec A serait le choix le plus efficace pour réduire le risque par diversification : $\text{cov}(A, C) \approx -1,89$ est nettement plus négative que $\text{cov}(B, C) \approx -1,03$, ce qui signifie

que C « compense » davantage les mouvements de A que ceux de B – un portefeuille combinant des actifs dont les rendements varient en sens contraire (covariance négative) est, toutes choses égales par ailleurs, moins risqué qu'un portefeuille d'actifs qui bougent ensemble.