

Introduction à l'analyse des données

Chapitre 3 : La covariance, généralisation de la variance

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une covariance, produit par produit

Une agence web mesure, pour 5 campagnes, le budget publicitaire (x , en k dh) et le nombre de visites générées (y , en centaines) :

Campagne	1	2	3	4	5
x (budget)	5	8	6	10	11
y (visites)	12	18	15	22	23

- Calculer $\bar{x}$ et $\bar{y}$.
- Calculer, campagne par campagne, les écarts $x_i - \bar{x}$, $y_i - \bar{y}$, et leur produit ; en déduire $\text{cov}(x, y)$.
- Le signe de $\text{cov}(x, y)$ est-il celui attendu ? Identifier la campagne qui contribue le plus au total (en valeur absolue), et expliquer pourquoi.

Exercice 2 — La covariance dépend des unités

On reprend les données de l'exercice 1 : $\text{cov}(x, y) = 9,4$.

- Si l'on exprimait y non plus en centaines de visites mais en unités de visites (c'est-à-dire en multipliant chaque valeur de y par 100), que deviendrait $\text{cov}(x, y)$? Justifier à partir de la formule, sans refaire le calcul complet.
- Vérifier votre réponse en recalculant $\text{cov}(x, y)$ avec y multiplié par 5 (au lieu de 100, pour rester simple) : $y' = 60, 90, 75, 110, 115$.
- Le cours affirme que « si les notes étaient sur 100 au lieu de 20, la covariance serait multipliée par 25 ». Est-ce cohérent avec votre calcul ? En déduire une règle générale : si l'on multiplie x par a et y par b , par quel facteur $\text{cov}(x, y)$ est-elle multipliée ?

Exercice 3 — La matrice des variances-covariances, à trois variables

Un fichier de 5 clients porte sur trois variables : a (âge, en dizaines d'années), b (ancienneté, en années) et c (distance au point de vente, en km).

Client	1	2	3	4	5
a	3	5	4	7	6
b	10	14	11	18	17
c	50	42	55	30	38

- Calculer $\bar{a}$, $\bar{b}$, $\bar{c}$, puis les trois variances $V(a)$, $V(b)$, $V(c)$.
- Calculer les trois covariances $\text{cov}(a, b)$, $\text{cov}(a, c)$, $\text{cov}(b, c)$.
- Écrire la matrice des variances-covariances Σ (une matrice 3×3), et vérifier qu'elle est symétrique.

2 Exercices cumulatifs (introduction au chapitre 3)

Exercice 4 — La matrice du fil rouge, et ce qu'elle réduit déjà

On reprend le fil rouge : cinq clients, accueil x et fidélité y : $(8, 4)$, $(10, 12)$, $(12, 8)$, $(14, 16)$, $(16, 20)$. On rappelle $V(x) = 8$ et $V(y) = 32$ (chapitre 2).

- Calculer, client par client, les produits des écarts, et vérifier qu'on retrouve $\text{cov}(x, y) = 14,4$.
- Écrire la matrice des variances-covariances Σ du fil rouge, et vérifier qu'elle est symétrique.
- Le cours affirme qu'« un tableau de trois cents lignes et douze colonnes se résume [...] à une

matrice de douze sur douze », et que « c'est déjà, en soi, une réduction considérable ». En reliant cette remarque au problème posé dans l'introduction du cours (le nombre de nuages de points croît en $p(p-1)/2$), expliquer pourquoi passer d'un tableau de n lignes à une matrice de $p \times p$ (qui ne dépend plus de n du tout) est une étape essentielle, même si cette matrice n'est *pas encore*, en elle-même, la réduction de dimension annoncée par l'introduction (celle qui réduira le nombre de *variables*, pas le nombre de lignes).

3 Applications en sciences économiques

Exercice 5 — Dépenses marketing et chiffre d'affaires régional

Une entreprise étudie, sur 6 régions de vente, la relation entre les dépenses marketing régionales (x , en k dh) et le chiffre d'affaires régional (y , en k dh) :

Région	1	2	3	4	5	6
x (marketing)	45	62	38	71	55	48
y (CA)	320	410	290	480	375	340

- Calculer $\bar{x}$, $\bar{y}$, puis $\text{cov}(x, y)$.
- Le signe de la covariance confirme-t-il l'intuition selon laquelle davantage de dépenses marketing s'accompagne d'un CA plus élevé?
- Le directeur commercial en conclut : « il suffit d'augmenter le budget marketing pour augmenter le chiffre d'affaires ». Cette conclusion est-elle justifiée par le seul calcul de covariance? Justifier à l'aide de la mise en garde du cours.

Exercice 6 — Une matrice de covariances entre trois actifs financiers

Un gérant de portefeuille dispose des rendements mensuels (en %) de trois actifs sur 6 mois :

Mois	1	2	3	4	5	6
Actif A	2,1	-0,5	3,2	1,0	-1,2	2,8
Actif B	1,5	0,8	2,0	-0,3	0,5	1,8
Actif C	-0,8	1,2	-1,5	2,0	1,8	-0,5

- Calculer les moyennes des trois actifs, puis la matrice des variances-covariances Σ (matrice 3×3).
- Comparer le signe de $\text{cov}(A, B)$ à celui de $\text{cov}(A, C)$ et de $\text{cov}(B, C)$. Que suggèrent ces signes sur la façon dont ces trois actifs évoluent les uns par rapport aux autres?
- Un gérant qui chercherait à réduire le risque de son portefeuille en combinant des actifs qui « bougent en sens contraire » aurait-il intérêt, d'après cette matrice, à combiner l'actif C avec A, ou avec B? Justifier sans calcul supplémentaire, à partir des valeurs de la matrice.


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{5 + 8 + 6 + 10 + 11}{5} = 8$. $\bar{y} = \frac{12 + 18 + 15 + 22 + 23}{5} = 18$.

(b) Écarts $x_i - \bar{x}$: -3, 0, -2, 2, 3. Écarts $y_i - \bar{y}$: -6, 0, -3, 4, 5. Produits : 18, 0, 6, 8, 15. Somme = 47.
 $\text{cov}(x, y) = \frac{47}{5} = 9,4$.

(c) **Oui** : le signe est positif, cohérent avec l'intuition que davantage de budget s'accompagne de davantage de visites. La campagne 1 contribue le plus (produit = 18) : elle s'écarte le plus fortement de la moyenne **dans le même sens** sur les deux variables (budget nettement inférieur *et* visites nettement inférieures à la moyenne).



Correction — Exercice 2

(a) $\text{cov}(x, y)$ serait multipliée par 100 : $\text{cov}(x, ay) = \frac{1}{n} \sum_i (x_i - \bar{x})(ay_i - a\bar{y}) = a \times \text{cov}(x, y)$, ici $a = 100$.

(b) Écarts de $y' = 5y$: -30, 0, -15, 20, 25 (soit 5× les écarts de y). $\text{cov}(x, y') = \frac{1}{5} [(-3)(-30) + 0 + (-2)(-15) + 2 \times 20 + 3 \times 25] = \frac{90 + 0 + 30 + 40 + 75}{5} = \frac{235}{5} = 47 = 5 \times 9,4$. Conforme à la prédiction.

(c) **Oui**, c'est cohérent : passer de notes sur 20 à des notes sur 100 revient à multiplier y (et x si les deux variables sont concernées) par 5 chacune, donc à multiplier leur produit par $5 \times 5 = 25$. Règle générale : si x est multipliée par a et y par b , alors $\text{cov}(ax, by) = ab \times \text{cov}(x, y)$.

Correction — Exercice 3

(a) $\bar{a} = \frac{3 + 5 + 4 + 7 + 6}{5} = 5$. $\bar{b} = \frac{10 + 14 + 11 + 18 + 17}{5} = 14$. $\bar{c} = \frac{50 + 42 + 55 + 30 + 38}{5} = 43$.

Écarts de a : -2, 0, -1, 2, 1, $V(a) = \frac{4 + 0 + 1 + 4 + 1}{5} = 2$. Écarts de b : -4, 0, -3, 4, 3, $V(b) = \frac{16 + 0 + 9 + 16 + 9}{5} = 10$. Écarts de c : 7, -1, 12, -13, -5, $V(c) = \frac{49 + 1 + 144 + 169 + 25}{5} = \frac{388}{5} = 77,6$.

(b) $\text{cov}(a, b) = \frac{(-2)(-4) + 0 + (-1)(-3) + 2 \times 4 + 1 \times 3}{5} = \frac{8 + 0 + 3 + 8 + 3}{5} = \frac{22}{5} = 4,4$. $\text{cov}(a, c) = \frac{(-2)(7) + 0 + (-1)(12) + 2(-13) + 1(-5)}{5} = \frac{-14 + 0 - 12 - 26 - 5}{5} = \frac{-57}{5} = -11,4$. $\text{cov}(b, c) = \frac{(-4)(7) + 0 + (-3)(12) + 4(-13) + 3(-5)}{5} = \frac{-28 + 0 - 36 - 52 - 15}{5} = \frac{-131}{5} = -26,2$.

(c)

$$\Sigma = \begin{pmatrix} 2 & 4,4 & -11,4 \\ 4,4 & 10 & -26,2 \\ -11,4 & -26,2 & 77,6 \end{pmatrix}$$

La matrice est bien symétrique par rapport à sa diagonale (par exemple, la case ligne 1/colonne 3 et la case ligne 3/colonne 1 valent toutes deux $-11,4$).

2 Exercices cumulatifs (introduction au chapitre 3)

Correction — Exercice 4

(a) Produits des écarts : $(-4)(-8) = 32$, $(-2)(0) = 0$, $(0)(-4) = 0$, $(2)(4) = 8$, $(4)(8) = 32$. Somme $= 72$. $\text{cov}(x, y) = \frac{72}{5} = 14,4$, conforme au cours.

(b)

$$\Sigma = \begin{pmatrix} 8 & 14,4 \\ 14,4 & 32 \end{pmatrix}$$

Symétrique : la case (1, 2) et la case (2, 1) valent toutes deux 14,4.

(c) La matrice Σ a une taille $p \times p$ qui ne dépend que du nombre de **variables**, jamais du nombre de **lignes** n du tableau initial : que le fichier compte 5 ou 500 000 clients, la matrice reste 2×2 pour deux variables. C'est une réduction **considérable** du volume d'information à manipuler (de $n \times p$ nombres à $p \times p$, et même $p(p+1)/2$ nombres distincts grâce à la symétrie). Mais ce n'est **pas encore** la réduction de dimension de l'introduction : celle-ci consiste à réduire le nombre de **variables** p elles-mêmes (en passant de p variables à 2 axes), alors que la matrice Σ conserve, elle, la totalité des p variables – elle ne fait que **résumer** les relations entre elles sous une forme compacte, qui servira justement de point de départ, au chapitre 8, pour calculer les axes qui, eux, réduiront véritablement le nombre de variables.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $\bar{x} = \frac{45 + 62 + 38 + 71 + 55 + 48}{6} \approx 53,17$ k dh. $\bar{y} = \frac{320 + 410 + 290 + 480 + 375 + 340}{6} \approx 369,17$ k dh. $\text{cov}(x, y) \approx 683,47$.

(b) **Oui** : $\text{cov}(x, y) > 0$ confirme que les régions qui dépensent le plus en marketing sont aussi, dans cet échantillon, celles qui réalisent le plus de chiffre d'affaires.

(c) **Non** : le cours est explicite – une covariance positive est une **association**, jamais une **causalité**. Il est tout à fait possible que la relation soit inverse (les régions au CA déjà élevé reçoivent davantage de budget marketing, par choix stratégique de l'entreprise) ou qu'un troisième facteur (la taille du marché régional, par exemple) explique à la fois le budget alloué et le CA réalisé, sans lien de cause à effet direct entre les deux. Conclure « il suffit d'augmenter le budget pour augmenter le CA » à partir de la seule covariance est une généralisation abusive.

Correction — Exercice 6

(a) $\bar{A} \approx 1,233$, $\bar{B} = 1,050$, $\bar{C} \approx 0,367$.

$$\Sigma \approx \begin{pmatrix} 2,676 & 0,920 & -1,892 \\ 0,920 & 0,643 & -1,025 \\ -1,892 & -1,025 & 1,836 \end{pmatrix}$$

(b) $\text{cov}(A, B) \approx 0,92 > 0$: A et B évoluent plutôt dans le même sens. $\text{cov}(A, C) \approx -1,89 < 0$ et $\text{cov}(B, C) \approx -1,03 < 0$: C évolue, lui, plutôt en **sens contraire** de A et de B. Ces signes suggèrent que A et B forment un groupe d'actifs qui « montent et descendent ensemble », tandis que C tend à faire le mouvement inverse.

(c) D'après cette matrice, combiner C avec A serait le choix le plus efficace pour réduire le risque par diversification : $\text{cov}(A, C) \approx -1,89$ est nettement plus négative que $\text{cov}(B, C) \approx -1,03$, ce qui signifie

que C « compense » davantage les mouvements de A que ceux de B – un portefeuille combinant des actifs dont les rendements varient en sens contraire (covariance négative) est, toutes choses égales par ailleurs, moins risqué qu'un portefeuille d'actifs qui bougent ensemble.