Introduction à l'analyse des données

Chapitre 3 : La covariance, généralisation de la variance

Jaouad Madkour

31 octobre 2026

Plan du chapitre

D'une variable à deux **2**
La variance, réécrite . . . 2
La définition . . . 2

Le calcul **3**
Sur le fil rouge . . . 3
Le calcul, en image . . . 3
Lire le signe de chaque produit . . . 3
La formule développée . . . 4
Ce que le signe signifie . . . 4

La variance d'une somme **5**
Combiner deux variables . . . 5
La vérification directe . . . 5
Pourquoi cette formule est au cœur du cours . . . 5
Un score moyen . . . 6

La limite de la covariance **6**
Un nombre qu'on ne sait pas interpréter . . . 6
La preuve par le fichier réel . . . 7
Le problème est celui du chapitre 2 . . . 7

Variances-covariances **8**
Ranger tous les calculs . . . 8
Ses deux propriétés, et son importance . . . 8
La matrice sur le fichier réel . . . 9
Quand les unités diffèrent . . . 9

Sur machine **10**
Avec R . . . 10
Avec Python . . . 10

S'entraîner **10**
Exercice 1 : une covariance à la main . . . 10

Exercice 1 : solution 11
Exercice 2 : somme et différence 11
Exercice 2 : solution 11
Exercice 3 : unités et signe 11
Exercice 3 : solution 12

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 12

D'une variable à deux

La variance, réécrite

Le point de départ

$$V(x) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 \;=\; \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})\,(x_i - \bar{x})$$

Écrite ainsi, la variance est la **moyenne du produit de l'écart de x par lui-même**.

La question qui vient naturellement

Si l'on peut multiplier l'écart de x par l'écart de x, rien n'interdit de le multiplier par l'écart de y.
C'est exactement ce que fait la covariance. **Elle n'est pas une notion nouvelle : c'est la variance, avec une seconde variable à la place de la première.**

La définition

La covariance

$$\mathrm{cov}(x, y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})\,(y_i - \bar{y})$$

La conséquence immédiate

$$\mathrm{cov}(x, x) = V(x) \qquad\qquad \mathrm{cov}(x, y) = \mathrm{cov}(y, x)$$

La variance est le cas particulier de la covariance d'une variable avec elle-même.
C'est le sens exact du mot « généralisation ». Et l'ordre des deux variables n'importe pas.

Le calcul

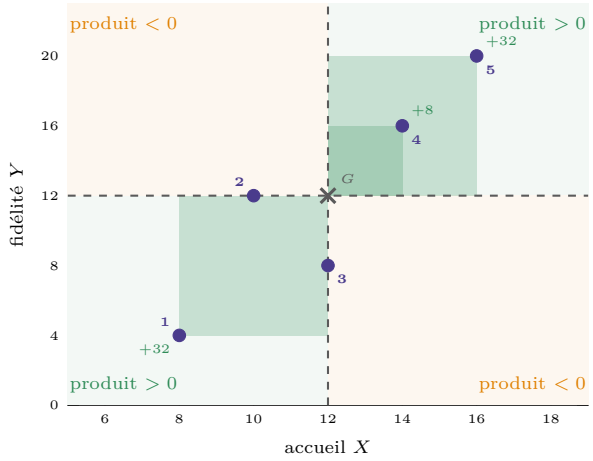
Sur le fil rouge

Produit des écarts, client par client

Client	$x_i - \bar{x}$	$y_i - \bar{y}$	Produit
1	-4	-8	$+32$
2	-2	0	0
3	0	-4	0
4	2	4	$+8$
5	4	8	$+32$
Somme	**0**	**0**	**72**

$$\mathrm{cov}(x, y) = \frac{72}{5} = 14{,}4$$

Le calcul, en image



Chaque produit est l'aire d'un rectangle

Le rectangle qui joint G au client a pour côtés ses deux écarts : son aire est leur produit, **comptée positivement** dans les quadrants verts, **négativement** dans les oranges.

Lire le signe de chaque produit

Accords et désaccords

Les clients 1 et 5 sont du même côté de la moyenne sur les deux critères — deux écarts de même signe, donc un produit **positif**. Un client au-dessus sur l'un et en dessous sur l'autre donnerait un produit **négatif**.

La covariance additionne ces accords et ces désaccords. Elle est positive lorsque les deux variables varient dans le même sens.

Les clients 2 et 3 ne comptent pas

Le client 2 est exactement à la moyenne de fidélité, le client 3 exactement à la moyenne d'accueil : un de leurs deux écarts est nul, et leur produit aussi. **Toute la covariance vient des clients 1, 4 et 5**, et les deux extrêmes en font 64 sur 72.

La formule développée

Moyenne du produit moins produit des moyennes

$$\operatorname{cov}(x,y) = \frac{1}{n}\sum_{i=1}^{n} x_i\,y_i \;-\; \bar{x}\,\bar{y}$$

C'est la formule développée de la variance du chapitre 2, avec y à la place du second x.

Démonstration : La covariance, moyenne des produits moins produit des moyennes

Développons le produit, puis sommons terme à terme :

$$\sum_i (x_i-\bar{x})(y_i-\bar{y}) = \sum_i x_i\,y_i - \bar{y}\sum_i x_i - \bar{x}\sum_i y_i + n\,\bar{x}\,\bar{y}.$$

Comme $\sum_i x_i = n\,\bar{x}$ et $\sum_i y_i = n\,\bar{y}$, les trois derniers termes valent $-n\,\bar{x}\,\bar{y} - n\,\bar{x}\,\bar{y} + n\,\bar{x}\,\bar{y} = -n\,\bar{x}\,\bar{y}$. Il reste

$$\sum_i (x_i-\bar{x})(y_i-\bar{y}) = \sum_i x_i\,y_i - n\,\bar{x}\,\bar{y},$$

et il suffit de diviser par n. Avec $y = x$, on retrouve la formule du chapitre 2 : $\operatorname{cov}(x,x) = \overline{x^2} - \bar{x}^{\,2} = V(x)$.

Sur les cinq clients, $792/5 - 12\times 12 = 158{,}4 - 144 = 14{,}4$.

■

Sur nos données

Client	1	2	3	4	5	Somme
$x_i\,y_i$	32	120	96	224	320	792

$$\operatorname{cov}(x,y) = \frac{792}{5} - 12\times 12 = 158{,}4 - 144 = 14{,}4$$

Ce que le signe signifie

Les trois cas

Signe	Lecture
$\operatorname{cov} > 0$	les deux variables varient **dans le même sens**

$\text{cov} < 0$	elles varient **en sens contraire**
$\text{cov} = 0$	**aucune liaison linéaire**

Sur nos clients

$\text{cov}(x, y) = 14{,}4 > 0$: les clients qui jugent bien l'accueil sont aussi les plus fidèles.
C'est une information de gestion immédiate — et c'est encore une **association**, non une causalité. Rien ici ne dit que soigner l'accueil produira de la fidélité.

La variance d'une somme

Combiner deux variables

La formule

$$V(x + y) = V(x) + V(y) + 2\,\text{cov}(x, y)$$
$$V(x - y) = V(x) + V(y) - 2\,\text{cov}(x, y)$$

On développe $[(x_i - \bar{x}) \pm (y_i - \bar{y})]^2$ et l'on moyenne : le double produit donne la covariance.

Sur nos cinq clients

$$V(x + y) = 8 + 32 + 2 \times 14{,}4 = 68{,}8 \qquad V(x - y) = 8 + 32 - 28{,}8 = 11{,}2$$

La vérification directe

Les sommes et les différences, client par client

Client	1	2	3	4	5	Moyenne
$x + y$	12	22	20	30	36	24
$x - y$	4	-2	4	-2	-4	0

Écarts de $x + y$: $-12, -2, -4, 6, 12$; carrés $144 + 4 + 16 + 36 + 144 = 344$, et $344/5 = 68{,}8$.
Carrés de $x - y$: $16+4+16+4+16 = 56$, et $56/5 = 11{,}2$. **Les deux formules sont exactes.**

Pourquoi cette formule est au cœur du cours

La covariance décide de ce que vaut une combinaison

Quand deux variables sont **liées positivement**, leur somme est très dispersée (68,8, bien plus que $8 + 32$) et leur différence l'est peu (11,2).
Additionner l'accueil et la fidélité **amplifie** ce qu'elles ont en commun ; les soustraire **l'annule**.

La forme générale

$$V(a\,x + b\,y) = a^2\,V(x) + b^2\,V(y) + 2ab\ \text{cov}(x, y)$$

L'ACP cherchera précisément les coefficients a et b qui rendent cette variance **maximale** :

c'est le chapitre 7.

Démonstration : La variance d'une combinaison linéaire

Posons $w_i = a\,x_i + b\,y_i$. Sa moyenne est $\bar{w} = a\,\bar{x} + b\,\bar{y}$ (chapitre 2), donc l'écart de w_i à sa moyenne est

$$w_i - \bar{w} = a\,(x_i - \bar{x}) + b\,(y_i - \bar{y}).$$

On élève au carré, on développe, et l'on moyenne sur les n individus :

$$V(w) = a^2 \underbrace{\frac{1}{n}\sum_i (x_i - \bar{x})^2}_{V(x)} + b^2 \underbrace{\frac{1}{n}\sum_i (y_i - \bar{y})^2}_{V(y)} + 2ab \underbrace{\frac{1}{n}\sum_i (x_i - \bar{x})(y_i - \bar{y})}_{\mathrm{cov}(x,y)}.$$

Les cas $(a, b) = (1, 1)$ et $(1, -1)$ donnent la somme et la différence du début du chapitre. Seul le terme $2ab\ \mathrm{cov}(x, y)$ dépend du signe de ab : avec une covariance positive, des coefficients de même signe augmentent la variance, des coefficients de signes opposés la diminuent.

Sur les cinq clients, avec $a = 2$ et $b = -1$: $4 \times 8 + 32 - 4 \times 14{,}4 = 6{,}4$. Directement, $2x - y$ prend les valeurs $12, 8, 16, 12, 12$, de moyenne 12 ; les écarts sont $0, -4, 4, 0, 0$ et la variance $32/5 = 6{,}4$.

■

Un score moyen

La moyenne des deux notes

Le score $\dfrac{x+y}{2}$ a pour variance

$$V\left(\frac{x+y}{2}\right) = \frac{1}{4}\,V(x+y) = \frac{68{,}8}{4} = 17{,}2$$

En termes de la forme générale, $a = b = \frac{1}{2}$: $\frac{1}{4} \times 8 + \frac{1}{4} \times 32 + 2 \times \frac{1}{4} \times 14{,}4 = 2 + 8 + 7{,}2 = 17{,}2$.

Ce que dit ce nombre

Le score moyen est **plus dispersé** que l'accueil seul (17,2 contre 8), parce que la fidélité y apporte sa propre dispersion et que les deux notes se renforcent. Un indicateur synthétique bien construit **conserve** les différences entre clients au lieu de les écraser.

La limite de la covariance

Un nombre qu'on ne sait pas interpréter

Quatorze virgule quatre, est-ce beaucoup ?

Impossible à dire. La covariance dépend des **unités** : elle s'exprime ici en « points d'accueil × points de fidélité », ce qui ne veut rien dire.
Si les notes d'accueil étaient sur 100 au lieu de 20, la covariance serait multipliée par 5 ; si

les deux l'étaient, par 25 — sans qu'aucune liaison ait changé.

Aucune borne

La covariance n'a ni maximum ni minimum. Elle peut valoir 0,003 ou 4 500 000 selon les grandeurs manipulées. On ne peut donc **ni la comparer d'un couple de variables à l'autre**, ni juger de la force d'une liaison à partir d'elle.

La preuve par le fichier réel

Deux covariances avec l'accueil

Paire	Covariance	Unité
panier et accueil	90,37	dirham × point
conseil et accueil	4,21	point × point

La plus grande covariance n'est pas la plus forte liaison

La covariance du panier avec l'accueil est vingt fois plus grande que celle du conseil avec l'accueil. Pourtant le conseil et l'accueil sont **bien plus liés** : leurs nuages de points le montrent, et la corrélation du chapitre 4 le chiffrera (0,73 contre 0,23).
Le panier l'emporte seulement parce qu'il se compte en **dirhams**, avec un écart-type de 166.

Le problème est celui du chapitre 2

La difficulté des unités, à nouveau

C'est exactement la difficulté déjà rencontrée avec les variances. Et le remède sera le même : **réduire**.
Diviser par les écarts-types va supprimer les unités et borner le résultat. C'est le chapitre 4, et cela donnera la corrélation.

L'effet d'un changement d'unité

$$\operatorname{cov}(a\,x,\ b\,y) = a\,b\ \operatorname{cov}(x,y)$$

Multiplier une variable par a multiplie la covariance par a. Sur nos clients, accueil noté sur 100 ($a = 5$) : cov $= 5 \times 14{,}4 = 72$.

Démonstration : La covariance dépend des unités et n'a pas de borne

Posons $x'_i = a\,x_i + c$ et $y'_i = b\,y_i + d$. Comme pour la variance, les constantes c et d disparaissent des écarts : $x'_i - \bar{x}' = a\,(x_i - \bar{x})$ et $y'_i - \bar{y}' = b\,(y_i - \bar{y})$. Donc

$$\operatorname{cov}(x', y') = \frac{1}{n}\sum_i a\,(x_i - \bar{x})\ b\,(y_i - \bar{y}) = a\,b\ \operatorname{cov}(x,y).$$

Elle n'a aucune borne. Si $\operatorname{cov}(x,y) \neq 0$, alors $|\operatorname{cov}(k\,x, y)| = |k|\,|\operatorname{cov}(x,y)|$ dépasse n'importe quel nombre donné quand on choisit k assez grand : aucune valeur de covariance ne peut

passer pour « grande » en elle-même.

Le paradoxe du fichier réel. La covariance du panier avec l'accueil est 90,37 (dirhams × points), celle du conseil avec l'accueil 4,21 (points × points) : la première est vingt et une fois plus grande. Comptons maintenant le panier en milliers de dirhams ($a = 1/1000$) : sa covariance avec l'accueil devient 0,090, plus de quarante fois **plus petite** que 4,21. Le classement s'est inversé sans qu'aucun client ait changé : il n'a fait que suivre l'unité.

■

Variances-covariances

Ranger tous les calculs

La matrice

Avec p variables, on range les variances sur la **diagonale** et les covariances ailleurs :

$$\Sigma = \begin{pmatrix} V(x_1) & \operatorname{cov}(x_1, x_2) & \cdots \\ \operatorname{cov}(x_2, x_1) & V(x_2) & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

Sur le fil rouge

$$\Sigma = \begin{pmatrix} 8 & 14{,}4 \\ 14{,}4 & 32 \end{pmatrix}$$

La diagonale porte les variances du chapitre 2 ; les deux autres cases portent la covariance.

Ses deux propriétés, et son importance

Deux propriétés

1. Elle est **symétrique**, puisque $\operatorname{cov}(x, y) = \operatorname{cov}(y, x)$.
2. Sa **diagonale** contient les variances — c'est encore la même identité $\operatorname{cov}(x, x) = V(x)$.

Pourquoi cet objet compte

Cette matrice contient **tout ce que l'analyse va utiliser**. Les axes du chapitre 8 s'en déduisent entièrement.
Un tableau de trois cents lignes et huit colonnes se résume donc à une matrice de huit sur huit, dont 8 variances et 28 covariances. C'est déjà, en soi, une réduction considérable.

Démonstration : La matrice de variances-covariances donne la variance de toute combinaison

Pour deux variables, la variance de $a\,x + b\,y$ (démonstration précédente) s'écrit avec Σ :

$$V(a\,x + b\,y) = \begin{pmatrix} a & b \end{pmatrix} \begin{pmatrix} V(x) & \operatorname{cov}(x, y) \\ \operatorname{cov}(x, y) & V(y) \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = a^2\,V(x) + 2ab\,\operatorname{cov}(x, y) + b^2\,V(y).$$

Pour p variables, l'idée est la même : l'écart de $\sum_j a_j\,x_j$ à sa moyenne est $\sum_j a_j\,(x_j - \bar{x}_j)$, et

le carré d'une somme est la somme de tous les produits deux à deux. En moyennant,

$$V\left(\sum_{j=1}^{p} a_j\, x_j\right) = \sum_{j=1}^{p}\sum_{k=1}^{p} a_j\, a_k\, \operatorname{cov}(x_j, x_k) = a'\,\Sigma\, a.$$

Les p variances et les $p(p-1)/2$ covariances de Σ suffisent donc à calculer la variance de n'importe quelle combinaison : $8 + 28 = 36$ nombres pour huit notes, quel que soit le nombre de clients. Et comme une variance n'est jamais négative, $a'\,\Sigma\, a \geq 0$ pour tous les a.

Exemple. La note moyenne des huit critères est la combinaison $a_j = 1/8$: sa variance est la somme des 64 cases de Σ divisée par 64, soit 3,24, sans retourner au tableau des trois cents clients.

■

La matrice sur le fichier réel

Quatre notes de satisfaction

	prix	qualité	conseil	accueil
prix	5,76	3,83	0,86	0,51
qualité	3,83	5,75	2,09	2,03
conseil	0,86	2,09	5,76	4,21
accueil	0,51	2,03	4,21	5,75

Deux blocs apparaissent déjà

Les quatre notes ont la même variance (environ 5,76), si bien que les covariances se comparent ici : **prix et qualité** vont ensemble (3,83), **conseil et accueil** aussi (4,21), et les deux paires se lient peu. Ce sont l'offre et le service de l'introduction.

Quand les unités diffèrent

Panier, âge, ancienneté, accueil

	panier	âge	ancienneté	accueil
panier	27 655	488,4	−27,8	90,4
âge	488,4	147,2	−1,2	0,8
ancienneté	−27,8	−1,2	9,5	1,1
accueil	90,4	0,8	1,1	5,75

Une matrice illisible

Les cases de la ligne du panier sont énormes **parce que le panier est en dirhams**, non parce qu'il est très lié aux autres. Seuls les **signes** se lisent : l'ancienneté varie légèrement en

sens inverse du panier. Il faut réduire avant de comparer.

Sur machine

Avec R

Le code et sa sortie

```r
x <- c(8, 10, 12, 14, 16)
y <- c(4, 12, 8, 16, 20)
cov(x, y)                                    # [1] 18
mean((x - mean(x)) * (y - mean(y)))          # [1] 14.4
clients <- read.csv("clients.csv")
round(cov(clients[, c("panier", "accueil")]) * 299 / 300, 2)
#           panier accueil
# panier  27655.17   90.37
# accueil    90.37    5.75
```

Toujours le diviseur n moins un

`cov` divise par $n-1$: $72/4 = 18$. Multiplier par $(n-1)/n$ retrouve la convention du cours.

Avec Python

np.cov renvoie la matrice entière ; bias=True divise par n

```python
import numpy as np
import pandas as pd
x = np.array([8, 10, 12, 14, 16])
y = np.array([4, 12, 8, 16, 20])
print(np.cov(x, y, bias=True))
# [[ 8.  14.4]
#  [14.4 32. ]]
clients = pd.read_csv("clients.csv")
print(clients[["panier", "accueil"]].cov(ddof=0).round(2))
#            panier  accueil
# panier   27655.17    90.37
# accueil     90.37     5.75
```

S'entraîner

Exercice 1 : une covariance à la main

Quatre magasins

Quatre magasins : surface x (centaines de m²) et chiffre d'affaires y (millions de dirhams).

Magasin	A	B	C	D
x	2	4	6	8
y	3	5	4	8

1. Calculer les moyennes, puis la covariance par les écarts.
2. Retrouver la covariance par la formule développée.
3. Écrire la matrice des variances-covariances.

Exercice 1 : solution

Covariance 3,5

1. $\bar{x} = 5$, $\bar{y} = 5$. Écarts : x : $-3, -1, 1, 3$; y : $-2, 0, -1, 3$. Produits : $6 + 0 - 1 + 9 = 14$, donc cov $= 14/4 = 3{,}5$.
2. $\sum x_i y_i = 6 + 20 + 24 + 64 = 114$; $114/4 - 25 = 28{,}5 - 25 = 3{,}5$.
3. $V(x) = (9 + 1 + 1 + 9)/4 = 5$; $V(y) = (4 + 0 + 1 + 9)/4 = 3{,}5$:

$$\Sigma = \begin{pmatrix} 5 & 3{,}5 \\ 3{,}5 & 3{,}5 \end{pmatrix}$$

Exercice 2 : somme et différence

Deux variables liées négativement

Deux notes ont pour variances $V(x) = 9$ et $V(y) = 4$, et pour covariance $\text{cov}(x, y) = -3$.

1. Calculer $V(x + y)$ et $V(x - y)$.
2. Calculer la variance du score $2x + y$.
3. Pourquoi $V(x + y)$ est-il ici plus petit que $V(x) + V(y)$?

Exercice 2 : solution

Une covariance négative réduit la somme

1. $V(x + y) = 9 + 4 - 6 = 7$; $V(x - y) = 9 + 4 + 6 = 19$.
2. $V(2x + y) = 4 \times 9 + 4 + 2 \times 2 \times (-3) = 36 + 4 - 12 = 28$.
3. Les deux variables varient **en sens contraire** : quand l'une est haute, l'autre tend à être basse, et leurs écarts se **compensent** dans la somme. C'est la situation inverse de nos cinq clients.

Exercice 3 : unités et signe

Deux covariances à interpréter

Sur un fichier de clients, on obtient $\text{cov}(\text{panier}, \text{âge}) = 488$ (dirhams $\times$ années) et $\text{cov}(\text{ancienneté}, \text{panier}) = -27{,}8$.

1. Que devient la première covariance si le panier est compté en milliers de dirhams ?
2. Peut-on dire que le panier est plus lié à l'âge qu'à l'ancienneté ?
3. Que dit le signe de la seconde ?

Exercice 3 : solution

Le signe se lit, la valeur non

1. Elle est divisée par 1 000 : 0,488. La liaison, elle, n'a pas changé.
2. **Non**. Les deux covariances sont bien en dirhams × années, mais chacune dépend de l'écart-type de sa variable : 12,1 ans pour l'âge, 3,1 pour l'ancienneté. Seule la corrélation du chapitre 4, sans unité, permet la comparaison.
3. Négative : les clients anciens ont en moyenne un panier un peu **plus faible**. C'est tout ce qu'on peut lire — et c'est une association, non une explication.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La covariance est la **moyenne du produit des écarts** aux deux moyennes ; elle **généralise la variance** : $\mathrm{cov}(x, x) = V(x)$.
2. Sur le fil rouge, $\mathrm{cov}(x, y) = 72/5 = \mathbf{14{,}4}$, ou $158{,}4 - 144$ par la formule développée.
3. $V(x \pm y) = V(x) + V(y) \pm 2\,\mathrm{cov}(x, y)$: 68,8 et 11,2 sur nos clients.
4. Son **signe** s'interprète ; sa **valeur**, non : elle dépend des unités et n'est pas bornée.
5. La **matrice des variances-covariances** est symétrique et porte les variances sur sa diagonale.
6. R et `pandas` divisent par $n - 1$; `np.cov(..., bias=True)` par n.

La suite

Rendre ce nombre lisible

Le chapitre 4 divise la covariance par les écarts-types — et obtient une mesure sans unité, bornée entre -1 et $+1$: la corrélation.

Ce qu'on y calculera

Sur nos cinq clients, $14{,}4/(\sqrt{8}\sqrt{32}) = 14{,}4/16 = 0{,}9$ exactement. Et l'on comprendra enfin pourquoi le panier, malgré sa covariance de 90, est à peine lié à l'accueil.