

Introduction à l'analyse des données

Chapitre 3 : La covariance, généralisation de la variance

Jaouad Madkour

24 septembre 2026

Plan du chapitre

D'une variable à deux	1
La variance, réécrite	1
Le calcul	2
Sur le fil rouge	2
Lire le signe de chaque produit	2
Ce que le signe signifie	2
La limite de la covariance	3
Un nombre qu'on ne sait pas interpréter	3
Variances-covariances	3
Ranger tous les calculs	3
Ce qu'il faut retenir	4
Le résumé du chapitre	4

D'une variable à deux

La variance, réécrite

Le point de départ

$$V(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(x_i - \bar{x})$$

Écris ainsi, la variance est la **moyenne du produit de l'écart de x par lui-même**.

La question qui vient naturellement

Si l'on peut multiplier l'écart de x par l'écart de x , rien n'interdit de le multiplier par l'écart de y .

C'est exactement ce que fait la covariance. **Elle n'est pas une notion nouvelle : c'est la variance, avec une seconde variable à la place de la première.**

La covariance

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

La conséquence immédiate

$$\text{cov}(x, x) = V(x)$$

La variance est le cas particulier de la covariance d'une variable avec elle-même. C'est le sens exact du mot « généralisation ».

Le calcul

Sur le fil rouge

Produit des écarts, client par client

Client	$x_i - \bar{x}$	$y_i - \bar{y}$	Produit
1	-4	-8	+32
2	-2	0	0
3	0	-4	0
4	2	4	+8
5	4	8	+32
Somme			72

$$\text{cov}(x, y) = \frac{72}{5} = 14,4$$

Lire le signe de chaque produit

Intuition

Les clients 1 et 5 sont du même côté de la moyenne sur les deux critères — deux écarts de même signe, donc un produit **positif**. Un client au-dessus sur l'un et en dessous sur l'autre donnerait un produit **négatif**.

La covariance additionne ces accords et ces désaccords. Elle est positive lorsque les deux variables varient dans le même sens.

Ce que le signe signifie

Les trois cas

Signe	Lecture
$\text{cov} > 0$	les deux variables varient dans le même sens
$\text{cov} < 0$	elles varient en sens contraire

$\text{cov} = 0$

aucune liaison linéaire

Sur nos clients

$\text{cov}(x, y) = 14,4 > 0$: les clients qui jugent bien l'accueil sont aussi les plus fidèles.
C'est une information de gestion immédiate — et c'est encore une **association**, non une causalité. Rien ici ne dit que soigner l'accueil produira de la fidélité.

La limite de la covariance

Un nombre qu'on ne sait pas interpréter

Quatorze virgule quatre, est-ce beaucoup ?

Impossible à dire. La covariance dépend des **unités** : elle s'exprime ici en « points d'accueil $\times$ points de fidélité », ce qui ne veut rien dire.

Si les notes étaient sur 100 au lieu de 20, la covariance serait multipliée par 25 — sans qu'aucune liaison ait changé.

Aucune borne

La covariance n'a ni maximum ni minimum. Elle peut valoir 0,003 ou 4 500 000 selon les grandeurs manipulées.

On ne peut donc **ni la comparer d'un couple de variables à l'autre**, ni juger de la force d'une liaison à partir d'elle.

Le problème est celui du chapitre 2

C'est exactement la difficulté des unités déjà rencontrée. Et le remède sera le même : **réduire**.

Diviser par les écarts-types va supprimer les unités et borner le résultat. C'est le chapitre 4, et cela donnera la corrélation.

Variances-covariances

Ranger tous les calculs

La matrice

Avec p variables, on range les variances sur la **diagonale** et les covariances ailleurs :

$$\Sigma = \begin{pmatrix} V(x_1) & \text{cov}(x_1, x_2) & \cdots \\ \text{cov}(x_2, x_1) & V(x_2) & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

Sur le fil rouge

$$\Sigma = \begin{pmatrix} 8 & 14,4 \\ 14,4 & 32 \end{pmatrix}$$

La diagonale porte les variances du chapitre 2 ; les deux autres cases portent la covariance.

Deux propriétés

1. Elle est **symétrique**, puisque $\text{cov}(x, y) = \text{cov}(y, x)$.
2. Sa **diagonale** contient les variances — c'est encore la même identité $\text{cov}(x, x) = V(x)$.

Pourquoi cet objet compte

Cette matrice contient **tout ce que l'analyse va utiliser**. Les axes du chapitre 8 s'en déduisent entièrement.

Un tableau de trois cents lignes et douze colonnes se résume donc à une matrice de douze sur douze. C'est déjà, en soi, une réduction considérable.

Ce qu'il faut retenir

Le résumé du chapitre

Cinq points

1. La covariance est la **moyenne du produit des écarts** aux deux moyennes.
2. Elle **généralise la variance** : $\text{cov}(x, x) = V(x)$.
3. Sur le fil rouge, $\text{cov}(x, y) = 72/5 = \mathbf{14,4}$ — positive.
4. Son **signe** s'interprète ; sa **valeur**, non : elle dépend des unités et n'est pas bornée.
5. La **matrice des variances-covariances** est symétrique et porte les variances sur sa diagonale.

La suite

Il reste à rendre ce nombre lisible. Le chapitre 4 le divise par les écarts-types — et obtient une mesure bornée entre -1 et $+1$.