

Chapitre 1

De la statistique descriptive à l'analyse des données

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données


1 Exercices du chapitre

Correction — Exercice 1

$$(a) \quad \bar{x} = \frac{6+8+5+9}{4} = 7. \quad \bar{y} = \frac{7+8+6+9}{4} = 7,5. \quad V(x) = \frac{(6-7)^2 + (8-7)^2 + (5-7)^2 + (9-7)^2}{4} = \frac{1+1+4+4}{4} = 2,5. \quad V(y) = \frac{0,25+0,25+2,25+2,25}{4} = 1,25.$$

$$(b) \quad \text{cov}(x, y) = \frac{(-1)(-0,5) + (1)(0,5) + (-2)(-1,5) + (2)(1,5)}{4} = \frac{0,5+0,5+3+3}{4} = 1,75. \quad r = \frac{1,75}{\sqrt{2,5 \times 1,25}} = \frac{1,75}{1,7678} \approx 0,990.$$

(c) Ce n'est pas le **calcul** qui pose problème (les formules de moyenne, variance et covariance s'appliquent sans difficulté à trente variables), mais la **représentation graphique** : un nuage de points bivarié tient sur une feuille en deux dimensions, alors qu'un nuage à trente dimensions ne peut, par construction, ni se dessiner ni se « voir » directement. C'est précisément l'écart entre « mesurer » (toujours possible) et « représenter » (impossible au-delà de deux ou trois variables) que ce cours va combler.



Correction — Exercice 2

(a) **Faux** : le cours est explicite – « ce cours n'introduit aucune notion statistique nouvelle ». La moyenne, la variance, la covariance, la corrélation sont déjà toutes connues ; seul change le nombre de variables traitées ensemble.

(b) **Vrai** : c'est exactement la distinction posée par le cours entre les deux démarches.

(c) **Faux** : le cours affirme sans ambiguïté que ce cours ne comporte « aucune loi de probabilité, aucun test, aucune p -value » ; un intervalle de confiance est un objet de statistique **inférentielle**, hors du champ de ce cours.

(d) **Vrai** : c'est exactement la répartition annoncée dans le plan du cours (chapitres 8-12 pour l'ACP, quantitatives ; chapitres 13-14 pour l'AFC, qualitatives).

Correction — Exercice 3

(a) Il a enfreint la règle selon laquelle « l'exploration vient avant » l'inférence, « jamais après sur les mêmes données » – il a testé une hypothèse (l'existence d'un groupe différent) sur les données mêmes qui la lui avaient suggérée.

(b) Le calcul du test est arithmétiquement correct, mais ses **prémisses** sont violées : un test suppose que l'hypothèse testée a été formulée **indépendamment** des données utilisées pour la tester. Ici, le groupe a été « choisi » par le graphique précisément parce qu'il semblait se détacher du reste – la p -value obtenue sous-estime donc systématiquement le risque réel de conclure à tort, exactement comme choisir la forme d'un test après avoir vu le signe de l'écart observé (vu dans le cours de statistique

inférentielle).

(c) Il faudrait confirmer l'existence de ce groupe sur un **nouvel** échantillon de clients, indépendant de celui qui a servi à le repérer – ou, à défaut, réserver dès le départ une partie du fichier initial à cette seule confirmation, sans jamais l'utiliser pour l'exploration.

2 Exercices cumulatifs (introduction et chapitre 1)

Correction — Exercice 4

(a) $\binom{9}{2} = \frac{9 \times 8}{2} = 36$ nuages de points bivariés pour les 9 variables quantitatives.

(b) Il faudrait recourir à l'**analyse en composantes principales** (chapitres 8-12) pour les 9 variables quantitatives, et à l'**analyse des correspondances** (chapitres 13-14) pour les 3 variables qualitatives – les deux méthodes fondatrices annoncées dans le plan du cours, chacune adaptée à un type de variables.

(c) Comme pour le chameau, la photographie (ici, le graphique obtenu par l'une ou l'autre méthode) ne montre qu'une **projection** des données, choisie pour être la plus lisible possible – elle **suggère** des structures, elle ne les **prouve** pas. Affirmer que « les clients qui ont beaucoup de sinistres sont significativement moins anciens » emploie le mot « significativement », qui appartient au vocabulaire de l'inférence : ce cours étant exploratoire (ni loi, ni test, ni p -value), une telle affirmation nécessiterait un test formel, mené sur des données indépendantes de celles ayant servi à repérer la structure – exactement la mise en garde de l'exercice 3.

3 Applications en sciences économiques

Correction — Exercice 5

(a) La question (1) (« des profils qui n'apparaissent pas dans nos catégories habituelles ») est **exploratoire** : elle ne pose aucune hypothèse préalable, elle cherche à faire émerger une structure inconnue. La question (2) (« le taux de défaut du BTP est-il significativement supérieur ») est **inférentielle** : elle pose une hypothèse précise (H_0 : pas de différence) et demande un verdict avec un risque d'erreur mesuré – le mot « significativement » en est la signature.

(b) Il faudrait traiter la question (1) **avant** la question (2) : l'exploration permettrait éventuellement de repérer, sans a priori, des profils de risque – dont le secteur BTP pourrait ou non faire partie – avant de formuler et tester une hypothèse précise. Tester (2) en premier, sur les mêmes données, puis « explorer » pour confirmer le résultat obtenu inverserait l'ordre méthodologique recommandé par le cours.


(c) Un intervalle de confiance est un objet **inférentiel**, qui suppose un modèle probabiliste et un risque d'erreur contrôlé ; l'analyse exploratoire, par construction, n'en calcule aucun – elle décrit un nuage de points, elle ne l'assortit d'aucune marge d'erreur statistique, ce que le cours rappelle explicitement (« aucune loi de probabilité, aucun intervalle de confiance »).

Correction — Exercice 6

(a) **Oui** : avec seulement deux variables, un simple nuage de points en deux dimensions suffit à « voir » entièrement la relation entre les cinq clients, sans qu'aucune méthode de réduction de dimension ne soit nécessaire. Dès qu'une **troisième** variable s'ajoute (par exemple l'ancienneté), le nuage cesse de suffire à montrer, sur une simple feuille, l'ensemble des relations entre les trois variables à la fois.

(b) Un exemple aussi réduit permet de suivre **à la main**, sans calculatrice ni logiciel, chacune des étapes du cours (moyenne, variance, variable centrée réduite, covariance, corrélation, inertie, axes, pourcentage d'inertie expliquée) et d'en **vérifier** soi-même chaque résultat – ce que le cours annonce explicitement (« ce qui permet de vérifier chaque étape soi-même plutôt que de la croire »). Une fois la logique acquise sur cinq clients, elle s'applique sans changement à un tableau de cinq cents lignes –

seul le calcul, pas la méthode, change d'échelle.



(c) On peut raisonnablement anticiper que, sur seulement **deux** variables, un unique axe bien choisi (une combinaison de l'accueil et de la fidélité) devrait pouvoir résumer la **quasi-totalité** de l'inertie du nuage – puisqu'avec deux variables, il n'existe au maximum que deux axes possibles, et que le premier, choisi pour capter le plus d'inertie possible, en captera nécessairement la part la plus importante. Le pourcentage d'inertie expliquée par ce premier axe devrait donc être élevé, sans doute proche de 100 % si les deux variables sont fortement corrélées – ce que les chapitres 6 à 8 permettront de vérifier précisément.