

Introduction à l'analyse des données

Chapitre 1 : De la statistique descriptive à l'analyse des données

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Réviser à deux variables, avant d'en affronter davantage

Quatre clients d'une agence de voyages sont notés sur deux critères, de 0 à 10 : la clarté du devis (x) et la satisfaction globale (y).

Client	1	2	3	4
x (clarté)	6	8	5	9
y (satisfaction)	7	8	6	9

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x)$ et $V(y)$ (variances au sens de la statistique descriptive, dénominateur n).
- (b) Calculer $\text{cov}(x, y)$ et le coefficient de corrélation $r = \text{cov}(x, y) / (\sigma_x \sigma_y)$.
- (c) Ces quatre calculs appartiennent tous au cours de statistique descriptive, pour **deux** variables. Le cours affirme qu'« une moyenne, une covariance se calculent aussi bien sur trente variables ». Qu'est-ce qui, alors, empêche réellement de « voir » la relation entre trente variables de la même façon qu'on vient de le faire ici pour deux ?

Exercice 2 — Vrai ou faux : descriptive et inférentielle

Pour chacune des affirmations suivantes, dire si elle est vraie ou fausse, et justifier en une phrase.

- (a) « Ce cours d'analyse des données introduit de nouvelles notions statistiques, propres au cas de plusieurs variables. »
- (b) « La statistique inférentielle part d'une hypothèse posée d'avance ; la statistique exploratoire n'en pose aucune. »
- (c) « On peut légitimement calculer, dans ce cours, un intervalle de confiance pour situer la position d'un groupe de clients sur un graphique. »
- (d) « L'analyse en composantes principales (chapitres 8 à 12) et l'analyse des correspondances (chapitres 13 à 14) traitent, respectivement, des variables quantitatives et des variables qualitatives. »

Exercice 3 — Repérer la faute de méthode

Un analyste applique une méthode exploratoire à son fichier clients et observe sur le graphique obtenu un groupe de points nettement séparé du reste du nuage. Il calcule alors, sur ce même fichier, un test comparant la moyenne de ce groupe à celle du reste des clients, et obtient une p -value très faible qu'il présente comme la preuve que ce groupe est « statistiquement différent ».

- (a) Quelle règle méthodologique, énoncée dans ce chapitre, cet analyste a-t-il enfreinte ?
- (b) Pourquoi la p -value obtenue de cette façon est-elle trompeuse, alors même que le calcul du test lui-même ne comporte aucune erreur arithmétique ?
- (c) Proposer une démarche correcte pour confirmer, ou infirmer, l'existence de ce groupe.

2 Exercices cumulatifs (introduction et chapitre 1)

Exercice 4 — De la photographie du chameau au plan du cours

Une compagnie d'assurance dispose d'un fichier de 400 clients, décrits par 9 variables quantitatives (prime annuelle, ancienneté, nombre de sinistres, etc.) et 3 variables qualitatives (type de contrat, région, canal de souscription).

- (a) En ne considérant que les 9 variables quantitatives, calculer le nombre de nuages de points bivariés qu'un examen exhaustif exigerait (formule de l'introduction).

- (b) Ce fichier mélangeant variables quantitatives et qualitatives, à quelles deux méthodes du plan du cours (rappelé au chapitre 1) faudrait-il, en principe, recourir pour l'explorer complètement – une pour chaque type de variables ?
- (c) En reliant l'analogie du chameau (introduction) à la mise en garde de ce chapitre sur l'inférence, expliquer pourquoi la compagnie aurait tort de conclure, à la seule vue d'une structure repérée sur le graphique obtenu par l'une de ces deux méthodes, que « les clients qui ont beaucoup de sinistres sont significativement moins anciens » sans autre vérification.

3 Applications en sciences économiques

Exercice 5 — Choisir le bon outil, au bon moment

Le service des études économiques d'une banque doit répondre à deux questions distinctes concernant sa clientèle d'entreprises : (1) « Existe-t-il, parmi nos 250 entreprises clientes, des profils de risque qui n'apparaissent pas dans nos catégories de classement habituelles ? » et (2) « Le taux de défaut moyen des entreprises du secteur « BTP » est-il significativement supérieur à celui de l'ensemble du portefeuille ? »

- (a) Pour chacune des deux questions, indiquer si elle relève de la démarche exploratoire (ce cours) ou de la démarche inférentielle (cours de statistique inférentielle), et justifier.
- (b) Dans quel ordre le service des études aurait-il intérêt à traiter ces deux questions si elles portaient, en réalité, sur le *même* sous-ensemble de données ? Justifier à l'aide du cours.
- (c) Le directeur des risques s'étonne : « pourquoi ne pas simplement laisser le logiciel calculer directement un intervalle de confiance sur le graphique de l'analyse exploratoire, plutôt que de refaire un test séparé ? ». Expliquer, en une phrase, pourquoi cette demande n'a pas de sens dans le cadre de ce cours.

Exercice 6 — Le fil rouge à venir, en anticipation

Le cours annonce qu'un fil rouge de « cinq clients, notés sur deux critères – l'accueil et la fidélité », traversera l'ensemble des quatorze chapitres, permettant de calculer « à la main » la moyenne, la variance, la variable centrée réduite, la covariance, la corrélation, l'inertie, les axes et le pourcentage d'inertie expliquée.

- (a) Sur ces deux seules variables (accueil, fidélité), un simple nuage de points suffirait-il à « voir » la relation entre les cinq clients ? À partir de quel nombre de variables supplémentaires ce même nuage cesserait-il de suffire ?
- (b) Pourquoi un exemple aussi « minuscule » (cinq clients, deux variables) est-il pédagogiquement utile pour un cours qui prépare, en réalité, à traiter des tableaux beaucoup plus grands ?
- (c) En anticipant sur le plan du cours (chapitres 6 à 7 : le nuage et l'inertie ; chapitres 8 à 12 : l'ACP), formuler une hypothèse sur ce que pourrait signifier, intuitivement, « le pourcentage d'inertie expliquée » par un premier axe, dans le cas de ce fil rouge à seulement deux variables.


1 Exercices du chapitre

Correction — Exercice 1

$$(a) \quad \bar{x} = \frac{6+8+5+9}{4} = 7. \quad \bar{y} = \frac{7+8+6+9}{4} = 7,5. \quad V(x) = \frac{(6-7)^2 + (8-7)^2 + (5-7)^2 + (9-7)^2}{4} = \frac{1+1+4+4}{4} = 2,5. \quad V(y) = \frac{0,25 + 0,25 + 2,25 + 2,25}{4} = 1,25.$$

$$(b) \quad \text{cov}(x, y) = \frac{(-1)(-0,5) + (1)(0,5) + (-2)(-1,5) + (2)(1,5)}{4} = \frac{0,5 + 0,5 + 3 + 3}{4} = 1,75. \quad r = \frac{1,75}{\sqrt{2,5 \times 1,25}} = \frac{1,75}{1,7678} \approx 0,990.$$

(c) Ce n'est pas le **calcul** qui pose problème (les formules de moyenne, variance et covariance s'appliquent sans difficulté à trente variables), mais la **représentation graphique** : un nuage de points bivarié tient sur une feuille en deux dimensions, alors qu'un nuage à trente dimensions ne peut, par construction, ni se dessiner ni se « voir » directement. C'est précisément l'écart entre « mesurer » (toujours possible) et « représenter » (impossible au-delà de deux ou trois variables) que ce cours va combler.



Correction — Exercice 2

(a) **Faux** : le cours est explicite – « ce cours n'introduit aucune notion statistique nouvelle ». La moyenne, la variance, la covariance, la corrélation sont déjà toutes connues ; seul change le nombre de variables traitées ensemble.

(b) **Vrai** : c'est exactement la distinction posée par le cours entre les deux démarches.

(c) **Faux** : le cours affirme sans ambiguïté que ce cours ne comporte « aucune loi de probabilité, aucun test, aucune p -value » ; un intervalle de confiance est un objet de statistique **inférentielle**, hors du champ de ce cours.

(d) **Vrai** : c'est exactement la répartition annoncée dans le plan du cours (chapitres 8-12 pour l'ACP, quantitatives ; chapitres 13-14 pour l'AFC, qualitatives).

Correction — Exercice 3

(a) Il a enfreint la règle selon laquelle « l'exploration vient avant » l'inférence, « jamais après sur les mêmes données » – il a testé une hypothèse (l'existence d'un groupe différent) sur les données mêmes qui la lui avaient suggérée.

(b) Le calcul du test est arithmétiquement correct, mais ses **prémisses** sont violées : un test suppose que l'hypothèse testée a été formulée **indépendamment** des données utilisées pour la tester. Ici, le groupe a été « choisi » par le graphique précisément parce qu'il semblait se détacher du reste – la p -value obtenue sous-estime donc systématiquement le risque réel de conclure à tort, exactement comme choisir la forme d'un test après avoir vu le signe de l'écart observé (vu dans le cours de statistique

inférentielle).

(c) Il faudrait confirmer l'existence de ce groupe sur un **nouvel** échantillon de clients, indépendant de celui qui a servi à le repérer – ou, à défaut, réserver dès le départ une partie du fichier initial à cette seule confirmation, sans jamais l'utiliser pour l'exploration.

2 Exercices cumulatifs (introduction et chapitre 1)

Correction — Exercice 4

(a) $\binom{9}{2} = \frac{9 \times 8}{2} = 36$ nuages de points bivariés pour les 9 variables quantitatives.

(b) Il faudrait recourir à l'**analyse en composantes principales** (chapitres 8-12) pour les 9 variables quantitatives, et à l'**analyse des correspondances** (chapitres 13-14) pour les 3 variables qualitatives – les deux méthodes fondatrices annoncées dans le plan du cours, chacune adaptée à un type de variables.

(c) Comme pour le chameau, la photographie (ici, le graphique obtenu par l'une ou l'autre méthode) ne montre qu'une **projection** des données, choisie pour être la plus lisible possible – elle **suggère** des structures, elle ne les **prouve** pas. Affirmer que « les clients qui ont beaucoup de sinistres sont significativement moins anciens » emploie le mot « significativement », qui appartient au vocabulaire de l'inférence : ce cours étant exploratoire (ni loi, ni test, ni p -value), une telle affirmation nécessiterait un test formel, mené sur des données indépendantes de celles ayant servi à repérer la structure – exactement la mise en garde de l'exercice 3.

3 Applications en sciences économiques

Correction — Exercice 5

(a) La question (1) (« des profils qui n'apparaissent pas dans nos catégories habituelles ») est **exploratoire** : elle ne pose aucune hypothèse préalable, elle cherche à faire émerger une structure inconnue. La question (2) (« le taux de défaut du BTP est-il significativement supérieur ») est **inférentielle** : elle pose une hypothèse précise (H_0 : pas de différence) et demande un verdict avec un risque d'erreur mesuré – le mot « significativement » en est la signature.

(b) Il faudrait traiter la question (1) **avant** la question (2) : l'exploration permettrait éventuellement de repérer, sans a priori, des profils de risque – dont le secteur BTP pourrait ou non faire partie – avant de formuler et tester une hypothèse précise. Tester (2) en premier, sur les mêmes données, puis « explorer » pour confirmer le résultat obtenu inverserait l'ordre méthodologique recommandé par le cours.


(c) Un intervalle de confiance est un objet **inférentiel**, qui suppose un modèle probabiliste et un risque d'erreur contrôlé ; l'analyse exploratoire, par construction, n'en calcule aucun – elle décrit un nuage de points, elle ne l'assortit d'aucune marge d'erreur statistique, ce que le cours rappelle explicitement (« aucune loi de probabilité, aucun intervalle de confiance »).

Correction — Exercice 6

(a) **Oui** : avec seulement deux variables, un simple nuage de points en deux dimensions suffit à « voir » entièrement la relation entre les cinq clients, sans qu'aucune méthode de réduction de dimension ne soit nécessaire. Dès qu'une **troisième** variable s'ajoute (par exemple l'ancienneté), le nuage cesse de suffire à montrer, sur une simple feuille, l'ensemble des relations entre les trois variables à la fois.

(b) Un exemple aussi réduit permet de suivre **à la main**, sans calculatrice ni logiciel, chacune des étapes du cours (moyenne, variance, variable centrée réduite, covariance, corrélation, inertie, axes, pourcentage d'inertie expliquée) et d'en **vérifier** soi-même chaque résultat – ce que le cours annonce explicitement (« ce qui permet de vérifier chaque étape soi-même plutôt que de la croire »). Une fois la logique acquise sur cinq clients, elle s'applique sans changement à un tableau de cinq cents lignes –

seul le calcul, pas la méthode, change d'échelle.



(c) On peut raisonnablement anticiper que, sur seulement **deux** variables, un unique axe bien choisi (une combinaison de l'accueil et de la fidélité) devrait pouvoir résumer la **quasi-totalité** de l'inertie du nuage – puisqu'avec deux variables, il n'existe au maximum que deux axes possibles, et que le premier, choisi pour capter le plus d'inertie possible, en captera nécessairement la part la plus importante. Le pourcentage d'inertie expliquée par ce premier axe devrait donc être élevé, sans doute proche de 100 % si les deux variables sont fortement corrélées – ce que les chapitres 6 à 8 permettront de vérifier précisément.