

Chapitre 1

De la statistique descriptive à l'analyse des données

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Réviser à deux variables, avant d'en affronter davantage

Quatre clients d'une agence de voyages sont notés sur deux critères, de 0 à 10 : la clarté du devis (x) et la satisfaction globale (y).

Client	1	2	3	4
x (clarté)	6	8	5	9
y (satisfaction)	7	8	6	9

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x)$ et $V(y)$ (variances au sens de la statistique descriptive, dénominateur n).
- (b) Calculer $\text{cov}(x, y)$ et le coefficient de corrélation $r = \text{cov}(x, y) / (\sigma_x \sigma_y)$.
- (c) Ces quatre calculs appartiennent tous au cours de statistique descriptive, pour **deux** variables. Le cours affirme qu'« une moyenne, une covariance se calculent aussi bien sur trente variables ». Qu'est-ce qui, alors, empêche réellement de « voir » la relation entre trente variables de la même façon qu'on vient de le faire ici pour deux ?

Exercice 2 — Vrai ou faux : descriptive et inférentielle

Pour chacune des affirmations suivantes, dire si elle est vraie ou fausse, et justifier en une phrase.

- (a) « Ce cours d'analyse des données introduit de nouvelles notions statistiques, propres au cas de plusieurs variables. »
- (b) « La statistique inférentielle part d'une hypothèse posée d'avance ; la statistique exploratoire n'en pose aucune. »
- (c) « On peut légitimement calculer, dans ce cours, un intervalle de confiance pour situer la position d'un groupe de clients sur un graphique. »
- (d) « L'analyse en composantes principales (chapitres 8 à 12) et l'analyse des correspondances (chapitres 13 à 14) traitent, respectivement, des variables quantitatives et des variables qualitatives. »

Exercice 3 — Repérer la faute de méthode

Un analyste applique une méthode exploratoire à son fichier clients et observe sur le graphique obtenu un groupe de points nettement séparé du reste du nuage. Il calcule alors, sur ce même fichier, un test comparant la moyenne de ce groupe à celle du reste des clients, et obtient une p -value très faible qu'il présente comme la preuve que ce groupe est « statistiquement différent ».

- (a) Quelle règle méthodologique, énoncée dans ce chapitre, cet analyste a-t-il enfreinte ?
- (b) Pourquoi la p -value obtenue de cette façon est-elle trompeuse, alors même que le calcul du test lui-même ne comporte aucune erreur arithmétique ?
- (c) Proposer une démarche correcte pour confirmer, ou infirmer, l'existence de ce groupe.

2 Exercices cumulatifs (introduction et chapitre 1)

Exercice 4 — De la photographie du chameau au plan du cours

Une compagnie d'assurance dispose d'un fichier de 400 clients, décrits par 9 variables quantitatives (prime annuelle, ancienneté, nombre de sinistres, etc.) et 3 variables qualitatives (type de contrat, région, canal de souscription).

- (a) En ne considérant que les 9 variables quantitatives, calculer le nombre de nuages de points bivariés qu'un examen exhaustif exigerait (formule de l'introduction).

- (b) Ce fichier mélangeant variables quantitatives et qualitatives, à quelles deux méthodes du plan du cours (rappelé au chapitre 1) faudrait-il, en principe, recourir pour l'explorer complètement – une pour chaque type de variables ?
- (c) En reliant l'analogie du chameau (introduction) à la mise en garde de ce chapitre sur l'inférence, expliquer pourquoi la compagnie aurait tort de conclure, à la seule vue d'une structure repérée sur le graphique obtenu par l'une de ces deux méthodes, que « les clients qui ont beaucoup de sinistres sont significativement moins anciens » sans autre vérification.

3 Applications en sciences économiques

Exercice 5 — Choisir le bon outil, au bon moment

Le service des études économiques d'une banque doit répondre à deux questions distinctes concernant sa clientèle d'entreprises : (1) « Existe-t-il, parmi nos 250 entreprises clientes, des profils de risque qui n'apparaissent pas dans nos catégories de classement habituelles ? » et (2) « Le taux de défaut moyen des entreprises du secteur « BTP » est-il significativement supérieur à celui de l'ensemble du portefeuille ? »

- (a) Pour chacune des deux questions, indiquer si elle relève de la démarche exploratoire (ce cours) ou de la démarche inférentielle (cours de statistique inférentielle), et justifier.
- (b) Dans quel ordre le service des études aurait-il intérêt à traiter ces deux questions si elles portaient, en réalité, sur le *même* sous-ensemble de données ? Justifier à l'aide du cours.
- (c) Le directeur des risques s'étonne : « pourquoi ne pas simplement laisser le logiciel calculer directement un intervalle de confiance sur le graphique de l'analyse exploratoire, plutôt que de refaire un test séparé ? ». Expliquer, en une phrase, pourquoi cette demande n'a pas de sens dans le cadre de ce cours.

Exercice 6 — Le fil rouge à venir, en anticipation

Le cours annonce qu'un fil rouge de « cinq clients, notés sur deux critères – l'accueil et la fidélité », traversera l'ensemble des quatorze chapitres, permettant de calculer « à la main » la moyenne, la variance, la variable centrée réduite, la covariance, la corrélation, l'inertie, les axes et le pourcentage d'inertie expliquée.

- (a) Sur ces deux seules variables (accueil, fidélité), un simple nuage de points suffirait-il à « voir » la relation entre les cinq clients ? À partir de quel nombre de variables supplémentaires ce même nuage cesserait-il de suffire ?
- (b) Pourquoi un exemple aussi « minuscule » (cinq clients, deux variables) est-il pédagogiquement utile pour un cours qui prépare, en réalité, à traiter des tableaux beaucoup plus grands ?
- (c) En anticipant sur le plan du cours (chapitres 6 à 7 : le nuage et l'inertie ; chapitres 8 à 12 : l'ACP), formuler une hypothèse sur ce que pourrait signifier, intuitivement, « le pourcentage d'inertie expliquée » par un premier axe, dans le cas de ce fil rouge à seulement deux variables.