Introduction à l'analyse des données

Chapitre 1 : De la statistique descriptive à l'analyse des données

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Continuité, non rupture **2**
- Ce que vous savez déjà faire . . . 2
- Le cours s'y arrêtait, et c'est là que celui-ci commence . . . 2
- Le nom exact de ce cours . . . 3

Ce que la descriptive dit du fichier clients **3**
- Une variable à la fois : huit moyennes . . . 3
- Ce que ces huit moyennes disent . . . 3
- Deux clients, une même moyenne . . . 4
- Le même 13,9, deux clients opposés . . . 4
- Deux variables à la fois : vingt-huit corrélations . . . 5
- Toutes les variables à la fois : un plan . . . 6

Descriptive et inférentielle **6**
- Deux démarches, deux moments . . . 6
- Laquelle vient en premier . . . 6

Les variables du fichier **7**
- Quantitatives et qualitatives . . . 7
- Actives et illustratives . . . 7

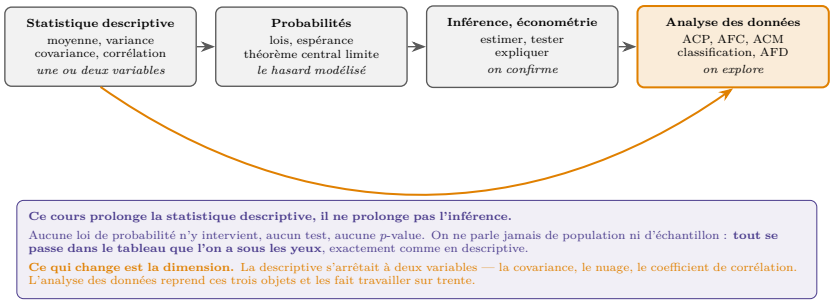
Le plan du cours **7**
- Quatre mouvements . . . 7
- Le fil rouge chiffré . . . 8
- Et ensuite . . . 8

S'entraîner **8**
- Exercice 1 : quelle méthode ? . . . 8
- Exercice 1 : solution . . . 9
- Exercice 2 : la moyenne qui cache tout . . . 9
- Exercice 2 : solution . . . 9
- Exercice 3 : la taille de la matrice des corrélations . . . 9
- Exercice 3 : solution . . . 10

Ce qu'il faut retenir **10**
Le résumé du chapitre 10
La suite 10

Continuité, non rupture

Ce que vous savez déjà faire



Le cours de statistique descriptive, rappelé

Nombre de variables	Ce qu'on y a appris
Une	tableau, graphiques, tendance centrale, dispersion, forme
Deux	tableau croisé, nuage de points, covariance, corrélation

Le cours s'y arrêtait, et c'est là que celui-ci commence

Ce qui manque n'est pas la mesure

La statistique descriptive s'arrête à **deux** variables, parce que deux variables se dessinent sur une feuille. Rien dans ses définitions ne l'exigeait pourtant : une moyenne, une covariance se calculent aussi bien sur trente variables.
Ce qui manque n'est pas la mesure : c'est la représentation.

Ce qui change, et ce qui ne change pas

	Descriptive	Analyse des données
Variables traitées ensemble	une ou deux	p, souvent 8 à 30
Outils de calcul	moyenne, variance, corrélation	**les mêmes**
Représentation	histogramme, nuage	**plan factoriel**

Le nom exact de ce cours

Trois appellations, un même objet

Nom	Ce qu'il souligne
Analyse des données	l'usage français courant
Statistique descriptive multivariée	la filiation exacte
Statistique exploratoire	la démarche : faire émerger, non tester

Multivariée, et rien de plus

Ce cours **n'introduit aucune notion statistique nouvelle**. La moyenne, la variance, la covariance, la corrélation — tout y est déjà. Ce qui change est le **nombre** de variables traitées ensemble, et l'outil géométrique qu'il faut pour les regarder.
C'est pourquoi les chapitres 2 à 4 sont des **rappels**. Il faut les prendre au sérieux : tout le reste du cours en découle mécaniquement.

Ce que la descriptive dit du fichier clients

Une variable à la fois : huit moyennes

Les huit notes de satisfaction des 300 clients

Note	Moyenne	Écart-type
prix	11,40	2,40
choix	13,20	2,40
qualité	14,10	2,40
agencement	13,00	2,40
propreté	14,59	2,38
rapidité	12,30	2,40
conseil	12,80	2,40
accueil	13,90	2,40

Ce que ces huit moyennes disent

Un palmarès des critères

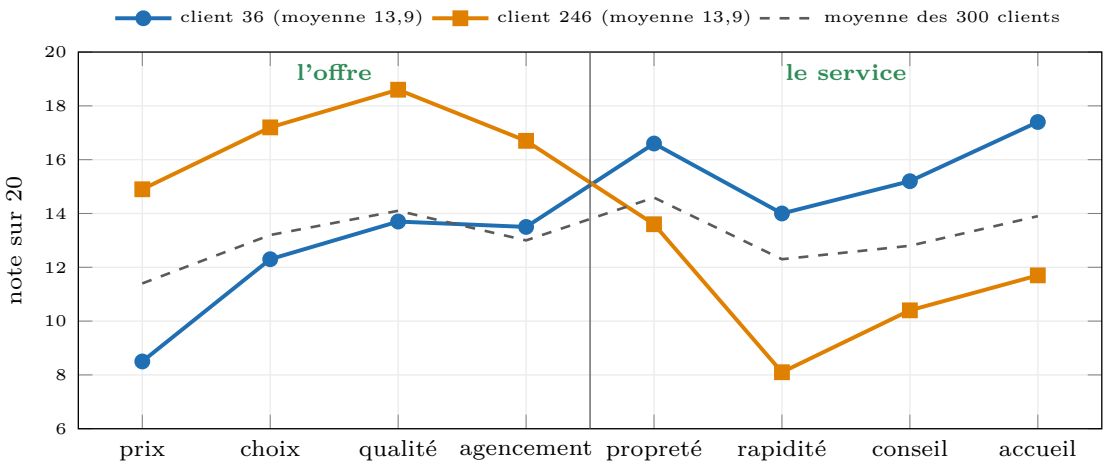
La **propreté** est le point fort de l'enseigne (14,59), le **prix** son point faible (11,40). Les huit notes sont aussi dispersées les unes que les autres : un écart-type d'environ 2,4 points chacune.
C'est une information utile, et c'est tout ce que la statistique d'une variable peut donner.

Ce qu'elles ne disent pas

Les moyennes décrivent les **critères**, une colonne après l'autre. Elles ne disent rien des **clients** : un client sévère sur le prix l'est-il aussi sur l'accueil ? Existe-t-il plusieurs types de clients ?

Pour le savoir, il faut regarder les colonnes **ensemble**.

Deux clients, une même moyenne



Le même 13,9, deux clients opposés

Les clients 36 et 246

Les deux clients donnent exactement la même note moyenne : $111{,}2/8 = 13{,}9$.
Le client 36 est **sévère sur l'offre** (prix 8,5) et **ravi du service** (accueil 17,4). Le client 246 est l'inverse : prix 14,9, rapidité 8,1.

Ce que la moyenne écrase

Résumer un client par un seul nombre fait disparaître **ce qui le distingue**. Ces deux clients n'attendent pas la même chose de l'enseigne, et une politique commerciale qui les traiterait de la même façon manquerait les deux.
L'analyse des données va retrouver cette opposition **automatiquement**, sur les trois cents clients à la fois : ce sera le second axe de l'ACP.

Démonstration : Deux clients de même moyenne, une différence orthogonale à la diagonale

Notons $x = (x_1, \dots, x_8)$ et $x' = (x'_1, \dots, x'_8)$ les huit notes de deux clients, et $\mathbf{1} = (1, \dots, 1)$. La note moyenne est un produit scalaire :

$$\bar{x} = \frac{1}{8}\sum_{j=1}^{8} x_j = \frac{1}{8}\,\langle x, \mathbf{1}\rangle.$$

Comme $\mathbf{1}/\sqrt{8}$ est de longueur 1, la **projection** du client sur la diagonale a pour coordonnée $\langle x, \mathbf{1}/\sqrt{8}\rangle = \sqrt{8}\,\bar{x}$: la moyenne ne voit que cette projection.

Deux clients de même moyenne vérifient donc $\langle x - x', \mathbf{1}\rangle = 0$: leur **différence est perpendiculaire à la diagonale**. Leur écart tout entier, c'est-à-dire leur distance, vit dans la

partie que la moyenne ne voit pas :

$$\|x - x'\|^2 = \underbrace{\left\langle x - x',\ \tfrac{\mathbf{1}}{\sqrt{8}} \right\rangle^2}_{=\,0} + \|\text{partie orthogonale}\|^2.$$

Les clients 36 *et* 246. Les huit écarts de notes valent −6,4 ; −4,9 ; −4,9 ; −3,2 ; +3,0 ; +5,9 ; +4,8 ; +5,7, de somme exactement 0 : même moyenne (13,9). Pourtant la distance entre leurs deux profils bruts est $\sqrt{\sum_j (x_j - x'_j)^2} = 14{,}1$ points de note, et elle vaut 5,87 sur les notes réduites. La moyenne les confond ; la géométrie les sépare.

■

Deux variables à la fois : vingt-huit corrélations

Le niveau suivant de la descriptive

Avec deux variables, on calcule une **corrélation**. Avec huit, on en calcule $8 \times 7/2 = 28$, rangées dans une **matrice des corrélations** de $8 \times 8 = 64$ cases.

Démonstration : Pourquoi 28 corrélations et non 64

La matrice des corrélations a $p \times p$ cases, mais seulement $p(p-1)/2$ informations distinctes. Deux faits suffisent, tous deux hérités de la statistique descriptive (et repris aux chapitres 3 et 4) :

1. **Elle est symétrique.** $r_{xy} = \dfrac{\operatorname{cov}(x,y)}{s_x\, s_y}$ et $\operatorname{cov}(x,y) = \operatorname{cov}(y,x)$: échanger x et y ne change pas le quotient. La case (j,k) répète la case (k,j).
2. **Sa diagonale vaut 1.** $r_{xx} = \dfrac{\operatorname{cov}(x,x)}{s_x^2} = \dfrac{V(x)}{V(x)} = 1$: une variable est parfaitement corrélée avec elle-même, ce qui n'apprend rien.

Il reste les cases hors de la diagonale, au nombre de $p^2 - p$, dont la moitié seulement est distincte :

$$\frac{p^2 - p}{2} = \frac{p\,(p-1)}{2} = 28 \qquad (p = 8).$$

C'est-à-dire $64 = 8 + 2 \times 28$: huit 1 sur la diagonale, et chacune des 28 corrélations écrite deux fois. C'est exactement le nombre de nuages de points de l'introduction : un nuage par corrélation.

■

Quelques-unes de ces corrélations

Paire de notes	Corrélation
conseil et accueil	0,73
choix et qualité	0,73
prix et qualité	0,67

prix et accueil	0,09

Toutes les variables à la fois : un plan

Les trois niveaux de description

Niveau	Ce qu'il produit sur nos huit notes
une variable	8 moyennes, 8 écarts-types
deux variables	28 corrélations
toutes à la fois	**un** plan, qui conserve 77,3 % de l'information

Le troisième niveau ne remplace pas les deux autres

Le plan factoriel se construit **à partir** des corrélations, qui se construisent à partir des moyennes et des variances. Chaque niveau s'appuie sur le précédent : c'est l'ordre du cours.

Descriptive et inférentielle

Deux démarches, deux moments

La distinction

La **statistique inférentielle** part d'une hypothèse posée d'avance et demande aux données si elles la démentent. Elle conclut avec un risque d'erreur mesuré.
La **statistique exploratoire** ne pose aucune hypothèse. Elle demande aux données quelles structures elles contiennent.

Ni loi de probabilité, ni test, ni p-value

Vous ne rencontrerez dans ce cours **aucune** loi normale, **aucun** intervalle de confiance, **aucune** p-value. Ce n'est pas un oubli : ces objets n'ont pas de rôle ici. On **décrit** le tableau qu'on a sous les yeux, le plus lisiblement possible.

Laquelle vient en premier

Explorer d'abord, confirmer ensuite

L'exploration vient **avant** : on repère des groupes, des liaisons, des valeurs aberrantes, puis on formule des hypothèses qu'on ira tester sur d'autres données.
L'ordre inverse — tester une hypothèse suggérée par les mêmes données — produit des conclusions qui ne se reproduisent pas. C'est une faute de méthode, et elle est fréquente.

Sur notre fichier

L'ACP montrera que les clients se partagent entre **offre** et **service**. Pour affirmer que c'est vrai de **tous** les clients de l'enseigne, il faudrait un nouvel échantillon et un test : c'est le métier du cours de statistique inférentielle.

Les variables du fichier

Quantitatives et qualitatives

La nature des seize variables

Nature	Variables
quantitatives	âge, ancienneté, panier, les huit notes
qualitatives	sexe, CSP, fréquence, carte, motif

La nature décide de la méthode

Une moyenne, une variance, une corrélation n'ont de sens que pour des variables **quantitatives**. Pour des catégories, on compte des **effectifs** dans un tableau croisé.
C'est la raison pour laquelle le cours a deux méthodes : l'**ACP** pour les variables quantitatives, l'**AFC** pour un tableau croisé de deux variables qualitatives.

Actives et illustratives

Toutes les variables ne jouent pas le même rôle

On choisit les variables **actives**, qui construisent la représentation — ici, les huit notes. Les autres sont **illustratives** : elles ne servent qu'à lire le résultat.

Pourquoi séparer

On veut savoir si les clients fréquents sont plus satisfaits. Si la fréquence participait au calcul, on retrouverait dans le résultat ce qu'on y aurait mis.
En la gardant de côté, puis en la projetant, on observe un lien **qu'on n'a pas fabriqué**. Le chapitre 11 en fera l'usage sur notre fichier : les clients hebdomadaires se placent nettement du côté des satisfaits.

Le plan du cours

Quatre mouvements

L'introduction et les treize chapitres

Unités	Objet
Intro, 1	le problème de la dimension, la place du cours
2–4	les rappels : centrer et réduire, covariance, corrélation
5–6	le tableau vu comme un **nuage**, et son **inertie**
7–11	l'**analyse en composantes principales**
12–13	l'**analyse des correspondances**

Pourquoi cet ordre

Chaque partie utilise la précédente : l'ACP projette un nuage, mesure ce qu'elle conserve par l'inertie, et calcule ses axes sur la matrice des corrélations. L'AFC refait la même chose sur un tableau croisé.

Le fil rouge chiffré

Cinq clients, de bout en bout

Un exemple minuscule traverse tout le cours : **cinq clients**, notés sur deux critères — l'accueil et la fidélité.
Vous y verrez naître, dans l'ordre, la moyenne, la variance, la variable centrée réduite, la covariance, la corrélation, l'inertie, les axes et le pourcentage d'inertie expliquée.

Et les trois cents clients

Chaque notion, calculée à la main sur les cinq clients, est ensuite appliquée au fichier réel : l'ACP de ses **huit notes** et l'AFC de la **CSP** croisée avec le **motif** de visite. Les chapitres 7 à 13 le font sur R et sur Python.

Et ensuite

Ce cours est une introduction

Il traite les deux méthodes fondatrices — composantes principales et correspondances. Le cours d'**analyse des données** du niveau Master reprend l'ensemble et l'approfondit :

Prolongement	Contenu
Correspondances **multiples**	plus de deux variables qualitatives
Classification	constituer des groupes de clients
Analyse **discriminante**	affecter un nouveau client à un groupe
Positionnement multidimensionnel	cartographier des ressemblances

S'entraîner

Exercice 1 : quelle méthode ?

La nature des variables décide

Pour chaque tableau, dire s'il relève de l'**ACP**, de l'**AFC**, ou d'aucune des deux.

1. 300 clients décrits par leurs huit notes de satisfaction.
2. Le croisement de la CSP et de la fréquence de visite.
3. 50 agences décrites par leur chiffre d'affaires, leur surface et leur effectif.
4. 300 clients décrits par leur seul sexe.

Exercice 1 : solution

Quantitatif : ACP ; tableau croisé : AFC

1. **ACP** : huit variables quantitatives, mesurées sur les mêmes individus.
2. **AFC** : deux variables qualitatives, résumées par un tableau d'effectifs (5×3).
3. **ACP** : trois variables quantitatives — à condition de les **réduire**, car elles n'ont pas les mêmes unités (chapitre 2).
4. **Aucune** : une seule variable se décrit par un tableau d'effectifs et un diagramme. Il n'y a pas de dimension à réduire.

Exercice 2 : la moyenne qui cache tout

Calculer, puis comparer

Voici les notes de deux clients sur quatre critères.

Client	prix	qualité	conseil	accueil
A	8	10	16	18
B	17	17	9	9

1. Calculer la note moyenne de chaque client.
2. Calculer, pour chacun, la moyenne « offre » (prix, qualité) et la moyenne « service » (conseil, accueil).
3. Conclure.

Exercice 2 : solution

Même niveau, profils opposés

1. A : $(8+10+16+18)/4 = 13$. B : $(17+17+9+9)/4 = 13$. **La même moyenne.**
2. A : offre 9, service 17. B : offre 17, service 9.
3. Les deux clients ont le même **niveau** de satisfaction et des **profils** inverses. Un seul nombre ne suffit pas : il en faut au moins deux — un niveau et une opposition. Ce seront les deux premiers axes de l'ACP.

Exercice 3 : la taille de la matrice des corrélations

Compter les coefficients utiles

1. Combien de cases compte la matrice des corrélations de $p = 8$ variables ? Combien valent 1 par construction ?
2. Combien de coefficients **distincts** reste-t-il à lire ?
3. Même question pour $p = 30$.

Exercice 3 : solution

p(p-1)/2 coefficients à lire

1. $8 \times 8 = 64$ cases, dont les 8 de la diagonale valent 1 (corrélation d'une variable avec elle-même).
2. Les 56 autres vont par paires égales, $r_{jk} = r_{kj}$: il reste $56/2 = 28$ coefficients, autant que de nuages de points.
3. 900 cases, 30 sur la diagonale, $870/2 = 435$ coefficients. **Plus personne ne lit une telle matrice** : c'est le problème que l'ACP résout.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Ce cours **prolonge** la statistique descriptive : c'est sa version **multivariée**, sans notion statistique nouvelle.
2. Huit moyennes décrivent des **critères**, pas des **clients** : les clients 36 et 246 ont la même moyenne et des profils opposés.
3. Trois niveaux : une variable (8 moyennes), deux (28 corrélations), toutes (**un** plan).
4. Le cours est **exploratoire** : ni loi, ni test, ni p-value ; l'exploration vient **avant** l'inférence.
5. La nature des variables décide de la méthode : **ACP** pour le quantitatif, **AFC** pour un tableau croisé.
6. Le plan : introduction et ch. 1, rappels (2–4), nuage et inertie (5–6), ACP (7–11), AFC (12–13).

La suite

Les rappels commencent

Le chapitre 2 reprend ce qu'il faut savoir sur **une** variable — et s'arrête longuement sur une opération qui paraîtra anodine et qui commande tout le cours : **centrer et réduire**.

Ce qu'on y calculera

Les moyennes, variances et écarts-types des cinq clients, puis leurs notes centrées réduites. Et l'on verra, sur le fichier réel, pourquoi un panier en dirhams écraserait toutes les notes si l'on ne réduisait pas.