

Introduction à l'analyse des données

Chapitre 7 : L'idée de l'analyse en composantes principales

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Hiérarchisation et additivité

Un nuage réduit à $p = 3$ variables (inertie totale $I = 3$) est décomposé sur ses trois composantes principales : $I_1 = 1,8$, $I_2 = 0,9$, $I_3 = 0,3$.

- (a) Vérifier que ces trois inerties s'additionnent bien pour redonner l'inertie totale. Quelle propriété du cours cela illustre-t-il ?
- (b) Calculer le pourcentage d'inertie porté par chacun des trois axes, puis le pourcentage *cumulé* porté par les deux premiers axes ensemble.
- (c) Un étudiant affirme : « puisque $I_1 = 1,8$ est la plus grande valeur, on pourrait tout aussi bien choisir I_2 comme premier axe et I_1 comme deuxième : l'ordre n'a pas d'importance. » Que répondre, en s'appuyant sur la définition même de la première composante principale ?

Exercice 2 — Interpréter une composante construite

Une entreprise réalise une ACP sur 4 variables réduites décrivant ses produits (prix, qualité perçue, service, notoriété). Le premier axe s'écrit $C_1 = 0,51 z_{\text{prix}} + 0,49 z_{\text{qualité}} + 0,52 z_{\text{service}} + 0,48 z_{\text{notoriété}}$ – les quatre coefficients sont positifs et de taille comparable.

- (a) C_1 est-elle une variable qui a été directement mesurée sur les produits, ou une variable *construite* ? Justifier à partir de sa définition.
- (b) Sachant que les quatre coefficients sont positifs et proches les uns des autres, proposer une interprétation économique plausible de C_1 (à quoi pourrait-elle correspondre en termes de gestion de produit) ?
- (c) Le cours met en garde : « une composante mal nommée est une erreur durable ». Quelle étape, indispensable avant de baptiser C_1 , ne doit-on jamais sauter ?

Exercice 3 — Quand l'ACP ne sert à rien

On calcule la matrice des corrélations de 4 variables mesurées sur des clients : toutes les corrélations hors diagonale sont comprises entre $-0,05$ et $0,08$.

- (a) D'après la condition énoncée dans le cours, cette ACP a-t-elle des chances d'être utile ? Justifier.
- (b) Si l'on calculait malgré tout les quatre inerties portées par les quatre axes principaux, à quoi devrait-on s'attendre : des valeurs très inégales (un ou deux axes dominants), ou des valeurs proches les unes des autres ?
- (c) Expliquer pourquoi ce résultat est cohérent avec l'idée que « si toutes les corrélations sont nulles, chaque variable porte une information propre » : que signifierait, dans ce cas, « résumer » le tableau par un seul axe ?

2 Exercices cumulatifs (introduction au chapitre 7)

Exercice 4 — Les deux inerties propres du fil rouge

On reprend le fil rouge : cinq clients, accueil x et fidélité y , de corrélation $r = 0,9$ (chapitre 4), et d'inertie totale réduite $I = 2$ (chapitre 6). On admet ici un résultat que le chapitre 8 démontrera : pour deux variables réduites de corrélation r , les deux inerties portées par les deux axes principaux valent exactement $\lambda_1 = 1 + r$ et $\lambda_2 = 1 - r$.

- (a) Calculer λ_1 et λ_2 , et vérifier qu'ils s'additionnent bien pour redonner $I = 2$.
- (b) Calculer le pourcentage d'inertie totale porté par le premier axe.
- (c) Au chapitre 4, on avait observé que x et y étaient « presque alignés » ($r = 0,9$, proche de 1). Expliquer en une phrase pourquoi ce pourcentage très élevé était prévisible *avant même* de faire

le calcul, à partir de cette seule observation qualitative.

3 Applications en sciences économiques

Exercice 5 — Choisir le nombre d'axes à retenir

Un cabinet d'analyse financière réalise une ACP sur $p = 4$ ratios réduits (endettement, liquidité, rentabilité, couverture des intérêts) fortement corrélés entre eux. L'inertie totale vaut $I = 4$, décomposée en $I_1 = 3,2$, $I_2 = 0,5$, $I_3 = 0,2$, $I_4 = 0,1$.

- (a) Calculer le pourcentage d'inertie porté par le premier axe seul, puis le pourcentage cumulé porté par les deux premiers axes, puis par les trois premiers.
- (b) Le cabinet décide de ne retenir que les axes qui, ensemble, dépassent 90 % de l'inertie totale. Combien d'axes doit-il retenir ?
- (c) Ces quatre ratios financiers mesurent, par construction, des dimensions différentes (dette, trésorerie, profit, sécurité). Que suggère une inertie aussi concentrée sur le premier axe (80 %) quant à la relation *statistique* entre ces quatre indicateurs, malgré leurs définitions comptables distinctes ?

Exercice 6 — Construire un indicateur synthétique de risque

Une banque dispose de trois scores de risque réduits pour chaque dossier de crédit (risque de marché r_1 , risque de crédit r_2 , risque opérationnel r_3), fortement corrélés entre eux ($r_{ij} > 0,7$ pour toutes les paires). Le premier axe de l'ACP s'écrit $C_1 = 0,58 z_{r_1} + 0,57 z_{r_2} + 0,58 z_{r_3}$ et porte 85 % de l'inertie totale.


- (a) Compte tenu du signe et de la taille des trois coefficients, quelle interprétation économique naturelle peut-on proposer pour C_1 ?
- (b) La direction des risques souhaite classer les dossiers uniquement à l'aide de ce premier axe plutôt que de suivre séparément les trois scores. Que gagne-t-elle en simplicité, et que risque-t-elle de perdre en information (penser aux 15 % d'inertie non captés) ?
- (c) Pourquoi la condition « les variables doivent être corrélées » du cours est-elle précisément ce qui rend cet indicateur synthétique pertinent ici, alors qu'elle interdirait une démarche similaire sur trois risques totalement indépendants ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $I_1 + I_2 + I_3 = 1,8 + 0,9 + 0,3 = 3,0 = I$. Cela illustre la propriété d'**additivité** : les inerties portées par les axes principaux, orthogonaux entre eux, se recomposent exactement en l'inertie totale, sans double compte ni perte.

(b) $\frac{1,8}{3} = 60\%$, $\frac{0,9}{3} = 30\%$, $\frac{0,3}{3} = 10\%$. Pourcentage cumulé des deux premiers axes : $60 + 30 = 90\%$.



(c) Non : par **définition**, la première composante principale est celle qui maximise l'inertie projetée *parmi tous les axes possibles*. Une fois cette valeur maximale identifiée (1,8), on ne peut pas « renommer » un autre axe (qui porte moins d'inertie, 0,9) comme premier axe : l'ordre $I_1 \geq I_2 \geq I_3$ n'est pas une convention arbitraire, c'est une conséquence nécessaire de la façon dont chaque axe est construit successivement (le premier maximise l'inertie totale projetée, le second maximise l'inertie *restante* sous contrainte d'orthogonalité, etc.).

Correction — Exercice 2

(a) C_1 est une variable **construite** : sa définition même, $C_1 = 0,51 z_{\text{prix}} + 0,49 z_{\text{qualité}} + 0,52 z_{\text{service}} + 0,48 z_{\text{notoriété}}$, est une combinaison linéaire des quatre variables mesurées – elle n'a jamais été directement observée ou notée par un client, elle résulte entièrement du calcul de l'ACP.

(b) Les quatre coefficients étant tous positifs et de taille comparable (autour de 0,5), C_1 augmente lorsque *tous* les critères augmentent ensemble : un produit avec un prix perçu favorable, une bonne qualité, un bon service *et* une bonne notoriété obtient un C_1 élevé. Une interprétation plausible est celle d'un indicateur de **positionnement global du produit** (ou « niveau général de valeur perçue »), qui résume en un seul chiffre ce que les quatre variables mesureraient séparément.

(c) Il ne faut jamais sauter l'examen des **coefficients** (les poids de chaque variable dans la combinaison linéaire) avant de nommer la composante – c'est précisément ce que fera le chapitre 10. Nommer C_1 « satisfaction globale » sans avoir vérifié que les quatre coefficients sont bien positifs et comparables (et non, par exemple, dominés par une seule variable ou de signes opposés) reviendrait à interpréter un résultat qu'on n'a pas réellement regardé.

Correction — Exercice 3

(a) Non : la condition du cours (« l'ACP n'apporte quelque chose que si les variables sont corrélées entre elles ») n'est pas remplie ici, puisque toutes les corrélations hors diagonale sont quasiment nulles (–0,05 à 0,08). Cette ACP n'a donc pratiquement aucune chance d'être utile.

(b) On doit s'attendre à des valeurs **proches les unes des autres** (à peu près $I/p = 4/4 = 1$ chacune), et non à un ou deux axes dominants – sans corrélation entre les variables, aucune direction de l'espace n'est privilégiée par rapport aux autres.

(c) Si chaque variable porte une information **propre**, non partagée avec les autres (corrélations nulles), alors « résumer » le tableau par un seul axe reviendrait à **perdre** une grande partie de l'information contenue dans les trois autres variables, puisque cet axe ne pourrait au mieux capter qu'une fraction proche de $1/p$ de l'inertie totale – l'exact opposé du cas où les variables corrélées permettent à un seul axe de « porter » ce que plusieurs variables redisaient en même temps.


2 Exercices cumulatifs (introduction au chapitre 7)

Correction — Exercice 4

(a) $\lambda_1 = 1 + 0,9 = 1,9$, $\lambda_2 = 1 - 0,9 = 0,1$. Somme = $1,9 + 0,1 = 2,0 = I$, conforme au chapitre 6.

(b) $\frac{1,9}{2} = 95\%$.

(c) Une corrélation $r = 0,9$ signifie que les cinq clients sont « presque alignés » sur une seule direction du plan (chapitre 4) : leur nuage ressemble davantage à une droite qu'à un ovale dispersé dans toutes les directions. Or l'inertie projetée sur un axe est justement **maximale** quand cet axe suit l'allongement du nuage (chapitre 7) – un nuage presque aligné ne peut donc, par construction, laisser que très peu d'inertie « en dehors » de cette direction dominante : un pourcentage proche de 100 % pour le premier axe était donc prévisible dès l'observation de $r = 0,9$, sans avoir besoin de calculer λ_1 et λ_2 .



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\frac{3,2}{4} = 80\%$. Deux premiers axes : $\frac{3,2 + 0,5}{4} = \frac{3,7}{4} = 92,5\%$. Trois premiers axes : $\frac{3,2 + 0,5 + 0,2}{4} = \frac{3,9}{4} = 97,5\%$.

(b) Un seul axe (le premier) suffit déjà à dépasser 90 % (80 % n'y suffit pas, mais les deux premiers ensemble atteignent $92,5\% > 90\%$) : le cabinet doit donc retenir **deux** axes.

(c) Une inertie aussi concentrée sur le premier axe suggère que, malgré leurs définitions comptables distinctes, ces quatre ratios **varient largement ensemble** d'une entreprise à l'autre – une entreprise plus endettée tend, dans cet échantillon, à être aussi moins liquide, moins rentable et moins bien couverte (ou l'inverse). Statistiquement, les quatre indicateurs sont donc fortement **corrélés** entre eux, même s'ils mesurent conceptuellement des risques différents : c'est précisément la condition qui rend l'ACP utile ici (exercice 3).

Correction — Exercice 6

(a) Les trois coefficients étant tous positifs et de taille très proche (0,57–0,58), C_1 augmente lorsque les trois risques augmentent *ensemble* : une interprétation naturelle est celle d'un **indice de risque global** du dossier, qui résume en un seul score la tendance commune des trois risques à être simultanément élevés ou faibles.

(b) La direction gagne en **simplicité opérationnelle** : un seul score à suivre et à comparer entre dossiers, au lieu de trois. Elle risque cependant de perdre l'information portée par les 15 % d'inertie **résiduelle** – les cas, par exemple, où un dossier présente un risque de crédit élevé mais un risque de marché ou opérationnel faible (une configuration que C_1 seul ne peut pas distinguer d'un dossier globalement risqué sur les trois plans).

(c) La condition « les variables doivent être corrélées » est précisément ce qui garantit qu'un seul indicateur peut capter 85 % de l'information des trois scores : c'est parce que r_1 , r_2 et r_3 évoluent largement ensemble qu'un seul axe suffit à les résumer sans perte majeure. Sur trois risques totalement **indépendants**, chaque variable porterait une information propre (exercice 3) : aucun axe unique ne pourrait alors capter plus qu'environ 1/3 de l'inertie totale, et fabriquer un « indice synthétique » reviendrait à ignorer arbitrairement les deux tiers de l'information disponible.