

Chapitre 7

L'idée de l'analyse en composantes principales

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Hiérarchisation et additivité

Un nuage réduit à $p = 3$ variables (inertie totale $I = 3$) est décomposé sur ses trois composantes principales : $I_1 = 1,8$, $I_2 = 0,9$, $I_3 = 0,3$.

- (a) Vérifier que ces trois inerties s'additionnent bien pour redonner l'inertie totale. Quelle propriété du cours cela illustre-t-il ?
- (b) Calculer le pourcentage d'inertie porté par chacun des trois axes, puis le pourcentage *cumulé* porté par les deux premiers axes ensemble.
- (c) Un étudiant affirme : « puisque $I_1 = 1,8$ est la plus grande valeur, on pourrait tout aussi bien choisir I_2 comme premier axe et I_1 comme deuxième : l'ordre n'a pas d'importance. » Que répondre, en s'appuyant sur la définition même de la première composante principale ?

Exercice 2 — Interpréter une composante construite

Une entreprise réalise une ACP sur 4 variables réduites décrivant ses produits (prix, qualité perçue, service, notoriété). Le premier axe s'écrit $C_1 = 0,51 z_{\text{prix}} + 0,49 z_{\text{qualité}} + 0,52 z_{\text{service}} + 0,48 z_{\text{notoriété}}$ – les quatre coefficients sont positifs et de taille comparable.

- (a) C_1 est-elle une variable qui a été directement mesurée sur les produits, ou une variable *construite* ? Justifier à partir de sa définition.
- (b) Sachant que les quatre coefficients sont positifs et proches les uns des autres, proposer une interprétation économique plausible de C_1 (à quoi pourrait-elle correspondre en termes de gestion de produit) ?
- (c) Le cours met en garde : « une composante mal nommée est une erreur durable ». Quelle étape, indispensable avant de baptiser C_1 , ne doit-on jamais sauter ?

Exercice 3 — Quand l'ACP ne sert à rien

On calcule la matrice des corrélations de 4 variables mesurées sur des clients : toutes les corrélations hors diagonale sont comprises entre $-0,05$ et $0,08$.

- (a) D'après la condition énoncée dans le cours, cette ACP a-t-elle des chances d'être utile ? Justifier.
- (b) Si l'on calculait malgré tout les quatre inerties portées par les quatre axes principaux, à quoi devrait-on s'attendre : des valeurs très inégales (un ou deux axes dominants), ou des valeurs proches les unes des autres ?
- (c) Expliquer pourquoi ce résultat est cohérent avec l'idée que « si toutes les corrélations sont nulles, chaque variable porte une information propre » : que signifierait, dans ce cas, « résumer » le tableau par un seul axe ?

2 Exercices cumulatifs (introduction au chapitre 7)

Exercice 4 — Les deux inerties propres du fil rouge

On reprend le fil rouge : cinq clients, accueil x et fidélité y , de corrélation $r = 0,9$ (chapitre 4), et d'inertie totale réduite $I = 2$ (chapitre 6). On admet ici un résultat que le chapitre 8 démontrera : pour deux variables réduites de corrélation r , les deux inerties portées par les deux axes principaux valent exactement $\lambda_1 = 1 + r$ et $\lambda_2 = 1 - r$.

- (a) Calculer λ_1 et λ_2 , et vérifier qu'ils s'additionnent bien pour redonner $I = 2$.
- (b) Calculer le pourcentage d'inertie totale porté par le premier axe.
- (c) Au chapitre 4, on avait observé que x et y étaient « presque alignés » ($r = 0,9$, proche de 1). Expliquer en une phrase pourquoi ce pourcentage très élevé était prévisible *avant même* de faire

le calcul, à partir de cette seule observation qualitative.

3 Applications en sciences économiques

Exercice 5 — Choisir le nombre d'axes à retenir

Un cabinet d'analyse financière réalise une ACP sur $p = 4$ ratios réduits (endettement, liquidité, rentabilité, couverture des intérêts) fortement corrélés entre eux. L'inertie totale vaut $I = 4$, décomposée en $I_1 = 3,2$, $I_2 = 0,5$, $I_3 = 0,2$, $I_4 = 0,1$.

- (a) Calculer le pourcentage d'inertie porté par le premier axe seul, puis le pourcentage cumulé porté par les deux premiers axes, puis par les trois premiers.
- (b) Le cabinet décide de ne retenir que les axes qui, ensemble, dépassent 90 % de l'inertie totale. Combien d'axes doit-il retenir ?
- (c) Ces quatre ratios financiers mesurent, par construction, des dimensions différentes (dette, trésorerie, profit, sécurité). Que suggère une inertie aussi concentrée sur le premier axe (80 %) quant à la relation *statistique* entre ces quatre indicateurs, malgré leurs définitions comptables distinctes ?

Exercice 6 — Construire un indicateur synthétique de risque

Une banque dispose de trois scores de risque réduits pour chaque dossier de crédit (risque de marché r_1 , risque de crédit r_2 , risque opérationnel r_3), fortement corrélés entre eux ($r_{ij} > 0,7$ pour toutes les paires). Le premier axe de l'ACP s'écrit $C_1 = 0,58 z_{r_1} + 0,57 z_{r_2} + 0,58 z_{r_3}$ et porte 85 % de l'inertie totale.

- (a) Compte tenu du signe et de la taille des trois coefficients, quelle interprétation économique naturelle peut-on proposer pour C_1 ?
- (b) La direction des risques souhaite classer les dossiers uniquement à l'aide de ce premier axe plutôt que de suivre séparément les trois scores. Que gagne-t-elle en simplicité, et que risque-t-elle de perdre en information (penser aux 15 % d'inertie non captés) ?
- (c) Pourquoi la condition « les variables doivent être corrélées » du cours est-elle précisément ce qui rend cet indicateur synthétique pertinent ici, alors qu'elle interdirait une démarche similaire sur trois risques totalement indépendants ?