Introduction à l'analyse des données

Chapitre 6 : L'inertie, ou l'information d'un nuage

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Mesurer l'information **2**
- Ce qui manque encore . . . 2
- L'inertie, en image . . . 2
- La définition . . . 3

Le calcul sur le fil rouge **3**
- Données brutes . . . 3
- Données réduites . . . 3
- Qui porte l'information . . . 4

Le résultat qui relie tout **4**
- L'inertie est une somme de variances . . . 4
- La vérification, sur les deux tableaux . . . 4
- Le cas des données réduites . . . 5
- Pourquoi ce résultat est si commode . . . 5

L'inertie du nuage réel **5**
- Trois cents distances au centre . . . 5
- Le client le plus éloigné . . . 6
- Les clients 36 et 246, à nouveau . . . 6

Le centre minimise l'inertie **6**
- L'inertie autour d'un autre point . . . 6
- Pourquoi les axes passent par le centre . . . 7

Décomposer l'inertie **8**
- Ce qu'une projection conserve . . . 8
- Le chameau, enfin chiffré . . . 9
- Deux projections des cinq clients . . . 9
- Quatre axes, quatre bilans . . . 9
- Le même bilan, sur le fichier réel . . . 10

Sur machine **10**
- Avec R . . . 10

Avec Python 10

S'entraîner **11**
Exercice 1 : quatre points 11
Exercice 1 : solution 11
Exercice 2 : le théorème de Huygens 11
Exercice 2 : solution 12
Exercice 3 : projeter les cinq clients 12
Exercice 3 : solution 12

Ce qu'il faut retenir **12**
Le résumé du chapitre 12
La suite 13

Mesurer l'information

Ce qui manque encore

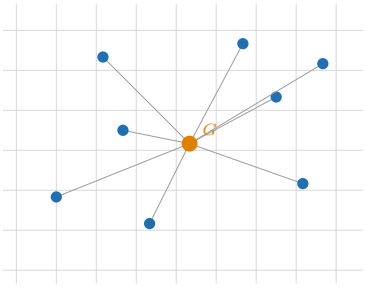
La question laissée en suspens à l'introduction

Le photographe cherche l'angle qui **perd le moins d'information**. Encore faut-il savoir la mesurer : sans quoi on ne peut ni comparer deux angles, ni dire qu'une représentation est bonne.

L'idée

Un nuage dont tous les points seraient **confondus** ne contiendrait aucune information : tous les individus seraient identiques.
Un nuage **très dispersé** en contient beaucoup : les individus diffèrent, et ces différences sont précisément ce qu'on veut décrire.
L'information d'un nuage, c'est donc sa dispersion.

L'inertie, en image



L'inertie totale

$$I_{\text{tot}} = \frac{1}{n}\sum_{i=1}^{n} d^2(i,G)$$

Elle mesure exactement ce que mesurait la variance — et pour une seule variable, elle *est* la variance.

Sur données centrées-réduites, chaque variable apporte une inertie de 1. Avec p variables, l'inertie totale vaut donc p : ici 8.

C'est la monnaie de tout le cours. « Cet axe explique 56,7 % » signifiera toujours : il en conserve 56,7 %.

La définition

Inertie totale

$$I = \frac{1}{n}\sum_{i=1}^{n} d^2(i,G)$$

C'est la **moyenne des carrés des distances** des individus au centre de gravité.

Le mot vient de la mécanique

En physique, le moment d'inertie mesure la difficulté à faire tourner un corps autour d'un axe : plus la masse est éloignée de l'axe, plus l'inertie est grande.
Ici, plus les individus sont éloignés du centre, plus l'inertie est grande. **Le vocabulaire est emprunté, la notion est la même.**

Le calcul sur le fil rouge

Données brutes

Les cinq carrés des distances au centre G = (12 ; 12)

Client	$x_i - 12$	$y_i - 12$	$d^2(i,G)$	Part de l'inertie
1	-4	-8	$16 + 64 = 80$	40 %
2	-2	0	$4 + 0 = 4$	2 %
3	0	-4	$0 + 16 = 16$	8 %
4	2	4	$4 + 16 = 20$	10 %
5	4	8	$16 + 64 = 80$	40 %
Somme			**200**	100 %

$$I = \frac{200}{5} = 40$$

Données réduites

Les mêmes carrés, avec les valeurs réduites

Client	z_x	z_y	$d^2(i,G)$	Part de l'inertie
1	$-1{,}414$	$-1{,}414$	$2 + 2 = 4$	40 %
2	$-0{,}707$	0	$0{,}5 + 0 = 0{,}5$	5 %
3	0	$-0{,}707$	$0 + 0{,}5 = 0{,}5$	5 %
4	0,707	0,707	$0{,}5 + 0{,}5 = 1$	10 %
5	1,414	1,414	$2 + 2 = 4$	40 %
Somme			**10**	100 %

$$I = \frac{10}{5} = 2$$

Qui porte l'information

Les deux extrêmes font les quatre cinquièmes

Les clients 1 et 5, aux deux bouts du nuage, portent chacun 40 % de l'inertie. Le client 4 en porte 10 %, les clients 2 et 3 presque rien.
L'inertie est **dominée par les individus éloignés du centre** — une conséquence directe des carrés.

La réduction a changé deux parts

Brut, le client 3 portait 8 % et le client 2 seulement 2 %, parce que l'écart du client 3 est sur la fidélité, très dispersée. Réduits, ils portent chacun 5 % : un écart d'un demi-écart-type pèse autant sur les deux critères.

Le résultat qui relie tout

L'inertie est une somme de variances

Le théorème

$$I = \sum_{j=1}^{p} V(x_j)$$

L'inertie totale du nuage est la somme des variances des variables.

Pourquoi c'est immédiat

Par Pythagore, $d^2(i, G) = \sum_j (x_{ij} - \bar{x}_j)^2$. Moyenner sur les individus et intervertir les deux sommes :

$$I = \frac{1}{n} \sum_i \sum_j (x_{ij} - \bar{x}_j)^2 = \sum_j \frac{1}{n} \sum_i (x_{ij} - \bar{x}_j)^2 = \sum_j V(x_j)$$

L'inertie est la dispersion totale, tous critères confondus — la dispersion du chapitre 2 est la taille du nuage du chapitre 5.

La vérification, sur les deux tableaux

Données brutes

$$I = V(x) + V(y) = 8 + 32 = 40$$

C'est bien la moyenne des cinq carrés de distances. La fidélité pèse **quatre fois** plus que l'accueil dans cette inertie — uniquement parce qu'elle est notée avec plus de dispersion.

Les huit notes du fichier réel

Huit variances d'environ 5,75 chacune : $I = 46{,}0$ en données brutes. La moyenne des 300 carrés de distances au centre donne exactement le même nombre.

Le cas des données réduites

Le résultat décisif

Après réduction, **chaque variable a une variance de** 1. Donc

$$\boxed{I = p}$$

L'inertie totale d'un tableau réduit est égale au nombre de variables.

Sur nos deux tableaux

Les cinq clients : deux variables réduites, $I = 1+1 = 2$ — la moyenne des carrés 10/5 trouvée plus haut.
Les trois cents clients : huit notes réduites, $I = 8$.

Pourquoi ce résultat est si commode

Un étalon

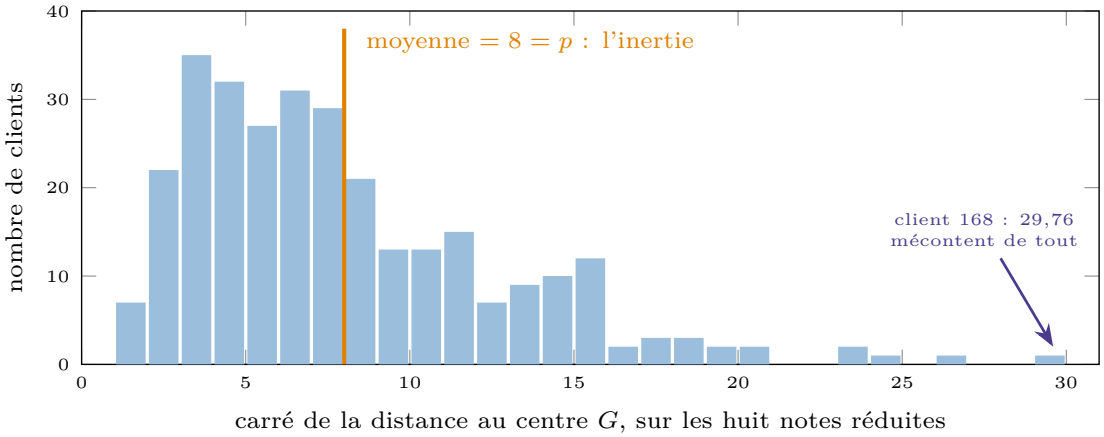
Si l'inertie totale vaut p, dire qu'un axe en porte 1,9 sur 2 signifie immédiatement 95 %. Sans lui, « 1,9 » ne voudrait rien dire. C'est ce qui rendra lisibles les pourcentages des chapitres 8 et 9.

Chaque variable apporte une unité d'inertie

Sur données réduites, chaque variable **pèse exactement** 1 dans l'inertie : l'accueil et la fidélité pèsent désormais autant l'une que l'autre, ce qui était bien l'intention du chapitre 2. Ajouter une variable au tableau, c'est ajouter une unité d'information à résumer.

L'inertie du nuage réel

Trois cents distances au centre



Ce que montre l'histogramme

La moyenne des 300 carrés vaut exactement 8. La médiane est plus basse (6,87) : quelques clients très éloignés tirent la moyenne vers le haut.

Le client le plus éloigné

Le client 168

Ses huit notes : prix 7,5, choix 11,2, qualité 11,9, agencement 6,0, propreté 10,1, rapidité 5,4, conseil 12,3, accueil 8,4.
Toutes sous la moyenne : $d^2 = 29{,}76$, près de **quatre fois** la moyenne. Il porte à lui seul $29{,}76/2\,400 = 1{,}24\,\%$ de l'inertie du nuage.

Atypique, mais pas dominant

Un client sur trois cents porte 1,24 % de l'information, quatre fois sa part « normale » ($1/300 = 0{,}33\,\%$). C'est beaucoup, mais il ne peut pas fabriquer un axe à lui seul. Sur cinq clients, en revanche, deux en portaient 80 %.

Les clients 36 et 246, à nouveau

Même moyenne, distances au centre différentes

Client	Note moyenne	$d^2(i,G)$	Part de l'inertie
36	13,9	6,01	0,25 %
246	13,9	15,88	0,66 %

Ce que la distance au centre mesure

La note moyenne des deux clients est proche de celle de l'ensemble ; pourtant le client 246 est **loin** du centre. Il ne s'écarte pas par son niveau, mais par son **profil** : très bon sur l'offre, très mauvais sur le service. L'inertie compte cette originalité, que la moyenne ignore.

Le centre minimise l'inertie

L'inertie autour d'un autre point

Le théorème de Huygens

Pour tout point A de l'espace :

$$I_A = \frac{1}{n}\sum_{i=1}^{n} d^2(i,A) = I_G + d^2(A,G)$$

L'inertie autour de A est l'inertie autour du centre, **augmentée** du carré de la distance de A au centre.

Démonstration : Le théorème de Huygens

Pour chaque individu i, écrivons $x_i - A = (x_i - G) + (G - A)$ et développons le carré de la norme (les individus sont des points de $\mathbb{R}^p$) :

$$d^2(i, A) = d^2(i, G) + 2\,\langle x_i - G,\ G - A\rangle + d^2(G, A).$$

Moyennons sur les n individus. Le premier terme donne I_G et le dernier est constant. Pour le terme du milieu, le produit scalaire est linéaire :

$$\frac{1}{n}\sum_i \langle x_i - G,\ G - A\rangle = \Big\langle \frac{1}{n}\sum_i (x_i - G),\ G - A\Big\rangle = 0,$$

car $\frac{1}{n}\sum_i (x_{ij} - \bar{x}_j) = 0$ pour **chaque** coordonnée j (chapitre 2) : le centre de gravité est justement le point où les écarts se compensent. Il reste $I_A = I_G + d^2(G, A)$.

Conséquence. $d^2(G, A) \geq 0$, avec égalité seulement si $A = G$: le centre de gravité est l'**unique** point autour duquel l'inertie est minimale. C'est le résultat du chapitre 2 (la moyenne minimise la somme des carrés), en dimension p.

Sur les huit notes brutes, avec $A = (10, \dots, 10)$, le milieu de l'échelle : $I_G = 46{,}0$ et $d^2(A, G) = 87{,}4$, donc l'inertie autour de A vaut $46{,}0 + 87{,}4 = 133{,}4$.

■

Sur les cinq clients bruts, autour de A = (10 ; 10)

Carrés des distances à A : 40, 4, 8, 52, 136. Leur moyenne : $240/5 = 48$.
Et $I_G + d^2(A, G) = 40 + (2^2 + 2^2) = 48$. **Le théorème est vérifié.**

Pourquoi les axes passent par le centre

G est le point le plus proche de tous

Le terme $d^2(A, G)$ est toujours positif, et nul seulement si $A = G$. Le centre de gravité est donc **le point autour duquel l'inertie est la plus petite** : le meilleur résumé du nuage par un point unique.

La conséquence pour la suite

Un axe qui ne passerait pas par G ajouterait à l'inertie un terme parasite, qui ne décrit pas les différences entre individus mais seulement le décalage de l'axe. C'est pourquoi **tous les axes de l'ACP passent par le centre** — et pourquoi on centre les données avant tout.

Décomposer l'inertie

Ce qu'une projection conserve

Le théorème de Pythagore, appliqué au nuage

Projeter le nuage sur un axe passant par G décompose l'inertie en deux parts :

$$\underbrace{I}_{\text{totale}} = \underbrace{I_{\text{projetée}}}_{\text{conservée}} + \underbrace{I_{\text{résiduelle}}}_{\text{perdue}}$$

Démonstration : L'inertie se partage en une part conservée et une part perdue

Soit u un vecteur de longueur 1 qui dirige l'axe (passant par G). Pour l'individu i, notons $c_i = \langle x_i - G,\ u\rangle$ la coordonnée de sa projection $P_i = G + c_i\, u$ sur l'axe. Le reste $x_i - P_i$ est **perpendiculaire** à l'axe :

$$\langle x_i - P_i,\ u\rangle = \langle x_i - G,\ u\rangle - c_i \langle u, u\rangle = c_i - c_i = 0.$$

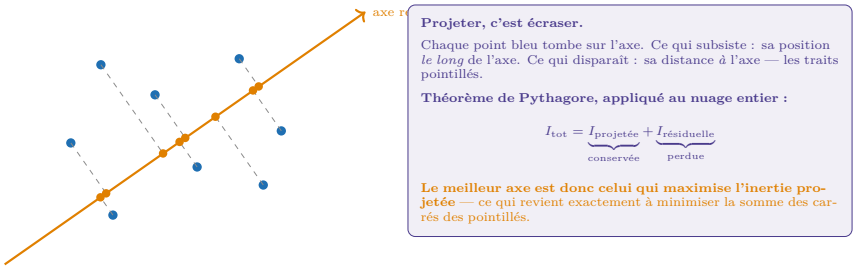
Le triangle $G\,P_i\,x_i$ est donc rectangle en P_i, et le théorème de Pythagore donne, pour chaque individu,

$$d^2(i,G) = \underbrace{c_i^2}_{d^2(P_i,G)} + \underbrace{d^2(i,P_i)}_{\text{ce que la projection écrase}}.$$

Moyennons sur les n individus : $I = I_{\text{projetée}} + I_{\text{résiduelle}}$, avec $I_{\text{projetée}} = \frac{1}{n}\sum_i c_i^2$. Comme $\frac{1}{n}\sum_i c_i = 0$ (les écarts à G se compensent), $I_{\text{projetée}}$ est la **variance** des coordonnées c_i.

Sur les cinq clients réduits, la diagonale $u = (1,1)/\sqrt{2}$ donne les coordonnées $c = (-2\,;\ -0{,}5\,;\ -0{,}5\,;\ 1\,;\ 2)$, donc $I_{\text{projetée}} = (4 + 0{,}25 + 0{,}25 + 1 + 4)/5 = 1{,}9$ et $I_{\text{résiduelle}} = 2 - 1{,}9 = 0{,}1$. Sur les huit notes réduites, l'axe qui donne le même poids aux huit notes conserve 4,502 unités d'inertie et en perd 3,498 : $4{,}502 + 3{,}498 = 8$.

■



Le chameau, enfin chiffré

Conserver, écraser

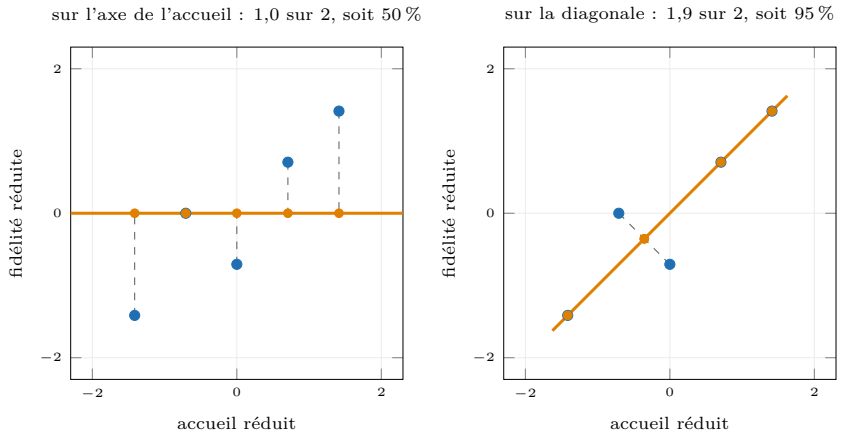
L'inertie projetée est ce que la photographie **conserve** ; l'inertie résiduelle est ce qu'elle **écrase**.
Un bon angle est celui qui rend l'inertie projetée maximale. **Le problème du photographe devient donc un problème d'optimisation**, et il a une solution exacte.

Le programme de l'analyse en composantes principales

trouver l'axe qui **maximise** l'inertie projetée

C'est tout. Les chapitres qui suivent ne font que résoudre ce problème et lire sa solution.

Deux projections des cinq clients



L'accueil seul, ou la diagonale

Projetés sur l'axe de l'accueil, les cinq clients gardent 1 des 2 unités d'inertie : 50 %. Projetés sur la **diagonale**, ils en gardent 1,9 : **95** %.

Quatre axes, quatre bilans

Inertie conservée et perdue, sur les cinq clients réduits

Axe	Conservée	Perdue	Part conservée
l'accueil (angle 0°)	1	1	50 %
la fidélité (angle 90°)	1	1	50 %
la diagonale (angle 45°)	1,9	0,1	**95** %
l'anti-diagonale (angle 135°)	0,1	1,9	5 %

Ce que le tableau annonce

Une variable d'origine ne garde que **sa propre** unité d'inertie. La diagonale, qui **combine** les deux notes, en garde presque tout. Et la diagonale et l'anti-diagonale, perpendiculaires, se partagent exactement les 2 unités : $1{,}9 + 0{,}1 = 2$.

Le même bilan, sur le fichier réel

Trois axes pour les huit notes réduites

Axe	Inertie conservée	Part sur 8
une seule note, le prix	1	12,5 %
la moyenne des huit notes	4,502	56,3 %
le meilleur axe (chapitre 8)	4,535	56,7 %

Un indicateur naïf déjà presque optimal

L'axe qui donne le même poids aux huit notes conserve déjà 56,3 % de l'information. Le meilleur axe fait à peine mieux, en pondérant un peu moins le prix : on verra au chapitre 8 comment il se calcule, et au chapitre 9 ce que le **second** axe ajoute.

Sur machine

Avec R

Le code et sa sortie

```r
clients <- read.csv("clients.csv")
notes <- c("prix", "choix", "qualite", "agencement",
           "proprete", "rapidite", "conseil", "accueil")
X <- as.matrix(clients[, notes])
Z <- scale(X) * sqrt(300 / 299)        # réduction en n
d2 <- rowSums(Z^2)                     # carrés des distances à G
mean(d2)                                          # [1] 8
round(sum(apply(X, 2, function(v) mean((v - mean(v))^2))), 2)
                                                  # [1] 46
clients$id[which.max(d2)]                         # [1] 168
round(max(d2), 2)                                 # [1] 29.76
```

Avec Python

Le code et sa sortie

```
import pandas as pd
clients = pd.read_csv("clients.csv")
notes = ["prix", "choix", "qualite", "agencement",
         "proprete", "rapidite", "conseil", "accueil"]
X = clients[notes]
Z = (X - X.mean()) / X.std(ddof=0)
d2 = (Z ** 2).sum(axis=1)
print(round(d2.mean(), 4), round(X.var(ddof=0).sum(), 2))
# 8.0 46.0
print(clients.id[d2.idxmax()], round(d2.max(), 2))
# 168 29.76
```

Les deux résultats du chapitre en deux lignes

L'inertie réduite vaut $p = 8$; l'inertie brute est la somme des variances, 46,0.

S'entraîner

Exercice 1 : quatre points

L'inertie, de deux façons

Quatre individus ont pour coordonnées $(0;0)$, $(2;0)$, $(0;4)$, $(2;4)$.

1. Calculer le centre de gravité.
2. Calculer l'inertie comme moyenne des carrés des distances au centre.
3. La retrouver comme somme des variances.

Exercice 1 : solution

Inertie 5

1. $G = (1;2)$.
2. Chaque point est à $(\pm 1;\pm 2)$ du centre : $d^2 = 1 + 4 = 5$ pour les quatre. $I = 20/4 = 5$.
3. Première coordonnée : $0, 2, 0, 2$, de variance 1. Seconde : $0, 0, 4, 4$, de variance 4. $I = 1 + 4 = 5$. La seconde variable porte $80\,\%$ de l'inertie.

Exercice 2 : le théorème de Huygens

L'inertie autour de l'origine

Reprendre les quatre points de l'exercice 1.

1. Calculer leur inertie autour de l'origine $O = (0;0)$, directement.
2. La retrouver par le théorème de Huygens.
3. Existe-t-il un point autour duquel l'inertie vaut 4 ?

Exercice 2 : solution

Toujours au moins I au centre

1. Carrés des distances à O : 0, 4, 16, 20. Moyenne : $40/4 = 10$.
2. $I_O = I_G + d^2(O,G) = 5 + (1+4) = 10$.
3. **Non** : pour tout point A, $I_A = 5 + d^2(A,G) \geq 5$. L'inertie la plus faible est atteinte au centre, et elle vaut 5.

Exercice 3 : projeter les cinq clients

Un axe à 30 degrés

On projette les cinq clients réduits sur l'axe de direction $u = (\cos 30°; \sin 30°) = (0{,}866; 0{,}5)$. La projection d'un client vaut $0{,}866\, z_x + 0{,}5\, z_y$.

1. Calculer les cinq projections.
2. Calculer l'inertie projetée et la part conservée.
3. Situer cet axe entre l'accueil et la diagonale.

Exercice 3 : solution

1,78 sur 2, soit 89 pour cent

1. Clients 1 à 5 : $-1{,}932$; $-0{,}612$; $-0{,}354$; $0{,}966$; $1{,}932$.
2. Carrés : $3{,}732 + 0{,}375 + 0{,}125 + 0{,}933 + 3{,}732 = 8{,}897$; inertie $8{,}897/5 = 1{,}779$, soit 89 % des 2 unités.
3. Entre l'accueil (50 %) et la diagonale (95 %) : plus l'axe se rapproche de la direction d'allongement du nuage, plus il conserve d'inertie.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. L'**information** d'un nuage est sa **dispersion** ; l'**inertie** est la moyenne des carrés des distances au centre.
2. Elle est égale à la **somme des variances** : 40 pour les cinq clients bruts, 46,0 pour les huit notes.
3. Sur données **réduites**, $I = p$: 2 pour les cinq clients, 8 pour les trois cents. C'est l'étalon des pourcentages.
4. L'inertie est dominée par les individus **éloignés** du centre : les clients 1 et 5 en portent 80 %.
5. **Huygens** : $I_A = I_G + d^2(A,G)$; le centre minimise l'inertie, et les axes y passent.
6. Une projection **décompose** l'inertie : la diagonale garde 1,9 sur 2, l'accueil seul 1.

La suite

Un problème bien posé

Le problème est posé, et il est bien posé : maximiser l'inertie projetée. Le chapitre 7 explique comment on le résout.

Ce qu'on y fera

On fera tourner l'axe autour du centre des cinq clients, on suivra l'inertie projetée degré par degré, et l'on montrera, en trois lignes de calcul, que la diagonale est le meilleur axe possible.