

Introduction à l'analyse des données

Chapitre 12 : Du khi-deux à l'analyse des correspondances

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer le khi-deux et l'inertie d'un tableau de contingence

Une banque croise le statut professionnel de ses clients (employés, cadres) et le type de compte détenu (Banque A, Banque B, Banque C) :

	Banque A	Banque B	Banque C	Total
Employés	120	50	30	200
Cadres	30	40	30	100
Total	150	90	60	300

- (a) Calculer les effectifs attendus sous indépendance pour chacune des six cases.
- (b) Calculer le $\chi^2 = \sum \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$, et préciser son nombre de degrés de liberté.
- (c) Calculer l'inertie totale $\Phi^2 = \chi^2/n$, et le nombre d'axes que l'AFC pourra produire sur ce tableau ($\min(\text{lignes}, \text{colonnes}) - 1$).

Exercice 2 — Raisonner en profils plutôt qu'en effectifs bruts

On reprend le tableau de l'exercice 1.

- (a) Calculer le profil-ligne des employés (répartition en % entre les trois banques) et celui des cadres.
- (b) Calculer le profil-ligne de « l'ensemble » (à partir des totaux en colonne).
- (c) Les employés sont deux fois plus nombreux que les cadres (200 contre 100). Expliquer pourquoi comparer directement les effectifs bruts (120 contre 30 pour la Banque A) confondrait deux choses différentes, et pourquoi les profils (60 % contre 30 %) évitent ce problème.

Exercice 3 — Ce que l'AFC ajoute au test du khi-deux

On rappelle que le cours de Statistique inférentielle permet de tester, à partir du χ^2 calculé à l'exercice 1, l'hypothèse d'indépendance entre statut professionnel et type de compte.

- (a) Que répond ce test, dans le meilleur des cas – que peut-on affirmer, et que ne peut-on *pas* encore affirmer, sur la nature du lien entre les deux variables ?
- (b) En quel sens l'inertie Φ^2 de l'AFC est-elle une généralisation de l'inertie définie au chapitre 6 pour un nuage de points – quel rôle joue ici la situation d'« indépendance » par rapport au « centre de gravité » du chapitre 6 ?
- (c) Pourquoi l'ACP (chapitres 7 à 9) ne peut-elle pas s'appliquer directement à un tableau de contingence comme celui-ci, alors que la démarche de décomposition d'une inertie sur des axes hiérarchisés est, comme le dit le cours, « identique » entre les deux méthodes ?

2 Exercices cumulatifs (introduction au chapitre 12)

Exercice 4 — Vérifier le tableau du cours

On reprend le tableau de contingence du cours : type de client (jeunes, familles, seniors) croisé avec le canal d'achat (magasin, web, téléphone) : jeunes = (30, 60, 10), familles = (80, 40, 30), seniors = (90, 20, 40), avec des totaux de ligne 100, 150, 150 et des totaux de colonne 200, 120, 80 (total général 400).

- (a) Calculer les neuf effectifs attendus sous indépendance, et vérifier qu'ils correspondent à ceux du cours (50, 30, 20 ; 75, 45, 30 ; 75, 45, 30).
- (b) Calculer χ^2 , et vérifier qu'on retrouve bien $\chi^2 \approx 64,1$ pour 4 degrés de liberté.

- (c) Calculer $\Phi^2 = \chi^2/n$, vérifier qu'on retrouve $\Phi^2 \approx 0,160$, et donner le nombre d'axes que l'AFC produira sur ce tableau 3×3 .

3 Applications en sciences économiques

Exercice 5 — Financement des entreprises selon leur taille

Un cabinet de conseil croise la taille de 400 entreprises (PME, grande entreprise) et leur principal mode de financement (crédit bancaire, obligataire, fonds propres) :

	Crédit bancaire	Obligataire	Fonds propres	Total
PME	140	20	40	200
Grande entreprise	60	80	60	200
Total	200	100	100	400

- Calculer les effectifs attendus sous indépendance, puis le χ^2 .
- Calculer Φ^2 et le nombre d'axes que produira l'AFC sur ce tableau.
- En comparant les effectifs observés et attendus, quelle case contribue le plus à l'écart entre PME et grande entreprise ? Formuler, en une phrase, ce que révèle cet écart sur le mode de financement des PME.

Exercice 6 — Le rating de risque prédit-il le défaut ?

Une banque croise le niveau de risque attribué à 400 dossiers de crédit (faible, moyen, élevé) et le fait qu'ils aient ou non fait défaut :

	Défaut	Pas de défaut	Total
Risque faible	10	190	200
Risque moyen	25	95	120
Risque élevé	45	35	80
Total	80	320	400

- Calculer les effectifs attendus sous indépendance pour les six cases.
- Calculer χ^2 et Φ^2 .
- Le dossier « risque élevé » affiche 45 défauts observés contre un effectif attendu bien plus faible sous indépendance. Que cela indique-t-il sur la qualité du système de notation de risque de cette banque ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Employés-A = $\frac{200 \times 150}{300} = 100$; Employés-B = $\frac{200 \times 90}{300} = 60$; Employés-C = $\frac{200 \times 60}{300} = 40$;
Cadres-A = $\frac{100 \times 150}{300} = 50$; Cadres-B = $\frac{100 \times 90}{300} = 30$; Cadres-C = $\frac{100 \times 60}{300} = 20$.
- (b) $\chi^2 = \frac{(120 - 100)^2}{100} + \frac{(50 - 60)^2}{60} + \frac{(30 - 40)^2}{40} + \frac{(30 - 50)^2}{50} + \frac{(40 - 30)^2}{30} + \frac{(30 - 20)^2}{20} = 4 + 1,667 + 2,5 + 8 + 3,333 + 5 = 24,5$. Degrés de liberté = $(2 - 1)(3 - 1) = 2$.
- (c) $\Phi^2 = \frac{24,5}{300} \approx 0,0817$. Nombre d'axes = $\min(2, 3) - 1 = 1$.

Correction — Exercice 2

- (a) Profil employés : $\frac{120}{200} = 60\%$ (A), $\frac{50}{200} = 25\%$ (B), $\frac{30}{200} = 15\%$ (C). Profil cadres : $\frac{30}{100} = 30\%$ (A), $\frac{40}{100} = 40\%$ (B), $\frac{30}{100} = 30\%$ (C).
- (b) Profil ensemble : $\frac{150}{300} = 50\%$ (A), $\frac{90}{300} = 30\%$ (B), $\frac{60}{300} = 20\%$ (C).
- (c) Comparer 120 à 30 mélange deux effets : les employés sont deux fois plus nombreux (200 contre 100), donc leurs effectifs bruts sont mécaniquement plus grands sur **toutes** les banques, y compris celles qu'ils choisissent *moins* en proportion. Les profils (60 % contre 30 % pour la Banque A) neutralisent cet effet de taille de groupe et ne montrent plus que la **préférence relative** : les employés choisissent réellement deux fois plus souvent la Banque A que les cadres, une fois la différence de taille des deux groupes retirée.

Correction — Exercice 3

- (a) Le test conclut seulement au **rejet ou non de l'indépendance** entre statut professionnel et type de compte – un verdict binaire (« il y a un lien » ou « on ne peut pas conclure à un lien »). Il ne dit **pas** quelles catégories s'attirent ou se repoussent (les employés préfèrent-ils la Banque A ou B?), ni selon quelles dimensions structurelles ce lien s'organise.
- (b) Au chapitre 6, l'inertie mesurait la dispersion d'un nuage de points autour de son **centre de gravité**, calculé à partir des données elles-mêmes. Ici, le « centre » de référence n'est plus une moyenne des observations, mais la situation théorique d'**indépendance** (les effectifs attendus) : Φ^2 mesure de combien le tableau observé s'écarte de cette situation de référence, exactement comme l'inertie du chapitre 6 mesurait de combien le nuage s'écartait de son centre.
- (c) L'ACP suppose des variables **quantitatives**, sur lesquelles on peut calculer une moyenne, une variance et une corrélation (chapitres 2 à 4) – des notions qui n'ont aucun sens sur des catégories comme « employés » ou « Banque A ». La démarche de décomposition d'une inertie totale sur des axes hiérarchisés reste *identique* dans les deux méthodes (chapitres 7 à 9), mais l'inertie de départ n'est pas calculée de la même façon : dispersion de mesures pour l'ACP, écart à l'indépendance pour l'AFC.

2 Exercices cumulatifs (introduction au chapitre 12)


Correction — Exercice 4

- (a) Jeunes-Magasin = $\frac{100 \times 200}{400} = 50$; Jeunes-Web = $\frac{100 \times 120}{400} = 30$; Jeunes-Téléphone = $\frac{100 \times 80}{400} = 20$;
Familles-Magasin = $\frac{150 \times 200}{400} = 75$; Familles-Web = $\frac{150 \times 120}{400} = 45$; Familles-Téléphone = $\frac{150 \times 80}{400} = 30$.

$= \frac{150 \times 80}{400} = 30$; Seniors-Magasin $= \frac{150 \times 200}{400} = 75$; Seniors-Web $= \frac{150 \times 120}{400} = 45$; Seniors-Téléphone $= \frac{150 \times 80}{400} = 30$. On retrouve exactement les valeurs du cours.

(b) $\chi^2 = \frac{(30 - 50)^2}{50} + \frac{(60 - 30)^2}{30} + \frac{(10 - 20)^2}{20} + \frac{(80 - 75)^2}{75} + \frac{(40 - 45)^2}{45} + \frac{(30 - 30)^2}{30} + \frac{(90 - 75)^2}{75} + \frac{(20 - 45)^2}{45} + \frac{(40 - 30)^2}{30} = 8 + 30 + 5 + 0,333 + 0,556 + 0 + 3 + 13,889 + 3,333 \approx 64,1$, pour 4 degrés de liberté. On retrouve bien le résultat du cours.

(c) $\Phi^2 = \frac{64,1}{400} \approx 0,160$, valeur identique à celle du cours. Nombre d'axes $= \min(3, 3) - 1 = 2$.



3 Applications en sciences économiques

Correction — Exercice 5

(a) PME-Crédit $= \frac{200 \times 200}{400} = 100$; PME-Obligataire $= \frac{200 \times 100}{400} = 50$; PME-FondsPropres $= \frac{200 \times 100}{400} = 50$; Grande entreprise : mêmes attendus par symétrie des totaux (100, 50, 50).

$\chi^2 = \frac{(140 - 100)^2}{100} + \frac{(20 - 50)^2}{50} + \frac{(40 - 50)^2}{50} + \frac{(60 - 100)^2}{100} + \frac{(80 - 50)^2}{50} + \frac{(60 - 50)^2}{50} = 16 + 18 + 2 + 16 + 18 + 2 = 72$.

(b) $\Phi^2 = \frac{72}{400} = 0,18$. Nombre d'axes $= \min(2, 3) - 1 = 1$.

(c) La case « PME-Obligataire » (20 observés contre 50 attendus) et la case « Grande entreprise-Obligataire » (80 observés contre 50 attendus) contribuent chacune 18 au χ^2 total de 72, soit ensemble la moitié de l'écart. Cela révèle que les PME recourent **beaucoup moins** au financement obligataire qu'attendu sous indépendance – et davantage au crédit bancaire (140 contre 100 attendus) – traduisant probablement leur accès plus difficile aux marchés obligataires, réservés en pratique aux plus grandes structures.

Correction — Exercice 6

(a) Risque faible-Défaut $= \frac{200 \times 80}{400} = 40$, Pas de défaut = 160. Risque moyen-Défaut $= \frac{120 \times 80}{400} = 24$, Pas de défaut = 96. Risque élevé-Défaut $= \frac{80 \times 80}{400} = 16$, Pas de défaut = 64.

(b) $\chi^2 = \frac{(10 - 40)^2}{40} + \frac{(190 - 160)^2}{160} + \frac{(25 - 24)^2}{24} + \frac{(95 - 96)^2}{96} + \frac{(45 - 16)^2}{16} + \frac{(35 - 64)^2}{64} \approx 22,5 + 5,625 + 0,042 + 0,010 + 52,563 + 13,141 \approx 93,88$. $\Phi^2 = \frac{93,88}{400} \approx 0,235$.

(c) L'écart le plus spectaculaire se situe précisément sur la catégorie « risque élevé » : 45 défauts observés contre seulement 16 attendus sous indépendance – près de trois fois plus. Cela indique que le système de notation de risque de la banque **fonctionne bien** : les dossiers qu'il classe comme risqués font effectivement défaut beaucoup plus souvent que ne le voudrait le hasard, et à l'inverse les dossiers « risque faible » font défaut bien moins souvent qu'attendu (10 contre 40) – le rating est statistiquement

associé au comportement réel des emprunteurs.