Introduction à l'analyse des données

Chapitre 12 : Du khi-deux à l'analyse des correspondances

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Un autre type de tableau **2**
- Le tableau de contingence . . . 2
- Deux tableaux, comme pour l'ACP . . . 2

L'écart à l'indépendance **3**
- Les effectifs attendus . . . 3
- Le tableau des écarts . . . 3
- Le khi-deux . . . 4
- Où se trouve l'écart . . . 4
- Ce que la statistique inférentielle en faisait . . . 5
- Le tableau réel, observé et attendu . . . 5
- Le khi-deux réel . . . 5
- Les cases qui font le khi-deux réel . . . 6

L'inertie d'un tableau croisé **6**
- Du khi-deux à l'inertie . . . 6
- Pourquoi diviser par n . . . 6
- Le pont avec tout ce qui précède . . . 7

Les profils **8**
- Comparer des lignes de tailles différentes . . . 8
- Les profils, dans un triangle . . . 8
- Pourquoi raisonner en profils . . . 8
- Les profils réels . . . 9
- Les profils réels, en image . . . 9

La distance du khi-deux **9**
- Mesurer l'écart d'un profil au profil moyen . . . 9
- Le calcul, sur le petit tableau . . . 10
- Sur le tableau réel . . . 11
- Une propriété remarquable . . . 11

Sur machine **12**
- Avec R : le test . . . 12

Avec R : l'inertie . . . 12
Avec Python . . . 12

S'entraîner **13**
Exercice 1 : un tableau deux sur trois . . . 13
Exercice 1 : solution . . . 13
Exercice 2 : profils et distances . . . 13
Exercice 2 : solution . . . 13
Exercice 3 : le tableau réel . . . 13
Exercice 3 : solution . . . 14

Ce qu'il faut retenir **14**
Le résumé du chapitre . . . 14
La suite . . . 14

Un autre type de tableau

Le tableau de contingence

La situation

Deux variables **qualitatives** croisées : chaque case porte un **effectif**, non une mesure. L'ACP ne s'applique pas : ni moyenne, ni variance, ni corrélation sur des catégories.

Le tableau du calcul à la main : type de client et canal d'achat

	Magasin	Web	Téléphone	**Total**
Jeunes	30	60	10	100
Familles	80	40	30	150
Seniors	90	20	40	150
Total	**200**	**120**	**80**	**400**

Deux tableaux, comme pour l'ACP

Un tableau pour calculer, un tableau réel

Comme pour l'ACP, deux fils rouges : ce petit tableau 3 × 3, qui se calcule entièrement à la main, et le croisement réel de la **CSP** et du **motif de visite** des 300 clients.

Le tableau réel : CSP et motif de visite

	Choix	Prix	Proximité	Service	**Total**
Cadre	40	8	8	16	72
Employé	20	45	26	10	101
Étudiant	2	14	5	1	22
Indépendant	19	12	12	32	75

Retraité	1	5	17	7	30
Total	**82**	**84**	**68**	**66**	**300**

L'écart à l'indépendance

Les effectifs attendus

Sous indépendance

Si les deux variables étaient sans lien, chaque case vaudrait

$$\text{attendu} = \frac{\text{total ligne} \times \text{total colonne}}{\text{total général}}$$

Une case, en détail

Jeunes et web : $100 \times 120/400 = 30$. Sous l'indépendance, les jeunes représentent 25 % des clients ; ils devraient donc faire 25 % des 120 achats sur le web.

Le tableau des écarts

Effectif observé, et attendu entre parenthèses

	Magasin	Web	Téléphone
Jeunes	30 (50)	60 (30)	10 (20)
Familles	80 (75)	40 (45)	30 (30)
Seniors	90 (75)	20 (45)	40 (30)

Les jeunes achètent **deux fois plus** sur le web qu'attendu, les seniors **deux fois moins** : c'est là qu'est l'information.

Les marges sont respectées

Le tableau des attendus a **les mêmes totaux** de lignes et de colonnes que le tableau observé. Il ne change que la façon dont les effectifs se répartissent à l'intérieur.

Démonstration : Les effectifs attendus respectent les marges

Notons $n_{i\cdot}$ le total de la ligne i, $n_{\cdot j}$ celui de la colonne j, n le total général, et $E_{ij} = n_{i\cdot}\, n_{\cdot j}/n$. En sommant sur les colonnes, puis sur les lignes,

$$\sum_j E_{ij} = \frac{n_{i\cdot}}{n} \sum_j n_{\cdot j} = \frac{n_{i\cdot}}{n}\, n = n_{i\cdot}, \qquad \sum_i E_{ij} = \frac{n_{\cdot j}}{n} \sum_i n_{i\cdot} = n_{\cdot j}.$$

Le tableau des attendus a donc **les mêmes marges** que le tableau observé : on compare deux répartitions d'un même nombre de clients par ligne et par colonne, et la différence $O_{ij} - E_{ij}$ a des sommes nulles sur chaque ligne et chaque colonne.

Sur le petit tableau, la ligne des jeunes attendus donne $50+30+20 = 100$ et la colonne du ma-

gasin $50 + 75 + 75 = 200$: ce sont les totaux observés.

■

Le khi-deux

La mesure de l'écart

$$\chi^2 = \sum_{\text{cases}} \frac{(\text{observé} - \text{attendu})^2}{\text{attendu}}$$

Le calcul

$$\chi^2 = \frac{400}{50} + \frac{900}{30} + \frac{100}{20} + \frac{25}{75} + \frac{25}{45} + 0 + \frac{225}{75} + \frac{625}{45} + \frac{100}{30}$$

$$\chi^2 = 8 + 30 + 5 + 0{,}33 + 0{,}56 + 0 + 3 + 13{,}89 + 3{,}33 \approx \mathbf{64{,}1}$$

pour $(3-1)(3-1) = 4$ degrés de liberté.

Démonstration : Le khi-deux se calcule sans former les écarts

Développons le carré, case par case : $\dfrac{(O-E)^2}{E} = \dfrac{O^2}{E} - 2\,O + E$. En sommant sur toutes les cases, $\sum O = n$ et $\sum E = n$ (les attendus ont le même total, démonstration précédente) :

$$\chi^2 = \sum \frac{O^2}{E} - 2n + n = \sum \frac{O_{ij}^2}{E_{ij}} - n = n\left(\sum_{i,j} \frac{O_{ij}^2}{n_{i\cdot}\, n_{\cdot j}} - 1\right),$$

car $O^2/E = n\,O^2/(n_{i\cdot}\, n_{\cdot j})$. Ce calcul n'utilise que les effectifs observés et les marges. Il montre aussi que $\chi^2 = 0$ si et seulement si chaque O_{ij} est égal à E_{ij} (somme de termes positifs ou nuls).

Sur le petit tableau, $\sum O^2/E = 18 + 120 + 5 + 85{,}33 + 35{,}56 + 30 + 108 + 8{,}89 + 53{,}33 = 464{,}11$; moins $n = 400$: 64,11, soit 577/9, le même nombre que le calcul case par case. *Sur le tableau réel,* $\sum O^2/E = 410{,}41$ et $410{,}41 - 300 = 110{,}41$.

■

Où se trouve l'écart

La part de chaque case dans le khi-deux

	Magasin	Web	Téléphone
Jeunes	12,5 %	**46,8** %	7,8 %
Familles	0,5 %	0,9 %	0
Seniors	4,7 %	**21,7** %	5,2 %

Deux cases font les deux tiers

Les jeunes sur le web et les seniors sur le web portent à eux seuls 68,5 % du khi-deux. La ligne des familles n'y contribue presque pas : **leur répartition ressemble à celle de l'ensemble**. Le chapitre 13 retrouvera tout cela sur une figure.

Ce que la statistique inférentielle en faisait

Un test, et une conclusion en un mot

Le chapitre 18 de *Statistique inférentielle* comparait ce 64,1 au seuil du khi-deux à 4 degrés de liberté, 9,49, et concluait au **rejet de l'indépendance** ($p \approx 4 \times 10^{-13}$).
Conclusion en un mot : *il y a un lien*. Elle ne dit **pas lequel** — ni quelles catégories s'attirent, ni selon quelles dimensions.

L'AFC prend le relais

L'analyse des correspondances reprend exactement le même nombre et le décompose : par case, par ligne, par colonne, et surtout par **axe**.

Le tableau réel, observé et attendu

observés	Prix	Choix	Proximité	Service	**total**
Étudiant	14	2	5	1	22
Employé	45	20	26	10	101
Cadre	8	40	8	16	72
Indépendant	12	19	12	32	75
Retraité	5	1	17	7	30
total	84	82	68	66	300

théoriques	Prix	Choix	Proximité	Service
Étudiant	6,16	6,01	4,99	4,84
Employé	28,28	27,61	22,89	22,22
Cadre	20,16	19,68	16,32	15,84
Indépendant	21,00	20,50	17,00	16,50
Retraité	8,40	8,20	6,80	6,60

Le khi-deux du chapitre 18 de l'inférence.

$$\chi^2 = \sum \frac{(n_{ij} - t_{ij})^2}{t_{ij}} = 110{,}41$$

Avec 12 degrés de liberté, le seuil à 5 % vaut 21,03. **L'indépendance est rejetée sans hésitation.**

Et ensuite ? Le test dit qu'il y a une liaison. **Il ne dit pas laquelle.**

Cinq lignes, quatre colonnes, vingt écarts à commenter — l'AFC va les mettre sur un plan.

Le khi-deux réel

CSP et motif de visite

$$\chi^2 = 110{,}41 \quad \text{pour} \quad (5-1)(4-1) = 12 \text{ degrés de liberté}$$

Le seuil à 5 % vaut 21,03 : l'indépendance est rejetée sans hésitation ($p \approx 5 \times 10^{-18}$).

Une réserve pour le test, pas pour la description

Deux effectifs attendus sont **inférieurs à** 5 : étudiants et service (4,84), étudiants et proximité (4,99). La condition de validité du test n'est pas tout à fait remplie — R l'affichera. L'écart est si grand que la conclusion ne change pas ; et l'AFC, qui **décrit**, n'a pas besoin de cette condition.

Les cases qui font le khi-deux réel

	Choix	Prix	Proximité	Service
Cadre	20,98 +	7,33 −	4,24 −	0,00 +
Employé	2,10 −	9,89 +	0,42 +	6,72 −
Étudiant	2,68 −	9,98 +	0,00 +	3,05 −
Indépendant	0,11 −	3,86 −	1,47 −	14,56 +
Retraité	6,32 −	1,38 −	15,30 +	0,02 +

chaque case : $(\text{observé} - \text{attendu})^2/\text{attendu}$; vert : plus qu'attendu (+), orange : moins (−) ; total 110,41

Quatre associations fortes

Les **cadres** viennent pour le **choix** (40 pour 19,7 attendus : 19 % du khi-deux), les **retraités** pour la **proximité** (17 pour 6,8), les **indépendants** pour le **service** (32 pour 16,5), les **employés** et les **étudiants** pour le **prix**.

L'inertie d'un tableau croisé

Du khi-deux à l'inertie

Le phi-deux

$$\Phi^2 = \frac{\chi^2}{n}$$

C'est le khi-deux **rapporté à l'effectif total** — et c'est l'**inertie totale** du tableau.

Sur nos deux tableaux

Tableau	χ^2	n	Φ^2
type × canal	64,1	400	**0,160**
CSP × motif	110,41	300	**0,368**

Pourquoi diviser par n

Le khi-deux grandit avec l'effectif

Doubler tous les effectifs, sans changer les proportions, double le khi-deux. La **liaison** n'a pourtant pas changé. Φ^2 ne dépend que des **proportions** : c'est une mesure de l'intensité de la liaison, et non de la taille de l'échantillon.

Le V de Cramér

$$V = \sqrt{\frac{\Phi^2}{\min(\text{lignes}, \text{colonnes}) - 1}} \qquad \text{entre 0 et 1}$$

Type × canal : $V = \sqrt{0{,}160/2} = 0{,}28$. CSP × motif : $V = \sqrt{0{,}368/3} = 0{,}35$. Deux liaisons nettes, la seconde plus forte.

Démonstration : Le phi-deux ne dépend que des proportions et reste borné

Notons $p_{ij} = n_{ij}/n$ les proportions, $p_{i\cdot}$ et $p_{\cdot j}$ leurs marges. La démonstration précédente, divisée par n, donne

$$\Phi^2 = \frac{\chi^2}{n} = \sum_{i,j} \frac{p_{ij}^2}{p_{i\cdot}\, p_{\cdot j}} - 1 = \sum_{i,j} \frac{\left(p_{ij} - p_{i\cdot}\, p_{\cdot j}\right)^2}{p_{i\cdot}\, p_{\cdot j}}.$$

Cette dernière écriture ne contient que des proportions : si l'on multiplie tous les effectifs par 2, les p_{ij} ne changent pas, Φ^2 **non plus**, alors que $\chi^2 = n\,\Phi^2$ double. C'est une somme de termes positifs : $\Phi^2 \geq 0$, avec $\Phi^2 = 0$ si et seulement si $p_{ij} = p_{i\cdot}\, p_{\cdot j}$ partout, c'est-à-dire l'indépendance.

La borne. Une case est inférieure au total de sa colonne : $p_{ij} \leq p_{\cdot j}$, donc $\sum_j p_{ij}^2/p_{\cdot j} \leq \sum_j p_{ij} = p_{i\cdot}$. Pour chaque ligne i, le terme correspondant de la première somme est donc au plus $\dfrac{1}{p_{i\cdot}}\, p_{i\cdot} = 1$: avec I lignes, $\Phi^2 \leq I - 1$. En échangeant lignes et colonnes, $\Phi^2 \leq J - 1$. Finalement

$$0 \leq \Phi^2 \leq \min(I, J) - 1,$$

et $V = \sqrt{\Phi^2/(\min(I, J) - 1)}$ est bien compris entre 0 et 1. La borne est atteinte quand chaque ligne ne contient qu'une seule colonne (par exemple un tableau diagonal 2×2 : $\Phi^2 = 1$).

Sur nos deux tableaux, $\Phi^2 = 0{,}160$ pour $\min = 3$ (borne 2) et 0,368 pour $\min = 4$ (borne 3) ; $V = \sqrt{0{,}160/2} = 0{,}28$ et $\sqrt{0{,}368/3} = 0{,}35$.

■

Le pont avec tout ce qui précède

Le centre est l'indépendance

Le chapitre 6 avait défini l'inertie comme la dispersion d'un nuage autour de son centre.
Ici, le « centre » est la situation d'**indépendance**, et l'inertie mesure de combien le tableau s'en écarte. Un tableau parfaitement indépendant aurait une inertie **nulle** : rien à représenter.
La démarche est donc identique à celle de l'ACP — décomposer une inertie totale sur des axes hiérarchisés — appliquée à un écart à l'indépendance plutôt qu'à une dispersion de mesures.

La décomposition

$$\Phi^2 = \lambda_1 + \lambda_2 + \ldots$$

Le nombre d'axes vaut $\min(\text{lignes}, \text{colonnes}) - 1$: $\min(3, 3) - 1 = 2$ axes pour le petit tableau, $\min(5, 4) - 1 = 3$ pour le tableau réel.

Les profils

Comparer des lignes de tailles différentes

Profil-ligne

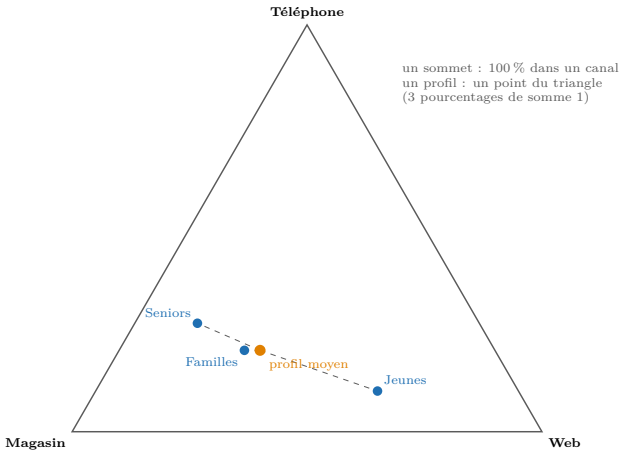
Le **profil** d'une ligne est sa répartition en pourcentages :

$$\text{profil}_{ij} = \frac{n_{ij}}{\text{total de la ligne } i}$$

Les trois profils-lignes du petit tableau

	Magasin	Web	Téléphone
Jeunes	30 %	**60** %	10 %
Familles	53 %	27 %	20 %
Seniors	60 %	13 %	27 %
Ensemble	50 %	30 %	20 %

Les profils, dans un triangle



Un profil est un point

Trois pourcentages de somme 1 se placent dans un **triangle** : plus un profil est proche d'un sommet, plus il est concentré sur ce canal. Les familles sont **presque confondues** avec le profil moyen ; les jeunes s'en écartent vers le web, les seniors vers le magasin et le téléphone.

Pourquoi raisonner en profils

Taille et comportement

Les jeunes sont 100 et les seniors 150 : comparer les effectifs bruts confondrait la **taille** du groupe et son **comportement**.
Les profils suppriment cet effet : les jeunes achètent sur le web dans 60 % des cas contre 30 % en moyenne, les seniors dans 13 %.

Le nuage de l'AFC est un nuage de profils, non d'effectifs.

Chaque profil a un poids

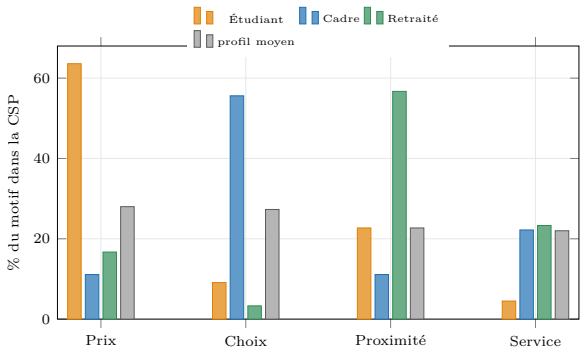
Chaque profil-ligne pèse le **poids de sa ligne** dans le total : 100/400 = 0,25 pour les jeunes, 0,375 pour les familles et les seniors. Le profil moyen est la moyenne des profils, pondérée par ces poids.

Les profils réels

Le motif de visite, par CSP

	Choix	Prix	Proximité	Service
Cadre	**55,6** %	11,1 %	11,1 %	22,2 %
Employé	19,8 %	**44,6** %	25,7 %	9,9 %
Étudiant	9,1 %	**63,6** %	22,7 %	4,5 %
Indépendant	25,3 %	16,0 %	16,0 %	**42,7** %
Retraité	3,3 %	16,7 %	**56,7** %	23,3 %
Ensemble	27,3 %	28,0 %	22,7 %	22,0 %

Les profils réels, en image



L'AFC compare des profils, pas des effectifs.

Il y a 22 étudiants et 101 employés : les comparer en effectifs n'aurait aucun sens.

En **pourcentages de ligne**, la comparaison redevient possible — et l'écart au **profil moyen**devient l'objet de l'analyse.

Un profil ligne égal au profil moyen n'apporte rien : il ira au centre du plan factoriel. C'est exactement ce que dit l'indépendance.

La distance du khi-deux

Mesurer l'écart d'un profil au profil moyen

La distance

$$d^2(i, \text{moyen}) = \sum_j \frac{\left(\text{profil}_{ij} - \text{profil moyen}_j\right)^2}{\text{profil moyen}_j}$$

Chaque écart est divisé par la part de la colonne : un écart sur une colonne **rare** pèse plus qu'un même écart sur une colonne fréquente.

C'est la réduction de l'AFC

Diviser par la part de la colonne joue le rôle de la **réduction** du chapitre 2 : sans cela, les colonnes de gros effectif domineraient toutes les distances, comme le panier en dirhams dominait les notes.

Le calcul, sur le petit tableau

Les trois distances au profil moyen (0,5 ; 0,3 ; 0,2)

Jeunes : $\dfrac{(0{,}3-0{,}5)^2}{0{,}5}+\dfrac{(0{,}6-0{,}3)^2}{0{,}3}+\dfrac{(0{,}1-0{,}2)^2}{0{,}2}=0{,}08+0{,}30+0{,}05=0{,}430$

Familles : $\dfrac{0{,}033^2}{0{,}5}+\dfrac{0{,}033^2}{0{,}3}+0=0{,}006$; Seniors : $0{,}020+0{,}093+0{,}022=0{,}135$

L'inertie retrouvée

$$\Phi^2=\sum_i \text{poids}_i \times d^2(i,\text{moyen})=0{,}25\times 0{,}430+0{,}375\times 0{,}006+0{,}375\times 0{,}135=0{,}160$$

L'inertie est la moyenne pondérée des carrés des distances au centre — exactement la définition du chapitre 6.

Démonstration : Le phi-deux est l'inertie des profils autour du profil moyen

Le profil de la ligne i est $f_{ij} = p_{ij}/p_{i\cdot}$; son poids est $p_{i\cdot}$. Le **profil moyen**, pondéré par ces poids, est bien le profil de l'ensemble :

$$\sum_i p_{i\cdot}\, f_{ij}=\sum_i p_{ij}=p_{\cdot j}.$$

L'inertie de ce nuage autour de son centre est la moyenne pondérée des carrés des distances du khi-deux :

$$\sum_i p_{i\cdot}\sum_j \frac{\left(f_{ij}-p_{\cdot j}\right)^2}{p_{\cdot j}}=\sum_{i,j}\frac{p_{i\cdot}\left(\dfrac{p_{ij}-p_{i\cdot}\,p_{\cdot j}}{p_{i\cdot}}\right)^2}{p_{\cdot j}}=\sum_{i,j}\frac{\left(p_{ij}-p_{i\cdot}\,p_{\cdot j}\right)^2}{p_{i\cdot}\,p_{\cdot j}}=\Phi^2.$$

L'inertie totale du nuage des profils **est** $\Phi^2 = \chi^2/n$: le khi-deux, que l'on savait calculer, devient la dispersion d'un nuage de points pondérés, comme au chapitre 6.

Sur le petit tableau, $0{,}25\times 0{,}430+0{,}375\times 0{,}006+0{,}375\times 0{,}135=0{,}160$. *Sur le tableau réel,* la somme des cinq produits poids $\times\, d^2$ vaut 0,368 ; le produit des cadres, $0{,}240\times 0{,}452=0{,}108$, en fait 29,5 %.

■

Sur le tableau réel

Les cinq CSP

CSP	Poids	d^2 au profil moyen	Part de l'inertie
Cadre	0,240	0,452	29,5 %
Employé	0,337	0,189	17,3 %
Étudiant	0,073	0,714	14,2 %
Indépendant	0,250	0,267	18,1 %
Retraité	0,100	**0,767**	20,9 %
Total	1		$\Phi^2 = 0{,}368$

Petit poids, grand écart

Les retraités et les étudiants ont les profils **les plus extrêmes**, mais ne pèsent que 10 % et 7 % des clients. Les cadres, moins extrêmes mais nombreux, font la plus grande part de l'inertie.

Une propriété remarquable

Deux nuages, une seule analyse

On peut construire le nuage des **profils-lignes** ou celui des **profils-colonnes**.
Les deux ont **la même inertie** Φ^2, **les mêmes valeurs propres**, et deux représentations qui se superposent.

La dualité, portée à sa forme la plus complète

C'est la **dualité** du chapitre 5. Dans l'ACP, individus et variables n'étaient pas de même nature ; ici, lignes et colonnes sont deux catégories **symétriques**. C'est ce qui permettra, au chapitre 13, de les lire sur **une seule** figure.

Démonstration : Lignes et colonnes ont la même inertie

Pour le nuage des profils-colonnes, le profil de la colonne j est $p_{ij}/p_{\cdot j}$ (en parcourant les lignes i), son poids est $p_{\cdot j}$ et le profil moyen est $p_{i\cdot}$. Le même calcul que pour les lignes donne

$$\sum_j p_{\cdot j} \sum_i \frac{\left(p_{ij}/p_{\cdot j} - p_{i\cdot}\right)^2}{p_{i\cdot}} = \sum_{i,j} \frac{\left(p_{ij} - p_{i\cdot}\, p_{\cdot j}\right)^2}{p_{i\cdot}\, p_{\cdot j}} = \Phi^2.$$

L'expression finale est **symétrique** en lignes et colonnes : les deux nuages ont la même inertie totale, Φ^2.

Sur le petit tableau, les distances des trois colonnes (magasin, web, téléphone) à leur profil moyen valent 0,057, 0,370 et 0,104, de poids 0,5, 0,3 et 0,2 : $0{,}5 \times 0{,}057 + 0{,}3 \times 0{,}370 + 0{,}2 \times 0{,}104 = 0{,}160$, comme pour les lignes. Sur le tableau réel transposé, on retrouve $\Phi^2 = 0{,}368$.

■

Sur machine

Avec R : le test

table, puis chisq.test

```r
clients <- read.csv("clients.csv")
tab <- table(clients$csp, clients$motif)
chisq.test(tab)
#   Pearson's Chi-squared test
# data:  tab
# X-squared = 110.41, df = 12, p-value < 2.2e-16
# Warning message:
# In chisq.test(tab) : Chi-squared approximation may be incorrect
```

L'avertissement

R signale que des effectifs **attendus** sont inférieurs à 5 — les étudiants. Le test reste ici sans ambiguïté, mais l'avertissement mérite toujours d'être lu.

Avec R : l'inertie

La fonction CA de FactoMineR

```r
library(FactoMineR)
afc <- CA(as.data.frame.matrix(tab), graph = FALSE)
round(sum(afc$eig[, 1]), 4)                    # [1] 0.368
```

Le khi-deux décomposé

La somme des valeurs propres de l'AFC est $\Phi^2 = 110{,}41/300 = 0{,}368$. Le chapitre 13 lira ces valeurs propres une à une, comme celles de l'ACP au chapitre 8.

Avec Python

Le tableau croisé, le test, le phi-deux et le V de Cramér

```python
import numpy as np
import pandas as pd
from scipy.stats import chi2_contingency
clients = pd.read_csv("clients.csv")
tab = pd.crosstab(clients.csp, clients.motif)
chi2, p, ddl, attendus = chi2_contingency(tab)
print(round(chi2, 2), ddl, f"{p:.1e}")       # 110.41 12 5.0e-18
phi2 = chi2 / tab.to_numpy().sum()
print(round(phi2, 4), round(np.sqrt(phi2 / 3), 3))    # 0.368 0.35
profils = tab.div(tab.sum(axis=1), axis=0)       # profils-lignes
```

S'entraîner

Exercice 1 : un tableau deux sur trois

Sexe et canal préféré

	Magasin	Web	Téléphone	Total
Femmes	50	30	20	100
Hommes	30	50	20	100
Total	80	80	40	200

1. Calculer les effectifs attendus sous l'indépendance.
2. Calculer le khi-deux, Φ^2 et le V de Cramér.
3. Combien d'axes aurait l'AFC de ce tableau ?

Exercice 1 : solution

Khi-deux 10, un seul axe

1. 40 ; 40 ; 20 dans chaque ligne.
2. Quatre cases s'écartent de 10 : $4 \times 100/40 = 10$; le téléphone, rien. $\chi^2 = 10$, $\Phi^2 = 10/200 = 0{,}05$, $V = \sqrt{0{,}05/1} = 0{,}22$.
3. $\min(2,3) - 1 = 1$ axe, qui porte toute l'inertie 0,05 et oppose femmes-magasin à hommes-web.

Exercice 2 : profils et distances

Le même tableau, en profils

Reprendre le tableau de l'exercice 1.

1. Calculer les deux profils-lignes et le profil moyen.
2. Calculer la distance du khi-deux de chaque profil au profil moyen.
3. Retrouver Φ^2 comme moyenne pondérée de ces distances.

Exercice 2 : solution

Deux profils symétriques

1. Femmes $(0{,}5; 0{,}3; 0{,}2)$, hommes $(0{,}3; 0{,}5; 0{,}2)$, moyen $(0{,}4; 0{,}4; 0{,}2)$.
2. Femmes : $0{,}1^2/0{,}4 + 0{,}1^2/0{,}4 + 0 = 0{,}05$. Hommes : la même chose, 0,05.
3. $0{,}5 \times 0{,}05 + 0{,}5 \times 0{,}05 = 0{,}05 = \Phi^2$. Les deux lignes sont à égale distance du centre, de part et d'autre.

Exercice 3 : le tableau réel

Ce que disent quelques chiffres

1. Combien d'axes aura l'AFC du tableau CSP × motif ? Que vaut la somme de leurs valeurs propres ?
2. La case cadres × choix contribue 20,98 au khi-deux. Quelle part du total ?

3. Les retraités ont le profil le plus éloigné du profil moyen ($d^2 = 0{,}767$) et ne portent que 20,9 % de l'inertie. Pourquoi ?

Exercice 3 : solution

Trois axes, une inertie de 0,368

1. $\min(5, 4) - 1 = 3$ axes ; la somme des valeurs propres est $\Phi^2 = 0{,}368$.
2. $20{,}98/110{,}41 = 19\,\%$: à elle seule, près d'un cinquième de l'écart à l'indépendance.
3. Ils ne sont que 30 sur 300 : leur poids 0,10 multiplie leur distance, $0{,}10 \times 0{,}767 = 0{,}077$, soit $0{,}077/0{,}368 = 20{,}9\,\%$. Une catégorie rare au profil extrême peut néanmoins **tirer un axe** à elle seule : le chapitre 13 le vérifiera.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Un tableau de **contingence** croise deux variables qualitatives ; l'ACP ne s'y applique pas.
2. Le **khi-deux** mesure l'écart à l'indépendance : 64,1 pour 4 ddl sur le petit tableau, 110,41 pour 12 ddl sur le tableau réel.
3. L'inertie totale est $\Phi^2 = \chi^2/n$: 0,160 et 0,368 ; le V de Cramér en donne l'intensité (0,28 et 0,35).
4. Le nuage est fait de **profils** pondérés par leurs effectifs, ce qui neutralise les différences de taille.
5. La **distance du khi-deux** divise chaque écart par la part de la colonne ; Φ^2 est la moyenne pondérée des d^2 au profil moyen.
6. L'AFC **décompose** cette inertie sur $\min(l, c) - 1$ axes, là où le test se contentait de conclure.

La suite

Lire la figure

L'inertie est décomposée. Reste à lire la figure — et les règles de lecture ne sont pas tout à fait celles de l'ACP.

Ce qu'on y fera

On calculera les deux axes du petit tableau, on placera lignes et colonnes sur un même plan, et l'on verra les retraités fabriquer presque la moitié du second axe du tableau réel.