

Introduction à l'analyse des données

Chapitre 13 : Lire un plan de correspondances, et la suite

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Lire un plan de correspondances RH

Une entreprise croise l'ancienneté de ses salariés (junior, confirmé, senior) et leur format de formation préféré (e-learning, mixte, présentiel). L'AFC donne les coordonnées suivantes sur le premier plan : junior = $(-0,82; 0,10)$, confirmé = $(0,03; -0,08)$, senior = $(0,78; 0,06)$; e-learning = $(-0,85; 0,12)$, mixte = $(0,02; -0,09)$, présentiel = $(0,81; 0,04)$.

- Quelles deux modalités (une ligne, une colonne) sont du même côté de l'axe 1, du côté négatif? Que peut-on en conclure?
- Quelles deux modalités sont du même côté, du côté positif? Que peut-on en conclure?
- La modalité « confirmé » est proche du centre du plan. Que signifie cette position, d'après la règle du cours sur le « profil moyen »?

Exercice 2 — Une catégorie rare qui capte l'axe

Dans un tableau croisant canal d'achat et catégorie de client sur $n = 400$ clients, une modalité rare (« achat via réseaux sociaux ») ne regroupe que 5 clients. Sa coordonnée sur le premier axe est $c = 2,4$, et la valeur propre de cet axe est $\lambda = 0,08$.

- Calculer la masse de cette modalité, $\text{masse} = \frac{\text{effectif}}{n}$.
- Calculer sa contribution à l'axe, $\text{contribution} = \frac{\text{masse} \times c^2}{\lambda}$.
- Comparer cette contribution à la masse de la modalité. Que doit faire l'analyste avant d'accepter l'interprétation de ce premier axe?

Exercice 3 — Corriger une lecture interdite

Sur un plan de correspondances, un stagiaire écrit dans son rapport : « la distance mesurée sur le graphique entre la modalité *seniors* et la modalité *magasin* est de 2 cm, contre 3,5 cm entre *seniors* et *web* : les seniors sont donc 1,75 fois plus proches du magasin que du web. »

- Cette phrase enfreint-elle une règle du cours? Laquelle?
- Reformuler correctement ce que l'on peut affirmer si *seniors* et *magasin* se trouvent du même côté d'un axe, sans mesurer la distance qui les sépare.
- Pourquoi « les deux nuages ne vivent pas dans le même espace » explique-t-il, plus fondamentalement, pourquoi cette distance n'a pas de sens mathématique (relier au chapitre 5)?

2 Exercices cumulatifs (bilan du cours)

Exercice 4 — Le fil rouge, chiffré d'un bout à l'autre

On reprend, une dernière fois, les cinq clients (accueil x , fidélité y) qui ont traversé tout ce cours.

- Chapitres 3 et 4 : sachant $\text{cov}(x, y) = 72/5 = 14,4$ et $s_x s_y = \sqrt{256} = 16$, calculer la corrélation r , et vérifier qu'elle vaut bien 0,9 comme annoncé dès le chapitre 4.
- Chapitres 8 et 9 : sachant $\lambda_1 = 1,9$ et $\lambda_2 = 0,1$, vérifier que leur somme redonne l'inertie réduite du chapitre 6 ($I = p = 2$), puis calculer le pourcentage d'inertie porté par le premier axe.
- Chapitre 12 : sachant $\chi^2 = 64,1$ pour le tableau (type de client $\times$ canal d'achat) à $n = 400$, calculer $\Phi^2 = \chi^2/n$. En quoi ce nombre joue-t-il, pour un tableau de contingence, exactement le même rôle que l'inertie réduite $I = 2$ jouait pour le nuage des cinq clients – et en quoi les deux « centres » de référence (centre de gravité pour l'un, indépendance pour l'autre) sont-ils conceptuellement

identiques, malgré la différence de nature des données ?

3 Applications en sciences économiques

Exercice 5 — Lire un plan secteur $\times$ financement

On reprend le tableau du chapitre 12 (secteur d'activité $\times$ mode de financement). L'AFC donne : Industrie = $(0,70; 0,10)$, Services = $(-0,65; 0,15)$, Commerce = $(-0,05; -0,60)$; Crédit bancaire = $(0,68; 0,05)$, Obligataire = $(-0,60; 0,20)$, Fonds propres = $(-0,08; -0,55)$.

- (a) Identifier les trois paires (un secteur, un mode de financement) qui se trouvent du même côté du plan, sur chacune des deux dimensions.
- (b) Proposer un nom pour l'axe 1, en tenant compte de ce qu'il oppose.
- (c) Un banquier veut savoir « de combien » le commerce est plus proche des fonds propres que des obligations, en mesurant les distances sur la figure. Que lui répondre ?

Exercice 6 — Lire un plan risque $\times$ défaut, avec prudence

On reprend le tableau du chapitre 12 (niveau de risque $\times$ défaut). L'AFC donne : Risque faible = $(-0,75; 0,05)$, Risque moyen = $(-0,05; -0,10)$, Risque élevé = $(0,80; 0,08)$; Défaut = $(0,85; 0,10)$, Pas de défaut = $(-0,20; -0,02)$.


- (a) Quelle modalité de risque est du même côté que « Défaut » ? Quelle modalité est du même côté que « Pas de défaut » ?
- (b) Ce résultat est-il cohérent avec le calcul du χ^2 effectué au chapitre 12, exercice 6 (où le risque élevé affichait beaucoup plus de défauts qu'attendu) ?
- (c) Un collègue affirme que la distance mesurée sur ce graphique entre « Risque élevé » et « Défaut » permet de quantifier précisément l'intensité de leur association. Que répondre, en s'appuyant sur la règle de lecture du cours ?

1 Exercices du chapitre

Correction — Exercice 1

(a) « Junior » $(-0,82)$ et « e-learning » $(-0,85)$ sont toutes deux du côté négatif de l'axe 1 : c'est une **attirance** – les salariés juniors préfèrent le format e-learning davantage que ne le voudrait l'indépendance entre ancienneté et format.

(b) « Senior » $(0,78)$ et « présentiel » $(0,81)$ sont toutes deux du côté positif : attirance également – les salariés seniors préfèrent le format présentiel.



(c) « Confirmé », proche de l'origine, a un profil **banal** : sa répartition entre les trois formats de formation ressemble à la moyenne générale de l'entreprise – il ne se distingue pas particulièrement d'un format ou d'un autre.

Correction — Exercice 2

(a) Masse = $\frac{5}{400} = 0,0125$, soit 1,25 %.

(b) Contribution = $\frac{0,0125 \times 2,4^2}{0,08} = \frac{0,0125 \times 5,76}{0,08} = \frac{0,072}{0,08} = 0,90$, soit 90 %.

(c) Cette modalité, qui ne pèse que 1,25 % des observations, construit à elle seule 90 % de l'axe – une contribution sans commune mesure avec sa masse. Avant d'accepter l'interprétation de ce premier axe, l'analyste doit **refaire l'AFC en excluant cette modalité rare** et vérifier si l'axe – et sa signification – subsiste. Si l'axe change radicalement en son absence, il ne décrivait pas une structure générale du tableau, mais uniquement le profil très particulier de cette catégorie à faible effectif.

Correction — Exercice 3

(a) Oui : le stagiaire enfreint la règle « on ne mesure pas une distance entre une ligne et une colonne ». Comparer 2 cm et 3,5 cm entre des points de deux familles différentes (une modalité-ligne, deux modalités-colonnes) n'a pas de sens, quelle que soit la précision de la mesure.

(b) On peut seulement affirmer : « seniors et magasin se trouvent du même côté de l'axe, ce qui traduit une attirance – les seniors achètent en magasin plus souvent que ne le voudrait l'indépendance ». On ne peut ni quantifier cette attirance par une distance sur la figure, ni la comparer directement à celle avec « web » de cette façon.

(c) Le nuage des modalités-lignes vit dans un espace construit à partir des profils-lignes, le nuage des modalités-colonnes dans un espace construit à partir des profils-colonnes – exactement comme, au chapitre 5, le nuage des individus ($\mathbb{R}^p$) et le nuage des variables ($\mathbb{R}^n$) ne vivaient pas dans le même espace. Superposer les deux nuages sur une même figure en AFC est une commodité de lecture des *directions*, pas une identité mathématique qui autoriserait à mesurer des distances *entre* les deux familles de points.

2 Exercices cumulatifs (bilan du cours)

Correction — Exercice 4

- (a) $r = \frac{14,4}{16} = 0,9$. On retrouve exactement la valeur annoncée dès le chapitre 4.
- (b) $\lambda_1 + \lambda_2 = 1,9 + 0,1 = 2,0 = I = p$, conforme au chapitre 6. Pourcentage porté par le premier axe : $\frac{1,9}{2} = 95\%$.
- (c) $\Phi^2 = \frac{64,1}{400} \approx 0,160$. Ce nombre joue, pour le tableau de contingence, exactement le rôle que jouait $I = 2$ pour le nuage des cinq clients : c'est l'**inertie totale** à décomposer sur des axes hiérarchisés (chapitres 8-9 pour l'ACP, chapitre 12 pour l'AFC). Les deux « centres » de référence – le centre de gravité du nuage d'un côté, la situation d'indépendance de l'autre – sont conceptuellement identiques : dans les deux cas, il s'agit d'un point ou d'une configuration de référence *sans structure*, par rapport auquel on mesure un écart, et cet écart, une fois décomposé sur des axes, révèle la structure du tableau. Que les données de départ soient des mesures quantitatives (chapitres 1-11) ou des effectifs de catégories (chapitres 12-13) ne change rien à la logique : **réduire la dimension, c'est toujours décomposer un écart à une référence sur des directions hiérarchisées**.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Sur l'axe 1 (positif) : Industrie (0,70) et Crédit bancaire (0,68) – attirance. Sur l'axe 1 (négatif) et l'axe 2 (positif) : Services (−0,65 ; 0,15) et Obligataire (−0,60 ; 0,20) – attirance. Sur l'axe 2 (fortement négatif) : Commerce (−0,05 ; −0,60) et Fonds propres (−0,08 ; −0,55) – attirance.
- (b) L'axe 1 oppose le crédit bancaire (associé à l'industrie) à l'obligataire (associé aux services) : on peut le nommer « financement classique (bancaire) contre financement de marché (obligataire) ».
- (c) On ne peut pas répondre en termes de « combien de fois plus proche » à partir des distances lues sur la figure : « commerce » est une modalité-ligne, « fonds propres » et « obligataire » des modalités-colonnes – ces distances croisées entre les deux familles de points ne sont pas mathématiquement interprétables. On peut seulement dire que commerce et fonds propres sont du même côté du plan (attirance), sans quantifier cette proximité par une mesure de distance.

Correction — Exercice 6

- (a) « Risque élevé » (0,80 ; 0,08) est du même côté que « Défaut » (0,85 ; 0,10) : attirance. « Risque faible » (−0,75 ; 0,05) est du même côté que « Pas de défaut » (−0,20 ; −0,02) sur l'axe 1 : attirance également.
- (b) Oui, c'est parfaitement cohérent : au chapitre 12, exercice 6, on avait observé 45 défauts pour la catégorie « risque élevé » contre 16 attendus sous indépendance (et seulement 10 défauts observés contre 40 attendus pour « risque faible ») – exactement l'attirance « risque élevé-défaut » et « risque faible-pas de défaut » que le plan de l'AFC vient de traduire visuellement.
- (c) Non : la règle du cours est explicite – on ne mesure jamais une distance entre une modalité-ligne (« risque élevé ») et une modalité-colonne (« défaut »), les deux nuages ne vivant pas dans le même espace. On peut affirmer qu'il existe une attirance entre ces deux modalités (elles sont du même côté de l'axe), mais pas quantifier son intensité par une distance lue sur la figure – l'intensité de la liaison se lit, si nécessaire, dans le χ^2 ou dans la contribution de la case correspondante à ce χ^2 (chapitre 12), pas dans une distance graphique.