

Introduction à l'analyse des données

Chapitre 13 : Lire un plan de correspondances, et la suite

Jaouad Madkour


24 septembre 2026

Plan du chapitre

Lire le plan	1
Ce qu'on y trouve	1
Les quatre règles de lecture	2
Ce que ce cours a construit	3
Le parcours	3
La suite, au Master	4
Ce qui reste à voir	4
Ce qu'il faut retenir	5
Le résumé du cours	5

Lire le plan

Ce qu'on y trouve



Le privilège de l'AFC : les deux nuages sur le même plan.

Lignes et colonnes sont projetées dans le même repère — ce qu'aucune ACP ne permet.

Axe 1 : *Prix* et les étudiants et employés d'un côté ; *Choix*, *Service* et les cadres et indépendants de l'autre. C'est la contrainte budgétaire.

Axe 2 : *Proximité* et les retraités, seuls en bas.

Attention : la proximité ne s'interprète que d'un nuage à l'autre. « Retraité est près de Proximité » se lit ; « Retraité est près d'Employé » ne se lit pas de la même façon.

Une figure, deux familles de points

Le plan porte **simultanément** les modalités des lignes et celles des colonnes. C'est l'avantage décisif de l'AFC sur l'ACP, où variables et individus exigeaient deux figures séparées.

Sur notre tableau

Le premier axe oppose le **web** au **magasin** et au **téléphone**. Du côté web se placent les **jeunes** ; de l'autre, les **seniors**. Les **familles** occupent une position intermédiaire. L'axe se nomme donc : **le canal, du plus numérique au plus traditionnel** — et il ordonne les générations dans le même mouvement.

Les quatre règles de lecture

Ce qu'on a le droit de dire

Comparaison	Interprétation
Deux lignes proches	profils semblables
Deux colonnes proches	profils semblables
Une ligne et une colonne du même côté	attraction — effectif supérieur à l'attendu
Un point loin du centre	modalité au profil très particulier

La règle qu'on enfreint le plus souvent

On ne mesure pas une distance entre une ligne et une colonne.

« Les jeunes sont à trois centimètres du web, donc plus proches que les familles » n'a pas de sens : les deux nuages ne vivent pas dans le même espace.

On lit une **direction commune**, jamais une distance croisée : *les jeunes et le web sont du même côté de l'axe, donc associés.*

Le centre du plan

L'origine représente le **profil moyen**.

Une modalité proche du centre a un profil banal — elle ne se distingue pas de l'ensemble. Ici, les **familles** sont proches du centre : leur répartition entre canaux ressemble à la moyenne générale.

Les mêmes prudenances qu'en ACP

Qualité de représentation et contribution s'appliquent à l'identique.

Une modalité de **faible effectif** peut avoir un profil extrême et tirer un axe à elle seule. Il faut vérifier sa contribution, et souvent refaire l'analyse sans elle.

C'est le défaut le plus fréquent de l'AFC en pratique : une catégorie rare qui capte le premier axe et masque la structure réelle.

Ce que ce cours a construit

Le parcours

Les quatorze chapitres

Chapitres	Acquis
1-2	Le problème de la dimension ; ce cours est de la descriptive multivariée
3-5	Centrer et réduire, covariance , corrélation
6-7	Le nuage , et l' inertie qui mesure son information
8-12	L' ACP : axes, valeurs propres, cercle, plan des individus
13-14	L' AFC : du khi-deux à la représentation

Le fil rouge chiffré, d'un bout à l'autre

Cinq clients, accueil et fidélité :

Chapitre	Grandeur	Valeur
3	Moyennes	12 et 12
3	Variances	8 et 32
4	Covariance	$72/5 = 14,4$
5	$s_x s_y = \sqrt{256}$	16
5	Corrélation	$14,4/16 = \mathbf{0,9}$
7	Inertie réduite	2
9	Valeurs propres	1,9 et 0,1
9	Inertie du premier axe	95 %

Et pour l'AFC : $\chi^2 = 64,1$, soit une inertie $\Phi^2 = 0,160$.

La réponse au chameau

L'introduction posait une question : quel angle perd le moins d'information, et combien perd-il ?

Le chapitre 8 y a répondu par un nombre : sur nos cinq clients, le meilleur axe conserve 95 % de l'inertie. Passer de deux dimensions à une ne coûte que 5 %.

C'est tout ce que fait l'analyse des données : trouver l'angle, et dire ce qu'il coûte.

La suite, au Master

Ce qui reste à voir

Le cours d'analyse des données du niveau Master

Il reprend l'ensemble depuis le début et le prolonge :

Prolongement	Question à laquelle il répond
Correspondances multiples Classification Analyse discriminante Positionnement multidimensionnel	et si l'on a dix variables qualitatives ? comment constituer des groupes de clients ? dans quel groupe placer un nouveau client ? comment cartographier des ressemblances déclarées ?
Mise en œuvre	sur R et sur Python , cas réels

	Variables quantitatives	Variables qualitatives
Décrire	ACP chapitres 4 à 9	AFC et ACM chapitres 10 à 13
Classer	CAH et k-means chapitres 14 à 17	les mêmes, après une AFC ou une ACM
		MDS à partir de simples distances chapitre 20
Prédire	AFD chapitres 18 et 19	régression logistique <i>hors programme</i>

Une seule question commande le choix : quelle est la nature des variables, et que veut-on en faire ?

Décrire un nuage, y former des groupes, ou séparer des groupes déjà connus. Les six méthodes du cours remplissent ce tableau — il n'y a pas d'autre case.

Où ce cours mène ailleurs

L'ACP réapparaîtra sous d'autres noms :

- en **économétrie financière**, comme méthode d'extraction de facteurs de risque ;
- en **apprentissage statistique**, comme réduction de dimension avant régression ;
- partout où le nombre de variables dépasse ce qu'on peut regarder.

Ce cours n'était donc pas une parenthèse : c'est l'un des outils les plus réemployés de tout le cursus.

Ce qu'il faut retenir

Le résumé du cours

Cinq points, pour quatorze chapitres

1. Réduire la dimension, c'est **perdre de l'information** — la seule question est combien.
2. L'**inertie** mesure cette information ; sur données réduites, elle vaut p .
3. Les axes sont les **vecteurs propres** de la matrice des corrélations, les inerties leurs **valeurs propres**.
4. On ne commente **que** ce qui est bien représenté — variables au bord du cercle, individus de qualité suffisante.
5. L'AFC applique la même démarche à un écart à l'**indépendance**, mesuré par le khi-deux.

Le mot de la fin

Aucune de ces méthodes ne teste quoi que ce soit, et aucune n'établit de causalité. Elles décrivent, et elles décrivent bien.

Leur mérite est de rendre **visible** une structure que trente colonnes de chiffres gardaient cachée. Ce que cette structure signifie, et ce qu'il faut en faire, relève du jugement — et des cours qui suivent.