# Introduction à l'analyse des données

Chapitre 13 : Lire un plan de correspondances, et la suite

Jaouad Madkour

22 octobre 2026

## Plan du chapitre

**Les axes du petit tableau** **2**
- Deux valeurs propres . . . 2
- L'axe unique, en image . . . 2
- La règle qui relie lignes et colonnes . . . 3
- Pourquoi « du même côté » veut dire « associés » . . . 3

**Lire le plan du tableau réel** **3**
- Les trois valeurs propres . . . 3
- Le plan, lignes et colonnes ensemble . . . 4
- Une figure, deux familles de points . . . 4
- Nommer les deux axes . . . 5

**Les règles de lecture** **5**
- Ce qu'on a le droit de dire . . . 5
- La règle qu'on enfreint le plus souvent . . . 5

**Les mêmes prudences qu'en ACP** **6**
- Qualité de représentation . . . 6
- Contributions : qui a fait les axes . . . 6
- Refaire l'analyse sans eux . . . 7
- Ce que l'épreuve montre . . . 7

**Sur machine** **7**
- Avec R : la fonction CA . . . 7
- Avec R : coordonnées et contributions . . . 8
- Le plan tracé par R . . . 8
- Avec Python : l'AFC par une décomposition . . . 8
- Ce que calcule le code Python . . . 9
- Le plan tracé par matplotlib . . . 9

**Ce que ce cours a construit** **10**
- Le parcours . . . 10
- Le premier fil rouge, d'un bout à l'autre . . . 10
- Le second fil rouge . . . 10

La réponse au chameau . . . . . 11

**La suite, au Master** **11**
Ce qui reste à voir . . . . . 11
La carte des méthodes . . . . . 11
Où ce cours mène ailleurs . . . . . 12

**S'entraîner** **12**
Exercice 1 : la relation de transition . . . . . 12
Exercice 1 : solution . . . . . 12
Exercice 2 : une catégorie rare . . . . . 12
Exercice 2 : solution . . . . . 13
Exercice 3 : vrai ou faux ? . . . . . 13
Exercice 3 : solution . . . . . 13

**Ce qu'il faut retenir** **13**
Le résumé du cours . . . . . 13
Le mot de la fin . . . . . 14

# Les axes du petit tableau

## Deux valeurs propres

**Type de client et canal d'achat**

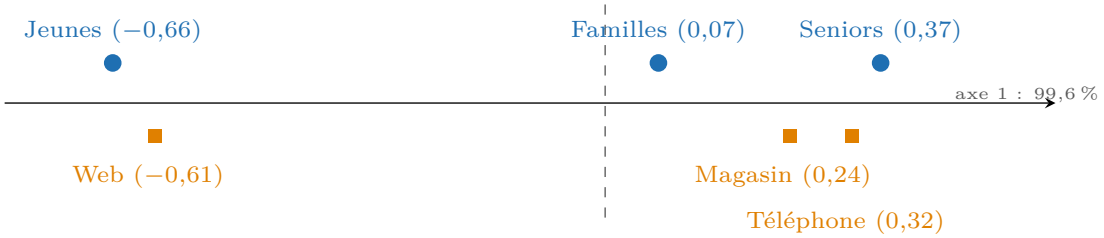
L'AFC du tableau $3 \times 3$ du chapitre 12 donne $\min(3,3) - 1 = 2$ axes :

| Axe | Valeur propre | Part |
|---|---|---|
| 1 | 0,1597 | **99,6 %** |
| 2 | 0,0006 | 0,4 % |
| **Total** | **0,1603** $= \Phi^2$ | 100 % |

**Un seul axe suffit**

La somme des valeurs propres est l'inertie $\Phi^2 = 0{,}160$ du chapitre 12, comme la somme des valeurs propres de l'ACP valait $p$. Ici, **un seul axe** porte presque toute l'information : l'écart à l'indépendance de ce tableau tient en une seule opposition.

## L'axe unique, en image



**Ce qu'on y lit**

Le premier axe oppose le **web** ($-0{,}61$) au **magasin** ($0{,}24$) et au **téléphone** ($0{,}32$). Du côté web se placent les **jeunes** ($-0{,}66$) ; de l'autre, les **seniors** ($0{,}37$). Les **familles** ($0{,}07$) occupent une position presque centrale : leur profil est proche du profil moyen.

### La règle qui relie lignes et colonnes

**La relation de transition**

La coordonnée d'une ligne est la **moyenne des coordonnées des colonnes**, pondérée par son profil, puis dilatée par $1/\sqrt{\lambda}$ :

$$F_i = \frac{1}{\sqrt{\lambda}} \sum_j \text{profil}_{ij}\, G_j$$

Et réciproquement pour une colonne, avec les profils-colonnes.

**La vérification, sur les jeunes**

Profil des jeunes : $(0{,}3; 0{,}6; 0{,}1)$ ; coordonnées des colonnes : $0{,}237$ ; $-0{,}609$ ; $0{,}320$.

$$F_{\text{jeunes}} = \frac{0{,}3 \times 0{,}237 + 0{,}6 \times (-0{,}609) + 0{,}1 \times 0{,}320}{\sqrt{0{,}1597}} = \frac{-0{,}262}{0{,}400} = -0{,}656$$

### Pourquoi « du même côté » veut dire « associés »

**Une ligne est attirée par les colonnes où elle est forte**

Les jeunes mettent $60\,\%$ de leurs achats sur le web : la moyenne des colonnes, pondérée par leur profil, est **tirée vers le web**. C'est pourquoi une ligne se place du côté des colonnes où elle est **surreprésentée**.

**Ce que la relation justifie**

La lecture conjointe de l'AFC n'est pas une commodité : elle découle de cette **relation barycentrique**. Elle autorise à lire des **directions communes** entre lignes et colonnes — jamais des distances entre une ligne et une colonne.

## Lire le plan du tableau réel

### Les trois valeurs propres

**CSP et motif de visite**

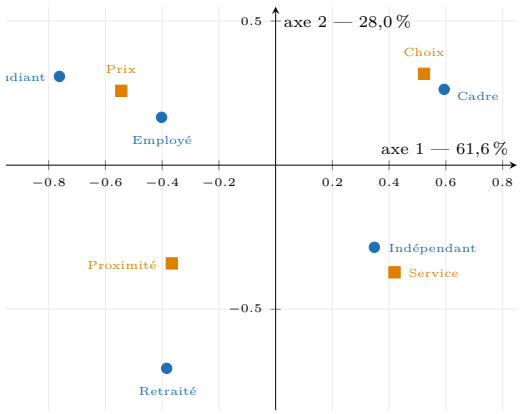
| Axe | Valeur propre | Part | Cumul |
|---|---|---|---|
| 1 | 0,2267 | 61,6 % | 61,6 % |
| 2 | 0,1030 | 28,0 % | **89,6** % |
| 3 | 0,0384 | 10,4 % | 100 % |

$0{,}2267 + 0{,}1030 + 0{,}0384 = 0{,}368 = \Phi^2$.

**Un plan presque complet**

Le plan des deux premiers axes conserve près de 90 % de l'écart à l'indépendance. On peut le commenter avec confiance — en vérifiant, comme toujours, la qualité de chaque modalité.

## Le plan, lignes et colonnes ensemble




**Le privilège de l'AFC : les deux nuages sur le même plan.**

**Lignes**et **colonnes**sont projetées dans le même repère — ce qu'aucune ACP ne permet.

**Axe 1** : *Prix* et les étudiants et employés d'un côté ; *Choix*, *Service* et les cadres et indépendants de l'autre. C'est la contrainte budgétaire.

**Axe 2** : *Proximité* et les retraités, seuls en bas.

**Attention : entre une ligne et une colonne, on lit une direction, pas une distance.** « Retraité est du côté de Proximité » se lit ; « Retraité est à trois centimètres de Proximité » ne se lit pas.

## Une figure, deux familles de points

**Le privilège de l'AFC**

Le plan porte **simultanément** les modalités des lignes et celles des colonnes.
C'est l'avantage décisif de l'AFC sur l'ACP, où variables et individus exigeaient deux figures séparées.

**Les coordonnées**

| CSP | axe 1 | axe 2 | Motif | axe 1 | axe 2 |
|---|---|---|---|---|---|
| Cadre | 0,59 | 0,26 | Choix | 0,52 | 0,32 |
| Employé | −0,40 | 0,17 | Prix | −0,54 | 0,26 |
| Étudiant | −0,76 | 0,31 | Proximité | −0,37 | −0,34 |
| Indépendant | 0,35 | −0,29 | Service | 0,42 | −0,37 |
| Retraité | −0,38 | −0,71 | | | |

### Nommer les deux axes

**Axe 1 : le prix contre le choix et le service**

À gauche, le **prix** avec les **étudiants** et les **employés** ; à droite, le **choix** et le **service** avec les **cadres** et les **indépendants**. L'axe oppose les clients qui viennent pour **payer moins** à ceux qui viennent pour **être mieux servis** : c'est la contrainte budgétaire.

**Axe 2 : la proximité, et les retraités**

En bas, la **proximité** et les **retraités**, avec le service et les indépendants ; en haut, le choix et le prix. Le deuxième axe isole surtout une clientèle **de quartier**, qui vient parce que le magasin est près de chez elle.

## Les règles de lecture

### Ce qu'on a le droit de dire

**Quatre règles**

| Comparaison | Interprétation |
|---|---|
| Deux **lignes** proches | profils semblables |
| Deux **colonnes** proches | profils semblables |
| Une ligne et une colonne du **même côté** | **attirance** — effectif supérieur à l'attendu |
| Un point **loin du centre** | modalité au profil très particulier |

**Sur le plan réel**

Étudiants et employés sont proches : leurs profils se ressemblent (prix d'abord). Les cadres sont du côté du choix : 40 cadres sur 72 viennent pour le choix, contre 19,7 attendus.

### La règle qu'on enfreint le plus souvent

**Pas de distance entre une ligne et une colonne**

**On ne mesure pas une distance entre une ligne et une colonne.**
« Les retraités sont à trois centimètres de la proximité, donc plus proches que les employés » n'a pas de sens : les deux nuages ne vivent pas dans le même espace.
On lit une **direction commune**, jamais une distance croisée : *les retraités et la proximité sont du même côté de l'axe* 2*, donc associés.*

**Le centre du plan**

L'origine représente le **profil moyen**. Une modalité proche du centre a un profil banal.
Sur le petit tableau, ce sont les **familles** ($d^2 = 0{,}006$) ; sur le tableau réel, les **employés** ($d^2 = 0{,}189$, le plus faible des cinq).

## Les mêmes prudences qu'en ACP

### Qualité de représentation

**Le cosinus carré d'une modalité**

Comme en ACP, la qualité d'une modalité sur le plan est la part de sa distance au centre que le plan restitue.

**Les cinq CSP**

| CSP | $\cos^2$ axe 1 | $\cos^2$ axe 2 | $\cos^2$ plan |
|---|---|---|---|
| Cadre | 0,78 | 0,15 | 0,93 |
| Employé | 0,85 | 0,15 | 1,00 |
| Étudiant | 0,81 | 0,13 | 0,95 |
| Indépendant | 0,46 | 0,31 | 0,76 |
| Retraité | 0,19 | 0,65 | 0,84 |

### Contributions : qui a fait les axes

**Les contributions des CSP**

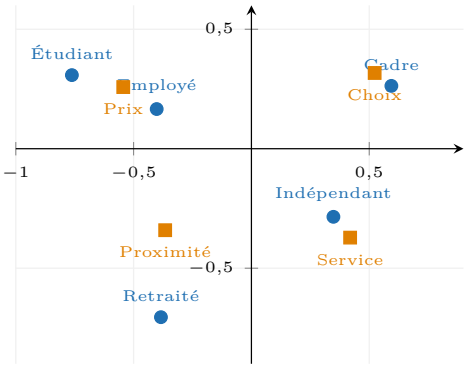
| CSP | Poids | ctr axe 1 | ctr axe 2 |
|---|---|---|---|
| Cadre | 24 % | **37,3** % | 16,1 % |
| Employé | 34 % | 24,0 % | 9,1 % |
| Étudiant | 7 % | 18,8 % | 6,8 % |
| Indépendant | 25 % | 13,4 % | 19,8 % |
| Retraité | 10 % | 6,5 % | **48,3** % |

**Un dixième des clients, la moitié d'un axe**

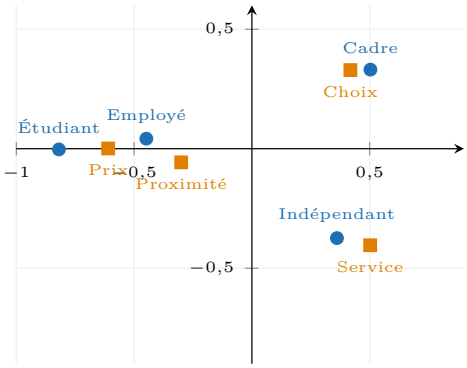
Les retraités ne sont que 30 sur 300, et fabriquent **à eux seuls près de la moitié** du deuxième axe. C'est le défaut le plus fréquent de l'AFC : une catégorie **rare** au profil extrême capte un axe.

### Refaire l'analyse sans eux

avec les retraités : axes à 61,6 et 28,0 %




sans les retraités : axes à 76,5 et 22,5 %




### Ce que l'épreuve montre

**Sans les 30 retraités**

Le premier axe **résiste** : il oppose toujours le prix (étudiants, employés) au choix et au service (cadres, indépendants), et porte désormais 76,5 % de l'inertie.
Le deuxième axe **change de nature** : il n'oppose plus la proximité au reste, mais le **service** (indépendants) au **choix** (cadres). La proximité revient près du centre.

**La conclusion à écrire**

Le premier axe est une **structure** de la clientèle. Le deuxième, dans l'analyse complète, décrivait surtout **un groupe** : les retraités venus par proximité. Les deux sont vrais, mais il faut le dire — c'est exactement la vérification demandée au chapitre 11 pour un individu de forte contribution.

## Sur machine

### Avec R : la fonction CA

**Les valeurs propres**

```
library(FactoMineR)
tab <- as.data.frame.matrix(table(clients$csp, clients$motif))
afc <- CA(tab, graph = FALSE)
e <- afc$eig
colnames(e) <- c("valeur", "pct", "cumul")
round(e, 4)
#       valeur     pct    cumul
# dim 1 0.2267 61.5955  61.5955
# dim 2 0.1030 27.9772  89.5726
# dim 3 0.0384 10.4274 100.0000
```

## Avec R : coordonnées et contributions

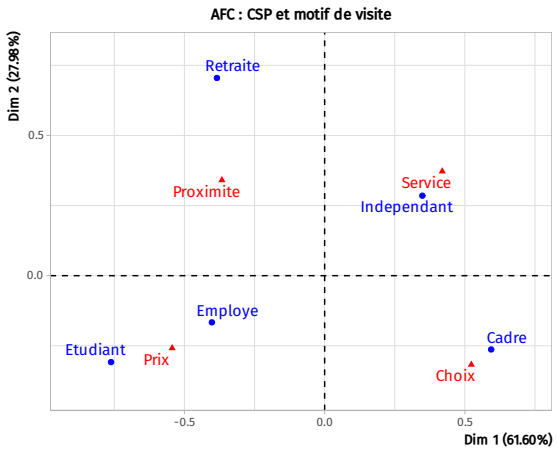
**Les cinq CSP**

```
round(cbind(afc$row$coord[, 1:2], ctr2 = afc$row$contrib[, 2]), 3)
#              Dim 1  Dim 2   ctr2
# Cadre        0.594 -0.263 16.145
# Employe     -0.402 -0.166  9.059
# Etudiant    -0.762 -0.308  6.769
# Independant  0.348  0.285 19.755
# Retraite    -0.384  0.705 48.272
```

**Les colonnes**

`afc$col$coord`, `afc$col$contrib` et `afc$col$cos2` donnent la même chose pour les quatre motifs ; `afc$row$cos2` les qualités des lignes.

## Le plan tracé par R




**Le signe, une dernière fois**

`plot(afc)` place les retraités **en haut** : `FactoMineR` donne au deuxième axe le signe opposé à celui des figures du cours. Les associations — retraités et proximité du même côté — sont les mêmes.

## Avec Python : l'AFC par une décomposition

**numpy suffit : une décomposition en valeurs singulières**

```
tab = pd.crosstab(clients.csp, clients.motif)
P = tab.to_numpy() / tab.to_numpy().sum()
r, c = P.sum(axis=1), P.sum(axis=0)
S = (P - np.outer(r, c)) / np.sqrt(np.outer(r, c))
u, s, vt = np.linalg.svd(S, full_matrices=False)
lam = s[:3] ** 2
print(lam.round(4), (100 * lam / lam.sum()).round(1))
# [0.2267 0.103  0.0384] [61.6 28.  10.4]
lignes = u[:, :2] * s[:2] / np.sqrt(r)[:, None]
colonnes = vt.T[:, :2] * s[:2] / np.sqrt(c)[:, None]
sg = np.array([np.sign(lignes[0, 0]), -np.sign(lignes[4, 1])])
lignes, colonnes = lignes * sg, colonnes * sg    # convention du cours
```

## Ce que calcule le code Python

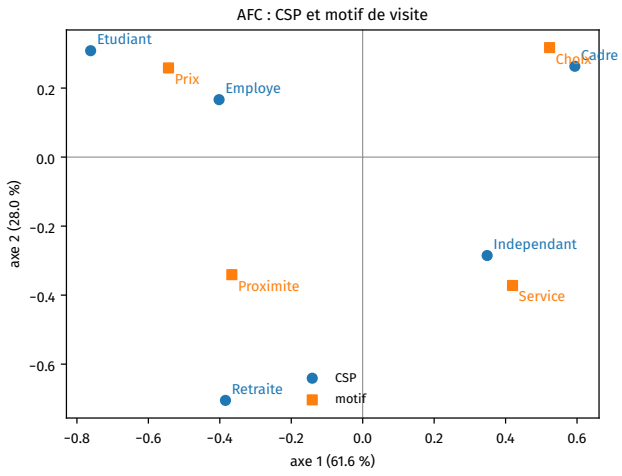
**La matrice S**

Chaque case de $S$ vaut $\dfrac{p_{ij} - r_i c_j}{\sqrt{r_i c_j}}$ : l'écart à l'indépendance, **réduit**. La somme de ses carrés est exactement $\Phi^2 = \chi^2/n$ — la case du khi-deux divisée par $n$.

**Pourquoi une décomposition en valeurs singulières**

Les carrés des valeurs singulières de $S$ sont les valeurs propres de l'AFC, et ses vecteurs singuliers donnent les coordonnées. C'est la même diagonalisation qu'en ACP, appliquée à un écart à l'indépendance : **le cours de Master** montre que l'ACP et l'AFC sont un seul et même calcul.

## Le plan tracé par matplotlib



**Avec la convention du cours**

Les retraités en bas, du côté de la proximité ; les cadres en haut à droite, du côté du choix. Le code de la figure est dans `figsrc/gen/fig_py.py`.

## Ce que ce cours a construit

### Le parcours

**L'introduction et les treize chapitres**

| Unités | Acquis |
|---|---|
| Intro, 1 | le problème de la dimension ; ce cours est de la descriptive **multivariée** |
| 2–4 | centrer et réduire, **covariance**, **corrélation** |
| 5–6 | le **nuage**, et l'**inertie** qui mesure son information |
| 7–11 | l'**ACP** : axes, valeurs propres, nombre d'axes, cercle, plan des individus |
| 12–13 | l'**AFC** : du khi-deux à la représentation |

### Le premier fil rouge, d'un bout à l'autre

**Cinq clients, accueil et fidélité**

| Chapitre | Grandeur | Valeur |
|---|---|---|
| 2 | moyennes ; variances | 12 et 12 ; 8 et 32 |
| 3 | covariance | $72/5 = 14{,}4$ |
| 4 | $s_x s_y = \sqrt{256}$ ; **corrélation** | 16 ; $14{,}4/16 = \mathbf{0{,}9}$ |
| 6 | inertie des données réduites | 2 |
| 8 | valeurs propres | 1,9 et 0,1 |
| 8 | **inertie du premier axe** | **95** % |
| 11 | coordonnées sur l'axe 1 | $-2$ ; $-0{,}5$ ; $-0{,}5$ ; 1 ; 2 |

Et pour l'AFC à la main : $\chi^2 = 64{,}1$, $\Phi^2 = 0{,}160$, un axe à 99,6 %.

### Le second fil rouge

**Trois cents clients**

| Chapitre | Grandeur | Valeur |
|---|---|---|
| 1 | clients 36 et 246 | même moyenne, 13,9 |
| 6 | inertie des huit notes réduites | 8 |
| 8 | deux premières valeurs propres | 4,535 et 1,645 |
| 9 | **inertie du plan** | **77,3** % |
| 10 | les deux axes | niveau ; offre contre service |
| 11 | clients hebdomadaires sur l'axe 1 | 1,41 |

| | | |
|---|---|---|
| 12 | $\chi^2$ CSP × motif ; $\Phi^2$ | 110,41 ; 0,368 |
| 13 | plan de l'AFC ; retraités sur l'axe 2 | 89,6 % ; 48,3 % |

### La réponse au chameau

**Trouver l'angle, et dire ce qu'il coûte**

L'introduction posait une question : quel angle perd le moins d'information, et combien perd-il ?
Le chapitre 8 y a répondu par un nombre : sur nos cinq clients, le meilleur axe conserve 95 % de l'inertie. Sur les huit notes des trois cents clients, le meilleur plan en conserve 77,3 %.
**C'est tout ce que fait l'analyse des données** : trouver l'angle, et dire ce qu'il coûte.

## La suite, au Master

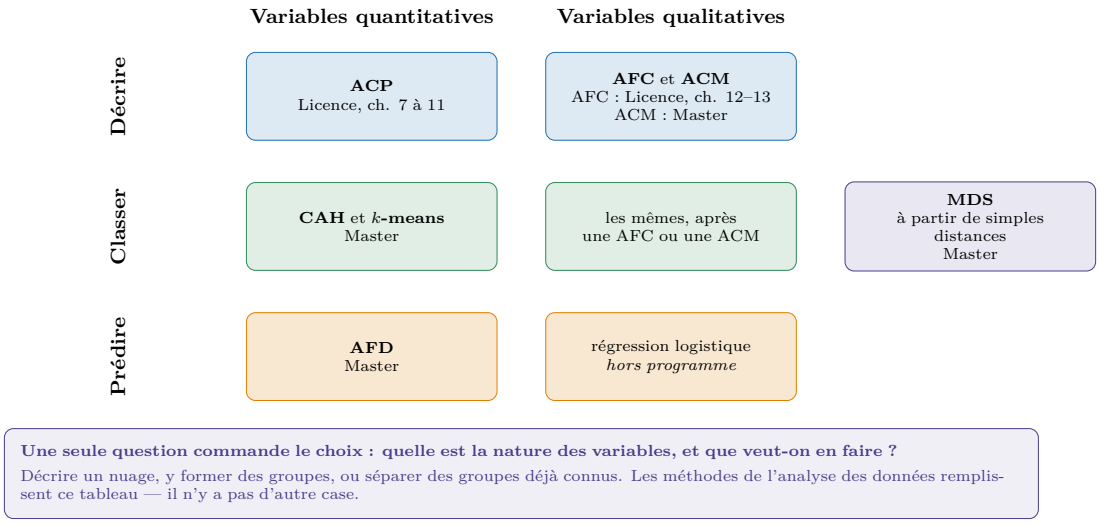
### Ce qui reste à voir

**Le cours d'analyse des données du niveau Master**

Il reprend l'ensemble depuis le début, sur le même fichier clients.csv, et le prolonge :

| Prolongement | Question à laquelle il répond |
|---|---|
| Correspondances **multiples** | et si l'on a **dix** variables qualitatives ? |
| **Classification** | comment constituer des groupes de clients ? |
| Analyse **discriminante** | dans quel groupe placer un **nouveau** client ? |
| **Positionnement** multidimensionnel | comment cartographier des ressemblances ? |
| Le formalisme | pourquoi ACP et AFC sont **le même calcul** |

### La carte des méthodes



### Où ce cours mène ailleurs

**L'ACP sous d'autres noms**

L'ACP réapparaîtra :

- en **économétrie financière**, comme méthode d'extraction de facteurs de risque ;
- en **apprentissage statistique**, comme réduction de dimension avant régression ;
- partout où le nombre de variables dépasse ce qu'on peut regarder.

**Ce cours n'était donc pas une parenthèse** : c'est l'un des outils les plus réemployés de tout le cursus.

**Et l'AFC**

L'AFC se retrouve partout où l'on croise des catégories : enquêtes, études de marché, textes (mots × documents). Son prolongement, l'ACM, est l'outil standard du traitement des questionnaires.

## S'entraîner

### Exercice 1 : la relation de transition

**Retrouver la coordonnée des seniors**

Sur le petit tableau, $\lambda_1 = 0{,}1597$ et les colonnes ont pour coordonnées 0,237 (magasin), −0,609 (web), 0,320 (téléphone). Le profil des seniors est $(0{,}6; 0{,}133; 0{,}267)$.

1. Calculer la coordonnée des seniors sur l'axe 1.
2. Pourquoi est-elle positive ?

### Exercice 1 : solution

**0,367**

1. $\dfrac{0{,}6 \times 0{,}237 + 0{,}133 \times (-0{,}609) + 0{,}267 \times 0{,}320}{0{,}400} = \dfrac{0{,}142 - 0{,}081 + 0{,}085}{0{,}400} = \dfrac{0{,}146}{0{,}400} = 0{,}366$, soit 0,367 aux arrondis près.
2. Les seniors achètent surtout en **magasin** et par **téléphone**, deux colonnes de coordonnée positive, et très peu sur le web : la moyenne pondérée est tirée du côté positif.

### Exercice 2 : une catégorie rare

**Contribution et poids**

Sur le tableau réel, $\lambda_2 = 0{,}1030$ ; les retraités pèsent 0,10 et ont pour coordonnée −0,705 sur l'axe 2.

1. Calculer leur contribution à l'axe 2, sachant que ctr = poids × $F^2/\lambda$.
2. Pourquoi faut-il refaire l'analyse sans eux ? Que montre-t-elle ?

### Exercice 2 : solution

**48,3 pour cent**

1. $0{,}10 \times 0{,}705^2 / 0{,}1030 = 0{,}10 \times 0{,}497 / 0{,}1030 = 0{,}483$, soit 48,3 % — près de la moitié de l'axe pour un dixième des clients.
2. Pour savoir si l'axe décrit une **structure** ou un **groupe**. Sans eux, le premier axe reste le même et le deuxième oppose désormais le service au choix : l'ancien axe 2 était surtout celui des retraités.

### Exercice 3 : vrai ou faux ?

**Cinq phrases sur le plan réel**

1. Les étudiants et les employés ont des profils de motif semblables.
2. Les retraités sont plus proches de la proximité que les indépendants du service, donc plus associés.
3. Les cadres viennent plus souvent pour le choix que l'ensemble des clients.
4. Le plan conserve 89,6 % de l'écart à l'indépendance.
5. L'AFC prouve que la CSP **cause** le motif de visite.

### Exercice 3 : solution

**Trois vrais, deux faux**

1. **Vrai** : deux lignes proches ont des profils semblables (prix d'abord).
2. **Faux** : on ne compare pas des distances entre une ligne et une colonne ; on dit seulement que chacun est du côté de l'autre.
3. **Vrai** : même côté du plan, et 55,6 % contre 27,3 %.
4. **Vrai** : $61{,}6 + 28{,}0 = 89{,}6$ % de $\Phi^2$.
5. **Faux** : l'AFC décrit une **association**. L'âge, le revenu ou le lieu de résidence peuvent expliquer à la fois la CSP et le motif.

## Ce qu'il faut retenir

### Le résumé du cours

**Six points, pour quatorze unités**

1. Réduire la dimension, c'est **perdre de l'information** — la seule question est combien.
2. L'**inertie** mesure cette information ; sur données réduites, elle vaut $p$.
3. Les axes sont les **vecteurs propres** de la matrice des corrélations, les inerties leurs **valeurs propres** : 95 % sur un axe pour les cinq clients, 77,3 % sur deux pour les huit notes.
4. On ne commente **que** ce qui est bien représenté, et l'on vérifie qui a **construit** chaque axe.
5. L'AFC applique la même démarche à un écart à l'**indépendance**, mesuré par le khi-deux : $\Phi^2 = \lambda_1 + \lambda_2 + \ldots$
6. Lignes et colonnes se lisent par **directions communes** ; une catégorie rare peut fabri-

quer un axe.

## Le mot de la fin

**Décrire, et bien**

Aucune de ces méthodes ne teste quoi que ce soit, et aucune n'établit de causalité. Elles décrivent, et elles décrivent bien.
Leur mérite est de rendre **visible** une structure que trente colonnes de chiffres gardaient cachée. Ce que cette structure signifie, et ce qu'il faut en faire, relève du jugement — et des cours qui suivent.

**Sur notre fichier, en deux phrases**

Les clients se distinguent d'abord par leur **niveau** de satisfaction, puis par ce qu'ils apprécient : l'**offre** ou le **service**. Leur motif de visite oppose d'abord ceux qui viennent pour le **prix** à ceux qui viennent pour le **choix** et le **service**, et isole une clientèle **de proximité**.