

Introduction

Voir en deux dimensions ce qui en a beaucoup

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données


1 Exercices du chapitre

Correction — Exercice 1

(a) Le nombre de nuages bivariés vaut $\binom{p}{2} = \frac{p(p-1)}{2}$.

(b) Pour $p = 10$: $\frac{10 \times 9}{2} = 45$ nuages. Pour $p = 18$: $\frac{18 \times 17}{2} = 153$ nuages.

(c) Le nombre de nuages croît en p^2 (**quadratiquement**), pas proportionnellement à p : doubler p multiplie approximativement le nombre de nuages par 4 (de 45 à 153, soit $\times 3,4$ en passant de 10 à 18, proche du rapport $(18/10)^2 = 3,24$). C'est cette croissance quadratique qui rend l'examen exhaustif des nuages rapidement impraticable : une étude à 30 variables compterait déjà 435 nuages, bien au-delà de ce qu'un analyste peut examiner un à un.



Correction — Exercice 2

(a)

Le chameau (cours)	Le jury de dégustation
un objet à 3 dimensions	un vin décrit par 12 critères sensoriels
une feuille à 2 dimensions	un graphique plan
l'angle de prise de vue	les axes factoriels
ce que la photo perd	les nuances sensorielles non représentées

(b) Le problème comporte, « au départ », 12 dimensions (une par critère sensoriel noté). En pratique, le jury ne pourra regarder qu'un graphique en 2 dimensions (éventuellement 3, mais rarement davantage de façon lisible).

(c) Comme pour le chameau, passer de 12 dimensions à 2 **détruit nécessairement** de l'information sur le profil sensoriel complet de chaque vin ; la seule question sensée n'est donc pas « comment tout garder » (impossible), mais « quels axes (quelles combinaisons de critères) résument le mieux les ressemblances et différences entre vins » – exactement le rôle que joue l'angle de prise de vue pour le photographe.

Correction — Exercice 3

(a) **Faux** : le cours est explicite – « l'analyse des données ne teste rien. Elle ne calcule aucune p -value ». C'est une démarche descriptive et exploratoire, pas inférentielle.

(b) **Faux** : les nuages bivariés ne montrent que des liaisons **deux à deux** ; une structure qui n'apparaît qu'en combinant plusieurs variables à la fois (par exemple trois ou quatre) reste invisible sur chacun des nuages pris séparément, même si on les examine tous.

(c) **Vrai** : c'est précisément la définition donnée par le cours – réduire la dimension (le nombre de variables considérées simultanément) tout en conservant la plus grande part possible de l'information, afin de révéler une structure invisible dans le tableau brut.

- (d) **Faux** : le cours insiste sur le fait que l'analyse des données « explore » et « fait apparaître des structures qu'on ne soupçonnait pas, et qu'il appartiendra ensuite de confirmer par d'autres moyens » — une structure explorée n'est jamais, à elle seule, définitivement établie.
- (e) **Vrai** : c'est explicitement énoncé dans le cours – « c'est pourquoi on l'appelle aussi statistique exploratoire, et pourquoi elle vient avant l'inférence, jamais après ».

2 Applications en sciences économiques

Correction — Exercice 4

(a) $\binom{20}{2} = \frac{20 \times 19}{2} = 190$ nuages de points bivariés.

(b) **Non** : les 20 histogrammes univariés décrivent chaque question **isolément** (par exemple, la distribution des notes sur « salaire » d'un côté, sur « ambiance » de l'autre) mais ne renseignent en rien sur la façon dont les réponses d'un même salarié se combinent. Un profil défini par une **combinaison** de réponses (bon salaire, mauvaise ambiance) est par nature une information **croisée** entre variables, totalement absente d'histogrammes univariés qui ne regardent jamais deux variables ensemble.

(c) Dans le vocabulaire du cours, la direction cherche les **axes** qui résument au mieux les 20 questions du questionnaire, de façon à faire apparaître sur un graphique en deux dimensions la **structure** des profils de salariés (par exemple, un axe « engagement général » et un axe « satisfaction matérielle »), en conservant la plus grande part possible de l'**inertie** (c'est-à-dire de l'information) contenue dans les 20 variables initiales.

Correction — Exercice 5

(a) **Non** : le mot « significativement » appartient au vocabulaire de l'inférence (chapitre 12 du cours de statistique inférentielle), qui suppose un test formel avec un seuil de risque contrôlé. L'analyse des données étant une démarche **exploratoire**, elle ne fait, au mieux, que « suggérer » l'existence de deux groupes ; l'équipe ne peut affirmer une différence « statistiquement significative » sans avoir conduit le test approprié.

(b) Un test de comparaison de deux moyennes (test de Welch, vu au chapitre 16 du cours de statistique inférentielle) permettrait de vérifier rigoureusement si le panier moyen diffère réellement entre les deux groupes observés, ou si l'écart apparent sur le graphique pourrait n'être qu'un effet du hasard d'échantillonnage.

(c) Tester une hypothèse sur les **mêmes** données qui ont servi à la « suggérer » biaiserait gravement le résultat : les données ayant déjà été scrutées pour y chercher une structure, il est presque garanti d'y retrouver, par construction, l'écart qu'on y a repéré – un peu comme choisir la forme d'un test *après avoir vu* le signe de l'écart observé (chapitre 14 du cours de statistique inférentielle). La bonne pratique consiste à confirmer la structure explorée sur un **nouvel** échantillon, indépendant de celui qui a permis de la découvrir, ou à réserver dès le départ une partie des données à cette seule confirmation.