

Introduction à l'analyse des données

Introduction : Voir en deux dimensions ce qui en a beaucoup

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Compter les nuages de points

Un service marketing dispose d'un fichier client décrit par p variables numériques (montant dépensé, fréquence de visite, ancienneté, notes de satisfaction, etc.).

- (a) Rappeler la formule du nombre de nuages de points bivariés qu'on peut tracer à partir de p variables.
- (b) Calculer ce nombre pour $p = 10$ variables, puis pour $p = 18$ variables (le cas d'une enquête de satisfaction à 18 questions).
- (c) Le nombre de nuages est-il proportionnel à p , ou croît-il plus vite ? Justifier à partir de la formule, et en déduire pourquoi doubler le nombre de variables d'une étude rend l'examen exhaustif des nuages rapidement impraticable.

Exercice 2 — Construire une nouvelle correspondance

Le cours établit une correspondance entre le problème du photographe et celui d'un fichier clients (chameau / fichier, angle de prise de vue / axes factoriels, silhouette reconnaissable / structure des données, ce que la photo perd / inertie non représentée).

On considère à présent un jury de dégustation de vins, qui note chaque vin sur une douzaine de critères sensoriels (acidité, tanin, fruité, longueur en bouche, etc.), et cherche à identifier des « familles » de vins aux profils sensoriels proches.

- (a) Construire, sur ce nouvel exemple, un tableau de correspondance à quatre lignes analogue à celui du cours (objet de départ, représentation réduite, ce qui joue le rôle des axes, ce qui est perdu).
- (b) Combien de dimensions ce problème comporte-t-il « au départ » (une par critère sensoriel) ? Sur combien de dimensions le jury pourra-t-il, en pratique, regarder un graphique ?
- (c) En quoi ce nouvel exemple illustre-t-il, comme celui du chameau, l'idée que « la seule question qui reste est : quel angle en détruit le moins » ?

Exercice 3 — Vrai ou faux : ce que fait, et ne fait pas, l'analyse des données

Pour chacune des affirmations suivantes, dire si elle est vraie ou fausse, et justifier en une phrase à l'aide du cours.

- (a) « L'analyse des données calcule une p -value pour vérifier si la structure observée dans un nuage de points est statistiquement significative. »
- (b) « Avec p variables, examiner tous les nuages de points deux à deux permet de détecter n'importe quelle structure présente dans les données, y compris celles qui combinent plusieurs variables à la fois. »
- (c) « L'analyse des données réduit le nombre de *variables* examinées simultanément, dans le but de faire apparaître une structure qu'on ne voyait pas dans le tableau brut. »
- (d) « Une structure mise en évidence par l'analyse des données doit, en toute rigueur, être considérée comme définitivement établie, sans besoin de vérification ultérieure. »
- (e) « L'analyse des données est qualifiée d'« exploratoire » car elle intervient logiquement avant l'inférence, jamais après. »

2 Applications en sciences économiques

Exercice 4 — Une enquête de satisfaction interne

Une direction des ressources humaines soumet à ses 500 salariés un questionnaire d'engagement comportant 20 questions notées de 1 à 10, et souhaite identifier des profils types de salariés (engagés, désabusés, en observation, etc.).

- (a) Calculer le nombre de nuages de points bivariés que compterait un examen exhaustif des 20 variables.
- (b) La direction propose d'examiner « seulement » les 20 histogrammes univariés (un par question), plutôt que les nuages bivariés, pour gagner du temps. Cette approche permettrait-elle de repérer un profil de salarié défini par une combinaison de plusieurs réponses (par exemple, une bonne évaluation du salaire mais une mauvaise évaluation de l'ambiance) ? Justifier.
- (c) Reformuler, dans le vocabulaire de ce cours (axes, inertie, structure), l'objectif réel de la direction des ressources humaines.

Exercice 5 — Explorer avant de confirmer


Une équipe marketing applique une méthode d'analyse des données à son fichier clients et observe, sur le graphique obtenu, ce qui ressemble à deux groupes de clients nettement séparés.

- (a) L'équipe peut-elle, sur la seule base de ce graphique, affirmer dans un rapport que « les clients se répartissent statistiquement en deux segments significativement différents » ? Justifier à partir de la distinction entre démarche exploratoire et démarche confirmatoire rappelée dans le cours.
- (b) Quel type d'outil, vu dans un cours antérieur, permettrait de vérifier plus rigoureusement si les deux groupes observés diffèrent réellement sur une variable donnée (par exemple leur panier moyen) ?
- (c) Pourquoi le cours insiste-t-il sur le fait que la démarche exploratoire vient *avant* la démarche confirmatoire, et non l'inverse ? Quel risque y aurait-il à tester une hypothèse « suggérée » par les mêmes données qui serviraient ensuite à la confirmer ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Le nombre de nuages bivariés vaut $\binom{p}{2} = \frac{p(p-1)}{2}$.
- (b) Pour $p = 10$: $\frac{10 \times 9}{2} = 45$ nuages. Pour $p = 18$: $\frac{18 \times 17}{2} = 153$ nuages.
- (c) Le nombre de nuages croît en p^2 (**quadratiquement**), pas proportionnellement à p : doubler p multiplie approximativement le nombre de nuages par 4 (de 45 à 153, soit $\times 3,4$ en passant de 10 à 18, proche du rapport $(18/10)^2 = 3,24$). C'est cette croissance quadratique qui rend l'examen exhaustif des nuages rapidement impraticable : une étude à 30 variables compterait déjà 435 nuages, bien au-delà de ce qu'un analyste peut examiner un à un.



Correction — Exercice 2

(a)

Le chameau (cours)	Le jury de dégustation
un objet à 3 dimensions	un vin décrit par 12 critères sensoriels
une feuille à 2 dimensions	un graphique plan
l'angle de prise de vue	les axes factoriels
ce que la photo perd	les nuances sensorielles non représentées

- (b) Le problème comporte, « au départ », 12 dimensions (une par critère sensoriel noté). En pratique, le jury ne pourra regarder qu'un graphique en 2 dimensions (éventuellement 3, mais rarement davantage de façon lisible).
- (c) Comme pour le chameau, passer de 12 dimensions à 2 **détruit nécessairement** de l'information sur le profil sensoriel complet de chaque vin ; la seule question sensée n'est donc pas « comment tout garder » (impossible), mais « quels axes (quelles combinaisons de critères) résument le mieux les ressemblances et différences entre vins » – exactement le rôle que joue l'angle de prise de vue pour le photographe.

Correction — Exercice 3

- (a) **Faux** : le cours est explicite – « l'analyse des données ne teste rien. Elle ne calcule aucune p -value ». C'est une démarche descriptive et exploratoire, pas inférentielle.
- (b) **Faux** : les nuages bivariés ne montrent que des liaisons **deux à deux** ; une structure qui n'apparaît qu'en combinant plusieurs variables à la fois (par exemple trois ou quatre) reste invisible sur chacun des nuages pris séparément, même si on les examine tous.
- (c) **Vrai** : c'est précisément la définition donnée par le cours – réduire la dimension (le nombre de variables considérées simultanément) tout en conservant la plus grande part possible de l'information, afin de révéler une structure invisible dans le tableau brut.

- (d) **Faux** : le cours insiste sur le fait que l'analyse des données « explore » et « fait apparaître des structures qu'on ne soupçonnait pas, et qu'il appartiendra ensuite de confirmer par d'autres moyens » – une structure explorée n'est jamais, à elle seule, définitivement établie.
- (e) **Vrai** : c'est explicitement énoncé dans le cours – « c'est pourquoi on l'appelle aussi statistique exploratoire, et pourquoi elle vient avant l'inférence, jamais après ».

2 Applications en sciences économiques

Correction — Exercice 4

- (a) $\binom{20}{2} = \frac{20 \times 19}{2} = 190$ nuages de points bivariés.
- (b) **Non** : les 20 histogrammes univariés décrivent chaque question **isolément** (par exemple, la distribution des notes sur « salaire » d'un côté, sur « ambiance » de l'autre) mais ne renseignent en rien sur la façon dont les réponses d'un même salarié se combinent. Un profil défini par une **combinaison** de réponses (bon salaire, mauvaise ambiance) est par nature une information **croisée** entre variables, totalement absente d'histogrammes univariés qui ne regardent jamais deux variables ensemble.
- (c) Dans le vocabulaire du cours, la direction cherche les **axes** qui résument au mieux les 20 questions du questionnaire, de façon à faire apparaître sur un graphique en deux dimensions la **structure** des profils de salariés (par exemple, un axe « engagement général » et un axe « satisfaction matérielle »), en conservant la plus grande part possible de l'**inertie** (c'est-à-dire de l'information) contenue dans les 20 variables initiales.

Correction — Exercice 5

- (a) **Non** : le mot « significativement » appartient au vocabulaire de l'inférence (chapitre 12 du cours de statistique inférentielle), qui suppose un test formel avec un seuil de risque contrôlé. L'analyse des données étant une démarche **exploratoire**, elle ne fait, au mieux, que « suggérer » l'existence de deux groupes ; l'équipe ne peut affirmer une différence « statistiquement significative » sans avoir conduit le test approprié.
- (b) Un test de comparaison de deux moyennes (test de Welch, vu au chapitre 16 du cours de statistique inférentielle) permettrait de vérifier rigoureusement si le panier moyen diffère réellement entre les deux groupes observés, ou si l'écart apparent sur le graphique pourrait n'être qu'un effet du hasard d'échantillonnage.
- (c) Tester une hypothèse sur les **mêmes** données qui ont servi à la « suggérer » biaiserait gravement le résultat : les données ayant déjà été scrutées pour y chercher une structure, il est presque garanti d'y retrouver, par construction, l'écart qu'on y a repéré – un peu comme choisir la forme d'un test *après avoir vu* le signe de l'écart observé (chapitre 14 du cours de statistique inférentielle). La bonne pratique consiste à confirmer la structure explorée sur un **nouvel** échantillon, indépendant de celui qui a permis de la découvrir, ou à réserver dès le départ une partie des données à cette seule confirmation.