

Introduction

Voir en deux dimensions ce qui en a beaucoup

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Compter les nuages de points

Un service marketing dispose d'un fichier client décrit par p variables numériques (montant dépensé, fréquence de visite, ancienneté, notes de satisfaction, etc.).

- (a) Rappeler la formule du nombre de nuages de points bivariés qu'on peut tracer à partir de p variables.
- (b) Calculer ce nombre pour $p = 10$ variables, puis pour $p = 18$ variables (le cas d'une enquête de satisfaction à 18 questions).
- (c) Le nombre de nuages est-il proportionnel à p , ou croît-il plus vite ? Justifier à partir de la formule, et en déduire pourquoi doubler le nombre de variables d'une étude rend l'examen exhaustif des nuages rapidement impraticable.

Exercice 2 — Construire une nouvelle correspondance

Le cours établit une correspondance entre le problème du photographe et celui d'un fichier clients (chameau / fichier, angle de prise de vue / axes factoriels, silhouette reconnaissable / structure des données, ce que la photo perd / inertie non représentée).

On considère à présent un jury de dégustation de vins, qui note chaque vin sur une douzaine de critères sensoriels (acidité, tanin, fruité, longueur en bouche, etc.), et cherche à identifier des « familles » de vins aux profils sensoriels proches.

- (a) Construire, sur ce nouvel exemple, un tableau de correspondance à quatre lignes analogue à celui du cours (objet de départ, représentation réduite, ce qui joue le rôle des axes, ce qui est perdu).
- (b) Combien de dimensions ce problème comporte-t-il « au départ » (une par critère sensoriel) ? Sur combien de dimensions le jury pourra-t-il, en pratique, regarder un graphique ?
- (c) En quoi ce nouvel exemple illustre-t-il, comme celui du chameau, l'idée que « la seule question qui reste est : quel angle en détruit le moins » ?

Exercice 3 — Vrai ou faux : ce que fait, et ne fait pas, l'analyse des données

Pour chacune des affirmations suivantes, dire si elle est vraie ou fausse, et justifier en une phrase à l'aide du cours.

- (a) « L'analyse des données calcule une p -valeur pour vérifier si la structure observée dans un nuage de points est statistiquement significative. »
- (b) « Avec p variables, examiner tous les nuages de points deux à deux permet de détecter n'importe quelle structure présente dans les données, y compris celles qui combinent plusieurs variables à la fois. »
- (c) « L'analyse des données réduit le nombre de *variables* examinées simultanément, dans le but de faire apparaître une structure qu'on ne voyait pas dans le tableau brut. »
- (d) « Une structure mise en évidence par l'analyse des données doit, en toute rigueur, être considérée comme définitivement établie, sans besoin de vérification ultérieure. »
- (e) « L'analyse des données est qualifiée d'« exploratoire » car elle intervient logiquement avant l'inférence, jamais après. »

2 Applications en sciences économiques

Exercice 4 — Une enquête de satisfaction interne

Une direction des ressources humaines soumet à ses 500 salariés un questionnaire d'engagement comportant 20 questions notées de 1 à 10, et souhaite identifier des profils types de salariés (engagés, désabusés, en observation, etc.).

- (a) Calculer le nombre de nuages de points bivariés que compterait un examen exhaustif des 20 variables.
- (b) La direction propose d'examiner « seulement » les 20 histogrammes univariés (un par question), plutôt que les nuages bivariés, pour gagner du temps. Cette approche permettrait-elle de repérer un profil de salarié défini par une combinaison de plusieurs réponses (par exemple, une bonne évaluation du salaire mais une mauvaise évaluation de l'ambiance) ? Justifier.
- (c) Reformuler, dans le vocabulaire de ce cours (axes, inertie, structure), l'objectif réel de la direction des ressources humaines.

Exercice 5 — Explorer avant de confirmer

Une équipe marketing applique une méthode d'analyse des données à son fichier clients et observe, sur le graphique obtenu, ce qui ressemble à deux groupes de clients nettement séparés.

- (a) L'équipe peut-elle, sur la seule base de ce graphique, affirmer dans un rapport que « les clients se répartissent statistiquement en deux segments significativement différents » ? Justifier à partir de la distinction entre démarche exploratoire et démarche confirmatoire rappelée dans le cours.
- (b) Quel type d'outil, vu dans un cours antérieur, permettrait de vérifier plus rigoureusement si les deux groupes observés diffèrent réellement sur une variable donnée (par exemple leur panier moyen) ?
- (c) Pourquoi le cours insiste-t-il sur le fait que la démarche exploratoire vient *avant* la démarche confirmatoire, et non l'inverse ? Quel risque y aurait-il à tester une hypothèse « suggérée » par les mêmes données qui serviraient ensuite à la confirmer ?