Introduction à l'analyse des données

Introduction : Voir en deux dimensions ce qui en a beaucoup

Jaouad Madkour

31 octobre 2026

Plan de l'introduction

Prérequis **2**
Ce que ce cours suppose acquis . . . 2
Ce que le cours établit lui-même . . . 2

Une photographie de chameau **3**
Le problème du photographe . . . 3
Ce que l'image montre . . . 3
Le métier du photographe . . . 3
Le chameau en chiffres . . . 4
Ce que ces trois pourcentages annoncent . . . 4

Le même problème, en gestion **5**
Trois cents clients, seize variables . . . 5
Le tableau, en image . . . 5
Du problème de la dimension . . . 5
Pourquoi les graphiques usuels échouent . . . 6
Le décompte, sur notre fichier . . . 6
Quatre notes, six nuages . . . 7
Ce que les six nuages laissent voir, et ce qu'ils cachent . . . 7
Un seul graphique, et le bon . . . 8
Ce que la méthode produit sur ce fichier . . . 8

L'objet du cours **8**
La correspondance, terme à terme . . . 8
Ce que le cours va donc devoir faire . . . 9
Ce que le cours ne fait pas . . . 9
Explorer et confirmer . . . 9

Les deux fils rouges **10**
Cinq clients, pour tout calculer à la main . . . 10
Ce que ces cinq lignes vont donner . . . 10
Trois cents clients, pour voir la méthode à l'œuvre . . . 10

S'entraîner **11**

Exercice 1 : compter les nuages . . . 11
Exercice 1 : solution . . . 11
Exercice 2 : ce qu'une photographie conserve . . . 11
Exercice 2 : solution . . . 11
Exercice 3 : explorer ou confirmer ? . . . 11
Exercice 3 : solution . . . 12

Ce qu'il faut retenir **12**
Le résumé de l'introduction . . . 12
La suite . . . 12

Prérequis

Ce que ce cours suppose acquis

Le cours qui précède

Statistique descriptive, en particulier la **covariance** et la **corrélation** — ce cours n'en est que le prolongement à plus de deux variables.

Les notions mobilisées

Moyenne, variance, écart-type, covariance, corrélation. La variable centrée réduite, qui commande tout le reste.
Les chapitres 2 à 4 les rappellent : ce n'est pas une formalité, c'est là que se joue la compréhension de la suite.

Ce que le cours établit lui-même

Ce cours ne suppose pas l'algèbre linéaire

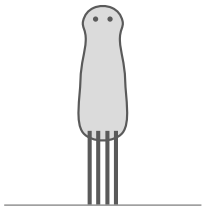
Vecteur propre et valeur propre sont **rappelés au moment où ils servent**, avec des démonstrations courtes, faites sur deux variables.
C'est le parti pris du niveau Licence : montrer ce que font les méthodes. *Analyse des données avancée*, au Master, reprend l'ensemble et démontre pourquoi elles le font — et là, l'algèbre linéaire est exigée.

Les deux logiciels du cours

Les chapitres d'analyse proprement dite (7 à 13) se terminent par une mise en œuvre **réelle** sur **R** (paquet `FactoMineR`) et sur **Python** (`numpy`, `pandas`). Le code est exécuté et les sorties sont reproduites telles quelles.

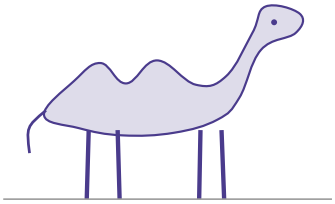
Une photographie de chameau

Le problème du photographe



vue de face

qu'est-ce que c'est ?



vue de profil

deux bosses, une encolure : aucun doute

Le même animal, le même appareil : seul l'angle a changé.

Un chameau a *trois* dimensions ; une photographie n'en a que *deux*. Passer de l'un à l'autre détruit forcément de l'information — et le photographe choisit l'angle qui en détruit le moins.

L'analyse des données fait exactement cela, sur un tableau de trente variables au lieu d'un animal.

Ce que l'image montre

Le même animal, deux clichés

De **face**, un chameau photographié en noir et blanc est une colonne étroite surmontée d'une tache. Rien ne permet de reconnaître l'animal : ni les bosses, ni l'encolure, ni la ligne du dos. De **profil**, il n'y a plus le moindre doute. Deux bosses, un long cou, une démarche caractéristique.
Pourtant, c'est le même animal, le même appareil, la même lumière. **Seul l'angle de prise de vue a changé.**

Pourquoi l'angle décide de tout

Un chameau est un objet à **trois dimensions**. Une photographie est une surface à **deux dimensions**.
Passer de trois à deux **détruit nécessairement** de l'information : c'est le prix de l'aplatissement. La seule question qui reste au photographe est donc : **quel angle en détruit le moins ?**

Le métier du photographe

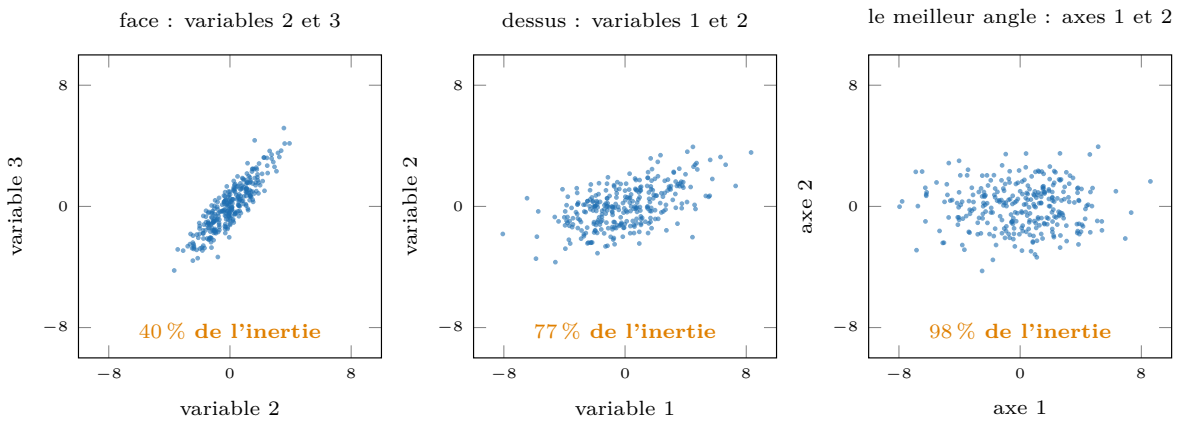
En une phrase

Il tourne autour de son sujet et cherche la position d'où la silhouette reste la plus reconnaissable — non pas *toute* l'information, ce qui est impossible, mais **la plus grande part possible**.

Ce qu'il ne sait pas faire

Le photographe juge à l'œil. Il ne peut pas dire *combien* d'information son cliché conserve, ni prouver qu'aucun angle ne ferait mieux.
C'est exactement ce que le cours va apprendre à faire : **mesurer** l'information conservée, et **trouver** l'angle qui la rend maximale.

Le chameau en chiffres



Trois cents points dans l'espace, trois photographies

Le même nuage à trois dimensions, photographié de trois façons. De **face**, il ne reste que 40 % de son information ; vu de **dessus**, 77 % ; sous le **meilleur angle**, 98 %.

Ce que ces trois pourcentages annoncent

Trois idées que le cours va construire

1. L'**information** d'un nuage se mesure : c'est sa dispersion, que l'on appellera **inertie** (chapitre 6).
2. Chaque photographie en conserve une **part**, qui s'exprime en pourcentage.
3. Il existe un angle **optimal**, qui se **calcule** : ce sont les axes de l'analyse en composantes principales (chapitres 7 et 8).

Pourquoi le meilleur angle n'est aucun des deux autres

Le nuage est **allongé en biais** par rapport aux variables mesurées. Aucune paire de variables d'origine ne le voit de profil : le bon plan est fait de **combinaisons** des trois variables.
C'est le cœur de la méthode : les axes qu'elle trouve ne sont pas les variables du tableau, mais des variables **construites**.

Le même problème, en gestion

Trois cents clients, seize variables

La situation ordinaire d'une entreprise

Une enseigne dispose d'un fichier de **trois cents clients**, chacun décrit par seize variables : sexe, âge, catégorie socioprofessionnelle, fréquence de visite, carte de fidélité, ancienneté, panier moyen, motif principal de visite, et **huit notes de satisfaction** sur 20 — prix, choix, qualité, agencement, propreté, rapidité, conseil, accueil.
La direction pose une question simple : **quels sont les profils de nos clients ?** Trois cents lignes de chiffres ne se regardent pas.

Le tableau, en image

	8 notes de satisfaction				signalétique	
client	prix	choix	⋯	accueil	CSP	fréquence
1	13,2	15,4	⋯	16,1	Cadre	Hebdo.
2	9,8	11,0	⋯	10,4	Employé	Rare
⋮	⋮	⋮		⋮	⋮	⋮
300	12,5	13,9	⋯	14,8	Retraité	Mensuelle

variables **actives** : elles construisent les axes — variables **illustratives** : on les projette ensuite

Le choix des variables actives est la seule décision vraiment engageante de toute l'analyse.

Elles fixent la géométrie du nuage — donc les axes, donc l'interprétation. Les illustratives n'y participent pas : on les superpose après coup pour *éclairer* les axes, jamais pour les construire.

Mettre le chiffre d'affaires en actif quand on étudie la satisfaction, c'est laisser la taille des clients écraser leur opinion.

Du problème de la dimension

2 variables
1 nuage de points
on voit tout

→

8 variables
$\binom{8}{2} = 28$ nuages
on ne voit plus rien

→

30 variables
$\binom{30}{2} = 435$ nuages
impossible

Et le problème n'est pas seulement le nombre de graphiques.

Vingt-huit nuages pris deux à deux ne montrent que des liaisons *par paires*. Une structure qui n'apparaît qu'en combinant quatre variables reste invisible sur les vingt-huit.

L'analyse des données ne fait pas plus de graphiques : elle en fait un seul, et le bon.

Pourquoi les graphiques usuels échouent

Le décompte

Avec p variables, on peut tracer

$$\binom{p}{2} = \frac{p(p-1)}{2} \text{ nuages de points}$$

Variables	Nuages à examiner
2	1
8	28
12	66
30	435

Démonstration : Le nombre de nuages de points

Un nuage de points se trace pour une **paire** de variables. Comptons les paires.

Pour la première variable de la paire, on a p choix ; pour la seconde, il en reste $p - 1$: cela fait $p(p-1)$ couples ordonnés (x, y). Mais le nuage de y selon x et celui de x selon y portent la même information (on a seulement échangé les axes) : chaque paire a été comptée **deux fois**. Donc

$$\binom{p}{2} = \frac{p(p-1)}{2}.$$

La croissance. Avec $2p$ variables, le même calcul donne

$$\frac{2p\,(2p-1)/2}{p\,(p-1)/2} = \frac{2\,(2p-1)}{p-1} = 4 + \frac{2}{p-1}.$$

Doubler le nombre de variables multiplie donc le nombre de nuages par **un peu plus de quatre** (par exactement quatre à la limite) : c'est une croissance en p^2. De 8 à 16 variables, on passe de 28 à 120 nuages, soit 4,29 fois plus.

■

Le décompte, sur notre fichier

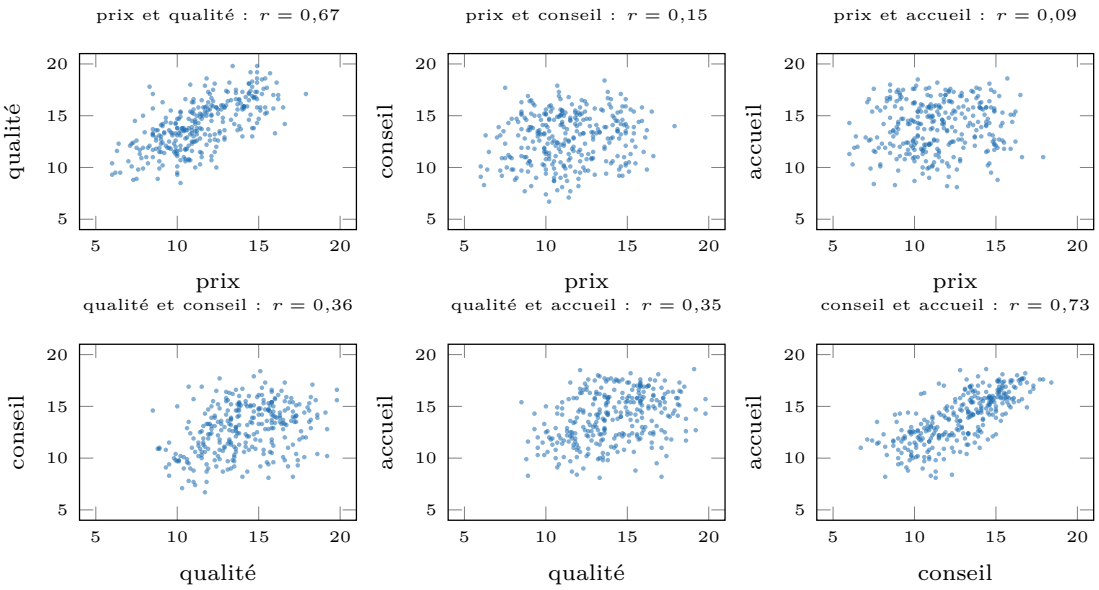
Vingt-huit nuages pour les seules notes

Les huit notes de satisfaction donnent déjà $8 \times 7/2 = 28$ nuages. Les seize variables, $16 \times 15/2 = 120$.

Une croissance en p au carré

Doubler le nombre de variables multiplie à peu près par **quatre** le nombre de nuages. Le procédé qui marche pour deux ou trois variables devient impraticable dès qu'on en a une dizaine.

Quatre notes, six nuages



Ce que les six nuages laissent voir, et ce qu'ils cachent

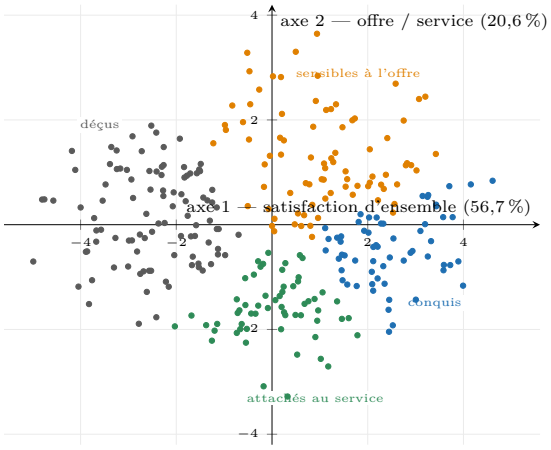
Ce qu'on y lit

Le **prix** va avec la **qualité** ($r = 0{,}67$), le **conseil** avec l'**accueil** ($r = 0{,}73$). Mais le prix n'a presque rien à voir avec l'accueil ($r = 0{,}09$).
On devine **deux familles de critères** — ce que le client pense de l'offre, ce qu'il pense du service.

Et le nombre n'est pas le vrai problème

Même en examinant les vingt-huit nuages, on ne verrait que des liaisons **deux à deux**. Une structure qui n'apparaît qu'en **combinant** plusieurs variables reste invisible sur chacun d'eux.
L'analyse des données ne fait donc pas plus de graphiques : elle en fait un seul, et le bon.

Un seul graphique, et le bon



Le même plan, vu du côté des clients.

Le cercle des corrélations disait ce que *signifient* les axes. Ce plan-ci dit *qui* se trouve où.

À droite : les clients satisfaits de tout. **À gauche** : les mécontents.

En haut : ceux qui louent l'offre et taisent le service. **En bas** : l'inverse.

Les quatre couleurs ne sont pas dans les données : elles viendront de la classification, étudiée au Master. Le nuage, lui, les suggérait déjà.

Ce que la méthode produit sur ce fichier

Huit dimensions, une feuille

Les trois cents clients, décrits par huit notes, sont placés sur **un plan**. Ce plan conserve **77,3** % de l'information des huit notes.
Il se lit en deux directions : de gauche à droite, du client **mécontent de tout** au client **satisfait de tout** ; de bas en haut, du client attaché au **service** au client sensible à l'**offre**.

C'est le résultat que le cours apprend à produire

Chacun des nombres de cette figure — 77,3 %, la position d'un client, le nom des axes — sera calculé, justifié et lu au fil des chapitres 7 à 11.
Rien n'y est magique : tout découle de la moyenne, de la variance et de la corrélation.

L'objet du cours

La correspondance, terme à terme

Deux problèmes, une seule méthode

Le chameau	Le fichier clients
un objet à 3 dimensions	un tableau à p variables
une feuille à 2 dimensions	un graphique plan
l'angle de prise de vue	les **axes factoriels**
la silhouette reconnaissable	la structure des données
ce que la photo perd	l'**inertie** non représentée

Analyse des données

L'**analyse des données** est l'ensemble des méthodes qui **réduisent la dimension** d'un tableau, en cherchant la représentation plane qui conserve la plus grande part de l'information.

Ce que le cours va donc devoir faire

Trois choses, dans cet ordre

1. **Mesurer l'information** contenue dans un tableau — sans quoi on ne peut pas dire qu'on en conserve beaucoup ou peu. Ce sera l'**inertie**.
2. **Trouver le meilleur angle** — c'est-à-dire les axes qui conservent le maximum de cette inertie.
3. **Lire la représentation obtenue**, ce qui est un travail à part entière.

Deux familles de tableaux, deux méthodes

Le tableau croise	Méthode	Chapitres
individus et variables **quantitatives**	**ACP**	7 à 11
deux variables **qualitatives**	**AFC**	12 et 13

Ce que le cours ne fait pas

Une mise au point utile dès maintenant

L'analyse des données ne **teste** rien. Elle ne calcule aucune p-value, ne rejette aucune hypothèse, ne conclut à aucune significativité.
Elle **explore** : elle fait apparaître des structures qu'on ne soupçonnait pas, et qu'il appartiendra ensuite de confirmer par d'autres moyens.
C'est pourquoi on l'appelle aussi **statistique exploratoire**, et pourquoi elle vient *avant* l'inférence, jamais après.

Explorer et confirmer

Démarche confirmatoire
Statistique inférentielle, économétrie
une hypothèse **posée d'avance**
↓
les données tranchent
on sait ce qu'on cherche

Démarche exploratoire
Analyse des données
aucune hypothèse préalable
↓
les données suggèrent
on cherche ce qu'on ne sait pas

Les deux démarches ne s'opposent pas : elles se suivent.
L'exploration fait *naître* les hypothèses ; la confirmation les *juge*. Une segmentation obtenue par classification n'est pas un résultat prouvé : c'est une hypothèse de travail, qu'il faudra tester sur d'autres données.
Le danger est de présenter comme démontré ce qui n'a été qu'observé. Aucune p-value ne sortira de ce cours ; ce n'est pas un oubli.

Les deux fils rouges

Cinq clients, pour tout calculer à la main

Le petit tableau

Client	Accueil X	Fidélité Y
1	8	4
2	10	12
3	12	8
4	14	16
5	16	20

Pourquoi un tableau si petit

Cinq lignes et deux colonnes se calculent **entièrement au tableau**. Tout ce qui se fait sur trois cents clients se fera d'abord ici, et l'on vérifiera chaque étape plutôt que de la croire.

Ce que ces cinq lignes vont donner

Les nombres du fil rouge, chapitre après chapitre

Chapitre	Grandeur	Valeur
2	moyennes, variances	12 et 12 ; 8 et 32
3	covariance	$72/5 = 14{,}4$
4	corrélation	$14{,}4/16 = 0{,}9$
6	inertie des données réduites	2
8	valeurs propres	1,9 et 0,1
8	part du premier axe	95 %

Trois cents clients, pour voir la méthode à l'œuvre

Le fichier clients.csv

Le même fichier que plus haut : 300 clients, seize variables. Il sert à **deux** analyses :

Méthode	Ce qui est analysé	Chapitres
ACP	les huit notes	7 à 11
AFC	CSP × motif de visite	12, 13

Des chiffres que chacun peut retrouver

Tous les résultats affichés sur ce fichier ont été **recalculés** : à la main pour les formules, puis sur R et sur Python. Les mêmes chiffres serviront au cours de Master, qui reprend ce fichier pour aller plus loin.

S'entraîner

Exercice 1 : compter les nuages

Combien de graphiques pour tout voir ?

1. Combien de nuages de points faut-il pour examiner toutes les paires parmi 5 variables ? parmi 16 ?
2. Un analyste regarde 10 nuages par heure. Combien de temps lui faut-il pour $p = 30$?
3. Après ce travail, sait-il s'il existe des groupes de clients définis par **trois** variables à la fois ?

Exercice 1 : solution

Une croissance en p au carré

1. $5 \times 4/2 = 10$ nuages pour 5 variables ; $16 \times 15/2 = 120$ pour 16.
2. $30 \times 29/2 = 435$ nuages, soit près de 44 heures — plus d'une semaine de travail.
3. **Non.** Chaque nuage ne montre que deux variables : une structure qui en combine trois peut n'apparaître sur aucun d'eux. Le nombre de graphiques n'est pas le seul obstacle.

Exercice 2 : ce qu'une photographie conserve

Un nuage à trois dimensions

Un nuage de points est allongé selon trois directions perpendiculaires, qui portent respectivement 60 %, 30 % et 10 % de son information.

1. Quelle part conserve la photographie prise dans le plan des **deux premières** directions ?
2. Et celle prise dans le plan des deux **dernières** ?
3. Peut-on, avec une seule photographie plane, conserver toute l'information ?

Exercice 2 : solution

Garder les deux plus grandes

1. $60 + 30 = 90$ % : c'est le meilleur cliché possible.
2. $30 + 10 = 40$ % : le cliché « de face » du chameau.
3. **Non** : un plan ne garde que deux directions, et la troisième porte 10 % qui seront perdus quoi qu'on fasse. Toute la méthode consiste à choisir les deux directions qui en perdent le moins.

Exercice 3 : explorer ou confirmer ?

Quatre questions de gestion

Pour chaque question, dire si elle relève de l'**exploration** (ce cours) ou de la **confirmation** (statistique inférentielle).

1. Quels profils de clients notre fichier contient-il ?
2. La satisfaction moyenne a-t-elle baissé depuis l'an dernier, au risque de 5 % ?
3. Quelles notes de satisfaction vont ensemble ?

4. Les cadres viennent-ils davantage pour le choix que les employés, dans la population de nos clients ?

Exercice 3 : solution

Décrire, ou généraliser avec un risque

1. **Exploration** : aucune hypothèse posée d'avance, on cherche une structure.
2. **Confirmation** : une hypothèse précise, un risque d'erreur — c'est un test.
3. **Exploration** : c'est exactement ce que fera l'ACP des huit notes.
4. **Confirmation** si l'on veut conclure sur la population. L'AFC du chapitre 13 **montrera** l'association dans le fichier ; le test du khi-deux la **confirmera**.

Ce qu'il faut retenir

Le résumé de l'introduction

Six points

1. Un objet à trois dimensions photographié sur une feuille **perd** de l'information : la seule question est **combien**.
2. Le photographe cherche l'**angle** qui en perd le moins ; l'analyse des données cherche les **axes**, et les calcule.
3. Avec p variables, il y a $p(p-1)/2$ nuages — et ils ne montrent que des liaisons **deux à deux**.
4. La méthode ne fait pas plus de graphiques : **elle en fait un seul, et le bon** — 77,3 % de l'information de huit notes sur un plan.
5. C'est une démarche **exploratoire**, qui décrit et suggère, sans tester.
6. Deux fils rouges : **cinq clients** pour le calcul à la main, **trois cents** pour la méthode réelle.

La suite

Situer le cours

Avant de construire quoi que ce soit, il faut situer ce cours par rapport à celui que vous connaissez déjà — la statistique descriptive.

Le chapitre 1

C'est l'objet du chapitre 1, et la réponse est plus simple qu'on ne l'imagine : l'analyse des données est de la statistique descriptive, faite sur plusieurs variables à la fois.