

Introduction à l'analyse des données

Chapitre 11 : Le plan des individus

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — La qualité de représentation d'un individu

Un individu a pour coordonnées sur quatre axes principaux : $c_1 = 2,1$, $c_2 = 0,8$, $c_3 = 0,3$, $c_4 = -0,1$.

- (a) Calculer $d^2(i, G) = c_1^2 + c_2^2 + c_3^2 + c_4^2$, la distance au carré totale de cet individu au centre de gravité.
- (b) Calculer la qualité de représentation de cet individu sur le premier plan (axes 1 et 2), $\frac{c_1^2 + c_2^2}{d^2(i, G)}$.
- (c) Cet individu peut-il être commenté de façon fiable sur ce premier plan ? Justifier par la valeur trouvée.

Exercice 2 — Une contribution qui doit alerter

Un fichier de $n = 10$ individus donne un axe de valeur propre $\lambda = 2,4$. Un individu a pour coordonnée $c = 3,5$ sur cet axe.

- (a) Calculer la contribution de cet individu à l'axe, $\frac{c^2}{n \times \lambda}$.
- (b) Comparer cette contribution à la contribution moyenne, $1/n$.
- (c) D'après le « contrôle à faire systématiquement » rappelé par le cours, que faudrait-il vérifier avant d'accepter la structure révélée par cet axe ?

Exercice 3 — Variables actives et illustratives

Un institut construit une ACP sur 8 notes de satisfaction client (variables actives), puis projette a posteriori la région d'habitation et l'ancienneté du client (variables illustratives).

- (a) Pourquoi la région n'a-t-elle pas participé au calcul des axes, alors qu'elle est bien représentée sur le plan final ?
- (b) Si les clients d'une région donnée se regroupent nettement d'un côté du premier axe, que peut-on en conclure sur le lien entre région et satisfaction ?
- (c) Le cours affirme que « l'ordre inverse serait circulaire » si l'on avait inclus la région parmi les variables actives dès le départ. Expliquer en une phrase pourquoi construire les axes à partir de la région, puis « découvrir » qu'elle explique le premier axe, ne prouverait rien.

2 Exercices cumulatifs (introduction au chapitre 11)

Exercice 4 — Le plan des cinq clients

On reprend le fil rouge, avec les coordonnées factorielles des cinq clients calculées au chapitre 8 : $C_1 = (-2,0; -0,5; -0,5; 1,0; 2,0)$ et $C_2 = (0; -0,5; 0,5; 0; 0)$ pour les clients 1 à 5.

- (a) Classer les cinq clients par ordre croissant de leur coordonnée sur le premier axe C_1 . Que représente, économiquement, le client qui a la coordonnée la plus faible ? Et celui qui a la plus élevée ?
- (b) Les clients 2 et 3 ont la **même** coordonnée sur le premier axe ($-0,5$). Que les distingue pourtant sur le second axe, et comment interpréter cette différence en termes d'accueil et de fidélité (chapitre 8, cours) ?
- (c) Calculer la qualité de représentation du client 1 sur ce plan, $\frac{c_{1,1}^2 + c_{2,1}^2}{d^2(1, G)}$ (avec $d^2(1, G) = c_{1,1}^2 + c_{2,1}^2$).
Ce résultat est-il surprenant, compte tenu de ce qui a déjà été observé au chapitre 10 pour les variables du fil rouge ?

3 Applications en sciences économiques

Exercice 5 — Détecter un individu qui fabrique l'axe à lui seul

Une enquête RH porte sur $n = 8$ salariés. Le premier axe a pour valeur propre $\lambda = 1,5$. Un salarié a pour coordonnée $c = 2,8$ sur cet axe.

- (a) Calculer la contribution de ce salarié à l'axe, et la comparer à la contribution moyenne $1/n$.
- (b) Le service RH s'apprête à conclure que « l'engagement des salariés se structure clairement autour de ce premier axe ». Cette conclusion est-elle prudente, compte tenu de la contribution calculée ?
- (c) Proposer la démarche à suivre avant de valider l'interprétation de cet axe.

Exercice 6 — Faire parler une variable illustrative

Une chaîne de distribution construit une ACP sur 6 notes de satisfaction (variables actives) recueillies auprès de 300 clients répartis dans 3 régions. Le plan des individus fait apparaître trois zones assez nettement séparées, chacune dominée par les clients d'une région.

- (a) La région a-t-elle été utilisée pour construire les axes ? Pourquoi ce choix méthodologique est-il important pour la validité du résultat obtenu ?
- (b) Formuler, en une phrase, la conclusion descriptive que l'entreprise peut légitimement tirer de cette séparation par région.
- (c) Le directeur commercial souhaite immédiatement en déduire une politique commerciale différenciée par région. Que répondre, en s'appuyant sur la mise en garde du cours (« résultat descriptif », « le tester relève d'autres cours ») ?

1 Exercices du chapitre

Correction — Exercice 1

(a) $d^2(i, G) = 2,1^2 + 0,8^2 + 0,3^2 + (-0,1)^2 = 4,41 + 0,64 + 0,09 + 0,01 = 5,15$.

(b) $\frac{2,1^2 + 0,8^2}{5,15} = \frac{4,41 + 0,64}{5,15} = \frac{5,05}{5,15} \approx 0,981$.

(c) Oui : avec une qualité de représentation de 98,1 %, ce premier plan restitue la quasi-totalité de la position réelle de cet individu – il peut être commenté de façon fiable.

Correction — Exercice 2

(a) $\frac{3,5^2}{10 \times 2,4} = \frac{12,25}{24} \approx 0,510$, soit 51,0 %.

(b) La contribution moyenne vaut $1/n = 1/10 = 10\%$. La contribution de cet individu (51 %) est plus de **cinq fois** supérieure à la moyenne.

(c) Il faut vérifier s'il s'agit d'une **erreur de saisie** ou d'un cas réellement exceptionnel, puis **refaire l'analyse sans cet individu** et comparer les résultats. Si les axes changent complètement en son absence, le premier axe ne décrivait pas la structure de la population : il décrivait ce seul individu.

Correction — Exercice 3

(a) La région n'a pas participé au calcul des axes parce qu'elle a été traitée comme une variable **illustrative** : elle est projetée *après coup* sur les axes déjà construits à partir des seules notes de satisfaction (variables actives), ce qui n'empêche pas de calculer, une fois les axes fixés, sa corrélation ou sa position par rapport à eux.

(b) On peut en conclure qu'il existe un **lien** entre région et niveau de satisfaction, révélé *sans que la région ait influencé* la construction des axes – la structure du nuage de satisfaction (obtenue indépendamment) se trouve coïncider avec le découpage régional.

(c) Si la région avait été incluse parmi les variables actives, l'axe se serait en partie construit *à partir d'elle* – retrouver ensuite que « la région explique l'axe » ne ferait alors que redire, de façon circulaire, ce qui avait été introduit dès le départ dans le calcul, sans apporter d'information nouvelle sur une relation réellement observée entre deux ensembles de variables indépendants.

2 Exercices cumulatifs (introduction au chapitre 11)


Correction — Exercice 4

(a) Par coordonnée croissante sur C_1 : client 1 $(-2,0)$, puis clients 2 et 3 à égalité $(-0,5)$, puis client 4 $(1,0)$, puis client 5 $(2,0)$. Le premier axe étant la « satisfaction globale » (chapitre 8), le client 1 (coordonnée la plus faible) est le client le **moins** satisfait globalement (faible accueil, faible fidélité), tandis que le client 5 (coordonnée la plus élevée) est le **plus** satisfait globalement (accueil et fidélité tous deux élevés).

(b) Sur le second axe, le client 2 a $c_2 = -0,5$ et le client 3 a $c_2 = +0,5$: ils sont donc **opposés** sur cet axe, qui « oppose les deux notes » (chapitre 8). Concrètement, le client 2 est **plus fidèle qu'accueilli** (sa fidélité dépasse ce que son accueil seul laisserait attendre), tandis que le client 3 est **plus accueilli que fidèle** (l'inverse) – une nuance invisible sur le seul premier axe, mais que le second axe, bien que ne portant que 5 % de l'inertie, permet de distinguer.

(c) $d^2(1, G) = (-2,0)^2 + 0^2 = 4$. Qualité = $\frac{4 + 0}{4} = 1,000$, soit 100 %. Ce résultat n'est pas surprenant : il retrouve, pour les individus, exactement la même propriété déjà observée pour les **variables** au chapitre 10 – avec $p = 2$ variables, les deux axes retenus couvrent la totalité de l'espace, donc aucun individu (comme aucune variable) ne peut avoir de position « cachée » sur un axe non représenté : la

qualité de représentation vaut nécessairement 100 % pour tous.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Contribution = $\frac{2,8^2}{8 \times 1,5} = \frac{7,84}{12} \approx 0,653$, soit 65,3 %, contre une moyenne $1/8 = 12,5\%$ – plus de **cinq fois** la moyenne.

(b) Non, cette conclusion n'est pas prudente : un seul salarié porte plus de 65 % de la construction de cet axe. L'axe risque de décrire avant tout le profil de ce salarié particulier, et non une structure partagée par l'ensemble des 8 salariés.

(c) Il faut vérifier s'il s'agit d'une réponse aberrante ou d'un cas exceptionnel, puis refaire l'ACP en **excluant** ce salarié et comparer le nouvel axe obtenu à l'axe initial : si la structure change radicalement une fois ce salarié retiré, l'interprétation « l'engagement se structure autour de cet axe » n'était pas valide pour l'ensemble des salariés.

Correction — Exercice 6

(a) Non, la région est une variable **illustrative** : elle n'a pas été utilisée pour construire les axes, qui reposent uniquement sur les 6 notes de satisfaction. Ce choix est essentiel pour la validité du résultat : il garantit que la séparation observée par région n'est pas un artefact circulaire du calcul, mais reflète un lien *réellement présent* entre la structure de satisfaction (indépendamment définie) et l'appartenance régionale.

(b) On peut conclure, de façon strictement descriptive, qu'il existe une association entre la région d'un client et son profil de satisfaction, telle que mesurée par ces 6 notes – les clients d'une même région tendent à se ressembler sur ces critères, et à se distinguer des clients des autres régions.

(c) Ce résultat reste **descriptif** : il montre une association observée sur cet échantillon, sans en établir la significativité statistique, la stabilité dans le temps, ni la relation de cause à effet. Avant d'en tirer une politique commerciale différenciée par région, il faudrait **tester** cette association (des outils que d'autres cours, statistique inférentielle notamment, permettent de mobiliser) plutôt que de l'assumer directement à partir de cette seule lecture graphique.