

Chapitre 2

Rappels sur une variable : centrer et réduire

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{42 + 38 + 50 + 45 + 55}{5} = \frac{230}{5} = 46.$

(b) Écarts : $-4, -8, 4, -1, 9$; somme $= -4 - 8 + 4 - 1 + 9 = 0$. $V(x) = \frac{16 + 64 + 16 + 1 + 81}{5} = \frac{178}{5} = 35,6$. $s_x = \sqrt{35,6} \approx 5,967$.

(c) La somme des écarts à la moyenne est nulle par **construction** : $\sum_i (x_i - \bar{x}) = \sum_i x_i - n\bar{x} = \sum_i x_i - n \times \frac{\sum_i x_i}{n} = \sum_i x_i - \sum_i x_i = 0$. Ce n'est pas une propriété des données observées, c'est une conséquence algébrique directe de la **définition même** de la moyenne – ce qui en fait un contrôle de calcul fiable : si la somme des écarts ne tombe pas à zéro, une erreur s'est glissée quelque part.



Correction — Exercice 2

(a) $z_1 = \frac{42 - 46}{5,967} \approx -0,670$; $z_2 = \frac{38 - 46}{5,967} \approx -1,341$; $z_3 = \frac{50 - 46}{5,967} \approx 0,670$; $z_4 = \frac{45 - 46}{5,967} \approx -0,168$; $z_5 = \frac{55 - 46}{5,967} \approx 1,508$.

(b) $\bar{z} = \frac{-0,670 - 1,341 + 0,670 - 0,168 + 1,508}{5} \approx 0,000$. $V(z) = \frac{0,449 + 1,798 + 0,449 + 0,028 + 2,275}{5} \approx \frac{5,0}{5} = 1,000$. Les deux propriétés sont vérifiées.

(c) L'objection confond deux choses : réduire uniformise l'**échelle** (moyenne 0, variance 1 pour toute variable), mais ne touche en rien à la **forme du nuage** ni aux positions **relatives** des individus entre eux. Deux clients très proches restent proches après réduction, deux clients éloignés restent éloignés (à un facteur d'échelle près, identique pour tous) ; la corrélation entre deux variables réduites, en particulier, est rigoureusement **la même** qu'avant réduction. Ce qui est perdu, c'est seulement l'unité et l'échelle d'origine – l'information sur la **structure** des données, elle, est intégralement préservée.

Correction — Exercice 3

(a) Le montant (variant de quelques centaines à plusieurs dizaines de milliers de dh) aura une variance considérablement plus grande que la note (1 à 5) – typiquement de plusieurs **ordres de grandeur** (la variance se comptant, ici, potentiellement en millions pour le montant, contre à peine plus d'un point pour la note).

(b) Sans réduction préalable, le montant **écraserait** totalement l'influence de la note dans tout calcul combiné (somme, distance) : les écarts sur le montant, mesurés en milliers, domineraient numériquement des écarts sur la note qui ne dépassent jamais quelques unités – la note deviendrait, de fait, presque invisible dans le résultat final, quelle que soit son importance réelle pour l'analyse.

(c) Une conclusion statistique porte sur la **structure** des données (qui ressemble à qui, quelles variables sont liées), pas sur l'unité arbitraire dans laquelle on choisit de les exprimer : que l'on compte le

montant en dh ou en k dh ne change rien à la réalité économique décrite. La réduction **divise** chaque variable par son propre écart-type, qui varie exactement dans les mêmes proportions que l'unité choisie (diviser toutes les valeurs par 1 000 divise aussi l'écart-type par 1 000) : le rapport $\frac{x_i - \bar{x}}{s_x}$ reste donc rigoureusement **identique** quelle que soit l'unité de départ, ce qui garantit que le résultat final ne dépend jamais d'un choix d'unité arbitraire.


2 Exercices cumulatifs (introduction au chapitre 2)

Correction — Exercice 4

(a) $\bar{x} = \frac{8 + 10 + 12 + 14 + 16}{5} = 12$; $\bar{y} = \frac{4 + 12 + 8 + 16 + 20}{5} = 12$. $V(x) = \frac{16 + 4 + 0 + 4 + 16}{5} = \frac{40}{5} = 8$; $V(y) = \frac{64 + 0 + 16 + 16 + 64}{5} = \frac{160}{5} = 32$. $s_x = \sqrt{8} \approx 2,828$; $s_y = \sqrt{32} \approx 5,657$. On retrouve exactement les valeurs du cours.

(b) Écarts de y : $-8, 0, -4, 4, 8$. $z_y = \frac{y_i - 12}{5,657}$: $z_{y,1} = -1,414$, $z_{y,2} = 0,000$, $z_{y,3} = -0,707$, $z_{y,4} = 0,707$, $z_{y,5} = 1,414$. $\bar{z}_y = 0$; $V(z_y) = \frac{2 + 0 + 0,5 + 0,5 + 2}{5} = \frac{5}{5} = 1$. Les deux propriétés sont bien vérifiées.

(c) **Non** : centrer et réduire l'accueil et la fidélité laisse le nombre de variables strictement **inchangé** – on a toujours deux variables (z_x et z_y) après l'opération, exactement comme avant. Centrer-réduire résout le problème des **unités** (rendre les variables comparables entre elles, quelle que soit leur échelle d'origine) ; réduire la **dimension** (le sujet de l'introduction, avec le problème des $\binom{p}{2}$ nuages) consiste à remplacer un grand nombre de variables par un petit nombre d'axes qui en résument l'essentiel. Ce sont deux opérations **complémentaires mais distinctes** : le cours va combiner les deux à partir du chapitre 6, en centrant-réduisant **d'abord** toutes les variables (pour qu'aucune ne domine par son unité), puis en cherchant **ensuite** les axes qui réduisent leur nombre – jamais l'inverse, et jamais en confondant l'une avec l'autre.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\overline{\text{montant}} = \frac{120 + 340 + 80 + 560 + 210 + 150}{6} \approx 243,33$ k dh. $V(\text{montant}) \approx 26\,888,9$. $\overline{\text{note}} = \frac{14 + 9 + 17 + 6 + 12 + 15}{6} \approx 12,17$. $V(\text{note}) \approx 13,81$.

(b) $\frac{V(\text{montant})}{V(\text{note})} \approx \frac{26\,888,9}{13,81} \approx 1\,948$. **Oui**, ce rapport (près de 2 000) confirme très nettement la mise

en garde du cours : sans réduction, le montant écraserait presque totalement l'influence de la note dans n'importe quel calcul combiné.

(c) $s_{\text{montant}} = \sqrt{26\,888,9} \approx 163,98$. Les valeurs centrées réduites du montant sont : $-0,75; 0,59; -1,00; 1,93; -0,20; -0,57$ – toutes de l'ordre de grandeur de $[-2; 2]$, exactement comme on l'attend pour **n'importe quelle** variable centrée réduite (moyenne 0, variance 1, quasi-totalité des valeurs entre -2 et 2 pour un échantillon de cette taille) : c'est bien cette mise à niveau qui rendra montant et note comparables terme à terme.

Correction — Exercice 6

(a) $\overline{\text{CA}} = 3,0$ M dh, $V(\text{CA}) \approx 0,7033$. $\overline{\text{heures}} \approx 15,83$, $V(\text{heures}) \approx 22,81$. Rapport $\approx \frac{22,81}{0,70} \approx 32,4$ – très inférieur au rapport de près de 2 000 de l'exercice 5. La raison tient aux **ordres de grandeur** des valeurs brutes elles-mêmes : ici, le CA (autour de 1 à 4) et les heures (autour de 8 à 22) restent des nombres du même ordre de grandeur, alors qu'à l'exercice 5, le montant (centaines) et la note (unités) différaient de plusieurs ordres de grandeur.

(b) Ce score serait trompeur car il additionnerait des grandeurs **sans commune mesure** : une variation d'une unité de CA (par exemple, 1 M dh) n'a économiquement rien à voir avec une variation d'une heure de formation, et la variance des heures étant ici 32 fois plus grande, ce sont en pratique les heures de formation qui domineraient le score, même si le CA est, pour l'entreprise, le critère le plus important.

(c) $z_{\text{CA}} : -1,073; 0,477; -1,431; 1,431; -0,119; 0,715$. $z_{\text{heures}} : -0,803; 0,454; -1,640; 1,291; -0,175; 0,873$.

Un score global correct et équilibré consisterait à **additionner les deux variables centrées réduites** (éventuellement pondérées selon l'importance relative que la direction souhaite leur donner) : $\text{score}_i = z_{\text{CA},i} + z_{\text{heures},i}$, qui donne, par exemple pour le commercial 4, $1,431 + 1,291 = 2,722$ – un score qui ne dépend plus de l'unité arbitraire de chacune des deux variables d'origine.