

Introduction à l'analyse des données

Chapitre 2 : Rappels sur une variable : centrer et réduire

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Moyenne et variance, écart par écart

Le chiffre d'affaires hebdomadaire (en k dh) de 5 magasins d'une même enseigne est : 42, 38, 50, 45, 55.

- (a) Calculer la moyenne $\bar{x}$.
- (b) Calculer les cinq écarts $x_i - \bar{x}$, vérifier que leur somme est nulle, puis calculer $V(x) = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ et $s_x = \sqrt{V(x)}$.
- (c) Cette vérification (« la somme des écarts vaut toujours zéro ») est rappelée par le cours comme un contrôle systématique. Pourquoi cette somme est-elle *nécessairement* nulle, quelles que soient les valeurs de x – à quoi cela tient-il dans la définition même de la moyenne ?

Exercice 2 — Centrer et réduire, et vérifier les deux propriétés

On reprend les données de l'exercice 1 : $\bar{x} = 46$, $s_x \approx 5,967$.

- (a) Calculer la variable centrée réduite $z_i = (x_i - \bar{x})/s_x$ pour les 5 magasins.
- (b) Vérifier que $\bar{z} = 0$ et $V(z) = 1$ sur vos cinq valeurs.
- (c) Le cours affirme que **toute** variable centrée réduite a une moyenne nulle et une variance de un, « quelles que soient ses valeurs de départ ». Un collègue objecte : « alors après réduction, toutes les variables se ressemblent, et on perd de l'information ». Que répondre à cette objection – qu'est-ce que la réduction change, et qu'est-ce qu'elle laisse, au contraire, intact ?

Exercice 3 — Pourquoi réduire est indispensable en présence d'unités différentes

Un fichier client comporte deux variables : le montant total des achats (en dh, variant de quelques centaines à plusieurs dizaines de milliers) et une note de satisfaction (de 1 à 5).

- (a) Sans faire aucun calcul, donner un ordre de grandeur : laquelle des deux variables aura, à votre avis, la variance la plus grande – et de combien d'ordres de grandeur environ ?
- (b) Si l'on combinait directement ces deux variables brutes (par exemple, en les additionnant, ou en calculant une distance entre deux clients à partir d'elles) sans les centrer-réduire au préalable, quel serait le résultat pratique sur l'influence respective des deux variables ?
- (c) Le cours affirme que « compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions » si l'on ne réduisait pas les variables. Expliquer pourquoi ce changement d'unité, purement conventionnel, ne devrait *jamais*, en toute rigueur, changer une conclusion statistique – et comment la réduction garantit cette invariance.

2 Exercices cumulatifs (introduction au chapitre 2)

Exercice 4 — Le fil rouge, vérifié à la main – et une distinction à ne pas manquer

On reprend le fil rouge du cours : cinq clients notés sur l'accueil (X) et la fidélité (Y) : (8,4), (10,12), (12,8), (14,16), (16,20).

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x)$, $V(y)$, s_x , s_y , et vérifier qu'on retrouve $\bar{x} = \bar{y} = 12$, $V(x) = 8$, $V(y) = 32$.
- (b) Le cours donne les valeurs centrées réduites de l'accueil (z_x). Calculer, de la même façon, les valeurs centrées réduites de la fidélité (z_y), et vérifier que $\bar{z}_y = 0$ et $V(z_y) = 1$.
- (c) L'introduction du cours pose le problème de la **dimension** (comment voir une structure quand il y a beaucoup de *variables*) ; ce chapitre résout le problème des **unités** (comment comparer des variables qui n'ont pas la même échelle). Sur ce fil rouge à seulement deux variables, centrer et réduire l'accueil et la fidélité a-t-il, en soi, réduit le *nombre* de variables à examiner ? Expliquer

pourquoi centrer-réduire et réduire la dimension sont deux opérations *différentes*, que le cours va combiner à partir du chapitre 6 sans jamais les confondre.

3 Applications en sciences économiques

Exercice 5 — Un dossier de crédit aux échelles incompatibles

Une banque étudie 6 dossiers de crédit décrits par le montant emprunté (en k dh) et une note de qualité de remboursement (de 0 à 20) :

Dossier	1	2	3	4	5	6
Montant (k dh)	120	340	80	560	210	150
Note (/20)	14	9	17	6	12	15

- (a) Calculer la moyenne et la variance de chacune des deux variables.
- (b) Calculer le rapport entre les deux variances. Ce rapport confirme-t-il la mise en garde du cours (« le montant écraserait tout ») ?
- (c) Calculer la variable centrée réduite du montant, et vérifier que ses valeurs sont désormais du même ordre de grandeur que celles attendues pour une variable centrée réduite de la note (sans faire ce second calcul en entier, à quel intervalle de valeurs vous attendez-vous?).

Exercice 6 — Évaluer des commerciaux sur des critères incomparables

Une direction commerciale évalue 6 commerciaux sur leur chiffre d'affaires annuel (en millions de dh) et leur nombre d'heures de formation suivies dans l'année :

Commercial	1	2	3	4	5	6
CA (M dh)	2,1	3,4	1,8	4,2	2,9	3,6
Heures de formation	12	18	8	22	15	20

- (a) Calculer la variance de chacune des deux variables. Le rapport des deux variances est-il aussi extrême que dans l'exercice 5 ? Pourquoi, à votre avis (comparer les ordres de grandeur des deux variables ici à ceux de l'exercice 5) ?
- (b) Un consultant propose un « score global » de chaque commercial en additionnant simplement le CA et le nombre d'heures de formation, sans aucun retraitement préalable. Expliquer pourquoi ce score serait trompeur.
- (c) Calculer les variables centrées réduites du CA et des heures de formation pour les 6 commerciaux, et proposer, à partir de ces deux séries, une définition correcte d'un « score global » comparable et équilibré entre les deux critères.


1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{x} = \frac{42 + 38 + 50 + 45 + 55}{5} = \frac{230}{5} = 46.$

(b) Écarts : $-4, -8, 4, -1, 9$; somme $= -4 - 8 + 4 - 1 + 9 = 0$. $V(x) = \frac{16 + 64 + 16 + 1 + 81}{5} = \frac{178}{5} = 35,6$. $s_x = \sqrt{35,6} \approx 5,967$.

(c) La somme des écarts à la moyenne est nulle par **construction** : $\sum_i (x_i - \bar{x}) = \sum_i x_i - n\bar{x} = \sum_i x_i - n \times \frac{\sum_i x_i}{n} = \sum_i x_i - \sum_i x_i = 0$. Ce n'est pas une propriété des données observées, c'est une conséquence algébrique directe de la **définition même** de la moyenne – ce qui en fait un contrôle de calcul fiable : si la somme des écarts ne tombe pas à zéro, une erreur s'est glissée quelque part.



Correction — Exercice 2

(a) $z_1 = \frac{42 - 46}{5,967} \approx -0,670$; $z_2 = \frac{38 - 46}{5,967} \approx -1,341$; $z_3 = \frac{50 - 46}{5,967} \approx 0,670$; $z_4 = \frac{45 - 46}{5,967} \approx -0,168$; $z_5 = \frac{55 - 46}{5,967} \approx 1,508$.

(b) $\bar{z} = \frac{-0,670 - 1,341 + 0,670 - 0,168 + 1,508}{5} \approx 0,000$. $V(z) = \frac{0,449 + 1,798 + 0,449 + 0,028 + 2,275}{5} \approx \frac{5,0}{5} = 1,000$. Les deux propriétés sont vérifiées.

(c) L'objection confond deux choses : réduire uniformise l'**échelle** (moyenne 0, variance 1 pour toute variable), mais ne touche en rien à la **forme du nuage** ni aux positions **relatives** des individus entre eux. Deux clients très proches restent proches après réduction, deux clients éloignés restent éloignés (à un facteur d'échelle près, identique pour tous) ; la corrélation entre deux variables réduites, en particulier, est rigoureusement **la même** qu'avant réduction. Ce qui est perdu, c'est seulement l'unité et l'échelle d'origine – l'information sur la **structure** des données, elle, est intégralement préservée.

Correction — Exercice 3

(a) Le montant (variant de quelques centaines à plusieurs dizaines de milliers de dh) aura une variance considérablement plus grande que la note (1 à 5) – typiquement de plusieurs **ordres de grandeur** (la variance se comptant, ici, potentiellement en millions pour le montant, contre à peine plus d'un point pour la note).

(b) Sans réduction préalable, le montant **écraserait** totalement l'influence de la note dans tout calcul combiné (somme, distance) : les écarts sur le montant, mesurés en milliers, domineraient numériquement des écarts sur la note qui ne dépassent jamais quelques unités – la note deviendrait, de fait, presque invisible dans le résultat final, quelle que soit son importance réelle pour l'analyse.

(c) Une conclusion statistique porte sur la **structure** des données (qui ressemble à qui, quelles variables sont liées), pas sur l'unité arbitraire dans laquelle on choisit de les exprimer : que l'on compte le

montant en dh ou en k dh ne change rien à la réalité économique décrite. La réduction **divise** chaque variable par son propre écart-type, qui varie exactement dans les mêmes proportions que l'unité choisie (diviser toutes les valeurs par 1 000 divise aussi l'écart-type par 1 000) : le rapport $\frac{x_i - \bar{x}}{s_x}$ reste donc rigoureusement **identique** quelle que soit l'unité de départ, ce qui garantit que le résultat final ne dépend jamais d'un choix d'unité arbitraire.


2 Exercices cumulatifs (introduction au chapitre 2)

Correction — Exercice 4

(a) $\bar{x} = \frac{8 + 10 + 12 + 14 + 16}{5} = 12$; $\bar{y} = \frac{4 + 12 + 8 + 16 + 20}{5} = 12$. $V(x) = \frac{16 + 4 + 0 + 4 + 16}{5} = \frac{40}{5} = 8$; $V(y) = \frac{64 + 0 + 16 + 16 + 64}{5} = \frac{160}{5} = 32$. $s_x = \sqrt{8} \approx 2,828$; $s_y = \sqrt{32} \approx 5,657$. On retrouve exactement les valeurs du cours.

(b) Écarts de y : $-8, 0, -4, 4, 8$. $z_y = \frac{y_i - 12}{5,657}$: $z_{y,1} = -1,414$, $z_{y,2} = 0,000$, $z_{y,3} = -0,707$, $z_{y,4} = 0,707$, $z_{y,5} = 1,414$. $\bar{z}_y = 0$; $V(z_y) = \frac{2 + 0 + 0,5 + 0,5 + 2}{5} = \frac{5}{5} = 1$. Les deux propriétés sont bien vérifiées.

(c) **Non** : centrer et réduire l'accueil et la fidélité laisse le nombre de variables strictement **inchangé** – on a toujours deux variables (z_x et z_y) après l'opération, exactement comme avant. Centrer-réduire résout le problème des **unités** (rendre les variables comparables entre elles, quelle que soit leur échelle d'origine) ; réduire la **dimension** (le sujet de l'introduction, avec le problème des $\binom{p}{2}$ nuages) consiste à remplacer un grand nombre de variables par un petit nombre d'axes qui en résument l'essentiel. Ce sont deux opérations **complémentaires mais distinctes** : le cours va combiner les deux à partir du chapitre 6, en centrant-réduisant **d'abord** toutes les variables (pour qu'aucune ne domine par son unité), puis en cherchant **ensuite** les axes qui réduisent leur nombre – jamais l'inverse, et jamais en confondant l'une avec l'autre.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\overline{\text{montant}} = \frac{120 + 340 + 80 + 560 + 210 + 150}{6} \approx 243,33$ k dh. $V(\text{montant}) \approx 26\,888,9$. $\overline{\text{note}} = \frac{14 + 9 + 17 + 6 + 12 + 15}{6} \approx 12,17$. $V(\text{note}) \approx 13,81$.

(b) $\frac{V(\text{montant})}{V(\text{note})} \approx \frac{26\,888,9}{13,81} \approx 1\,948$. **Oui**, ce rapport (près de 2 000) confirme très nettement la mise

en garde du cours : sans réduction, le montant écraserait presque totalement l'influence de la note dans n'importe quel calcul combiné.

(c) $s_{\text{montant}} = \sqrt{26\,888,9} \approx 163,98$. Les valeurs centrées réduites du montant sont : $-0,75; 0,59; -1,00; 1,93; -0,20; -0,57$ – toutes de l'ordre de grandeur de $[-2; 2]$, exactement comme on l'attend pour **n'importe quelle** variable centrée réduite (moyenne 0, variance 1, quasi-totalité des valeurs entre -2 et 2 pour un échantillon de cette taille) : c'est bien cette mise à niveau qui rendra montant et note comparables terme à terme.

Correction — Exercice 6

(a) $\overline{CA} = 3,0$ M dh, $V(CA) \approx 0,7033$. $\overline{\text{heures}} \approx 15,83$, $V(\text{heures}) \approx 22,81$. Rapport $\approx \frac{22,81}{0,70} \approx 32,4$ – très inférieur au rapport de près de 2 000 de l'exercice 5. La raison tient aux **ordres de grandeur** des valeurs brutes elles-mêmes : ici, le CA (autour de 1 à 4) et les heures (autour de 8 à 22) restent des nombres du même ordre de grandeur, alors qu'à l'exercice 5, le montant (centaines) et la note (unités) différaient de plusieurs ordres de grandeur.

(b) Ce score serait trompeur car il additionnerait des grandeurs **sans commune mesure** : une variation d'une unité de CA (par exemple, 1 M dh) n'a économiquement rien à voir avec une variation d'une heure de formation, et la variance des heures étant ici 32 fois plus grande, ce sont en pratique les heures de formation qui domineraient le score, même si le CA est, pour l'entreprise, le critère le plus important.

(c) $z_{CA} : -1,073; 0,477; -1,431; 1,431; -0,119; 0,715$. $z_{\text{heures}} : -0,803; 0,454; -1,640; 1,291; -0,175; 0,873$.

Un score global correct et équilibré consisterait à **additionner les deux variables centrées réduites** (éventuellement pondérées selon l'importance relative que la direction souhaite leur donner) : $\text{score}_i = z_{CA,i} + z_{\text{heures},i}$, qui donne, par exemple pour le commercial 4, $1,431 + 1,291 = 2,722$ – un score qui ne dépend plus de l'unité arbitraire de chacune des deux variables d'origine.