

Chapitre 2

Rappels sur une variable : centrer et réduire

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Moyenne et variance, écart par écart

Le chiffre d'affaires hebdomadaire (en k dh) de 5 magasins d'une même enseigne est : 42, 38, 50, 45, 55.

- (a) Calculer la moyenne $\bar{x}$.
- (b) Calculer les cinq écarts $x_i - \bar{x}$, vérifier que leur somme est nulle, puis calculer $V(x) = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ et $s_x = \sqrt{V(x)}$.
- (c) Cette vérification (« la somme des écarts vaut toujours zéro ») est rappelée par le cours comme un contrôle systématique. Pourquoi cette somme est-elle *nécessairement* nulle, quelles que soient les valeurs de x – à quoi cela tient-il dans la définition même de la moyenne ?

Exercice 2 — Centrer et réduire, et vérifier les deux propriétés

On reprend les données de l'exercice 1 : $\bar{x} = 46$, $s_x \approx 5,967$.

- (a) Calculer la variable centrée réduite $z_i = (x_i - \bar{x})/s_x$ pour les 5 magasins.
- (b) Vérifier que $\bar{z} = 0$ et $V(z) = 1$ sur vos cinq valeurs.
- (c) Le cours affirme que **toute** variable centrée réduite a une moyenne nulle et une variance de un, « quelles que soient ses valeurs de départ ». Un collègue objecte : « alors après réduction, toutes les variables se ressemblent, et on perd de l'information ». Que répondre à cette objection – qu'est-ce que la réduction change, et qu'est-ce qu'elle laisse, au contraire, intact ?

Exercice 3 — Pourquoi réduire est indispensable en présence d'unités différentes

Un fichier client comporte deux variables : le montant total des achats (en dh, variant de quelques centaines à plusieurs dizaines de milliers) et une note de satisfaction (de 1 à 5).

- (a) Sans faire aucun calcul, donner un ordre de grandeur : laquelle des deux variables aura, à votre avis, la variance la plus grande – et de combien d'ordres de grandeur environ ?
- (b) Si l'on combinait directement ces deux variables brutes (par exemple, en les additionnant, ou en calculant une distance entre deux clients à partir d'elles) sans les centrer-réduire au préalable, quel serait le résultat pratique sur l'influence respective des deux variables ?
- (c) Le cours affirme que « compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions » si l'on ne réduisait pas les variables. Expliquer pourquoi ce changement d'unité, purement conventionnel, ne devrait *jamaïs*, en toute rigueur, changer une conclusion statistique – et comment la réduction garantit cette invariance.

2 Exercices cumulatifs (introduction au chapitre 2)

Exercice 4 — Le fil rouge, vérifié à la main – et une distinction à ne pas manquer

On reprend le fil rouge du cours : cinq clients notés sur l'accueil (X) et la fidélité (Y) : (8,4), (10,12), (12,8), (14,16), (16,20).

- (a) Calculer $\bar{x}$, $\bar{y}$, $V(x)$, $V(y)$, s_x , s_y , et vérifier qu'on retrouve $\bar{x} = \bar{y} = 12$, $V(x) = 8$, $V(y) = 32$.
- (b) Le cours donne les valeurs centrées réduites de l'accueil (z_x). Calculer, de la même façon, les valeurs centrées réduites de la fidélité (z_y), et vérifier que $\bar{z}_y = 0$ et $V(z_y) = 1$.
- (c) L'introduction du cours pose le problème de la **dimension** (comment voir une structure quand il y a beaucoup de *variables*) ; ce chapitre résout le problème des **unités** (comment comparer des variables qui n'ont pas la même échelle). Sur ce fil rouge à seulement deux variables, centrer et réduire l'accueil et la fidélité a-t-il, en soi, réduit le *nombre* de variables à examiner ? Expliquer

pourquoi centrer-réduire et réduire la dimension sont deux opérations *différentes*, que le cours va combiner à partir du chapitre 6 sans jamais les confondre.

3 Applications en sciences économiques

Exercice 5 — Un dossier de crédit aux échelles incompatibles

Une banque étudie 6 dossiers de crédit décrits par le montant emprunté (en k dh) et une note de qualité de remboursement (de 0 à 20) :

Dossier	1	2	3	4	5	6
Montant (k dh)	120	340	80	560	210	150
Note (/20)	14	9	17	6	12	15

- Calculer la moyenne et la variance de chacune des deux variables.
- Calculer le rapport entre les deux variances. Ce rapport confirme-t-il la mise en garde du cours (« le montant écraserait tout ») ?
- Calculer la variable centrée réduite du montant, et vérifier que ses valeurs sont désormais du même ordre de grandeur que celles attendues pour une variable centrée réduite de la note (sans faire ce second calcul en entier, à quel intervalle de valeurs vous attendez-vous?).

Exercice 6 — Évaluer des commerciaux sur des critères incomparables

Une direction commerciale évalue 6 commerciaux sur leur chiffre d'affaires annuel (en millions de dh) et leur nombre d'heures de formation suivies dans l'année :

Commercial	1	2	3	4	5	6
CA (M dh)	2,1	3,4	1,8	4,2	2,9	3,6
Heures de formation	12	18	8	22	15	20

- Calculer la variance de chacune des deux variables. Le rapport des deux variances est-il aussi extrême que dans l'exercice 5 ? Pourquoi, à votre avis (comparer les ordres de grandeur des deux variables ici à ceux de l'exercice 5) ?
- Un consultant propose un « score global » de chaque commercial en additionnant simplement le CA et le nombre d'heures de formation, sans aucun retraitement préalable. Expliquer pourquoi ce score serait trompeur.
- Calculer les variables centrées réduites du CA et des heures de formation pour les 6 commerciaux, et proposer, à partir de ces deux séries, une définition correcte d'un « score global » comparable et équilibré entre les deux critères.