Introduction à l'analyse des données

Chapitre 2 : Rappels sur une variable : centrer et réduire

Jaouad Madkour

22 octobre 2026

Plan du chapitre

Le fil rouge du cours **2**
- Cinq clients, deux critères . . . 2
- Les deux séries, côte à côte . . . 2

La moyenne et la variance **3**
- Les deux résumés d'une variable . . . 3
- La variance . . . 3
- Le calcul, écart par écart . . . 3
- Deux vérifications à faire systématiquement . . . 4
- La formule développée . . . 4
- Diviser par n, ou par n moins un ? . . . 4

Centrer et réduire **5**
- L'opération qui commande tout le cours . . . 5
- La fidélité, réduite à son tour . . . 5
- Les deux propriétés de la variable réduite . . . 5
- La vérification, sur les cinq clients . . . 6

Pourquoi c'est indispensable ici **6**
- Le problème des unités . . . 6
- Qui pèse dans la variance totale . . . 7
- La réduction, en image . . . 7
- Ce que chaque opération accomplit . . . 7
- Comparer deux clients sur des échelles différentes . . . 8

Sur machine **8**
- Avec R . . . 8
- Avec Python . . . 9

S'entraîner **9**
- Exercice 1 : une série de cinq notes . . . 9
- Exercice 1 : solution . . . 9
- Exercice 2 : changer d'échelle . . . 9
- Exercice 2 : solution . . . 10

Exercice 3 : le client le plus atypique 10
Exercice 3 : solution 10

Ce qu'il faut retenir **10**
Le résumé du chapitre 10
La suite 10

Le fil rouge du cours

Cinq clients, deux critères

Le tableau qui portera tout le cours

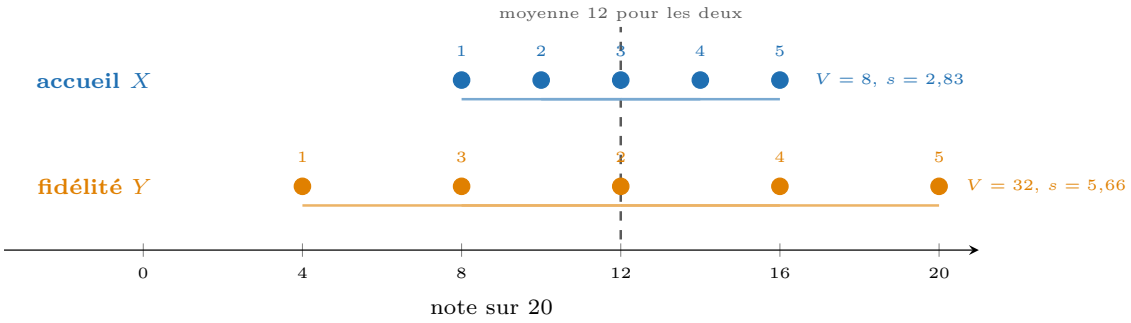
Cinq clients ont noté l'enseigne sur deux critères, de 0 à 20 :

Client	Accueil X	Fidélité Y
1	8	4
2	10	12
3	12	8
4	14	16
5	16	20

Pourquoi cinq lignes

Un fichier réel en compte des milliers. Cinq permettent de **tout vérifier à la main**, et c'est le seul moyen de comprendre ce que les logiciels calculent.
Ce tableau reviendra à chaque chapitre jusqu'à l'analyse en composantes principales.

Les deux séries, côte à côte



Ce que l'œil voit avant tout calcul

Les deux séries sont **centrées au même endroit**, la note 12. Mais les notes de fidélité s'étalent de 4 à 20, celles d'accueil seulement de 8 à 16. Il faut deux nombres pour le dire : la moyenne et la variance.

La moyenne et la variance

Les deux résumés d'une variable

La moyenne

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Sur nos données

$$\bar{x} = \frac{8+10+12+14+16}{5} = \frac{60}{5} = 12 \qquad \bar{y} = \frac{4+12+8+16+20}{5} = \frac{60}{5} = 12$$

Les deux variables ont la **même moyenne**. Elles ne se ressemblent pourtant pas du tout, et c'est la variance qui va le dire.

La variance

Moyenne des carrés des écarts

$$V(x) = \frac{1}{n}\sum_{i=1}^{n} (x_i - \bar{x})^2$$

C'est la **moyenne des carrés des écarts** à la moyenne. L'**écart-type** $s_x = \sqrt{V(x)}$ la ramène à l'unité de la variable.

Pourquoi des carrés

Les écarts à la moyenne se compensent : leur somme est toujours nulle. Les élever au carré les rend tous positifs, et donne **plus de poids aux grands écarts**. C'est ce choix qui fera, au chapitre 6, de la variance une distance au carré — donc une grandeur géométrique.

Le calcul, écart par écart

Les cinq écarts, et leurs carrés

Client	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
1	-4	16	-8	64
2	-2	4	0	0
3	0	0	-4	16
4	2	4	4	16
5	4	16	8	64
Somme	**0**	**40**	**0**	**160**

$$V(x) = \frac{40}{5} = 8 \qquad V(y) = \frac{160}{5} = 32 \qquad s_x = \sqrt{8} \approx 2{,}83 \qquad s_y = \sqrt{32} \approx 5{,}66$$

Deux vérifications à faire systématiquement

La somme des écarts

La somme des écarts vaut **toujours zéro** — c'est la définition même de la moyenne. Si elle ne tombe pas juste, le calcul est faux.

Même moyenne, dispersions très différentes

La fidélité est **quatre fois** plus dispersée que l'accueil (32 contre 8), et son écart-type deux fois plus grand (5,66 contre 2,83). Deux variables de même moyenne peuvent donc décrire des situations entièrement différentes.

La formule développée

Moyenne des carrés moins carré de la moyenne

$$V(x) = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \; - \; \bar{x}^{\,2}$$

On développe $(x_i - \bar{x})^2 = x_i^2 - 2\bar{x}x_i + \bar{x}^{\,2}$ et l'on moyenne : $\overline{x^2} - 2\bar{x}^{\,2} + \bar{x}^{\,2}$.

Sur nos données

Carrés de l'accueil : $64+100+144+196+256 = 760$; de la fidélité : $16+144+64+256+400 = 880$.

$$\overline{x^2} = 760/5 = 152 \qquad V(x) = 152 - 144 = 8$$
$$\overline{y^2} = 880/5 = 176 \qquad V(y) = 176 - 144 = 32$$

Le même résultat, sans calculer un seul écart.

Diviser par n, ou par n moins un ?

Deux conventions

Diviseur	Variance	Usage
n	**descriptive**	décrire le tableau
$n-1$	**corrigée**	estimer une population

Ce cours divise par n

L'analyse des données **décrit** : elle divise par n, comme le paquet `FactoMineR` de R. Sur nos cinq clients, $V(x) = 40/5 = 8$.
Mais la fonction `var` de R et la méthode `.var()` de `pandas` divisent par $n-1$: elles renvoient $40/4 = 10$. **Un écart de 25 % sur cinq lignes**, de 0,3 % sur trois cents. Il faut le savoir pour ne pas croire à une erreur.

Centrer et réduire

L'opération qui commande tout le cours

La variable centrée réduite

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

Centrer, c'est retrancher la moyenne. **Réduire**, c'est diviser par l'écart-type.

Sur l'accueil

Client	x_i	$x_i - 12$	$z_i = (x_i - 12)/2{,}83$
1	8	-4	$-1{,}414$
2	10	-2	$-0{,}707$
3	12	0	0
4	14	2	0,707
5	16	4	1,414

La fidélité, réduite à son tour

Les cinq valeurs centrées réduites

Client	y_i	$y_i - 12$	$z_i = (y_i - 12)/5{,}66$
1	4	-8	$-1{,}414$
2	12	0	0
3	8	-4	$-0{,}707$
4	16	4	0,707
5	20	8	1,414

Lire une valeur réduite

z compte les écarts **en écarts-types**. Le client 1 est à 1,41 écart-type sous la moyenne pour l'accueil, et **aussi** pour la fidélité : sur l'échelle réduite, ses deux notes disent la même chose, alors que ses notes brutes (8 et 4) semblaient différentes.

Les deux propriétés de la variable réduite

Moyenne nulle, variance unité

$$\bar{z} = 0 \qquad V(z) = 1$$

Toute variable centrée réduite a une moyenne nulle et une variance de un, quelles que soient ses valeurs de départ.

La démonstration, en deux lignes

$\bar{z} = \frac{1}{s_x}(\bar{x} - \bar{x}) = 0$, puisque retrancher une constante retranche la même constante à la moyenne.

$V(z) = \frac{1}{s_x^2} V(x) = \frac{V(x)}{V(x)} = 1$, puisque diviser par s_x divise la variance par s_x^2.

La vérification, sur les cinq clients

Les carrés des valeurs réduites de l'accueil

$$\sum z_i^2 = 2 + 0{,}5 + 0 + 0{,}5 + 2 = 5 \qquad \Longrightarrow \qquad V(z) = \frac{5}{5} = 1$$

Les cinq valeurs réduites de la fidélité ont exactement les mêmes carrés, dans un autre ordre : leur variance vaut aussi 1.

Ce que la réduction a fait

Avant : deux variables de variances 8 et 32. Après : deux variables de variance 1. **Elles pèsent désormais autant l'une que l'autre**, et c'est la condition pour les traiter ensemble.

Pourquoi c'est indispensable ici

Le problème des unités

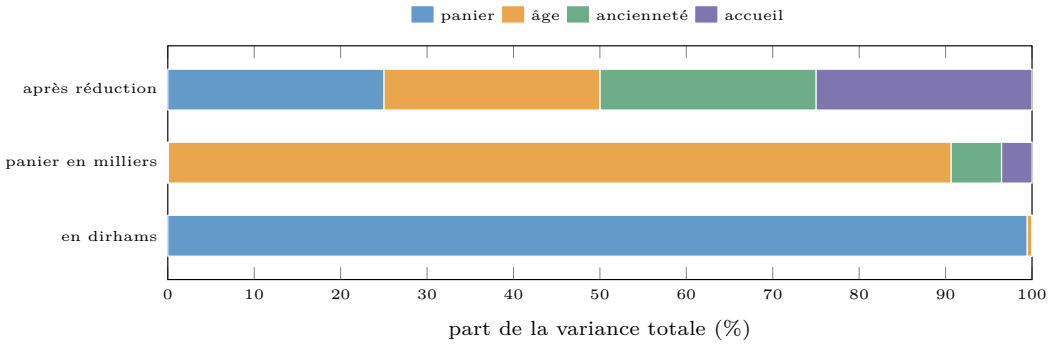
Un fichier client mêle des grandeurs sans commune mesure

Un montant en dirhams, une note de satisfaction sur 20, une ancienneté en années, un âge. La variance du montant se compte en dizaines de milliers ; celle de la note, en unités. Sans précaution, **le montant écraserait tout** : compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions. C'est inacceptable.

Sur le fichier réel

Variable	Unité	Variance
panier	dirham	27 655
âge	année	147,2
ancienneté	année	9,50
accueil	point sur 20	5,75

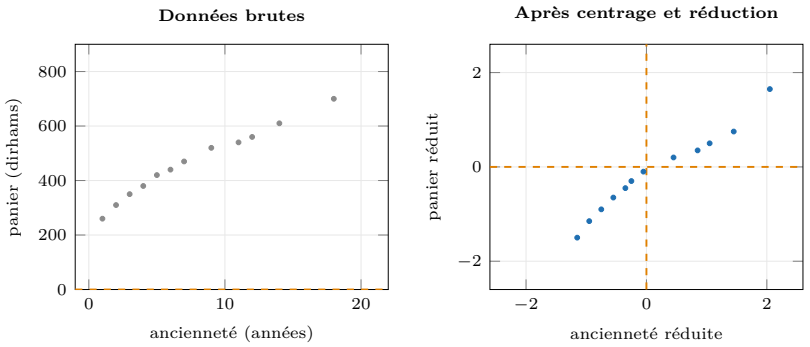
Qui pèse dans la variance totale



Un simple changement d'unité renverse tout

En dirhams, le panier porte **99,4 %** de la variance totale des quatre variables. Comptons-le en milliers de dirhams : sa variance est divisée par un million, et c'est l'âge qui porte 90,6 %. **Après réduction, chaque variable porte** 25 %, quelle que soit l'unité choisie.

La réduction, en image



Sans réduction, l'ACP mesurerait des dirhams contre des années.

Le panier varie de plusieurs centaines, l'ancienneté de quelques unités : le premier axe suivrait le panier et ne dirait rien d'autre que « le panier a une grande variance ».

Réduire, c'est donner à chaque variable le même poids — une inertie de 1 chacune. L'ACP porte alors sur la *matrice des corrélations*, et non sur celle des covariances.

Ce que chaque opération accomplit

Centrer, puis réduire

Centrer déplace l'origine au centre du nuage : ni les formes ni les distances ne changent, seulement le point depuis lequel on regarde. C'est ce qui permettra, au chapitre 5, de faire passer les axes par le centre.

Réduire donne à chaque variable **le même poids**. Après réduction, toutes ont une variance

de un : aucune ne peut dominer par son unité.

La conséquence, à retenir

Après centrage et réduction, une variable n'a plus d'unité. On peut donc **comparer et combiner** des grandeurs qui n'avaient rien à voir — un montant, une note, une durée. **C'est ce qui rend l'analyse multivariée possible.**

Comparer deux clients sur des échelles différentes

Trois valeurs extrêmes du fichier

Variable	Valeur	Moyenne	Écart-type	z
meilleur accueil	18,6	13,90	2,40	1,96
plus gros panier	1 027	407,3	166,3	3,73
plus âgé	67	40,18	12,13	2,21

Ce que z permet de dire

Un accueil noté 18,6 et un panier de 1 027 dirhams ne se comparent pas. Leurs valeurs réduites, si : le plus gros panier est **bien plus exceptionnel** (3,7 écarts-types) que la meilleure note d'accueil (2 écarts-types).

Sur machine

Avec R

Le code et sa sortie

```
x <- c(8, 10, 12, 14, 16)
mean(x)                      # [1] 12
var(x)                       # [1] 10      divise par n - 1
mean((x - mean(x))^2)        # [1] 8       divise par n
z <- (x - mean(x)) / sqrt(mean((x - mean(x))^2))
round(z, 3)           # [1] -1.414 -0.707  0.000  0.707  1.414
round(scale(x)[, 1], 3)
                      # [1] -1.265 -0.632  0.000  0.632  1.265
```

Le piège de scale

`scale` réduit avec l'écart-type en $n - 1$: ses valeurs ne sont pas celles du cours. `FactoMineR` divise par n et retrouve exactement $-1{,}414$.

Avec Python

Le code et sa sortie

```
import numpy as np
import pandas as pd
x = np.array([8, 10, 12, 14, 16])
print(x.mean(), x.var(), x.var(ddof=1))   # 12.0 8.0 10.0
z = (x - x.mean()) / x.std()
print(z.round(3))     # [-1.414 -0.707  0.     0.707  1.414]
s = pd.Series(x)
print(s.var(), s.var(ddof=0))             # 10.0 8.0
```

Deux bibliothèques, deux conventions

`numpy` divise par n par défaut, `pandas` par $n-1$. L'argument `ddof` (*degrés de liberté retranchés*) choisit : `ddof=0` pour la convention du cours.

S'entraîner

Exercice 1 : une série de cinq notes

Moyenne, variance, valeurs réduites

Cinq clients ont noté la propreté : 11, 13, 15, 17, 19.

1. Calculer la moyenne et la variance (diviseur n), par les écarts puis par la formule développée.
2. Calculer les valeurs centrées réduites.
3. Vérifier que leur moyenne est nulle et leur variance égale à 1.

Exercice 1 : solution

Moyenne 15, variance 8

1. $\bar{x} = 75/5 = 15$. Écarts : $-4, -2, 0, 2, 4$; carrés : $16+4+0+4+16 = 40$, donc $V = 8$. Formule développée : $\overline{x^2} = (121+169+225+289+361)/5 = 233$, et $233 - 225 = 8$.
2. $s = \sqrt{8} \approx 2{,}83$: $z = -1{,}414$; $-0{,}707$; 0 ; $0{,}707$; $1{,}414$.
3. Somme nulle ; somme des carrés 5, donc $V(z) = 1$. **Ce sont les valeurs réduites de l'accueil** : décaler toutes les notes de 3 points ne change rien après centrage.

Exercice 2 : changer d'échelle

Des notes sur 100 au lieu de 20

On convertit les notes d'accueil des cinq clients en notes sur 100, en les multipliant par 5.

1. Que deviennent la moyenne, la variance et l'écart-type ?
2. Que deviennent les valeurs centrées réduites ?
3. Qu'en conclure pour une méthode qui travaille sur données réduites ?

Exercice 2 : solution

La variance est multipliée par 25, z ne bouge pas

1. Moyenne $5 \times 12 = 60$; variance $5^2 \times 8 = 200$; écart-type $5 \times 2{,}83 = 14{,}1$.
2. **Inchangées** : $z = (5x - 5\bar{x})/(5s_x) = (x - \bar{x})/s_x$. Le facteur 5 disparaît.
3. Une méthode sur données réduites ne dépend **pas des unités** : notes sur 20 ou sur 100, dirhams ou milliers de dirhams, le résultat est le même. C'est exactement ce qu'on attend d'elle.

Exercice 3 : le client le plus atypique

Comparer par les valeurs réduites

Un nouveau client a un panier de 750 dirhams, 60 ans et une note de prix de 6.
Moyennes et écarts-types : panier 407,3 et 166,3 ; âge 40,2 et 12,1 ; prix 11,4 et 2,4.

1. Calculer les trois valeurs réduites.
2. Sur quelle variable ce client est-il le plus atypique ?

Exercice 3 : solution

La note de prix est la plus exceptionnelle

1. Panier : $(750-407{,}3)/166{,}3 = 2{,}06$. Âge : $(60-40{,}2)/12{,}1 = 1{,}64$. Prix : $(6-11{,}4)/2{,}4 = -2{,}25$.
2. C'est la note de prix : 2,25 écarts-types **sous** la moyenne. Le signe dit le sens de l'écart, la valeur absolue sa rareté. En dirhams, l'écart du panier (343) paraissait énorme et celui du prix (5,4) minuscule : la réduction remet les choses à leur place.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Le fil rouge : **cinq clients**, accueil et fidélité, moyennes toutes deux égales à 12.
2. $V(x) = 8$ et $V(y) = 32$: même moyenne, dispersions très différentes ; $V = \overline{x^2} - \bar{x}^2$.
3. Le cours divise par n ; `var` de R et `pandas` divisent par $n - 1$.
4. La variable **centrée réduite** $z = (x - \bar{x})/s_x$ a une moyenne de 0 et une variance de 1.
5. Sans réduction, le panier en dirhams porte 99,4 % de la variance totale ; après, chaque variable en porte autant.
6. Réduire donne à chaque variable **le même poids** et supprime l'effet des unités.

La suite

De une variable à deux

Une variable est décrite. Il faut maintenant en relier **deux** — et le chapitre 3 montre que l'outil pour le faire n'est pas nouveau : c'est la variance, généralisée.

Ce qu'on y calculera

Le produit des écarts des cinq clients, client par client, et leur covariance : $72/5 = 14{,}4$.