# Introduction à l'analyse des données

Chapitre 2 : Rappels sur une variable : centrer et réduire

Jaouad Madkour

31 octobre 2026

## Plan du chapitre

**Le fil rouge du cours** **2**
Cinq clients, deux critères . . . 2
Les deux séries, côte à côte . . . 2

**La moyenne et la variance** **3**
Les deux résumés d'une variable . . . 3
La variance . . . 3
Le calcul, écart par écart . . . 3
Deux vérifications à faire systématiquement . . . 4
La formule développée . . . 4
Diviser par n, ou par n moins un ? . . . 5

**Centrer et réduire** **6**
L'opération qui commande tout le cours . . . 6
La fidélité, réduite à son tour . . . 7
Les deux propriétés de la variable réduite . . . 7
La vérification, sur les cinq clients . . . 7

**Pourquoi c'est indispensable ici** **8**
Le problème des unités . . . 8
Qui pèse dans la variance totale . . . 8
La réduction, en image . . . 9
Ce que chaque opération accomplit . . . 9
Comparer deux clients sur des échelles différentes . . . 10

**Sur machine** **10**
Avec R . . . 10
Avec Python . . . 10

**S'entraîner** **11**
Exercice 1 : une série de cinq notes . . . 11
Exercice 1 : solution . . . 11
Exercice 2 : changer d'échelle . . . 11
Exercice 2 : solution . . . 12

Exercice 3 : le client le plus atypique . . . . . 12
Exercice 3 : solution . . . . . 12

**Ce qu'il faut retenir** **12**
Le résumé du chapitre . . . . . 12
La suite . . . . . 12

# Le fil rouge du cours

## Cinq clients, deux critères

**Le tableau qui portera tout le cours**

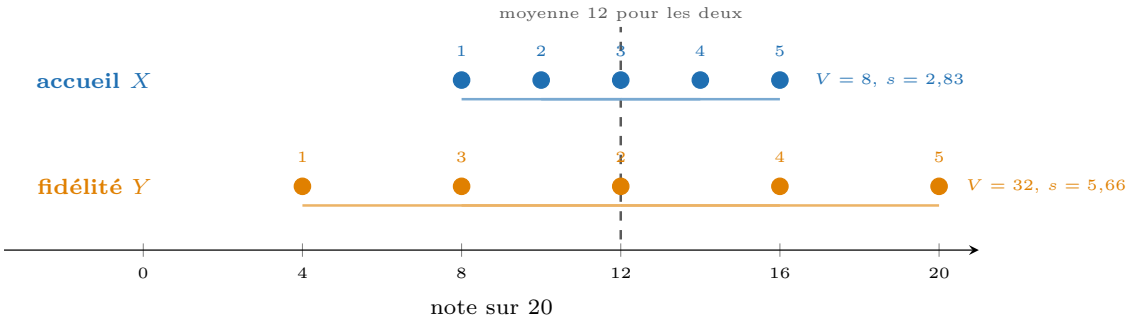
Cinq clients ont noté l'enseigne sur deux critères, de 0 à 20 :

| Client | Accueil $X$ | Fidélité $Y$ |
|---|---|---|
| 1 | 8 | 4 |
| 2 | 10 | 12 |
| 3 | 12 | 8 |
| 4 | 14 | 16 |
| 5 | 16 | 20 |

**Pourquoi cinq lignes**

Un fichier réel en compte des milliers. Cinq permettent de **tout vérifier à la main**, et c'est le seul moyen de comprendre ce que les logiciels calculent.
Ce tableau reviendra à chaque chapitre jusqu'à l'analyse en composantes principales.

## Les deux séries, côte à côte




**Ce que l'œil voit avant tout calcul**

Les deux séries sont **centrées au même endroit**, la note 12. Mais les notes de fidélité s'étalent de 4 à 20, celles d'accueil seulement de 8 à 16. Il faut deux nombres pour le dire : la moyenne et la variance.

# La moyenne et la variance

## Les deux résumés d'une variable

**La moyenne**

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

**Sur nos données**

$$\bar{x} = \frac{8+10+12+14+16}{5} = \frac{60}{5} = 12 \qquad \bar{y} = \frac{4+12+8+16+20}{5} = \frac{60}{5} = 12$$

Les deux variables ont la **même moyenne**. Elles ne se ressemblent pourtant pas du tout, et c'est la variance qui va le dire.

## La variance

**Moyenne des carrés des écarts**

$$V(x) = \frac{1}{n}\sum_{i=1}^{n} (x_i - \bar{x})^2$$

C'est la **moyenne des carrés des écarts** à la moyenne. L'**écart-type** $s_x = \sqrt{V(x)}$ la ramène à l'unité de la variable.

**Pourquoi des carrés**

Les écarts à la moyenne se compensent : leur somme est toujours nulle. Les élever au carré les rend tous positifs, et donne **plus de poids aux grands écarts**. C'est ce choix qui fera, au chapitre 6, de la variance une distance au carré — donc une grandeur géométrique.

## Le calcul, écart par écart

**Les cinq écarts, et leurs carrés**

| Client | $x_i - \bar{x}$ | $(x_i - \bar{x})^2$ | $y_i - \bar{y}$ | $(y_i - \bar{y})^2$ |
|---|---|---|---|---|
| 1 | $-4$ | 16 | $-8$ | 64 |
| 2 | $-2$ | 4 | 0 | 0 |
| 3 | 0 | 0 | $-4$ | 16 |
| 4 | 2 | 4 | 4 | 16 |
| 5 | 4 | 16 | 8 | 64 |
| **Somme** | **0** | **40** | **0** | **160** |

$$V(x) = \frac{40}{5} = 8 \qquad V(y) = \frac{160}{5} = 32 \qquad s_x = \sqrt{8} \approx 2{,}83 \qquad s_y = \sqrt{32} \approx 5{,}66$$

## Deux vérifications à faire systématiquement

**La somme des écarts**

La somme des écarts vaut **toujours zéro** — c'est la définition même de la moyenne. Si elle ne tombe pas juste, le calcul est faux.

**Démonstration : La somme des écarts est nulle, et la moyenne minimise la somme des carrés**

*La somme des écarts.* Par définition $\bar{x} = \frac{1}{n}\sum_i x_i$, donc

$$\sum_i (x_i - \bar{x}) = \sum_i x_i - n\,\bar{x} = n\,\bar{x} - n\,\bar{x} = 0.$$

*La moyenne est le point dont les valeurs s'écartent le moins.* Soit $c$ un réel quelconque. Écrivons $x_i - c = (x_i - \bar{x}) + (\bar{x} - c)$ et élevons au carré :

$$\sum_i (x_i - c)^2 = \sum_i (x_i - \bar{x})^2 + 2\,(\bar{x} - c)\underbrace{\sum_i (x_i - \bar{x})}_{=\,0} + n\,(\bar{x} - c)^2.$$

En divisant par $n$ :

$$\frac{1}{n}\sum_i (x_i - c)^2 = V(x) + (\bar{x} - c)^2 \;\geq\; V(x),$$

avec égalité si et seulement si $c = \bar{x}$. La variance est donc la plus petite des moyennes de carrés d'écarts, celle que l'on obtient en mesurant les écarts **à la moyenne**.

*Sur l'accueil des cinq clients,* avec $c = 10$ : $(8-10)^2 + 0 + 2^2 + 4^2 + 6^2 = 60 = 40 + 5 \times (12-10)^2$. Le chapitre 6 refera ce calcul pour un nuage de points en dimension $p$ (théorème de Huygens).

■

**Même moyenne, dispersions très différentes**

La fidélité est **quatre fois** plus dispersée que l'accueil (32 contre 8), et son écart-type deux fois plus grand (5,66 contre 2,83). Deux variables de même moyenne peuvent donc décrire des situations entièrement différentes.

## La formule développée

**Moyenne des carrés moins carré de la moyenne**

$$V(x) = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \;-\; \bar{x}^{\,2}$$

On développe $(x_i - \bar{x})^2 = x_i^2 - 2\bar{x}x_i + \bar{x}^{\,2}$ et l'on moyenne : $\overline{x^2} - 2\bar{x}^{\,2} + \bar{x}^{\,2}$.

**Démonstration : La variance, moyenne des carrés moins carré de la moyenne**

Développons le carré, puis sommons terme à terme :

$$\sum_i (x_i - \bar{x})^2 = \sum_i x_i^2 - 2\,\bar{x} \sum_i x_i + n\,\bar{x}^2.$$

Comme $\sum_i x_i = n\,\bar{x}$, le terme du milieu vaut $-2n\,\bar{x}^2$ et il reste

$$\sum_i (x_i - \bar{x})^2 = \sum_i x_i^2 - n\,\bar{x}^2.$$

Diviser par $n$ donne la formule : $V(x) = \overline{x^2} - \bar{x}^2$.

*Deux conséquences.* Une variance est une somme de carrés divisée par $n$ : elle est positive ou nulle, donc la moyenne des carrés est toujours au moins égale au carré de la moyenne. Et $V(x) = 0$ exige que **chaque** écart soit nul (une somme de carrés ne s'annule que si tous ses termes s'annulent) : une variance nulle signifie que tous les individus ont la même valeur. Ce second point servira au chapitre 4, pour les corrélations $\pm 1$.

*Sur l'accueil,* $760/5 - 12^2 = 152 - 144 = 8$.

■

**Sur nos données**

Carrés de l'accueil : $64+100+144+196+256 = 760$ ; de la fidélité : $16+144+64+256+400 = 880$.

$$\overline{x^2} = 760/5 = 152 \qquad V(x) = 152 - 144 = 8$$
$$\overline{y^2} = 880/5 = 176 \qquad V(y) = 176 - 144 = 32$$

Le même résultat, sans calculer un seul écart.

## Diviser par n, ou par n moins un ?

**Deux conventions**

| Diviseur | Variance | Usage |
|---|---|---|
| $n$ | **descriptive** | décrire le tableau |
| $n-1$ | **corrigée** | estimer une population |

**Ce cours divise par n**

L'analyse des données **décrit** : elle divise par $n$, comme le paquet `FactoMineR` de R. Sur nos cinq clients, $V(x) = 40/5 = 8$.
Mais la fonction `var` de R et la méthode `.var()` de `pandas` divisent par $n-1$ : elles renvoient $40/4 = 10$. **Un écart de 25 % sur cinq lignes**, de 0,3 % sur trois cents. Il faut le savoir pour ne pas croire à une erreur.

**Démonstration : Les deux diviseurs sont dans un rapport constant**

Notons $S = \sum_i (x_i - \bar{x})^2$. Les deux variances sont $V_n = S/n$ et $V_{n-1} = S/(n-1)$, donc

$$V_{n-1} = \frac{n}{n-1}\, V_n \qquad \text{et} \qquad s_{n-1} = \sqrt{\frac{n}{n-1}}\, s_n.$$

Le rapport ne dépend que de $n$ : $5/4 \quad = \quad 1{,}25$ pour les cinq clients (10 contre 8, un écart de 25 %) et $300/299 \approx 1{,}0033$ pour le fichier réel (un écart de 0,3 %).

*Pour les valeurs réduites,* la fonction `scale` de R divise par $s_{n-1}$ au lieu de $s_n$ : elle renvoie

$$\frac{x_i - \bar{x}}{s_{n-1}} = \sqrt{\frac{n-1}{n}}\, z_i,$$

des valeurs un peu plus petites que celles du cours ($\sqrt{4/5} \quad = \quad 0{,}894$ pour cinq clients, 0,998 pour trois cents). Pour retrouver les $z_i$ du cours, on les multiplie par $\sqrt{n/(n-1)}$.

*La corrélation ne change pas :* la covariance et le produit $s_x\, s_y$ sont multipliés par le même facteur $\frac{n}{n-1}$, qui se simplifie dans le quotient.

■

# Centrer et réduire

## L'opération qui commande tout le cours

**La variable centrée réduite**

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

**Centrer**, c'est retrancher la moyenne. **Réduire**, c'est diviser par l'écart-type.

**Sur l'accueil**

| Client | $x_i$ | $x_i - 12$ | $z_i = (x_i - 12)/2{,}83$ |
|---|---|---|---|
| 1 | 8 | −4 | −1,414 |
| 2 | 10 | −2 | −0,707 |
| 3 | 12 | 0 | 0 |
| 4 | 14 | 2 | 0,707 |
| 5 | 16 | 4 | 1,414 |

## La fidélité, réduite à son tour

**Les cinq valeurs centrées réduites**

| Client | $y_i$ | $y_i - 12$ | $z_i = (y_i - 12)/5{,}66$ |
|---|---|---|---|
| 1 | 4 | $-8$ | $-1{,}414$ |
| 2 | 12 | 0 | 0 |
| 3 | 8 | $-4$ | $-0{,}707$ |
| 4 | 16 | 4 | 0,707 |
| 5 | 20 | 8 | 1,414 |

**Lire une valeur réduite**

$z$ compte les écarts **en écarts-types**. Le client 1 est à 1,41 écart-type sous la moyenne pour l'accueil, et **aussi** pour la fidélité : sur l'échelle réduite, ses deux notes disent la même chose, alors que ses notes brutes (8 et 4) semblaient différentes.

## Les deux propriétés de la variable réduite

**Moyenne nulle, variance unité**

$$\bar{z} = 0 \qquad V(z) = 1$$

**Toute** variable centrée réduite a une moyenne nulle et une variance de un, quelles que soient ses valeurs de départ.

**La démonstration, en deux lignes**

$\bar{z} = \dfrac{1}{s_x}(\bar{x} - \bar{x}) = 0$, puisque retrancher une constante retranche la même constante à la moyenne.

$V(z) = \dfrac{1}{s_x^2} V(x) = \dfrac{V(x)}{V(x)} = 1$, puisque diviser par $s_x$ divise la variance par $s_x^2$.

## La vérification, sur les cinq clients

**Les carrés des valeurs réduites de l'accueil**

$$\sum z_i^2 = 2 + 0{,}5 + 0 + 0{,}5 + 2 = 5 \qquad \Longrightarrow \qquad V(z) = \frac{5}{5} = 1$$

Les cinq valeurs réduites de la fidélité ont exactement les mêmes carrés, dans un autre ordre : leur variance vaut aussi 1.

**Ce que la réduction a fait**

Avant : deux variables de variances 8 et 32. Après : deux variables de variance 1. **Elles pèsent désormais autant l'une que l'autre**, et c'est la condition pour les traiter ensemble.

## Pourquoi c'est indispensable ici

### Le problème des unités

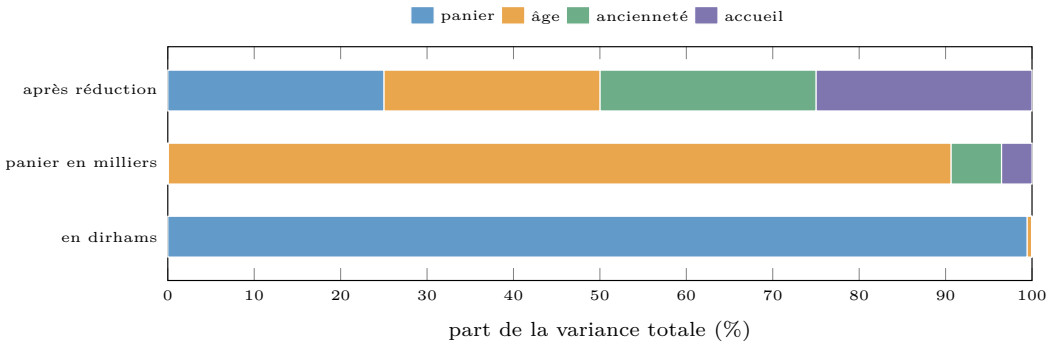
**Un fichier client mêle des grandeurs sans commune mesure**

Un montant en dirhams, une note de satisfaction sur 20, une ancienneté en années, un âge. La variance du montant se compte en dizaines de milliers ; celle de la note, en unités. Sans précaution, **le montant écraserait tout** : compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions. C'est inacceptable.

**Sur le fichier réel**

| Variable | Unité | Variance |
|---|---|---|
| panier | dirham | 27 655 |
| âge | année | 147,2 |
| ancienneté | année | 9,50 |
| accueil | point sur 20 | 5,75 |

### Qui pèse dans la variance totale




**Un simple changement d'unité renverse tout**

En dirhams, le panier porte **99,4 %** de la variance totale des quatre variables. Comptons-le en milliers de dirhams : sa variance est divisée par un million, et c'est l'âge qui porte 90,6 %. **Après réduction, chaque variable porte** 25 %, quelle que soit l'unité choisie.

**Démonstration : Changer d'unité ou d'origine**

Remplaçons chaque valeur $x_i$ par $x'_i = a\,x_i + b$ : multiplier par $a$ change l'unité, ajouter $b$ change l'origine.

- *Moyenne.* $\bar{x}' = \frac{1}{n}\sum_i (a\,x_i + b) = a\,\bar{x} + b$.
- *Écarts.* $x'_i - \bar{x}' = a\,x_i + b - a\,\bar{x} - b = a\,(x_i - \bar{x})$ : l'origine $b$ disparaît, l'unité $a$ reste.
- *Variance.* $V(x') = \frac{1}{n}\sum_i a^2\,(x_i - \bar{x})^2 = a^2\,V(x)$, et donc $s_{x'} = |a|\,s_x$.

Une variance se multiplie donc par le **carré** du facteur d'unité, et ne dépend pas de l'origine.

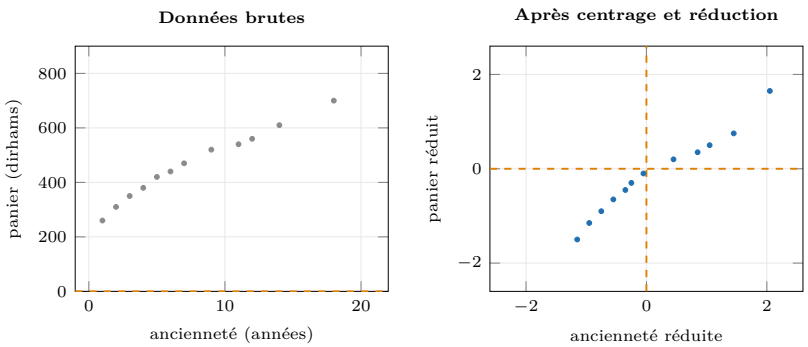
*Conséquences sur nos données.* (1) L'accueil noté sur 100 au lieu de 20 ($a = 5$) a une variance $25 \times 8 = 200$. (2) Le panier compté en milliers de dirhams ($a = 1/1000$) a une variance divisée par $10^6$ : de 27 655 à 0,028. Sa part dans la variance totale des quatre variables tombe de 99,4 % à 0,02 %, et celle de l'âge passe de 0,5 % à 90,6 %. (3) La variable réduite ne dépend pas de l'unité : pour $a > 0$,

$$\frac{x'_i - \bar{x}'}{s_{x'}} = \frac{a\,(x_i - \bar{x})}{a\,s_x} = z_i,$$

et l'on trouve $-z_i$ si $a < 0$.

■

## La réduction, en image




**Sans réduction, l'ACP mesurerait des dirhams contre des années.**

Le panier varie de plusieurs centaines, l'ancienneté de quelques unités : le premier axe suivrait le panier et ne dirait rien d'autre que « le panier a une grande variance ».

**Réduire, c'est donner à chaque variable le même poids** — une inertie de 1 chacune. L'ACP porte alors sur la *matrice des corrélations*, et non sur celle des covariances.

## Ce que chaque opération accomplit

### Centrer, puis réduire

**Centrer** déplace l'origine au centre du nuage : ni les formes ni les distances ne changent, seulement le point depuis lequel on regarde. C'est ce qui permettra, au chapitre 5, de faire passer les axes par le centre.

**Réduire** donne à chaque variable **le même poids**. Après réduction, toutes ont une variance de un : aucune ne peut dominer par son unité.

### La conséquence, à retenir

Après centrage et réduction, une variable n'a plus d'unité. On peut donc **comparer et combiner** des grandeurs qui n'avaient rien à voir — un montant, une note, une durée.

**C'est ce qui rend l'analyse multivariée possible.**

### Comparer deux clients sur des échelles différentes

**Trois valeurs extrêmes du fichier**

| Variable | Valeur | Moyenne | Écart-type | $z$ |
|---|---|---|---|---|
| meilleur accueil | 18,6 | 13,90 | 2,40 | 1,96 |
| plus gros panier | 1 027 | 407,3 | 166,3 | 3,73 |
| plus âgé | 67 | 40,18 | 12,13 | 2,21 |

**Ce que z permet de dire**

Un accueil noté 18,6 et un panier de 1 027 dirhams ne se comparent pas. Leurs valeurs réduites, si : le plus gros panier est **bien plus exceptionnel** (3,7 écarts-types) que la meilleure note d'accueil (2 écarts-types).

## Sur machine

### Avec R

**Le code et sa sortie**

```
x <- c(8, 10, 12, 14, 16)
mean(x)                     # [1] 12
var(x)                      # [1] 10      divise par n - 1
mean((x - mean(x))^2)       # [1] 8       divise par n
z <- (x - mean(x)) / sqrt(mean((x - mean(x))^2))
round(z, 3)           # [1] -1.414 -0.707  0.000  0.707  1.414
round(scale(x)[, 1], 3)
                      # [1] -1.265 -0.632  0.000  0.632  1.265
```

**Le piège de scale**

`scale` réduit avec l'écart-type en $n - 1$ : ses valeurs ne sont pas celles du cours. `FactoMineR` divise par $n$ et retrouve exactement −1,414.

### Avec Python

**Le code et sa sortie**

```
import numpy as np
import pandas as pd
x = np.array([8, 10, 12, 14, 16])
print(x.mean(), x.var(), x.var(ddof=1))   # 12.0 8.0 10.0
z = (x - x.mean()) / x.std()
print(z.round(3))     # [-1.414 -0.707  0.     0.707  1.414]
s = pd.Series(x)
print(s.var(), s.var(ddof=0))             # 10.0 8.0
```

**Deux bibliothèques, deux conventions**

`numpy` divise par $n$ par défaut, `pandas` par $n-1$. L'argument `ddof` (*degrés de liberté retranchés*) choisit : `ddof=0` pour la convention du cours.

## S'entraîner

### Exercice 1 : une série de cinq notes

**Moyenne, variance, valeurs réduites**

Cinq clients ont noté la propreté : 11, 13, 15, 17, 19.

1. Calculer la moyenne et la variance (diviseur $n$), par les écarts puis par la formule développée.
2. Calculer les valeurs centrées réduites.
3. Vérifier que leur moyenne est nulle et leur variance égale à 1.

### Exercice 1 : solution

**Moyenne 15, variance 8**

1. $\bar{x} = 75/5 = 15$. Écarts : $-4, -2, 0, 2, 4$ ; carrés : $16+4+0+4+16 = 40$, donc $V = 8$. Formule développée : $\overline{x^2} = (121+169+225+289+361)/5 = 233$, et $233 - 225 = 8$.
2. $s = \sqrt{8} \approx 2{,}83$ : $z = -1{,}414$ ; $-0{,}707$ ; $0$ ; $0{,}707$ ; $1{,}414$.
3. Somme nulle ; somme des carrés 5, donc $V(z) = 1$. **Ce sont les valeurs réduites de l'accueil** : décaler toutes les notes de 3 points ne change rien après centrage.

### Exercice 2 : changer d'échelle

**Des notes sur 100 au lieu de 20**

On convertit les notes d'accueil des cinq clients en notes sur 100, en les multipliant par 5.

1. Que deviennent la moyenne, la variance et l'écart-type ?
2. Que deviennent les valeurs centrées réduites ?
3. Qu'en conclure pour une méthode qui travaille sur données réduites ?

### Exercice 2 : solution

**La variance est multipliée par 25, z ne bouge pas**

1. Moyenne $5 \times 12 = 60$ ; variance $5^2 \times 8 = 200$ ; écart-type $5 \times 2{,}83 = 14{,}1$.
2. **Inchangées** : $z = (5x - 5\bar{x})/(5s_x) = (x - \bar{x})/s_x$. Le facteur 5 disparaît.
3. Une méthode sur données réduites ne dépend **pas des unités** : notes sur 20 ou sur 100, dirhams ou milliers de dirhams, le résultat est le même. C'est exactement ce qu'on attend d'elle.

### Exercice 3 : le client le plus atypique

**Comparer par les valeurs réduites**

Un nouveau client a un panier de 750 dirhams, 60 ans et une note de prix de 6.
Moyennes et écarts-types : panier 407,3 et 166,3 ; âge 40,2 et 12,1 ; prix 11,4 et 2,4.

1. Calculer les trois valeurs réduites.
2. Sur quelle variable ce client est-il le plus atypique ?

### Exercice 3 : solution

**La note de prix est la plus exceptionnelle**

1. Panier : $(750-407{,}3)/166{,}3 = 2{,}06$. Âge : $(60-40{,}2)/12{,}1 = 1{,}64$. Prix : $(6-11{,}4)/2{,}4 = -2{,}25$.
2. C'est la note de prix : 2,25 écarts-types **sous** la moyenne. Le signe dit le sens de l'écart, la valeur absolue sa rareté. En dirhams, l'écart du panier (343) paraissait énorme et celui du prix (5,4) minuscule : la réduction remet les choses à leur place.

## Ce qu'il faut retenir

### Le résumé du chapitre

**Six points**

1. Le fil rouge : **cinq clients**, accueil et fidélité, moyennes toutes deux égales à 12.
2. $V(x) = 8$ et $V(y) = 32$ : même moyenne, dispersions très différentes ; $V = \overline{x^2} - \bar{x}^2$.
3. Le cours divise par $n$ ; `var` de R et `pandas` divisent par $n - 1$.
4. La variable **centrée réduite** $z = (x - \bar{x})/s_x$ a une moyenne de 0 et une variance de 1.
5. Sans réduction, le panier en dirhams porte 99,4 % de la variance totale ; après, chaque variable en porte autant.
6. Réduire donne à chaque variable **le même poids** et supprime l'effet des unités.

### La suite

**De une variable à deux**

Une variable est décrite. Il faut maintenant en relier **deux** — et le chapitre 3 montre que l'outil pour le faire n'est pas nouveau : c'est la variance, généralisée.

**Ce qu'on y calculera**

Le produit des écarts des cinq clients, client par client, et leur covariance : $72/5 = 14{,}4$.