

Introduction à l'analyse des données

Chapitre 2 : Rappels sur une variable : centrer et réduire

Jaouad Madkour

24 septembre 2026

Plan du chapitre

Le fil rouge du cours	1
Cinq clients, deux critères	1
La moyenne et la variance	2
Les deux résumés d'une variable	2
La variance	2
Le calcul, écart par écart	2
Centrer et réduire	3
L'opération qui commande tout le cours	3
Les deux propriétés de la variable réduite	3
Pourquoi c'est indispensable ici	4
Ce qu'il faut retenir	5
Le résumé du chapitre	5

Le fil rouge du cours

Cinq clients, deux critères

Le tableau qui portera tout le cours

Cinq clients ont noté l'enseigne sur deux critères, de 0 à 20 :

Client	Accueil X	Fidélité Y
1	8	4
2	10	12
3	12	8
4	14	16
5	16	20

Pourquoi cinq lignes

Un fichier réel en compte des milliers. Cinq permettent de **tout vérifier à la main**, et c'est le seul moyen de comprendre ce que les logiciels calculent.

Ce tableau reviendra à chaque chapitre jusqu'à l'analyse en composantes principales.

La moyenne et la variance

Les deux résumés d'une variable

La moyenne

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Sur nos données

$$\bar{x} = \frac{8 + 10 + 12 + 14 + 16}{5} = \frac{60}{5} = 12 \qquad \bar{y} = \frac{4 + 12 + 8 + 16 + 20}{5} = \frac{60}{5} = 12$$

Les deux variables ont la **même moyenne**. Elles ne se ressemblent pourtant pas du tout, et c'est la variance qui va le dire.

La variance

Définition

$$V(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

C'est la **moyenne des carrés des écarts** à la moyenne. L'**écart-type** $s_x = \sqrt{V(x)}$ la ramène à l'unité de la variable.

Le calcul, écart par écart

Les cinq écarts, et leurs carrés

Client	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
1	-4	16	-8	64
2	-2	4	0	0
3	0	0	-4	16
4	2	4	4	16
5	4	16	8	64
Somme	0	40	0	160

$$V(x) = \frac{40}{5} = 8 \quad V(y) = \frac{160}{5} = 32$$

$$s_x = \sqrt{8} \approx 2,83 \quad s_y = \sqrt{32} \approx 5,66$$

Deux vérifications à faire systématiquement

La somme des écarts vaut **toujours zéro** — c'est la définition même de la moyenne. Si elle ne tombe pas juste, le calcul est faux.

Et la fidélité est **quatre fois** plus dispersée que l'accueil (32 contre 8). Deux variables de même moyenne peuvent donc décrire des situations entièrement différentes.

Centrer et réduire

L'opération qui commande tout le cours

La variable centrée réduite

$$z_i = \frac{x_i - \bar{x}}{s_x}$$

Centrer, c'est retrancher la moyenne. **Réduire**, c'est diviser par l'écart-type.

Sur l'accueil

Client	x_i	$x_i - 12$	$z_i = \frac{x_i - 12}{2,83}$
1	8	-4	-1,414
2	10	-2	-0,707
3	12	0	0
4	14	2	0,707
5	16	4	1,414

Les deux propriétés de la variable réduite

Moyenne nulle, variance unité

$$\bar{z} = 0 \quad V(z) = 1$$


Toute variable centrée réduite a une moyenne nulle et une variance de un, quelles que soient ses valeurs de départ.

Pourquoi c'est indispensable ici

Le problème des unités

Un fichier client mêle des variables sans commune mesure : un montant en dirhams qui varie de 200 à 50 000, une note de satisfaction entre 1 et 5, une ancienneté en années.

La variance du montant se compte en millions ; celle de la note, en dixièmes. Sans précaution, **le montant écraserait tout** : compter en milliers de dirhams plutôt qu'en dirhams changerait les conclusions. C'est inacceptable.



Sans réduction, l'ACP mesurerait des dirhams contre des années.

Le panier varie de plusieurs centaines, l'ancienneté de quelques unités : le premier axe suivrait le panier et ne dirait rien d'autre que « le panier a une grande variance ».

Réduire, c'est donner à chaque variable le même poids — une inertie de 1 chacune. L'ACP porte alors sur la *matrice des corrélations*, et non sur celle des covariances.

Ce que chaque opération accomplit

Centrer déplace l'origine au centre du nuage : ni les formes ni les distances ne changent, seulement le point depuis lequel on regarde. C'est ce qui permettra, au chapitre 5, de faire passer les axes par le centre.

Réduire donne à chaque variable **le même poids**. Après réduction, toutes ont une variance de un : aucune ne peut dominer par son unité.

La conséquence, à retenir

Après centrage et réduction, une variable n'a plus d'unité. On peut donc **comparer et combiner** des grandeurs qui n'avaient rien à voir — un montant, une note, une durée. **C'est ce qui rend l'analyse multivariée possible**, et c'est pourquoi ce chapitre, en apparence le plus élémentaire, est le plus important des trois rappels.

Ce qu'il faut retenir

Le résumé du chapitre

Cinq points

1. Le fil rouge : **cinq clients**, accueil et fidélité, moyennes toutes deux égales à 12.
2. $V(x) = 8$ et $V(y) = 32$: même moyenne, dispersions très différentes.
3. La somme des écarts à la moyenne vaut **toujours zéro** — c'est un contrôle.
4. La variable **centrée réduite** $z = (x - \bar{x})/s_x$ a une moyenne de 0 et une variance de 1.
5. Réduire donne à chaque variable **le même poids** et supprime l'effet des unités.

La suite

Une variable est décrite. Il faut maintenant en relier **deux** — et le chapitre 3 montre que l'outil pour le faire n'est pas nouveau : c'est la variance, généralisée.