

Introduction à l'analyse des données

Chapitre 5 : Le tableau de données et le nuage

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'analyse des données

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le centre de gravité, à trois variables

Un jury évalue 5 produits sur trois critères notés sur 10 : qualité perçue (a), rapport prix (b), service associé (c).

Produit	1	2	3	4	5
a (qualité)	7	5	8	6	9
b (prix)	6	8	5	7	4
c (service)	8	6	9	7	8

- (a) Calculer les coordonnées du centre de gravité $G = (\bar{a}, \bar{b}, \bar{c})$ du nuage des 5 produits.
- (b) Dans quel espace ce nuage des 5 produits vit-il – de quelle dimension ?
- (c) Si l'on ajoutait un quatrième critère (par exemple, la durabilité), que deviendrait la dimension de cet espace ? Ce nuage resterait-il visible sur une simple feuille de papier ?

Exercice 2 — La distance, avant et après réduction

Une banque compare deux dossiers de crédit sur deux variables : le montant emprunté (en k dh) et une note de qualité de remboursement (sur 20). Dossier A : (120, 14). Dossier B : (340, 9). On rappelle (chapitre 2) que, sur l'ensemble des dossiers étudiés, $\overline{\text{montant}} \approx 243,33$, $s_{\text{montant}} \approx 163,98$, $\overline{\text{note}} \approx 12,17$, $s_{\text{note}} \approx 3,716$.

- (a) Calculer la distance euclidienne brute entre A et B, $d = \sqrt{(340 - 120)^2 + (9 - 14)^2}$.
- (b) Calculer les coordonnées centrées réduites z_A et z_B des deux dossiers, puis la distance $d(z_A, z_B) = \sqrt{\sum_j (z_{Aj} - z_{Bj})^2}$ sur données réduites.
- (c) La distance brute (question a) est-elle représentative d'une différence « globale » entre les deux dossiers, ou est-elle dominée par une seule des deux variables ? Justifier en comparant les contributions du montant et de la note à chacune des deux distances calculées.

Exercice 3 — Les deux nuages, deux questions différentes

Un tableau réunit $n = 200$ clients décrits par $p = 6$ variables.

- (a) Dans quel espace vit le nuage des **individus** de ce tableau – quelle est sa dimension ?
- (b) Dans quel espace vit le nuage des **variables** de ce tableau – quelle est sa dimension ?
- (c) Un client se plaint que deux visualisations produites par le même logiciel, à partir du même tableau, semblent « montrer des choses différentes ». Expliquer, à l'aide de la distinction du cours, pourquoi c'est parfaitement normal : quelle question pose chacun des deux nuages, et pourquoi elles n'ont pas à donner la même image ?

2 Exercices cumulatifs (introduction au chapitre 5)

Exercice 4 — Le nuage du fil rouge, en distances

On reprend le fil rouge : cinq clients, accueil x et fidélité y : (8,4), (10,12), (12,8), (14,16), (16,20), de centre de gravité $G = (12,12)$ (chapitre 5) et de variables centrées réduites $z_x = (-1,414, -0,707, 0, 0,707, 1,414)$, $z_y = (-1,414, 0, -0,707, 0,707, 1,414)$ (chapitre 2).

- (a) Calculer, sur données réduites, la distance entre le client 1 et le client 2, puis entre le client 1 et le client 4.
- (b) Le client 1 est-il plus proche du client 2 ou du client 4 ? Ce résultat est-il cohérent avec le tableau

brut des données (regarder les valeurs d'accueil et de fidélité des trois clients) ?

- (c) Le cours affirme, à propos du fil rouge, qu'« avec deux variables, on voit tout. Le problème de l'introduction ne se pose pas encore – il commencera à trois ». En reliant cette remarque à l'exercice 3 du chapitre 1 (le nombre de nuages de points croît en $p(p-1)/2$), expliquer pourquoi un nuage à deux variables ne pose aucun problème de représentation, alors qu'un nuage à $p \geq 3$ variables commence à en poser un – même si la formule de la distance, elle, reste rigoureusement la même quel que soit p .

3 Applications en sciences économiques

Exercice 5 — Comparer deux salariés sur des critères hétérogènes

Une direction commerciale compare deux commerciaux sur leur chiffre d'affaires annuel (en M dh) et leur nombre d'heures de formation. Commercial 1 : (2,1 ; 12). Commercial 4 : (4,2 ; 22). On rappelle (chapitre 2, exercice 6) $\overline{CA} = 3,0$, $s_{CA} \approx 0,839$, $\overline{\text{heures}} \approx 15,83$, $s_{\text{heures}} \approx 4,776$.

- (a) Calculer la distance brute entre les deux commerciaux.
- (b) Calculer leur distance sur données centrées réduites.
- (c) La direction souhaite classer les commerciaux par « profils proches » en se basant sur une distance calculée sur les données **brutes**. Pourquoi ce choix méthodologique risquerait-il de sous-représenter l'importance du critère « heures de formation » dans le classement obtenu ?

Exercice 6 — Anticiper le nuage des variables

On reprend la matrice des corrélations calculée à l'exercice 2 du chapitre 4, pour trois variables produit : prix (p_1), marge (p_2), part de marché (p_3) : $r_{p_1 p_2} \approx 0,999$, $r_{p_1 p_3} \approx -0,953$, $r_{p_2 p_3} \approx -0,957$.

- (a) Dans le nuage des **variables** (chaque variable devenant un point), à quoi ressemblerait, intuitivement, la position de p_1 (prix) par rapport à celle de p_2 (marge), sachant que leur corrélation est presque égale à 1 ?
- (b) À quoi ressemblerait, à l'inverse, la position de p_3 (part de marché) par rapport à p_1 et p_2 , sachant que ses corrélations avec elles sont proches de -1 ?
- (c) Le cours annonce que cette lecture du nuage des variables donnera, au chapitre 10, le « cercle des corrélations ». Sans connaître encore cet outil, formuler une hypothèse sur ce que pourrait signifier, visuellement, le fait que deux variables soient « proches » sur ce futur graphique, et ce que pourrait signifier le fait qu'elles soient « à l'opposé » l'une de l'autre.

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\bar{a} = \frac{7+5+8+6+9}{5} = 7$, $\bar{b} = \frac{6+8+5+7+4}{5} = 6$, $\bar{c} = \frac{8+6+9+7+8}{5} = 7,6$. $G = (7; 6; 7,6)$.
- (b) Ce nuage de 5 produits vit dans un espace à $\mathbb{R}^3$ (trois dimensions), une dimension par critère.
- (c) Avec un quatrième critère, l'espace deviendrait $\mathbb{R}^4$ (quatre dimensions). Ce nuage ne pourrait alors plus être représenté **directement** sur une feuille de papier, qui n'offre que deux dimensions – c'est précisément le problème posé dans l'introduction du cours, qui commence dès que $p \geq 3$.

Correction — Exercice 2

- (a) $d = \sqrt{(340 - 120)^2 + (9 - 14)^2} = \sqrt{220^2 + (-5)^2} = \sqrt{48\,400 + 25} = \sqrt{48\,425} \approx 220,06$.
- (b) $z_A = \left(\frac{120 - 243,33}{163,98}, \frac{14 - 12,17}{3,716} \right) \approx (-0,752; 0,493)$. $z_B = \left(\frac{340 - 243,33}{163,98}, \frac{9 - 12,17}{3,716} \right) \approx (0,590; -0,852)$. $d(z_A, z_B) = \sqrt{(0,590 - (-0,752))^2 + (-0,852 - 0,493)^2} = \sqrt{1,342^2 + (-1,346)^2} \approx \sqrt{1,801 + 1,812} \approx 1,900$.
- (c) Dans la distance **brute**, l'écart sur le montant (220) est plus de 40 fois plus grand que l'écart sur la note (5) : le carré de 220 (48 400) écrase totalement le carré de 5 (25) dans la somme – la distance brute est donc, en pratique, entièrement dominée par le montant, et ne dit presque rien de la différence de qualité de remboursement entre A et B. Sur données **réduites**, les deux contributions ($1,342^2 \approx 1,80$ et $1,346^2 \approx 1,81$) sont, au contraire, du même ordre de grandeur : la réduction restituée à la note un poids comparable à celui du montant dans le jugement de « proximité » entre les deux dossiers.

Correction — Exercice 3


- (a) Le nuage des individus vit dans $\mathbb{R}^6$ (autant de dimensions que de variables, $p = 6$) ; il comporte 200 points (un par client).
- (b) Le nuage des variables vit dans $\mathbb{R}^{200}$ (autant de dimensions que d'individus, $n = 200$) ; il comporte 6 points (un par variable).
- (c) C'est parfaitement normal, car les deux nuages répondent à des questions **différentes** : le nuage des individus (dans $\mathbb{R}^6$) répond à « quels clients se ressemblent ? », tandis que le nuage des variables (dans $\mathbb{R}^{200}$) répond à « quels critères vont ensemble ? ». Ce sont deux lectures complémentaires – la **dualité** du cours – du même tableau de données, chacune projetée et affichée séparément par le logiciel ; il n'y a aucune raison qu'elles se ressemblent visuellement, puisqu'elles ne vivent même pas dans le même espace de départ.

2 Exercices cumulatifs (introduction au chapitre 5)

Correction — Exercice 4

- (a) $d(1, 2) = \sqrt{(-0,707 - (-1,414))^2 + (0 - (-1,414))^2} = \sqrt{0,707^2 + 1,414^2} = \sqrt{0,500 + 1,999} \approx \sqrt{2,499} \approx 1,581$. $d(1, 4) = \sqrt{(0,707 - (-1,414))^2 + (0,707 - (-1,414))^2} = \sqrt{2,121^2 + 2,121^2} = \sqrt{4,499 + 4,499} \approx \sqrt{8,998} \approx 3,000$.
- (b) Le client 1 est nettement plus **proche** du client 2 ($d \approx 1,58$) que du client 4 ($d \approx 3,00$). C'est cohérent avec le tableau brut : le client 1 (8, 4) et le client 2 (10, 12) restent dans la même zone « basse » du nuage (accueil et fidélité tous deux inférieurs à la moyenne pour le client 1, accueil légèrement inférieur pour le client 2), alors que le client 4 (14, 16) se situe dans la zone « haute », nettement au-dessus de la moyenne sur les deux critères.
- (c) Avec deux variables, le nuage tient entièrement sur **un seul** graphique en deux dimensions – il n'y a donc, comme le rappelle l'exercice 1 du chapitre 1, qu'un seul nuage de points possible

$\binom{2}{2} = 1$), qu'on peut regarder directement sans perte d'information de représentation. Dès que $p \geq 3$, le nombre de nuages bivariés possibles dépasse 1 ($\binom{3}{2} = 3$, $\binom{4}{2} = 6$, etc.), et **aucun** d'entre eux, pris isolément, ne montre plus l'ensemble du nuage à p dimensions : c'est le moment où le problème de représentation posé par l'introduction commence réellement à se poser. La formule de la distance $d(i, i') = \sqrt{\sum_j (z_{ij} - z_{i'j})^2}$, elle, continue de s'appliquer sans changement quel que soit p – c'est seulement la possibilité de *voir* le nuage qui se perd, pas celle de le *calculer*.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $d = \sqrt{(4,2 - 2,1)^2 + (22 - 12)^2} = \sqrt{2,1^2 + 10^2} = \sqrt{4,41 + 100} = \sqrt{104,41} \approx 10,22$.

(b) $z_{1,CA} = \frac{2,1 - 3,0}{0,839} \approx -1,073$, $z_{1,h} = \frac{12 - 15,83}{4,776} \approx -0,802$. $z_{4,CA} = \frac{4,2 - 3,0}{0,839} \approx 1,431$, $z_{4,h} = \frac{22 - 15,83}{4,776} \approx 1,292$. $d(z_1, z_4) = \sqrt{(1,431 - (-1,073))^2 + (1,292 - (-0,802))^2} = \sqrt{2,504^2 + 2,094^2} \approx \sqrt{6,270 + 4,385} \approx 3,264$.

(c) Avec des données brutes, l'écart sur les heures de formation (10) est presque 5 fois plus grand, en valeur absolue, que l'écart sur le CA (2,1) ; son carré (100) domine donc très largement la distance (104,41 au total), au point que le CA – pourtant le critère commercial le plus déterminant pour la direction – pèserait à peine plus de 4 % dans le classement obtenu. Ne pas réduire reviendrait donc, de fait, à classer les commerciaux presque uniquement sur leur nombre d'heures de formation, sans que ce choix soit assumé explicitement.

Correction — Exercice 6

(a) Avec $r_{p_1 p_2} \approx 0,999$ (très proche de 1), p_1 et p_2 devraient apparaître comme deux points **quasiment confondus**, ou du moins situés dans la même direction depuis l'origine – l'angle entre leurs deux positions serait proche de 0° (précisément, $\arccos(0,999) \approx 2,6^\circ$).

(b) Avec $r_{p_1 p_3} \approx -0,953$ et $r_{p_2 p_3} \approx -0,957$ (proches de -1), p_3 devrait apparaître à l'**opposé** de p_1 et de p_2 par rapport à l'origine – un angle proche de 180° ($\arccos(-0,953) \approx 162^\circ$, $\arccos(-0,957) \approx 163^\circ$).

(c) On peut raisonnablement anticiper que deux variables « proches » sur ce futur graphique (petit angle entre elles) signaleront une forte corrélation **positive** – deux façons de mesurer, en partie, la même chose – tandis que deux variables « à l'opposé » (angle proche de 180°) signaleront une forte corrélation **négative**. Deux variables formant, à l'inverse, un angle proche de 90° signaleraient probablement une corrélation proche de 0, donc l'absence de liaison linéaire entre elles – ce que le chapitre 10 permettra de vérifier précisément.

