

Chapitre 5

Le tableau de données et le nuage

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Introduction à l'analyse de données

1 Exercices du chapitre

Exercice 1 — Le centre de gravité, à trois variables

Un jury évalue 5 produits sur trois critères notés sur 10 : qualité perçue (a), rapport prix (b), service associé (c).

Produit	1	2	3	4	5
a (qualité)	7	5	8	6	9
b (prix)	6	8	5	7	4
c (service)	8	6	9	7	8

- (a) Calculer les coordonnées du centre de gravité $G = (\bar{a}, \bar{b}, \bar{c})$ du nuage des 5 produits.
- (b) Dans quel espace ce nuage des 5 produits vit-il – de quelle dimension ?
- (c) Si l'on ajoutait un quatrième critère (par exemple, la durabilité), que deviendrait la dimension de cet espace ? Ce nuage resterait-il visible sur une simple feuille de papier ?

Exercice 2 — La distance, avant et après réduction

Une banque compare deux dossiers de crédit sur deux variables : le montant emprunté (en k dh) et une note de qualité de remboursement (sur 20). Dossier A : (120, 14). Dossier B : (340, 9). On rappelle (chapitre 2) que, sur l'ensemble des dossiers étudiés, $\overline{\text{montant}} \approx 243,33$, $s_{\text{montant}} \approx 163,98$, $\overline{\text{note}} \approx 12,17$, $s_{\text{note}} \approx 3,716$.

- (a) Calculer la distance euclidienne brute entre A et B, $d = \sqrt{(340 - 120)^2 + (9 - 14)^2}$.
- (b) Calculer les coordonnées centrées réduites z_A et z_B des deux dossiers, puis la distance $d(z_A, z_B) = \sqrt{\sum_j (z_{Aj} - z_{Bj})^2}$ sur données réduites.
- (c) La distance brute (question a) est-elle représentative d'une différence « globale » entre les deux dossiers, ou est-elle dominée par une seule des deux variables ? Justifier en comparant les contributions du montant et de la note à chacune des deux distances calculées.

Exercice 3 — Les deux nuages, deux questions différentes

Un tableau réunit $n = 200$ clients décrits par $p = 6$ variables.

- (a) Dans quel espace vit le nuage des **individus** de ce tableau – quelle est sa dimension ?
- (b) Dans quel espace vit le nuage des **variables** de ce tableau – quelle est sa dimension ?
- (c) Un client se plaint que deux visualisations produites par le même logiciel, à partir du même tableau, semblent « montrer des choses différentes ». Expliquer, à l'aide de la distinction du cours, pourquoi c'est parfaitement normal : quelle question pose chacun des deux nuages, et pourquoi elles n'ont pas à donner la même image ?

2 Exercices cumulatifs (introduction au chapitre 5)

Exercice 4 — Le nuage du fil rouge, en distances

On reprend le fil rouge : cinq clients, accueil x et fidélité y : (8, 4), (10, 12), (12, 8), (14, 16), (16, 20), de centre de gravité $G = (12, 12)$ (chapitre 5) et de variables centrées réduites $z_x = (-1,414, -0,707, 0, 0,707, 1,414)$, $z_y = (-1,414, 0, -0,707, 0,707, 1,414)$ (chapitre 2).

- (a) Calculer, sur données réduites, la distance entre le client 1 et le client 2, puis entre le client 1 et le client 4.
- (b) Le client 1 est-il plus proche du client 2 ou du client 4 ? Ce résultat est-il cohérent avec le tableau

brut des données (regarder les valeurs d'accueil et de fidélité des trois clients) ?

- (c) Le cours affirme, à propos du fil rouge, qu'« avec deux variables, on voit tout. Le problème de l'introduction ne se pose pas encore – il commencera à trois ». En reliant cette remarque à l'exercice 3 du chapitre 1 (le nombre de nuages de points croît en $p(p-1)/2$), expliquer pourquoi un nuage à deux variables ne pose aucun problème de représentation, alors qu'un nuage à $p \geq 3$ variables commence à en poser un – même si la formule de la distance, elle, reste rigoureusement la même quel que soit p .

3 Applications en sciences économiques

Exercice 5 — Comparer deux salariés sur des critères hétérogènes

Une direction commerciale compare deux commerciaux sur leur chiffre d'affaires annuel (en M dh) et leur nombre d'heures de formation. Commercial 1 : (2,1 ; 12). Commercial 4 : (4,2 ; 22). On rappelle (chapitre 2, exercice 6) $\overline{CA} = 3,0$, $s_{CA} \approx 0,839$, $\overline{\text{heures}} \approx 15,83$, $s_{\text{heures}} \approx 4,776$.

- (a) Calculer la distance brute entre les deux commerciaux.
- (b) Calculer leur distance sur données centrées réduites.
- (c) La direction souhaite classer les commerciaux par « profils proches » en se basant sur une distance calculée sur les données **brutes**. Pourquoi ce choix méthodologique risquerait-il de sous-représenter l'importance du critère « heures de formation » dans le classement obtenu ?

Exercice 6 — Anticiper le nuage des variables

On reprend la matrice des corrélations calculée à l'exercice 2 du chapitre 4, pour trois variables produit : prix (p_1), marge (p_2), part de marché (p_3) : $r_{p_1 p_2} \approx 0,999$, $r_{p_1 p_3} \approx -0,953$, $r_{p_2 p_3} \approx -0,957$.

- (a) Dans le nuage des **variables** (chaque variable devenant un point), à quoi ressemblerait, intuitivement, la position de p_1 (prix) par rapport à celle de p_2 (marge), sachant que leur corrélation est presque égale à 1 ?
- (b) À quoi ressemblerait, à l'inverse, la position de p_3 (part de marché) par rapport à p_1 et p_2 , sachant que ses corrélations avec elles sont proches de -1 ?
- (c) Le cours annonce que cette lecture du nuage des variables donnera, au chapitre 10, le « cercle des corrélations ». Sans connaître encore cet outil, formuler une hypothèse sur ce que pourrait signifier, visuellement, le fait que deux variables soient « proches » sur ce futur graphique, et ce que pourrait signifier le fait qu'elles soient « à l'opposé » l'une de l'autre.