Introduction à l'analyse des données

Chapitre 5 : Le tableau de données et le nuage

Jaouad Madkour

31 octobre 2026

Plan du chapitre

Le tableau **2**
- Sa forme . . . 2
- Nos deux tableaux . . . 2
- Ce qui doit être vérifié avant de commencer . . . 3
- Les contrôles, sur le fichier réel . . . 3

Les deux nuages **3**
- Un tableau, deux lectures . . . 3
- La dualité, en image . . . 4
- Deux regards sur le même objet . . . 4
- Le nuage du fil rouge . . . 4
- Ce que montre ce nuage . . . 5

Le centre de gravité **5**
- Le point moyen . . . 5
- Le centre du nuage réel . . . 5
- Ce que centrer signifie géométriquement . . . 6

Distances et ressemblances **6**
- La distance entre deux individus . . . 6
- Le calcul, sur deux paires de clients . . . 7
- Toutes les distances, brutes et réduites . . . 7
- Pourquoi la réduction est ici décisive . . . 7
- Deux clients de même moyenne, loin l'un de l'autre . . . 8

Le nuage des variables **8**
- Une variable est une flèche . . . 8
- Ce que ce nuage permet de dire . . . 9

Sur machine **9**
- Avec R . . . 9
- Avec Python . . . 9

S'entraîner **10**

Exercice 1 : un petit nuage 10
Exercice 1 : solution 10
Exercice 2 : le plus proche voisin 10
Exercice 2 : solution 10
Exercice 3 : lire des angles 11
Exercice 3 : solution 11

Ce qu'il faut retenir **11**
Le résumé du chapitre 11
La suite 11

Le tableau

Sa forme

	8 notes de satisfaction				signalétique	
client	prix	choix	···	accueil	CSP	fréquence
1	13,2	15,4	···	16,1	Cadre	Hebdo.
2	9,8	11,0	···	10,4	Employé	Rare
⋮	⋮	⋮		⋮	⋮	⋮
300	12,5	13,9	···	14,8	Retraité	Mensuelle

variables **actives** : elles construisent les axes — variables **illustratives** : on les projette ensuite

Le choix des variables actives est la seule décision vraiment engageante de toute l'analyse.
Elles fixent la géométrie du nuage — donc les axes, donc l'interprétation. Les illustratives n'y participent pas : on les superpose après coup pour *éclairer* les axes, jamais pour les construire.
Mettre le chiffre d'affaires en actif quand on étudie la satisfaction, c'est laisser la taille des clients écraser leur opinion.

Le tableau individus-variables

n lignes — les **individus** — et p colonnes — les **variables** : la case (i, j) porte la valeur de j pour i. C'est le format d'entrée de toute l'analyse des données.

Nos deux tableaux

Le fil rouge et le fichier réel

Tableau	n	p	Variables
les cinq clients	5	2	accueil, fidélité
clients.csv, notes	300	8	prix … accueil

Une case, deux lectures

La case (i, j) dit **qui** est l'individu i quand on lit sa ligne, et **ce que mesure** la variable j quand on lit sa colonne. Toute l'analyse alterne entre ces deux lectures.

Ce qui doit être vérifié avant de commencer

Quatre contrôles

Point	Question
Homogénéité	les lignes sont-elles comparables entre elles ?
Valeurs manquantes	combien, et pourquoi manquent-elles ?
Valeurs aberrantes	erreurs de saisie, ou individus atypiques ?
Doublons	le même client compte-t-il deux fois ?

Ce contrôle n'est pas une formalité

Un individu aberrant peut **capter à lui seul un axe entier** : c'est la sensibilité du chapitre 4, où un sixième client faisait passer la corrélation de 0,9 à 0,035, aggravée par le nombre de variables.

Les contrôles, sur le fichier réel

Les 300 clients

Contrôle	Résultat
valeurs manquantes	**aucune**, sur les 17 colonnes
doublons	**aucun** client répété
notes	toutes entre 5,4 et 20
panier	de 83 à 1 027 dirhams
ancienneté	de 0 à 21 ans

Ce qu'on en conclut

Aucune valeur impossible : les huit notes restent dans l'intervalle de 0 à 20. Le panier de 1 027 dirhams et l'ancienneté de 21 ans sont rares mais plausibles — on les garde, en sachant qu'il faudra surveiller leur influence.

Les deux nuages

Un tableau, deux lectures

Le nuage des individus

Chaque **ligne** devient un **point** dans un espace à p dimensions : ses coordonnées sont ses p valeurs.
Cinq clients notés sur deux critères donnent cinq points dans un plan.

Le nuage des variables

Chaque **colonne** devient un **point** — ou une flèche — dans un espace à n dimensions.
Deux variables observées sur cinq clients donnent deux flèches dans un espace à cinq dimen-

sions.

La dualité, en image



Une seule ACP, deux lectures — c'est ce qu'on appelle la dualité.
On ne fait pas deux calculs : la décomposition de la matrice des corrélations donne *en même temps* les axes des individus et ceux des variables. Le pourcentage d'inertie est donc le même des deux côtés.
D'où la méthode de lecture, invariable : on interprète d'abord le *cercle des corrélations* — il donne le *sens* des axes — puis le *plan des individus* — il dit *qui* se trouve où. Jamais l'inverse.

Deux regards sur le même objet

Deux questions distinctes

Ce sont deux façons de lire **le même tableau**, et elles répondent à deux questions distinctes :

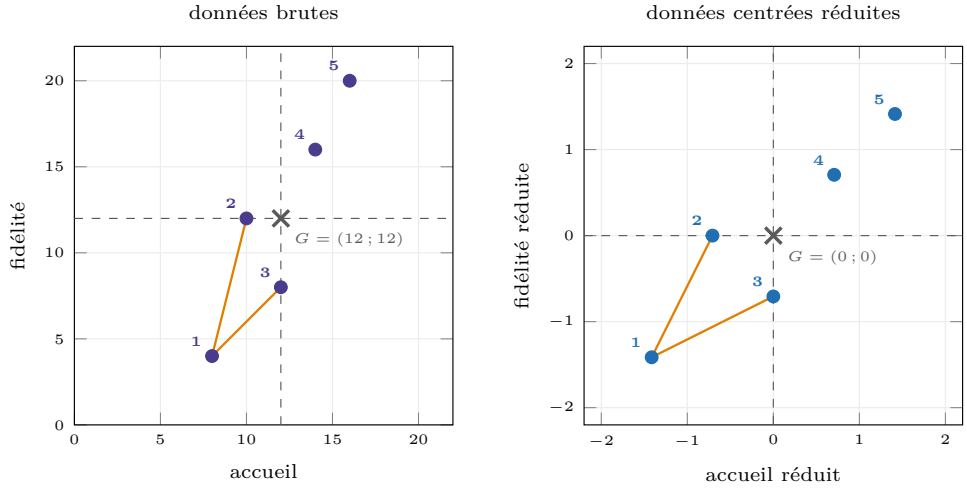
- le nuage des **individus** demande : quels clients se ressemblent ?
- le nuage des **variables** demande : quels critères vont ensemble ?

Elles se répondront simultanément : c'est la **dualité**, qui donnera le cercle des corrélations au chapitre 10 et le plan des individus au chapitre 11.

Sur le fichier réel

Le nuage des individus : 300 points dans un espace à 8 dimensions. Le nuage des variables : 8 flèches dans un espace à 300 dimensions. Ni l'un ni l'autre ne se dessine — c'est tout le problème.

Le nuage du fil rouge



Ce que montre ce nuage

Cinq points dans le plan

Placés dans un repère, ces cinq points s'alignent presque : c'est la traduction visuelle du $r = 0{,}9$ du chapitre 4.

Avec deux variables, on voit tout. Le problème de l'introduction ne se pose pas encore — il commencera à trois.

Ce que la réduction change à l'image

Brut, le nuage est **étiré verticalement** : la fidélité varie deux fois plus que l'accueil. Réduit, il occupe autant de place dans les deux directions, et son allongement se lit le long de la **diagonale**. Les deux segments orange, de longueurs différentes à gauche, deviennent égaux à droite.

Le centre de gravité

Le point moyen

Centre de gravité

Le **centre de gravité** G du nuage est le point dont les coordonnées sont les **moyennes** de chaque variable :

$$G = (\bar{x}_1, \bar{x}_2, \dots, \bar{x}_p)$$

Sur le fil rouge

$$G = (12\,;\,12)$$

Les deux moyennes valant 12, le centre du nuage est le point $(12\,;\,12)$.

Le centre du nuage réel

Un point dans un espace à huit dimensions

$$G = (11{,}40\,;\,13{,}20\,;\,14{,}10\,;\,13{,}00\,;\,14{,}59\,;\,12{,}30\,;\,12{,}80\,;\,13{,}90)$$

Ce sont les huit moyennes du chapitre 1, dans l'ordre prix, choix, qualité, agencement, propreté, rapidité, conseil, accueil.

Le client moyen n'existe pas

Aucun des trois cents clients n'a exactement ces huit notes. G est un **point de référence**, pas un individu : c'est par rapport à lui qu'on mesurera combien chaque client s'écarte de la norme.

Ce que centrer signifie géométriquement

Déplacer l'origine

Centrer les variables, comme au chapitre 2, revient à **déplacer l'origine du repère en** G. Le nuage ne change ni de forme, ni de taille, ni d'orientation : seul le point d'où on le regarde a bougé.

Après centrage et réduction

Le nuage est **centré en l'origine**, et chaque variable a une variance de 1. Les axes qu'on cherchera **passeront tous par le centre du nuage** : un axe qui n'y passerait pas ne pourrait pas résumer l'ensemble.
C'est dans cette configuration que travaillera toute la suite du cours.

Distances et ressemblances

La distance entre deux individus

Pythagore, en p dimensions

Sur données réduites, la distance entre deux individus i et i' se calcule par le théorème de Pythagore, étendu à p dimensions :

$$d(i,i') = \sqrt{\sum_{j=1}^{p} \left(z_{ij} - z_{i'j}\right)^2}$$

Démonstration : Pythagore en dimension p

En dimension 1, la distance entre deux points est $|z_{i1} - z_{i'1}|$: son carré est le carré de la différence.

De $q - 1$ *à* q *dimensions.* Notons A et B les deux points, et B' le point qui a les $q - 1$ premières coordonnées de B et la dernière coordonnée de A. Le déplacement de A à B' ne modifie que les $q - 1$ premières coordonnées ; celui de B' à B ne modifie que la dernière, il est **perpendiculaire** à tout déplacement des $q - 1$ premières. Le triangle $A\,B'\,B$ est donc rectangle en B', et le théorème de Pythagore donne

$$AB^2 = AB'^2 + B'B^2 = \underbrace{\sum_{j=1}^{q-1} \left(z_{Aj} - z_{Bj}\right)^2}_{\text{hypothèse en dimension } q-1} + \left(z_{Aq} - z_{Bq}\right)^2.$$

La formule est vraie en dimension q dès qu'elle l'est en dimension $q - 1$; elle l'est en dimension 1 : elle l'est donc en dimension p.

Sur nos données. Clients 1 et 2 en données brutes : $d^2 = 2^2 + 8^2 = 68$, $d = 8{,}25$. En données réduites : $d^2 = 2{,}5$, $d = 1{,}58$. Pour les clients 36 et 246, la somme de huit carrés de différences réduites vaut $5{,}87^2 \approx 34{,}5$.

■

Ce que la géométrie apporte

Deux clients **proches** dans le nuage ont des valeurs semblables sur l'ensemble des critères. Deux clients **éloignés** diffèrent.
La question « quels clients se ressemblent ? » devient donc une question de **distance** — et ce basculement vers la géométrie rend la suite possible.

Le calcul, sur deux paires de clients

Les clients 1 et 2, puis 1 et 3

Données brutes :

$$d(1,2) = \sqrt{(8-10)^2 + (4-12)^2} = \sqrt{4+64} = 8{,}25 \qquad d(1,3) = \sqrt{16+16} = 5{,}66$$

Données réduites (z du chapitre 2) :

$$d(1,2) = \sqrt{(-1{,}414+0{,}707)^2 + (-1{,}414-0)^2} = \sqrt{0{,}5+2} = 1{,}581$$

$$d(1,3) = \sqrt{(-1{,}414-0)^2 + (-1{,}414+0{,}707)^2} = \sqrt{2+0{,}5} = 1{,}581$$

Toutes les distances, brutes et réduites

Les dix paires de clients

Paire	1-2	1-3	1-4	1-5	2-3	2-4	2-5	3-4	3-5	4-5
brute	8,25	5,66	13,4	17,9	4,47	5,66	10,0	8,25	12,6	4,47
réduite	1,58	1,58	3,00	4,00	1,00	1,58	2,55	1,58	2,55	1,00

La réduction change qui ressemble à qui

Brut, le client 1 ressemble davantage au client 3 (5,66) qu'au client 2 (8,25) : leur différence de fidélité (8 points) pèse plus que leur différence d'accueil. Réduit, les deux paires sont **à égalité** (1,58) : un écart d'un écart-type compte autant sur les deux critères.

Pourquoi la réduction est ici décisive

Un choix, qu'il faut savoir qu'on fait

Sans réduction, la distance serait dominée par la variable de plus grande dispersion : deux clients seraient jugés éloignés parce qu'ils diffèrent en montant dépensé, quelle que soit leur satisfaction.
Réduire, c'est décider que chaque critère compte autant dans la ressemblance.

Sur le fichier réel : panier et accueil

Les clients 1 et 2 ont des paniers de 581 et 435 dirhams, des accueils de 15,4 et 14,9. Leur distance brute vaut $\sqrt{146^2 + 0{,}5^2} = 146{,}0$: **l'accueil n'y compte pour rien**. Sur données réduites, 146 dirhams font 0,88 écart-type, et 0,5 point en fait 0,21.

Deux clients de même moyenne, loin l'un de l'autre

Les clients 36 et 246 du chapitre 1

Même note moyenne (13,9), mais sur les huit notes réduites leur distance vaut **5,87**, alors que deux clients pris au hasard sont en moyenne à 3,76 l'un de l'autre.
Le plus proche voisin du client 36 est le client 234, à 0,83 seulement.

Ce que la distance voit et la moyenne non

La distance compare les clients **critère par critère** : elle ne laisse pas un prix sévère se compenser par un accueil généreux. C'est pourquoi elle sépare deux clients que leur moyenne confondait.

Le nuage des variables

Une variable est une flèche

Longueur et angle

Une variable centrée réduite, vue comme une flèche de $\mathbb{R}^n$, a une **longueur** de 1 (avec les poids $1/n$, sa longueur au carré est sa variance).
L'**angle** entre deux variables a pour cosinus leur **corrélation** : c'est la lecture géométrique du chapitre 4.

Démonstration : Longueur un, et angle dont le cosinus est la corrélation

Rangeons deux variables réduites z_j et z_k en vecteurs de $\mathbb{R}^n$, avec le poids $1/n$ pour chaque individu : leur produit scalaire est $\langle z_j, z_k\rangle = \frac{1}{n}\sum_i z_{ij}\, z_{ik}$.

- *Longueur.* $\|z_j\|^2 = \frac{1}{n}\sum_i z_{ij}^2 = V(z_j) = 1$: toute variable réduite est une flèche de longueur 1.
- *Angle.* $\langle z_j, z_k\rangle = \frac{1}{n}\sum_i z_{ij}\, z_{ik} = r_{jk}$ (chapitre 4), donc $\cos\theta_{jk} = \dfrac{\langle z_j, z_k\rangle}{\|z_j\|\,\|z_k\|} = r_{jk}$.
- *Distance.* $\|z_j - z_k\|^2 = \|z_j\|^2 + \|z_k\|^2 - 2\langle z_j, z_k\rangle = 2 - 2\,r_{jk}$. Deux variables très corrélées sont deux flèches **voisines** ; deux variables non corrélées sont à la distance $\sqrt{2}$ l'une de l'autre ; deux variables opposées, à la distance 2.

Sur nos données. $r = 0{,}90$ (accueil et fidélité, cinq clients) donne $\theta = \arccos 0{,}90 = 25{,}8°$ et une distance $\sqrt{0{,}2} = 0{,}45$. Conseil et accueil ($r = 0{,}73$) font 43,0° ; prix et accueil ($r = 0{,}09$) font 84,9°, presque un angle droit.

■

Quelques angles

Paire	r	Angle
accueil et fidélité (cinq clients)	0,90	25,8°
conseil et accueil	0,73	43,0°
prix et accueil	0,09	84,9°

Des variables proches mesurent la même chose

Deux flèches qui font un **petit angle** sont fortement corrélées ; deux flèches **perpendiculaires** sont sans liaison linéaire ; deux flèches **opposées** varient en sens contraire.

Ce qu'on attend de la suite

Le nuage des variables vit dans un espace à 300 dimensions : on ne peut pas le dessiner tel quel. L'ACP en donnera une **projection plane**, le cercle des corrélations, où ces angles se liront directement.

scale réduit en n moins un : on corrige par la racine de 5/4

```r
B <- data.frame(accueil = c(8, 10, 12, 14, 16),
                fidelite = c(4, 12, 8, 16, 20))
colMeans(B)
#  accueil fidelite
#       12       12
Z <- scale(B) * sqrt(5 / 4)        # réduction en n
round(dist(Z), 3)
#       1     2     3     4
# 2 1.581
# 3 1.581 1.000
# 4 3.000 1.581 1.581
# 5 4.000 2.550 2.550 1.000
```

Le code et sa sortie

```python
import numpy as np
from scipy.spatial.distance import pdist, squareform
B = np.array([[8, 4], [10, 12], [12, 8], [14, 16], [16, 20]])
print(B.mean(axis=0))                       # [12. 12.]
Z = (B - B.mean(axis=0)) / B.std(axis=0)
print(squareform(pdist(Z)).round(3))
# [[0.    1.581 1.581 3.    4.   ]
#  [1.581 0.    1.    1.581 2.55 ]
#  [1.581 1.    0.    1.581 2.55 ]
#  [3.    1.581 1.581 0.    1.   ]
#  [4.    2.55  2.55  1.    0.   ]]
```

Trois agences, deux variables réduites

Trois agences sont décrites par deux variables déjà centrées réduites :

Agence	z_1	z_2
A	1	1
B	-1	0
C	0	-1

1. Vérifier que le centre de gravité est l'origine.
2. Calculer les trois distances deux à deux.
3. Quelles agences se ressemblent le plus ?

B et C sont les plus proches

1. $(1-1+0)/3 = 0$ et $(1+0-1)/3 = 0$: $G = (0\,;0)$.
2. $d(A,B) = \sqrt{4+1} = 2{,}24$; $d(A,C) = \sqrt{1+4} = 2{,}24$; $d(B,C) = \sqrt{1+1} = 1{,}41$.
3. **B et C** : chacune est au-dessous de la moyenne sur une variable et à la moyenne sur l'autre. A est l'agence qui se détache, au-dessus de la moyenne sur les deux.

Brut ou réduit ?

Reprendre le tableau des distances des cinq clients.

1. Quel est le plus proche voisin du client 4 ? du client 1 ? Répondre en distances brutes, puis réduites.
2. Pour quel client la réponse change-t-elle ? Pourquoi ?

Le client 1 hésite après réduction

1. Client 4 : le client 5, brut (4,47) comme réduit (1,00). Client 1 : le client 3 en brut (5,66 contre 8,25 pour le 2) ; en réduit, les clients 2 et 3 sont **à égalité** (1,58).
2. C'est le client 1. En brut, l'écart de fidélité avec le client 2 (8 points) pèse lourd parce que la fidélité est très dispersée. La réduction ramène cet écart à 1,41 écart-type, exactement l'écart d'accueil avec le client 3.

Du coefficient à la figure

1. Deux variables réduites ont $r = 0{,}5$. Quel angle font leurs flèches ?
2. Deux variables font un angle de 120°. Quelle est leur corrélation ?
3. Pourquoi deux flèches de longueur 1 ne peuvent-elles jamais faire un angle dont le cosinus vaudrait 1,2 ?

Le cosinus est la corrélation

1. $\cos\theta = 0{,}5$, donc $\theta = 60°$.
2. $r = \cos 120° = -0{,}5$: une liaison négative modérée.
3. Un cosinus est toujours compris entre -1 et 1 : c'est la borne $-1 \leq r \leq 1$ du chapitre 4, **lue géométriquement**.

Six points

1. Le tableau **individus-variables** est le format d'entrée : n lignes, p colonnes ; il se contrôle avant tout calcul.
2. Il se lit de **deux façons** : nuage des individus dans $\mathbb{R}^p$, nuage des variables dans $\mathbb{R}^n$.
3. Le **centre de gravité** a pour coordonnées les moyennes — $(12\,;\,12)$ pour les cinq clients.
4. **Centrer** place l'origine en G ; la forme du nuage ne change pas.
5. La **ressemblance** devient une **distance** ; la réduction donne le même poids à chaque critère et peut changer qui ressemble à qui.
6. Dans le nuage des variables, la longueur vaut 1 et le **cosinus de l'angle est la corrélation**.

Mesurer l'information du nuage

Le nuage est en place. Reste à mesurer l'information qu'il contient — sans quoi on ne pourra pas dire qu'une projection en conserve beaucoup ou peu.

Le chapitre 6

C'est l'inertie : la moyenne des carrés des distances au centre G. Sur les cinq clients réduits, elle vaudra exactement 2.