


# Introduction à l'analyse des données

## Chapitre 5 : La corrélation linéaire



---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 août 2026

Rendre la covariance lisible

Ce que  $r$  vaut, et ce qu'il dit

La lecture géométrique

Les trois pièges

Ce qu'il faut retenir

Rendre la covariance lisible

---

## Le coefficient de corrélation linéaire

$$r_{xy} = \frac{\text{cov}(x, y)}{s_x s_y}$$

On divise la covariance par le produit des deux écarts-types.

## Pourquoi cette division précisément

La covariance s'exprime en « unité de  $x$  × unité de  $y$  », et le produit  $s_x s_y$  **exactement** dans la même **unité**. Le quotient est donc **sans unité** — la condition pour comparer, établie au chapitre 3.

## Sur le fil rouge

$$s_x s_y = \sqrt{8} \times \sqrt{32} = \sqrt{8 \times 32} = \sqrt{256} = 16$$

$$r_{xy} = \frac{14,4}{16} = \mathbf{0,9}$$

Le produit des écarts-types tombe **exactement** sur 16, et la corrélation vaut **exactement** 0,9.

Ce que r vaut, et ce qu'il dit

---

## Le résultat central

$$-1 \leq r_{xy} \leq +1$$

Cette borne ne dépend d'aucune hypothèse : elle est une propriété algébrique du quotient.

## La lecture

| Valeur de $r$ | Situation                                                  |
|---------------|------------------------------------------------------------|
| +1            | les points sont <b>exactement alignés</b> , pente positive |
| proche de +1  | liaison positive forte                                     |
| 0             | <b>aucune liaison linéaire</b>                             |
| proche de -1  | liaison négative forte                                     |
| -1            | alignement exact, pente négative                           |

### Application économique

$r = 0,9$  est une liaison **très forte**. Accueil et fidélité vont ensemble de façon presque parfaitement linéaire.

Sur des données réelles, un tel  $r$  entre deux critères est d'ailleurs suspect : il suggère que les deux questions **mesurent la même chose**. L'analyse en composantes principales exploitera précisément ces redondances.

## La lecture géométrique

---



# La corrélation est une covariance de variables réduites

## Une écriture équivalente

Si  $z_x$  et  $z_y$  désignent les variables centrées réduites du chapitre 3 :

$$r_{xy} = \text{COV}(z_x, z_y) = \frac{1}{n} \sum_{i=1}^n z_{x,i} z_{y,i}$$

## Ce que cela révèle

Corréler, c'est **réduire d'abord, covarier ensuite**.

Les trois chapitres de rappel se referment ici : centrer et réduire (chapitre 3), covarier (chapitre 4), et le quotient du chapitre 5 n'est que la combinaison des deux.

**Une fois les variables réduites, covariance et corrélation sont le même nombre.** C'est pourquoi l'analyse en composantes principales travaillera systématiquement sur données réduites : elle n'aura plus à choisir entre les deux.

# La matrice des corrélations

## La matrice

$$R = \begin{pmatrix} 1 & 0,9 \\ 0,9 & 1 \end{pmatrix}$$

Sa diagonale ne contient que des 1 :  $\text{cov}(z, z) = V(z) = 1$ .

|            | prix | choix | qual. | agen. | prop. | rapid. | cons. | accu. |
|------------|------|-------|-------|-------|-------|--------|-------|-------|
| prix       | 1    | 0,67  | 0,67  | 0,59  | 0,43  | 0,22   | 0,15  | 0,09  |
| choix      | 0,67 | 1     | 0,73  | 0,69  | 0,56  | 0,32   | 0,34  | 0,31  |
| qualité    | 0,67 | 0,73  | 1     | 0,71  | 0,56  | 0,41   | 0,36  | 0,35  |
| agencement | 0,59 | 0,69  | 0,71  | 1     | 0,59  | 0,50   | 0,44  | 0,41  |
| propreté   | 0,43 | 0,56  | 0,56  | 0,59  | 1     | 0,64   | 0,59  | 0,58  |
| rapidité   | 0,22 | 0,32  | 0,41  | 0,50  | 0,64  | 1      | 0,69  | 0,71  |
| conseil    | 0,15 | 0,34  | 0,36  | 0,44  | 0,59  | 0,69   | 1     | 0,73  |
| accueil    | 0,09 | 0,31  | 0,35  | 0,41  | 0,58  | 0,71   | 0,73  | 1     |

L'ACP est déjà là, dans ce tableau.

Deux blocs sombres se détachent : **prix, choix, qualité, agencement** d'un côté — ce que le magasin *propose* — et **propreté, rapidité, conseil, accueil** de l'autre — ce que le personnel *fait*. Entre les deux, les corrélations tombent à 0,09.

L'ACP ne fera que rendre visible cette structure — mais sur 30 variables, aucun œil ne l'aurait vue dans le tableau.

### Application économique

Sur un fichier réel, la matrice des corrélations se regarde **avant** de lancer quoi que ce soit :

- des blocs de variables fortement corrélées entre elles signalent des **groupes de critères redondants** ;
- une variable corrélée à aucune autre n'apportera rien aux premiers axes ;
- une corrélation proche de 1 entre deux variables indique qu'on en mesure une deux fois.

C'est déjà de l'analyse des données, faite à l'œil.

## Les trois pièges

---

### Premier piège : la liaison non linéaire

$r$  ne mesure que la liaison **linéaire**.

Deux variables liées par une relation en cloche parfaitement déterministe peuvent avoir une corrélation **nulle**. Un  $r$  de zéro signifie « pas de liaison **linéaire** », jamais « pas de liaison ».

**Il faut donc toujours regarder le nuage de points**, et ne jamais se contenter du coefficient.

### Deuxième piège : les points aberrants

Un seul point très éloigné peut créer une corrélation forte là où il n'y en a aucune, ou détruire une corrélation réelle.

Le coefficient est une moyenne : il est sensible aux valeurs extrêmes, comme toute moyenne.

### Application économique

Une corrélation forte n'établit **aucun** lien de cause à effet. Trois explications restent ouvertes :

1.  $x$  agit sur  $y$ ;
2.  $y$  agit sur  $x$ ;
3. une **troisième variable** agit sur les deux.

Le troisième est le plus fréquent : l'ancienneté du client, par exemple, peut produire à elle seule la corrélation entre accueil et fidélité.

Les distinguer est l'objet du cours d'**inférence causale**, au Master. Celui-ci décrit des associations, et s'y tient.

Ce qu'il faut retenir

---

## Cinq points

1.  $r_{xy} = \text{cov}(x, y) / (s_x s_y)$  : la covariance débarrassée de ses unités.
2. Sur le fil rouge :  $s_x s_y = \sqrt{256} = 16$ , donc  $r = 14,4 / 16 = \mathbf{0,9}$  exactement.
3.  $r$  est toujours compris entre  $-1$  et  $+1$ .
4. La corrélation est la **covariance des variables réduites** — les trois rappels se referment ici.
5. Trois pièges : liaison **non linéaire**, points **aberrants**, et **causalité**.

## La suite

Les rappels sont terminés. Le chapitre 6 change de regard : il cesse de voir un tableau de chiffres et se met à voir un **nuage de points** dans un espace à  $p$  dimensions.