Introduction à l'analyse des données

Chapitre 4 : La corrélation linéaire

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 22 octobre 2026

Plan du chapitre

Rendre la covariance lisible

Ce que r vaut, et ce qu'il dit

La lecture géométrique

Les trois pièges

Sur machine

S'entraîner

Ce qu'il faut retenir

Rendre la covariance lisible

Le coefficient de corrélation linéaire

$$r_{xy} = \frac{\operatorname{cov}(x, y)}{s_x \, s_y}$$

On divise la covariance par le produit des deux écarts-types.

Pourquoi cette division précisément

La covariance s'exprime en « unité de x × unité de y », et le produit $s_x s_y$ **exactement dans la même unité**. Le quotient est donc **sans unité** — la condition pour comparer, établie au chapitre 2.

Changer d'unité multiplie la covariance par $a\,b$ et le produit des écarts-types par $a\,b$ aussi : **le quotient ne bouge pas**.

Un calcul qui tombe juste

$$s_x\, s_y = \sqrt{8} \times \sqrt{32} = \sqrt{8 \times 32} = \sqrt{256} = 16$$

$$r_{xy} = \frac{14{,}4}{16} = \mathbf{0{,}9}$$

Le produit des écarts-types tombe **exactement** sur 16, et la corrélation vaut **exactement** $0{,}9$.

Deux liaisons avec l'accueil

Paire	Covariance	Corrélation
panier et accueil	$90{,}37$	$0{,}23$
conseil et accueil	$4{,}21$	$\mathbf{0{,}73}$

Une fois les unités retirées, l'ordre s'inverse : le conseil est **trois fois plus** lié à l'accueil que le panier.

Ce que la division a fait

$90{,}37/(166{,}3 \times 2{,}40) = 0{,}23$ et $4{,}21/(2{,}40 \times 2{,}40) = 0{,}73$. La grande covariance du panier venait **entièrement** de son écart-type en dirhams.

Ce que r vaut, et ce qu'il dit

Le résultat central

$$-1 \;\leq\; r_{xy} \;\leq\; +1$$

Cette borne ne dépend d'aucune hypothèse : elle est une propriété algébrique du quotient.

La démonstration, en une ligne

Avec les variables réduites z_x et z_y, la formule du chapitre 3 donne

$$V(z_x \pm z_y) = V(z_x) + V(z_y) \pm 2\,\mathrm{cov}(z_x, z_y) = 2 \pm 2\,r_{xy}$$

Une variance n'est jamais négative : $2 + 2r \geq 0$ et $2 - 2r \geq 0$, donc $-1 \leq r \leq 1$.

Les deux variances

$$V(z_x + z_y) = 2 + 2 \times 0{,}9 = 3{,}8 \qquad V(z_x - z_y) = 2 - 1{,}8 = 0{,}2$$

La somme des deux notes réduites est très dispersée ; leur différence l'est à peine.

Deux nombres à garder en mémoire

$3{,}8$ et $0{,}2$, divisés par deux, donnent $1{,}9$ et $0{,}1$. Ce seront, au chapitre 8, les **deux valeurs propres** de l'ACP des cinq clients : la somme et la différence des notes réduites sont déjà, à un facteur près, ses deux axes.

Ce que dit la valeur de r

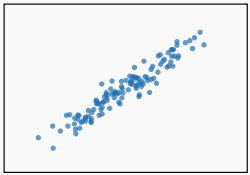
Valeur de r	Situation
$+1$	les points sont **exactement alignés**, pente positive
proche de $+1$	liaison positive forte
0	**aucune liaison linéaire**
proche de -1	liaison négative forte
-1	alignement exact, pente négative

Les cas extrêmes

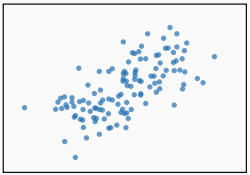
$r = \pm 1$ exactement si $V(z_x \mp z_y) = 0$, c'est-à-dire si $z_y = \pm z_x$ pour **tous** les individus : les points sont sur une droite.

Six nuages, six corrélations

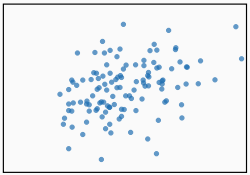
$r = 0{,}96$



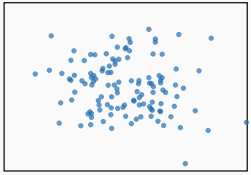
$r = 0{,}65$



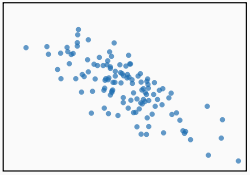
$r = 0{,}38$



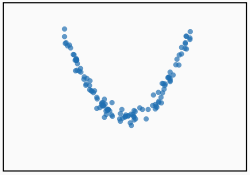
$r = -0{,}15$



$r = -0{,}76$



$r = 0{,}03$: une parabole



Lire r sur un nuage

Plus le nuage est **étiré le long d'une droite**, plus $|r|$ est proche de 1. À $0{,}38$, la liaison existe mais se voit à peine ; à $-0{,}15$, l'œil n'en voit aucune.

Le dernier nuage montre une liaison **parfaite**, en forme de parabole, et pourtant $r = 0{,}03$: nous y reviendrons avec les pièges.

Sur nos cinq clients

$r = 0{,}9$ est une liaison **très forte**. Accueil et fidélité vont ensemble de façon presque parfaitement linéaire.

Sur des données réelles, un tel r entre deux critères suggère que les deux questions **mesurent en partie la même chose**. L'analyse en composantes principales exploitera précisément ces redondances.

La lecture géométrique

La corrélation est une covariance de variables réduites

Une écriture équivalente

$$r_{xy} = \mathrm{cov}(z_x, z_y) = \frac{1}{n} \sum_{i=1}^{n} z_{x,i}\, z_{y,i}$$

Sur nos cinq clients

Client	1	2	3	4	5	Somme
z_x	$-1{,}414$	$-0{,}707$	0	$0{,}707$	$1{,}414$	
z_y	$-1{,}414$	0	$-0{,}707$	$0{,}707$	$1{,}414$	
$z_x\, z_y$	2	0	0	$0{,}5$	2	$4{,}5$

$$r = 4{,}5/5 = 0{,}9$$

Les trois rappels se referment ici

Centrer et réduire (chapitre 2), covarier (chapitre 3), et le quotient du chapitre 4 n'est que la combinaison des deux.

Une fois les variables réduites, covariance et corrélation sont le même nombre. C'est pourquoi l'analyse en composantes principales travaillera sur données réduites : elle n'aura plus à choisir entre les deux.

Un cosinus

La corrélation est le **cosinus de l'angle** entre les deux colonnes centrées, vues comme des vecteurs de $\mathbb{R}^n$. Sur nos cinq clients, $\cos\theta = 0{,}9$: les deux colonnes font un angle de $25{,}8°$. Le chapitre 10 en fera une figure.

La matrice du fil rouge

$$R = \begin{pmatrix} 1 & 0{,}9 \\ 0{,}9 & 1 \end{pmatrix}$$

Sa diagonale ne contient que des 1 : $\mathrm{cov}(z, z) = V(z) = 1$. C'est la matrice des variances-covariances des **variables réduites**.

Le même objet que la matrice du chapitre 3

R se déduit de Σ en divisant chaque case par le produit des deux écarts-types : $14{,}4/(2{,}83 \times 5{,}66) = 0{,}9$, et $8/(2{,}83 \times 2{,}83) = 1$.

Les huit notes du fichier réel

	prix	choix	qual.	agen.	prop.	rapid.	cons.	accu.
prix	1	0,67	0,67	0,59	0,43	0,22	0,15	0,09
choix	0,67	1	0,73	0,69	0,56	0,32	0,34	0,31
qualité	0,67	0,73	1	0,71	0,56	0,41	0,36	0,35
agencement	0,59	0,69	0,71	1	0,59	0,50	0,44	0,41
propreté	0,43	0,56	0,56	0,59	1	0,64	0,59	0,58
rapidité	0,22	0,32	0,41	0,50	0,64	1	0,69	0,71
conseil	0,15	0,34	0,36	0,44	0,59	0,69	1	0,73
accueil	0,09	0,31	0,35	0,41	0,58	0,71	0,73	1

L'ACP est déjà là, dans ce tableau.

Deux blocs sombres se détachent : **prix, choix, qualité, agencement**d'un côté — ce que le magasin *propose* — et **propreté, rapidité, conseil, accueil**de l'autre — ce que le personnel *fait*. Entre les deux, les corrélations tombent à 0,09.

L'ACP ne fera que rendre visible cette structure — mais sur 30 variables, aucun œil ne l'aurait vue dans le tableau.

Ce qu'on y lit avant tout calcul

La matrice se regarde avant de lancer quoi que ce soit

- des blocs de variables fortement corrélées entre elles signalent des **groupes de critères redondants** ;
- une variable corrélée à aucune autre n'apportera rien aux premiers axes ;
- une corrélation proche de 1 entre deux variables indique qu'on en mesure une deux fois.

C'est déjà de l'analyse des données, faite à l'œil.

Sur nos huit notes

Toutes les corrélations sont **positives** : un client sévère sur un critère tend à l'être sur tous. Et deux blocs se détachent — prix, choix, qualité, agencement d'un côté ; rapidité, conseil, accueil de l'autre, la propreté entre les deux.

Les trois pièges

r ne voit que les droites

r ne mesure que la liaison **linéaire**. Deux variables liées par une relation en cloche ou en creux, parfaitement déterministe, peuvent avoir une corrélation **nulle**.

Cinq points sur une parabole

u	-2	-1	0	1	2
$v = u^2$	4	1	0	1	4

$\bar{u} = 0$, $\bar{v} = 2$. Produits des écarts :
$(-2)(2) + (-1)(-1) + 0 + (1)(-1) + (2)(2) = -4 + 1 - 1 + 4 = 0$. **Donc** $r = 0$, alors que v est entièrement déterminé par u.

La règle qui en découle

Toujours regarder le nuage

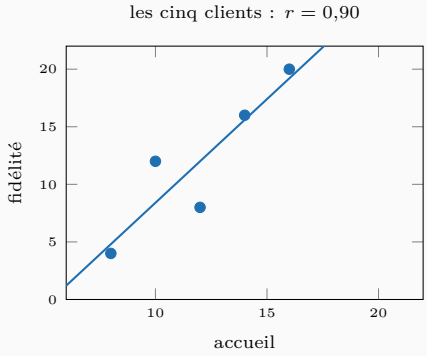
Un r de zéro signifie « pas de liaison **linéaire** », jamais « pas de liaison ».

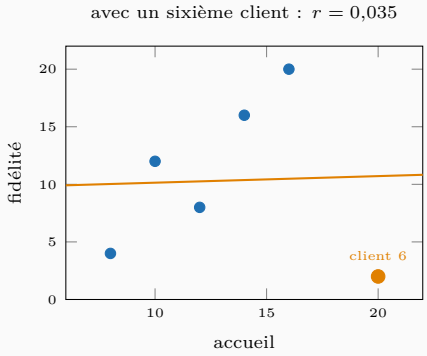
Il faut donc **toujours regarder le nuage de points**, et ne jamais se contenter du coefficient.

En gestion

La satisfaction peut être maximale pour un prix **moyen** et plus faible aux deux extrêmes — trop cher, ou si bon marché qu'il inquiète. La corrélation entre prix et satisfaction serait alors proche de zéro, et masquerait une relation forte.

Deuxième piège : les points aberrants





Un seul client de plus

Ajoutons un sixième client, très accueilli (20) et pas du tout fidèle (2). La corrélation passe de $0{,}90$ à $\mathbf{0{,}035}$: **un point sur six a effacé la liaison**.

Une moyenne, sensible aux extrêmes

Le coefficient est une **moyenne de produits** $z_x\, z_y$. Un individu très éloigné du centre fournit un produit énorme, qui domine tous les autres.

Il peut ainsi **détruire** une corrélation réelle — comme ici — ou en **créer** une là où il n'y en a aucune.

Ce qu'il faut faire

Repérer les individus extrêmes **avant** de calculer, se demander s'il s'agit d'une erreur de saisie ou d'un cas réel, et calculer r avec et sans eux. Si les deux valeurs diffèrent beaucoup, aucune ne résume seule la liaison.

Troisième piège : la causalité

Corrélation n'est pas cause

Une corrélation forte n'établit **aucun** lien de cause à effet. Trois explications restent ouvertes :

1. x agit sur y ;
2. y agit sur x ;
3. une **troisième variable** agit sur les deux.

Le troisième cas est le plus fréquent : l'ancienneté du client, par exemple, pourrait produire à elle seule la corrélation entre accueil et fidélité.

Ce que ce cours s'interdit

Les distinguer est l'objet du cours d'**inférence causale**, au Master. Celui-ci décrit des associations, et s'y tient.

Sur machine

Le code et sa sortie

```r
x <- c(8, 10, 12, 14, 16)
y <- c(4, 12, 8, 16, 20)
cor(x, y)                                    # [1] 0.9
clients <- read.csv("clients.csv")
round(cor(clients[, c("panier", "conseil", "accueil")]), 3)
#         panier conseil accueil
# panier   1.000   0.247   0.227
# conseil  0.247   1.000   0.731
# accueil  0.227   0.731   1.000
```

Plus de piège du diviseur

La corrélation est un **quotient** : le diviseur n ou $n-1$ apparaît en haut et en bas, et s'élimine.

R, `numpy` et `pandas` donnent exactement $0{,}9$.

Le code et sa sortie

```
import numpy as np
import pandas as pd
x = np.array([8, 10, 12, 14, 16])
y = np.array([4, 12, 8, 16, 20])
print(round(np.corrcoef(x, y)[0, 1], 4))   # 0.9
clients = pd.read_csv("clients.csv")
cols = ["panier", "conseil", "accueil"]
print(clients[cols].corr().round(3))
#          panier  conseil  accueil
# panier    1.000    0.247    0.227
# conseil   0.247    1.000    0.731
# accueil   0.227    0.731    1.000
```

S’entraîner

La corrélation de l'exercice du chapitre 3

Pour les quatre magasins du chapitre 3, on a trouvé $V(x) = 5$, $V(y) = 3{,}5$ et $\mathrm{cov}(x, y) = 3{,}5$.

1. Calculer la corrélation entre surface et chiffre d'affaires.
2. Que devient-elle si la surface est mesurée en m² plutôt qu'en centaines de m² ?
3. Calculer $V(z_x + z_y)$ et $V(z_x - z_y)$.

r = 0,837

1. $r = 3{,}5/\sqrt{5 \times 3{,}5} = 3{,}5/\sqrt{17{,}5} = 3{,}5/4{,}183 = 0{,}837$.
2. **Inchangée** : la covariance et l'écart-type de la surface sont tous deux multipliés par 100.
3. $V(z_x + z_y) = 2 + 2 \times 0{,}837 = 3{,}67$; $V(z_x - z_y) = 2 - 1{,}67 = 0{,}33$. Les deux sont positives, comme la démonstration l'exige.

Exercice 2 : un client aberrant

Avant et après

Cinq clients ont pour notes (accueil, fidélité) : $(10;12)$, $(11;10)$, $(12;13)$, $(13;11)$, $(14;12)$.
On ajoute un sixième client noté $(30;30)$.

1. Sans calcul : la corrélation des cinq premiers est-elle forte ?
2. On trouve $r = 0{,}14$ sans le sixième, $r = 0{,}98$ avec. Expliquer.
3. Laquelle des deux valeurs décrit le mieux ces clients ?

Un point fabrique la liaison

1. **Non** : les cinq fidélités $(12, 10, 13, 11, 12)$ montent et descendent sans suivre l'accueil.
2. Le sixième client est à près de 2 écarts-types de tous les autres sur **les deux** notes : son produit $z_x z_y$ est énorme et positif, et il domine la moyenne. **Il fabrique à lui seul** une corrélation de $0{,}98$.
3. Aucune seule. Il faut décrire la situation : cinq clients sans liaison nette, et un client très différent — à vérifier (erreur de saisie ?) avant toute conclusion.

Trois questions sur la matrice des huit notes

Dans la matrice des corrélations des huit notes (diapositive « Les huit notes du fichier réel ») :

1. Quelle est la paire de notes la plus liée ? la moins liée ?
2. Le prix et l'accueil ont $r = 0{,}09$. Peut-on en conclure que le prix n'a aucun rapport avec l'accueil ?
3. Toutes les corrélations sont positives. Qu'est-ce que cela suggère sur les clients ?

Deux blocs et un effet de niveau

1. Les plus liées : choix et qualité, conseil et accueil $(0{,}73)$. La moins liée : prix et accueil $(0{,}09)$.
2. **Non** : seulement qu'il n'y a pas de liaison **linéaire**. Il faut regarder le nuage — c'était le troisième des six nuages de l'introduction, et il ne montre rien de net.
3. Un client sévère tend à l'être **partout** : il existe un **niveau général** de satisfaction, qui sera le premier axe de l'ACP. Les deux blocs, eux, annoncent le second.

Ce qu’il faut retenir

Six points

1. $r_{xy} = \mathrm{cov}(x, y)/(s_x s_y)$: la covariance débarrassée de ses unités.
2. Sur le fil rouge : $s_x s_y = \sqrt{256} = 16$, donc $r = 14{,}4/16 = \mathbf{0{,}9}$ exactement.
3. $V(z_x \pm z_y) = 2 \pm 2r \geq 0$, d'où $-1 \leq r \leq +1$; sur nos clients, $3{,}8$ et $0{,}2$.
4. La corrélation est la **covariance des variables réduites**, et le cosinus d'un angle.
5. La matrice des huit notes montre déjà deux blocs : l'offre et le service.
6. Trois pièges : liaison **non linéaire**, points **aberrants** ($0{,}9 \to 0{,}035$ avec un client de plus), et **causalité**.

Les rappels sont terminés

Le chapitre 5 change de regard : il cesse de voir un tableau de chiffres et se met à voir un **nuage de points** dans un espace à p dimensions.

Ce qu'on y calculera

Le centre de gravité des cinq clients, leurs distances deux à deux, brutes puis réduites — et l'on verra que la réduction change qui ressemble à qui.